




Применение метода «смесь экспертов» в архитектурах больших языковых моделей



14 марта 2024 года

+54 Нравится

Обсудить (0)

Авторы: [Кайл Кранен](#) и [Вин Нгуен](#)

Сгенерированное искусственным интеллектом резюме



Смешанная экспертная оценка (Mixed of Experts, MoE) в больших языковых моделях (БЯМ) появилась недавно как в проприетарных БЯМ, таких как GPT-4, так и в моделях сообщества с открытым исходным кодом Mistral Mixtral 8x7B. Высокая относительная производительность модели Mixtral вызвала большой интерес и множество вопросов о



Смешанная экспертная система — это архитектурный паттерн для нейронных сетей, в котором вычисления на уровне или в рамках операции (например, в линейных слоях, многослойных перцептронах или проекциях внимания) распределяются между несколькими «экспертными» подсетями. Каждая из этих подсетей независимо выполняет свои вычисления, а их результаты объединяются для получения окончательного результата на уровне смешанной экспертной системы. Смешанные экспертные системы могут быть как плотными, то есть использующими всех экспертов для каждого входного сигнала, так и разреженными, то есть использующими подмножество экспертов для каждого входного сигнала.

В этом посте основное внимание уделяется применению метода смеси экспертов в архитектурах больших языковых моделей. Чтобы узнать больше о применении метода смеси экспертов в других областях, прочтите статьи [«Масштабирование компьютерного зрения с помощью разреженной смеси экспертов»](#), [«Смешанный экспертный конформер для потоковой многоязычной системы автоматического распознавания речи»](#) и [«FEDformer: частотно-расширенный декомпозированный трансформер для прогнозирования долгосрочных рядов»](#).

Смесь экспертных знаний в области архитектур больших языковых моделей

В этом разделе представлена справочная информация и описаны преимущества использования Mixture of Experts в архитектурах больших языковых моделей.

Возможности модели

Потенциал модели можно определить как уровень сложности, который модель способна понять или выразить. Как правило, модели с большим количеством параметров (при достаточной тренировке) обладают более высоким потенциалом.

Как коэффициент извлечения информации влияет на емкость? Модели с большим количеством параметров, как правило, обладают большей емкостью, а модели с коэффициентом извлечения информации могут эффективно увеличивать емкость по сравнению с базовой моделью за счет замены слоев модели на слои с коэффициентом



Исследователи сравнили точность моделей с промежуточными слоями и полносвязных моделей аналогичного размера, обученных на одинаковом количестве токенов (размер модели с промежуточными слоями: параметры $E \times P$, размер полносвязной модели: параметры EP). Полносвязные модели в целом показывают лучшие результаты, хотя эта область исследований все еще активно изучается. Подробнее см. в статье [«Унифицированные законы масштабирования для языковых моделей с маршрутизацией»](#).

Возникает вопрос: почему бы просто не использовать плотную модель? Ответ кроется в разреженных моделях с матрицей ошибок, а именно в том, что разреженные модели с матрицей ошибок более эффективны с точки зрения количества операций на один используемый параметр.

Рассмотрим [Mixtral 8x7B](#) — модель, в которой используется метод экспертных оценок с восемью экспертами, при этом для каждого токена используются только два эксперта. В этом случае при каждом прямом проходе через модель для одного токена количество используемых параметров для каждого токена в пакете значительно меньше (12 миллиардов параметров из общего числа в 46 миллиардов). Это требует меньше вычислительных ресурсов по сравнению с использованием всех восьми экспертов или полностью плотной модели такого же размера. Учитывая, что при обучении токены объединяются в пакеты, используются почти все эксперты, если не все. Это означает, что в таком режиме разреженная модель с разреженными матрицами использует меньше вычислительных ресурсов и занимает столько же памяти, сколько и плотная модель того же размера.

В мире, где время работы графического процессора является крайне ценным ресурсом, обучение полносвязной модели в больших масштабах обходится непомерно дорого как с точки зрения времени, так и с точки зрения затрат. По имеющимся данным, на предварительное обучение набора моделей Llama 2 (полносвязных) от Meta было потрачено 3,3 миллиона [NVIDIA A100](#) часов работы графического процессора. Для сравнения: 3,3 миллиона часов работы 1024 графических процессоров на полную мощность без простоев заняли бы примерно 134 дня. При этом не учитываются эксперименты, подбор гиперпараметров и перерывы в обучении.

Министерство образования обучает более крупные модели, снижая при этом затраты

MoE models help reduce cost by being more flop-efficient per weight, meaning that under regimes with fixed time or compute cost constraints, more tokens can be processed and the



on a fixed budget.

MoE provides decreased latency

With large prompts and batches where computation is the bottleneck, MoE architecture can be used to deliver decreased first-token serving latency. Latency decreases are made even more important as use cases like [retrieval-augmented generation \(RAG\)](#) and autonomous agents may require many calls to the model, compounding single-call latency.

How do MoE architectures work?

Two key components contribute to MoE models. First, the “expert” subnetworks that compose the mixture, which are used for both dense and sparse MoE. Second, the routing algorithm used by sparse models to determine which experts process which tokens. In some formulations for dense and sparse MoE, the MoE may include a weighting mechanism that is used to perform a weighted average of expert outputs. For the purpose of this post, we will focus on the sparse case.

In many published papers, the MoE technique is applied to Multi-Layer Perceptrons (MLPs) within transformer blocks. In this case, the MLP within the transformer block is usually replaced with a set of expert MLP subnetworks, the results of which are combined to produce the MLP MoE output using averaging or summation.

Research has also suggested that the concept of MoE can be extrapolated to other parts of the transformer architecture. The recent paper [SwitchHead: Accelerating Transformers with Mixture-of-Experts Attention](#) suggests that MoE can also be applied to the projection layers that transform inputs into Q, K, and V matrices to be consumed by the attention operation. Other papers have proposed the application of the conditional execution MoE concept to the attention heads themselves.

Routing networks (or algorithms) are used to determine which of the experts are activated in the case of a particular input. Routing algorithms can vary from simple (uniform selection or binning across average values of tensors) to complex, as explained in [Mixture-of-Experts with Expert Choice Routing](#).

Among many factors that determine the applicability of a given routing algorithm to a problem, two core factors are often discussed: model accuracy under a specific routing regime and load balancing under a specific regime. Choosing the right routing algorithm can be a trade-off between accuracy and flop efficiency. A perfectly load-balanced routing algorithm might reduce



Many proposed routing algorithms are designed to maximize model accuracy while minimizing the bottleneck presented by any given expert. While Mixtral 8x7B uses a Top-K algorithm to route tokens, papers such as [Mixture-of-Experts with Expert Choice Routing](#) introduce concepts to ensure that experts are not overly routed to. This prevents the formation of bottlenecks.

Experimenting with the Mixtral model

In practice, what does each expert learn? Do they specialize in low-level lingual constructs, such as punctuation, verbs, adjectives, and so forth, or are they the masters of high-level concepts and domains, such as coding, math, biology, and law?

To this end, we designed an experiment using the [Mixtral 8x7B model](#). This model has 32 sequential transformer blocks, wherein each MLP layer is replaced with a sparse MoE block with eight experts, of which only two are activated for each token. The remaining layers, including self-attention and normalization layers, are shared by all the tokens.

It is worth noting that when reading the name 8x7B, one could imagine the experts being eight separate full networks, each of 7 billion parameters, and each token is fully processed end-to-end by one of these eight full networks (Figure 1). This design would yield an 8x7B = 56B model.

Figure 1. A possible interpretation of the Mixtral 8x7B model



token and its copy (which is processed by the second-picked expert at each layer) is processed by only 12.9 billion parameters in total, not $2 \times 7B = 14B$. And the whole network is only 47 billion, not $8 \times 7B = 56B$ parameters, due to the shared layers.

Figure 2. Simplified Mixtral 8x7B model architecture

Therefore, each of the tokens passing through the network must go through a lattice-like structure, with $\binom{8}{2} = 28$ possible combinations of two experts at each layer. Mixtral 8x7B has 32 transformer blocks, thus there are a total of 28^{32} possible instantiations of the network.

If we consider each of these instantiations as a “full-stack expert” (one that processes a token end to end), is it possible to find out what expertise they offer? Unfortunately, since 28^{32} is a really large number ($\sim 2 \times 10^{46}$), which is orders upon orders of magnitude larger than all the data used to train LLMs ($\sim 3T$ to $10T$ tokens for most LLMs), rarely will any two tokens be processed by the same instantiation. Thus, we will study what each layer expert specializes on as opposed to each full expert combination.

Experimental results



algebra, world religions, professional law, anatomy, astronomy, and business ethics, to name a few. We recorded the token-expert assignment for each of the eight experts on layers 1, 16, and 32.

Upon parsing the data, several observations are worth noting.

Load balancing

Thanks to load balancing, the experts receive equalized loads, yet the most busy expert still receives up to 40–60% more tokens than the least busy one.

Figure 3. Expert loading distribution over all MMLU topics

Domain-expert assignment

Some domains activate some experts more than others.

In layer 32, one such example is abstract algebra, which makes use of experts three and eight much more than others.

Figure 4. Token distribution over expert in layer 32 for abstract algebra



Figure 5. Token distribution over expert in layer 32 for professional law

World religions is another fascinating example, in that expert seven receives more than 5x less tokens than expert eight.

Figure 6. Token distribution over expert in layer 32 for world religions

These experimental results show that the experts' load distribution tends towards uniformity across a diverse range of topics. However, when samples all fall exclusively under a certain topic, there could be a large distributional imbalance.



The word cloud in Figure 7 shows which tokens were most frequently processed by each expert.

Figure 7. Most common tokens processed by experts

Most preferred experts by tokens

Does each token have a preferred expert? Each token seems to have a more preferred set of experts, as the following examples show.

Expert assignment for token “.”, all “.” tokens are processed by experts one and seven in layer one, and experts three and eight in layer 32 (Figure 8). Figures 9, 10, and 11 show the expert assignment for various tokens.



Figure 8. Expert assignment for token “.”

Figure 9. Expert assignment for token “.”

Figure 10. Expert assignment for token “what”

Figure 11. Expert assignment for token “who”



MoE models provide demonstrable benefits to model pretraining throughput, enabling a more expressive sparse MoE model to be trained on the same amount of compute as a dense model. This leads to more competitive models under the same compute budget. MoE models can target the entire network, or specific layers within the existing network. Generally, sparse MoE with routing is applied to ensure that only some experts are used.

Our experiments explore how tokens are assigned and the relative load balance between experts. These experiments show that despite the load-balancing algorithm, there could still be large distributional imbalances, potentially affecting inference inefficiency, as some experts finish their work early while others are overloaded. This is an interesting area of active research.

You can try [Mixtral 8x7B Instruct](#), as well as other AI models on [build.nvidia.com](#).

Want to learn more? Don't miss the panel session, [Mistral AI: Frontier AI in Your Hands](#) from NVIDIA GTC.

Learn how NVIDIA Blackwell NVL72 runs 10x faster and delivers 1/10 the token cost for MoE models in this [blog](#).

Discuss (0)

+54 Like

Tags

[Agentic AI / Generative AI](#) | [General](#) | [A100](#) | [AI Foundation Models](#) | [Intermediate Technical](#) | [Advanced Technical](#) | [Deep Dive](#) | [Algorithms / Numerical Techniques](#) | [Graph Neural Networks](#) | [LLMs](#) | [Mixture Of Experts \(MoE\)](#)

About the Authors

About Kyle Kranen

Kyle Kranen is a deep learning software engineer at NVIDIA. He received a BS in electrical engineering and computer sciences from the University of California, Berkeley. At NVIDIA, his research is currently concentrated on recommender systems and time-series modeling.

[View all posts by Kyle Kranen](#) >

About Vinh Nguyen

Vinh Nguyen is a deep learning engineer and data scientist, having published more than 50



applications, including large language models and multi-modality models.

View all posts by Vinh Nguyen >

Comments

Start the discussion at forums.developer.nvidia.com

Related posts

Optimizing Communication for Mixture-of-Experts Training with Hybrid Expert Parallel



**New Open Source Qwen3-Next Models Preview Hybrid MoE Architecture
Delivering Improved Accuracy and Accelerated Parallel Processing across
NVIDIA Platform**

**How NVIDIA GB200 NVL72 and NVIDIA Dynamo Boost Inference
Performance for MoE Models**



Achieving High Mixtral 8x7B Performance with NVIDIA H100 Tensor Core GPUs and NVIDIA TensorRT-LLM

Leverage Mixture of Experts-Based DBRX for Superior LLM Performance on Diverse Tasks



РАЗРАБОТЧИК



Присоединиться

It all starts here. June 1-4 | Taipei



Sign up for NVIDIA News

Subscribe

Follow NVIDIA Developer



[Privacy Policy](#) | [Your Privacy Choices](#) | [Terms of Use](#) | [Accessibility](#) | [Corporate Policies](#) | [Contact](#)

Copyright © 2026 NVIDIA Corporation