

Что такое объедине



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности [параметры](#).
[Посещая наш сайт, вы соглашаетесь на обработку информации в соответствии с настройками использования файлов cookie](#) [Для получения дополнительной информации ознакомьтесь с.](#)

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

Принять все

Другие варианты



Что такое объедине

Смешанное обучение с учителем (I подход к [машинному обучению](#), пр [интеллекта \(ИИ\)](#) делится на отдельные каждая из которых специализирует данные, для совместного выполне

Архитектура «смесь экспертов» позволяет которые содержат многие миллиарды пара вычисления при предварительном обучении время логического вывода. В общих чертах выборочного включения только тех «экспер конкретной задачи, а не за счет включения задачи.

Несмотря на то, что большая часть современ была разработана (приблизительно) за пос моделей смеси экспертов восходит к статье экспертов». В ней предлагалось обучить си состоящую из отдельных сетей, каждая из и определенном подмножестве обучающих п самих «экспертных сетей», так и *управляю* сетей использовать для решения каждой п традиционной моделью экспериментальн



она достигала целевого порога точности за

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



Смешанные команды э глубокого обучения

Современные модели глубокого обучения с сетях, состоящих из множества слоев взаи Каждый нейрон имеет *функцию активации*: над данными, полученными от предыдущей качестве входных данных для следующего сети (feed-forward, FFN) обрабатывают инф данные от нейронов одного слоя к нейрона внешнего слоя, где формируются окончате. нейронных сетей включают в себя дополни внутреннего внимания *трансформерных мс* дополнительные закономерности и взаимо

The connections between different layers and *parameters*: variable weights (and biases) tha part of the network's output has on other part "learns" by adjusting these parameters, using *descent*, in a way that increases the accuracy

While a larger number of parameters increase information and patterns therein—it also incre train and operate the model. In a typical deep referred to as a *dense* model—the entire netw inputs. This creates a tradeoff between model



Unlike conventional dense models, mixture of

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



The lat

Discover e
cloud and

Subscr

How do mixture of e work?

MoE models process data by designating a nu
within a larger neural network, and training a ξ
specific expert(s) best suited to a given input.

The primary benefit of the MoE approach is th
the entire neural network for each input token
essentially keeping computational costs const

On an architectural level, this is achieved by re
network (FFN) layers with sparse MoE layers (

networks, “block” refers to a recurring structu

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



An SMOE may be composed entirely of sparse architectures entail both sparse and dense blocks responsible for the model's self-attention experts. In practice, this makes designations like many of the model's parameters are shared by network, Mixtral has a total of about 47 billion assume through simple multiplication.

This overall parameter count is commonly referred to as the total number of parameters. It can generally be understood as a measure of the model's capacity that will actually be used to process an individual token (tokens that are not activated in the blocks and bypasses others) is called the *activation*. The *activation* is a measure of the model's computational costs. In the given example, access to 46.7 billion parameters, only 12.9 billion are used in the given example.

Understanding this optimal utilization of parameters is the upside of MoE models. For example, Mixtral outperforms other models of Meta's [Llama 2](#) across most benchmarks—using a third fewer total parameters and using less than half the inference time.³

It's worth noting, however, that a sparse MoE's parameter count is irrelevant to computational requirements. During inference, the entirety of the model's parameters are accessed, meaning that the computational efficiency enjoyed by SMOEs is offset by increased RAM/VRAM requirements.



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



linear: for example, in NLP tasks that call for a each word is typically only related to a small s makes SMOEs an area of tremendous potentia MoE models can enjoy the benefits of sparsity gated MoE models have also been successfull remain an area of active study in that field.

This sparsity is achieved through conditional c specific parameters in response to specific inp network (or “router”), which enforces that cor success of MoE models.

Routing

A number of gating mechanisms can be used i situation. The right gating function is critical to strategy can result in some experts being und the efficacy of the entire network.

A typical gating mechanism in a traditional Mc paper, uses the *softmax* function: for each of t router predicts a probability value (based on t current parameter) of that expert yielding the computing the output of all the experts, the router predicts to be) the top *k* experts for that exam classic top-k routing strategy: specifically, it u

best 2 (out of its total of 8) experts.

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)

predictions than the other, less-trained expert ultimately end up, figuratively and literally, as

To mitigate this, Shazeer *et al* introduced *noisy* to the probability values predicted for each expert, which better encourages more evenly distributed activation. Additionally, trainable regularization terms to expert select an overreliance on any one expert, while minimizing utilization of all experts.

Google's 2020 paper, "GShard: Scaling Giant Models with Automatic Sharding," introduced two additional

- **Random routing:** While the "top" expert is selected by a standard softmax function, the second expert is selected with a probability of any expert being picked proportional to its rank. The second-highest ranked expert is thus *guaranteed* to be selected.
- **Expert capacity:** The authors set a threshold on the number of tokens that can be processed by any one expert. If an expert is at capacity, the token is deemed "overflowed" and is sent to the next layer of the network.⁷

Mixture of Experts | 24 April, episode 10

think podcast

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.	заявление о конфиденциальности	Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных здесь .
	настройками использования файлов cookie Для получения дополнительной информации ознакомьтесь с.	

and insights.

[Watch all episodes of Mixture of Experts](#)

Fine-tuning MoE mo

As mentioned earlier, the advantages of spars added complexity. The challenges of impleme [fine-tuning](#) process. Sparse models are more | models, and the presence of both sparse MoE layers and dense FFN layers complicated a one-size-fits-all approach.

A number of observations and approaches have been proposed to reduce instability when fine-tuning MoEs. The authors of the Switch Transforlners paper observed that variants with fewer experts enjoyed more successful fine-tuning, which suggests that the benefits of a larger number of experts in pre-training may be countered by its hindrance to specialization on downstream tasks.

In the 2022 paper “ST-MoE: Designing Stable and Transferable Sparse Expert Models,” Zoph *et al* compared the results of 5 different approaches: fine-tuning all parameters (“All”), only non-MoE parameters (“Non MoE”), only MoE parameters (“MoE”), only the self-attention and encoder-decoder attention parameters (“Attention”) and only the non-MoE FFN parameters (“FFN”).

– Almost no difference was found between All and Non-MoE

– Fine-tuning only Attention parameters resulted in a minor decrease in performance.

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– Fine-tuning only the self-attention and encoder-decoder attention parameters resulted in performance relative to the All baseline.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– Fine-tuning only the self-attention and encoder-decoder attention parameters resulted in performance relative to the All baseline.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– Fine-tuning only the self-attention and encoder-decoder attention parameters resulted in performance relative to the All baseline.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and

– Fine-tuning only MoE parameters significantly *degraded* model performance, despite that roughly half the parameters were updated in the sparse MoE layers.

– The authors hypothesized that because experts represented only a quarter of their layer’s parameters, and a token will see only two experts per layer, isolating MoE parameters results in less comprehensive weight updates (and thus greater overfitting and



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных

Для

IBM,

перечисленных

заявление о конфиденциальности

Для обеспечения удобной навигации ваши настройки использования файлов cookie [Для](#) [получения](#) [дополнительной информации](#) [ознакомьтесь с](#).

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных

здесь.

version of T5 instruction-tuned with [Google's Flan protocol](#) —LLMs as a baseline. Their experiment compared four setups: fine-tuning a dense T5 model, fine-tuning a dense Flan-T5 model, fine-tuning an MoE model and fine-tuning an instruction-tuned Flan-MoE model.

As expected, the dense T5 equivalent outperformed the MoE after fine-tuning. But conversely, the fine-tuned Flan-MoE model significantly outperformed the fine-tuned Flan-T5 model. Furthermore, the improvement of Flan-MoE compared to the MoE was even greater than the improvement of Flan-T5 over the original T5.9

Encouragingly, this suggests that despite their difficulties with standard fine-tuning, MoE models actually benefit more from instruction tuning than their dense counterparts. This finding was realized with the acclaimed release of Mixtral 8x7B Instruct, an instruction-tuned variant of Mixtral that is [offered as a foundation model](#) in [IBM watsonx.ai™](#).

Upcoming webinar - May 20, 2026

Upcoming webinar on AI-native development

Engineering teams are strained

by legacy tools and tech debt.

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).



IBV Report

The enterprise in 2030: Engineered for perpetual innovation

Discover our five predictions about what will define the most successful enterprises in 2030 and the steps leaders can take to gain an AI-first advantage.

[Read the report](#)



AI models

Explore IBM Granite



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).

Techsplainers podcast

Large language models explained

Techsplainers by IBM breaks down the essentials of LLMs, from key concepts to real-world use cases.

Ebook

How to choose the right foundation model

Learn how to select the most suitable AI foundation model for your use case.

[Read the ebook](#)



Article

О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).



Guide

The CEO's guide to model optimization

Learn how to continually push teams to improve model performance and outpace the competition by using the latest AI techniques and infrastructure.

Report

A differentiated approach to AI foundation models

Explore the value of enterprise-grade foundation models that provide trust, performance and cost-effective benefits to all industries.



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности

настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)



Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь](#).


business operations for improved performance.



1 / 8




Похожие решения



IBM watsonx Orchestrate®

Easily design scalable AI assistants and agents, automate repetitive tasks and simplify complex processes with IBM watsonx Orchestrate.


[Explore watsonx Orchestrate](#) →



IBM Bob

Accelerate software delivery with Bob, your AI partner for secure, intent-aware development.

[Explore IBM Bob](#) →



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.

заявление о конфиденциальности
настройками использования файлов cookie [Для получения дополнительной информации ознакомьтесь с.](#)

Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных [здесь.](#)



Discover how you can scale and govern your AI with watsonx Orchestrate, the control plane that helps you streamline operations, automate workflows, and manage intelligent agents with ease.

Discover watsonx Orchestrate

Explore IBM Bob



² "AI Expert Speculates on GPT-4 Architecture," [Weights and Biases](#), 21 June 2023

³ "Mixtral of experts," [Mistral AI](#), 11 December 2023

⁴ "Outrageously Large Neural Networks: The Sparsely-Gated Mixture-of-Experts Layer," [arXiv](#), 23 January 2017

⁵ "Scaling Vision with Sparse Mixture of Experts," [arXiv](#), 10 June 2021; "MoCaE: Mixture of Calibrated Experts Significantly Improves Object Detection," [Papers with Code](#), 26 September 2023

⁶ "Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity," [arXiv](#), 11 January 2021 (last updated 16 June 2022)

⁷ "GShard: Scaling Giant Models with Conditional Computation and Automatic Sharding," [arXiv](#), 30 June 2020

⁸ "ST-MoE: Designing Stable and Transferable Sparse Expert Models," [arXiv](#), 17 February 2022

⁹ "Mixture-of-Experts Meets Instruction Tuning: A Winning Combination for Large Language Models," [arXiv](#), last updated 5 July 2023



О файлах cookie на этом сайте

Для корректной работы наших сайтов требуются некоторые файлы cookie (обязательные). Кроме того, другие файлы cookie могут использоваться с вашего согласия для анализа использования сайта, улучшения пользовательского опыта и в рекламных целях.	заявление о конфиденциальности	Для обеспечения удобной навигации ваши настройки использования файлов cookie будут применяться на всех веб-сайтах IBM, перечисленных здесь .
	настройками использования файлов cookie Для получения дополнительной информации ознакомьтесь с.	