

КАРТА ПОТОКА · 6 ЭТАПОВ

Соберите локальную LLM под свое железо.

Вбейте параметры компьютера слева — симулятор подберёт движок вычислений, модель и квантизацию, покажет **живой бюджет видеопамяти**, спрогнозирует скорость и соберёт готовую команду

СБОРКА ЛОКАЛЬНОЙ LLM

ИНТЕРАКТИВНЫЙ СИМУЛЯТОР · LLAMA.CPP

CUDA · 12 ГБ VRAM

≈ 21-31 ток/с

Главное ограничение - видеопамять.
Самый частый пробел - скорость RAM / XMP.

— загрузить пресет железа —

▼

ПРОИЗВОДИТЕЛЬ GPU

NVIDIA

AMD

Intel

Apple

Нет GPU

VRAM

12

ГБ

RAM

240

ГБ

GPU ВЫВОДИТ КАРТИНКУ НА МОНИТОР?

Да

Нет

XMP / EXPO ВКЛЮЧЁН? · ВАЖНЕЕ ВСЕГО ДЛЯ МОЕ

Да

Нет

Не знаю

СКОРОСТЬ RAM

DDR5-

8000

sudo dmidecode -t memory | grep Speed

INTEL 12-Е ПОКОЛЕНИЕ И НОВЕЕ? (P/E-ЯДРА)

Да

Нет

ОС

Linux

НАКОПИТЕЛЬ

NVMe

ЦЕЛЬ ИСПОЛЬЗОВАНИЯ

Программирование

УРОВЕНЬ КОМФОРТА

Новичок · GUI

Контроль

СИМУЛЯЦИЯ

РЕКОМЕНДАЦИИ

КОМАНДА

ДИАГНОСТИКА

БЕЗОПАСНОСТЬ

МОДЕЛЬ И СТРАТЕГИЯ

MoE · 5B активных

МОДЕЛЬ

gpt-oss-120b (MoE)

КВАНТИЗАЦИЯ

MXFP4

ДЛИНА КОНТЕКСТА

64 k

--PARALLEL (СЛОТОВ)

1

KV-КЭШ

q8_0

f16

ЗРЕНИЕ

Нет

Да

МТР

Нет

Да

ЭТАП 3 · БЮДЖЕТ ВИДЕОПАМЯТИ

всего 12 ГБ · свободно под веса 8.8 ГБ

ёмкость 12 ГБ



Композитор рабочего стола 0.8 ГБ Запас(--fit-target) 0.5 ГБ KV-кэш 2 ГБ

Веса на GPU 8.8 ГБ

ЭКСПЕРТЫ МОЕ В RAM

55 ГБ → системная RAM (240 ГБ)



Система/ОС 4 ГБ Эксперты MoE 55 ГБ Свободно 181 ГБ

Это нормально для MoE: эксперты живут в системной RAM (--n-сри-тое), на GPU остаются внимание и общие слои. Скорость определяет память — включите XMP.

ПРОГНОЗ СКОРОСТИ ГЕНЕРАЦИИ

≈ 21–31 ток/с

Быстро — агенты программирования летают



RAM на номинале (DDR5-8000)

Упор: скорость системной RAM

ЧЕСТНАЯ ОГОВОРКА

Это оценка, не гарантия. Точную цифру даёт только бенчмарк (lata-bench) на реальной длине контекста, а не на коротком промпте. Числа калиброваны по одной машине: RTX 4070 12 ГБ, i5-12600K, DDR5-6000.

ПОПРОБУЙ СЛОМАТЬ

Включайте аварии — и сразу видите падение скорости, симптом и исправление. Лучший способ понять, откуда берутся тормоза.

XMP/EXPO выключен Память падает к базовой JEDEC. Для MoE генерация замедляется примерно в 3 раза.	Е-ядра в диапазоне потоков Е-ядра режут скорость на 20–30%. Нужно закрепление на Р-ядра (taskset -c).
--parallel 4 Четыре слота умножают KV-кэш ×4 — память уходит из-под весов.	--fit-target слишком мал Запас 0.1 ГБ → нехватка памяти не на старте, а посреди сессии. Поднимите до 512 МБ.
power-profiles-daemon Скорость гуляет 20–30% между загрузками. Замена — tuned-ppd + throughput-performance.	