

Начало работы

Основные понятия

 Copy page

Как работает VectorAI DB, ее модель данных и как поисковый запрос проходит через систему.

! **Впервые слышите о векторных базах данных?** Векторные базы данных хранят числовые представления ваших данных, называемые эмбедингами, и находят результаты по сходству, а не по точному совпадению ключевых слов. Используйте его, когда смысл важнее точного текста: семантический поиск, RAG-конвейеры, память агента.

Архитектура

VectorAI DB работает как единый Docker-контейнер без внешних зависимостей. Данные сохраняются в подключенном к хосту каталоге.

Порт	Протокол	Назначение
6573	HTTP	REST API
6574	gRPC	gRPC API (рекомендуется для SDK)
6575	HTTP	Локальный пользовательский интерфейс

По умолчанию SDK для Python и JavaScript взаимодействуют через gRPC.

Модель данных

<u>Точки</u>	Единица данных в коллекции. Каждая точка имеет уникальный идентификатор, векторное представление и необязательную полезную нагрузку в формате JSON.
<u>Векторы</u>	Массивы чисел с фиксированной длиной, которые семантически представляют ваши данные. Создаются с помощью моделей встраивания на основе текста, изображений или другого контента.
<u>Полезная нагрузка</u>	Метаданные JSON, прикрепленные к точке. Используйте полезную нагрузку для хранения контекста и фильтрации результатов поиска.
<u>Метрики расстояния</u>	Функция, используемая для измерения сходства между векторами. Поддерживаемые метрики: косинусное расстояние, евклидово расстояние и скалярное произведение.

Как работает поиск

1 Генерация эмбединга

Ваше приложение преобразует запрос (текст, изображение или другие данные) в вектор с помощью модели эмбединга.

2 Отправка поискового запроса

Вектор отправляется в VectorAI DB через gRPC или REST.

3 Поиск ближайших соседей с помощью HNSW

VectorAI DB просматривает индекс HNSW, чтобы найти ближайшие векторы, применяя все фильтры полезной нагрузки.

4 Возвращаются ранжированные результаты

Результаты возвращаются с идентификаторами, показателями сходства и необязательными полезными нагрузками. Пост-обработка не требуется.

- **Фильтрации** для условий, связанных с полезной нагрузкой: «обязательно», «желательно» и «нежелательно»

Следующие шаги

Установка

Установите VectorAI DB с помощью Docker.

Быстрый старт

Создайте коллекцию, вставьте векторы и выполните поиск.

Основы

Коллекции, точки, векторы, поиск и фильтрация.

Академия

Практические руководства по семантическому поиску, RAG и многому другому.