

ИИ / МОДЕЛИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА

Google выпустила 3 новые модели Gemini. Но не ту, которую все так ждали.

Google выпустила Gemini 3.6 Flash, 3.5 Flash-Lite и 3.5 Flash Cyber, но флагманская модель 3.5 Pro до сих пор не поступила в продажу, хотя обещанная дата выхода уже прошла.

21 июля 2026 г. в 11:00 [Фредерик Лардинуа](#)



Фото https://unsplash.com/@mitchel3uo?utm_source=unsplash&utm_medium=referral&utm_content=creditCopyText Митчелл Ло на https://unsplash.com/photos/google-logo-neon-light-signage-jz4ca36oJ_M?utm_source=unsplash&utm_medium=referral&utm_content=creditCopyText Unsplash.

Во вторник компания Google представила три новые модели Gemini: Gemini 3.6 Flash, более дешевую и быструю модель 3.5 Flash-Lite и 3.5 Flash Cyber — модель, оптимизированную для использования в сфере кибербезопасности и в целом превосходящую **модель 4.6 Opus от Anthropic**.

Google впервые анонсировала GPT-5 на конференции I/O в мае, пообещав выпустить ее в июне. Google сообщает, что модель Pro «в настоящее время тестируется совместно с партнерами» и что компания планирует сделать ее общедоступной «как только она будет готова».

Google никогда не упускает возможности заглянуть в будущее и сообщает, что приступила к предварительному обучению модели Gemini 4.

3.6 Flash

Большинство из нас не ожидали, что модель Gemini Flash обновится раньше, чем модель Gemini 3.5 Pro, но вот оно — обновление.

Хорошая новость заключается в том, что 3.6 Flash — это значимое обновление по сравнению с предыдущей версией, и оно немного дешевле. Входная цена за миллион токенов остается на уровне 1,50 доллара, но Google снижает цену за миллион выходных токенов с 9 до 7,50 долларов.

Большинство из нас не ожидали, что модель Gemini Flash обновится раньше модели Gemini 3.5 Pro, но вот оно — обновление.


Google также особо отмечает, что 3.6 Flash требует меньше логических шагов и вызовов инструментов для достижения целей в агентных рабочих процессах, что также должно сделать его более экономичным в эксплуатации. По данным Artificial Analysis, он использует на 17% меньше токенов.

Результаты тестирования 3.6 Flash

По большинству показателей 3.6 Flash значительно превосходит своего предшественника, особенно в том, что касается написания кода. Например, в новом **бенчмарке DeepSWE для разработки программного обеспечения** Flash 3.6 набрал 49 % против 37 % у Flash 3.5. Однако это не самый лучший результат. **Claude Sonnet 5 от Anthropic** набрал 54 %, а топовые передовые цели — более 70 %.

1. Google выпускает 3 новые модели Gemini. Но не ту, которую все так ждали.
2. AWS теперь будет следить за облаком Microsoft за вас
3. За 24 часа OpenAI, SpaceX и Meta превратили искусственный интеллект в гонку за минимальными ценами
4. Клод Коворк из Anthropic теперь продолжает работать, когда вы закрываете ноутбук
5. Руководство разработчика по масштабированию данных CRM, искусственного интеллекта и взаимодействия с приложениями

Команда также добилась значительных успехов в тестировании MLE Benchmark machine learning research benchmark (63,9% против 49,7%) и проверенном OSWorld тесте использования компьютера (83% против 78,4%). Большинство современных моделей показывают примерно такие же результаты, что на самом деле весьма впечатляет для модели среднего класса, такой как 3.6 Flash. Для сравнения, у Claude Fable этот показатель лишь немного выше — 85%.



Источник: Google.

Что касается knowledge work, 3,6 Flash достигает 1421 в GDPval-AA v2, что много лучше, чем 3,5 Flash за 1349, но на данный момент это значительно

What's important to remember here, of course, is that Google is also competing on price, but even there, the picture is complicated. 3.6 Flash doesn't always outperform **GPT 5.6 Luna**, for example, and that's available for \$1/\$6 per million input/output tokens (but only as long as the context window is under 272,000 tokens). Anthropic's Sonnet 5 is available for an introductory price of \$2/\$10 until the end of August, too.

3.6 Flash and 3.5 Flash Lite availability

3.6 Flash and 3.5 Flash Lite are now available in the Gemini API via Google AI Studio and Android Studio, while 3.6 Flash is also available in **Google's Antigravity agentic coding tool** and for enterprise users in the Gemini Enterprise Agent Platform (previously known as Vertex AI).

For consumers, 3.5 Flash-Lite is coming to Google Search.

3.5 Flash-Lite

3.5 Flash-Lite is Google's newest low-end model. Given that 3.1 Flash Lite, the most recent 'lite' release, is **almost half a year old**, it's no surprise that 3.5 Flash shows an improvement across the board. But it's also a bit more expensive, at \$0.3/\$2.5 per million input/output tokens (up from \$0.25/\$1.5).

In terms of benchmarks, it's not going to break any records, but that isn't the purpose of this model either. It's meant for high-throughput tasks like agentic search and document processing, not for tasks where reasoning and planning agentic workloads are key.

That said, it is a significantly better model than 3.1 Flash Lite, though. On GDPval-AA v2, it scores 1140 compared to the previous lite models' 642. SWE-Bench Pro numbers go up from 49.6% to 54.2%, and on OSWorld-Verified, it hits 74% now.

For many companies, it will land in a sweet spot for latency-sensitive workloads, as Ramp's head of applied AI Veeral Patel notes. "Gemini 3.5 Flash-Lite landed on the Pareto frontier in our receipt extraction benchmark, offering one of the best tradeoffs we've tested between accuracy, latency, and cost," he writes in today's announcement. "That combination is critical at Ramp, where we need to process receipts quickly and reliably at scale."

cybersecurity use cases — without risking any **Fable 5-like fallout**.

As Google notes, today's "AI models have become capable of finding security vulnerabilities faster than current systems can fix them. The company built 3.5 Flash Cyber on top of the regular 3.5 Flash model and is charging the same for it, too, which gives Google the ability to claim that it "offers a cost-efficient and highly capable alternative to large, costly cybersecurity models."

But you won't be able to get your hands on the Cyber model just yet. It is only available in a limited-access pilot exclusively for governments and trusted partners, and only in Google's own CodeMender tool. The plan is to expand access over time.

It seems unlikely that 3.5 Flash Cyber is at the level of an **Anthropic Mythos** when it comes to finding and exploiting software vulnerabilities, but this goes to show how nervous frontier labs now are about rolling out these models. "This will give frontline defenders a head start in finding and fixing critical vulnerabilities before they can be exploited, while mitigating against broader misuse," Google notes.

Meanwhile, many Chinese open-source models like **Kimi K3** are probably at the same level as 3.5 Flash Cyber.

Google says it performs at the level of Opus 4.6 and notes that "more recent competitor models perform less well than Claude Opus 4.6 because of guardrails."

TNS



Before joining The New Stack as its senior editor for AI, Frederic was the enterprise editor at TechCrunch, where he covered everything from the rise of the cloud and the earliest days of Kubernetes to the advent of quantum computing....

[Read more from Frederic Lardinois →](#)

TNS owner Insight Partners is an investor in: Anthropic.

SHARE THIS STORY



-
2. AWS will now watch Microsoft's cloud for you
 3. In 24 hours, OpenAI, SpaceXAI, and Meta turned AI into a race to the bottom on price
 4. Anthropic's Claude Cowork now keeps working when you close your laptop
 5. The Developer's Guide to Connecting CRM Data, AI and App Experience, at Scale

INSIGHTS FROM OUR SPONSORS

Where Were We: Watch Meko Give AI Agents a
Shared Context

16 July 2026

Flink CDC for YugabyteDB

9 July 2026

Meko is Open for Self Sign-Up: Here's How to Get Started!

6 July 2026



CONFLUENT

Announcing Upvest as Confluent's 2026 EMEA Data Streaming Startup of the Year

16 July 2026

Tableflow: Turn Kafka Topics into Iceberg Tables

10 July 2026

Deep Dive into SASL PLAIN and SCRAM in Kafka: Login Modules and Config Hot-Reload

6 July 2026



Kubeshop™

Build vs. Buy Test Orchestration: The Hidden Cost

22 July 2026

Functional Service Validation in Kubernetes

13 July 2026

Testkube Git Triggers: A GitHub Actions Alternative

8 July 2026

most recent TNS articles in your inbox each day.

svo1975pvn1982@gmail.com

SUBSCRIBE

The New Stack does not sell your information or share it with unaffiliated third parties. By continuing, you agree to our [Terms of Use](#) and [Privacy Policy](#).

ARCHITECTURE

Cloud Native Ecosystem
Containers
Databases
Edge Computing
Infrastructure as Code
Linux
Microservices
Open Source
Networking
Storage

OPERATIONS

AI Operations
CI/CD
Cloud Services
DevOps
Kubernetes

ENGINEERING

AI
AI Engineering
API Management
Backend development
Data
Frontend Development
Large Language Models
Security
Software Development
WebAssembly

CHANNELS

Podcasts
Ebooks
Events
Webinars
Newsletter

THE NEW STACK

[About / Contact](#)
[Sponsors](#)
[Advertise With Us](#)
[Contributions](#)



Community created roadmaps, articles, resources and journeys for developers to help you choose your path and grow in your career.

[Frontend Developer Roadmap](#)
[Backend Developer Roadmap](#)
[Devops Roadmap](#)

FOLLOW TNS



© The New Stack 2026

[Disclosures](#)
[Terms of Use](#)
[Advertising Terms & Conditions](#)
[Privacy Policy](#)
[Cookie Policy](#)