

⚠️ **Примечание:** пропускная способность в настоящее время ограничена. Эта модель может часто выдавать ошибку 429. ✕

🔍 MoonshotAI: Kimi K3

moonshotai/kimi-k3 

Kimi K3 — это мультимодальная модель логического вывода с открытым исходным кодом и 2,8 терапараметрами от Moonshot AI. Он подходит для сложного кодирования, ...

Показать больше ▾

MODALITIES

T  → T

ВХОДНАЯ / ВЫХОДНАЯ ЦЕНА

\$3 / \$15 за 1 млн

КОНТЕКСТ

1 млн

ДАТА ВЫПУСКА

16 июля 2026 г.

📁 Провайдеры

▾

📁 Провайдеры

Эта модель размещена у одного провайдера. OpenRouter перенаправляет все запросы напрямую — никаких решений по маршрутизации принимать не нужно.

Провайдер ↑↓	↑↓ Вход /М	↑↓ Выход /М	↑↓ Cache Read /М	↑↓ Latency
 Moonshot AI 	\$3,00	\$15,00	\$0,30	6,13s

\$ Эффективное ценообразование

может быть на 60–80 % дешевле, чем цена, указанная провайдером. Показаны скользящие средние значения за последние 30 дней.

Compare

Средневзвешенная цена входа

\$0,544

/M токенов


Средневзвешенная цена выхода

\$15,00

/M токенов

Провайдер ↑↓	↑↓ Вход \$/1M	↑↓ Выход \$/1M	↑↓ Cache hit rate	↑↓ Token share
 Moonshot AI	\$0.544	\$15.00	91.0%	100.0%

Цена входа / 1M токенов (7 дней)



Зарегистрироваться

Цена выхода / 1M токенов (7 дней)

Сравнить

16

Compare



Производительность

Пропускная способность — это скорость записи модели (токенов в секунду, чем выше, тем лучше).
Задержка — это общее время прохождения сигнала в обе стороны (чем меньше, тем лучше). TTFT — время до первого токена, то есть время, которое проходит до появления чего-либо (чем меньше, тем лучше).


Пропускная способность
22 ток/с
лучшая среди провайдеров

Задержка
6,13 с
p50, лучший провайдер

Все локации

3 дня


Пропускная способность



Сравнить

Compare


Задержка



Moonshot AI

Avg 5.89 s

E2E Latency



Moonshot AI

Avg 23.10 s

Tool Call Error Rate



Сравнить




Compare



Moonshot AI

Avg 0.23 %

Structured Output Error Rate



Moonshot AI

Avg 8.88 %

Cache Hit Rate



Moonshot AI

Avg 89.34 %

Сравнить

⚡ Время безотказной работы


Процент успешных запросов за последние 30 дней. OpenRouter непрерывно отслеживает работу

📊 Compare

Avg. Provider Uptime (3d)

99.95%

averaged across all endpoints



When an error occurs in an upstream provider, we can recover by routing to another healthy provider, if your request filters allow it. You can access uptime data programmatically through the [Endpoints API](#). [Learn more](#) about our load balancing and customization options.

Generated by Datadog

Сравнить 📊

Compare

57.1

Artificial Analysis
Intelligence Index

Better than 97% of models compared

76.2

Artificial Analysis
Coding Index

Better than 95% of models compared

50.1

Artificial Analysis
Agentic Index

Better than 97% of models compared

Reasoning

GPQA Diamond ⓘ

Graduate-level scientific reasoning

87.5%

Сравнить

Compare

Long context reasoning evaluation

74.7%

GDPval-AA ⓘ

Economically valuable tasks

59.2%

CritPt ⓘ

Research-level physics reasoning

23.4%

Coding

SciCode ⓘ

Python programming for scientific computing

58.7%

Knowledge

AA-Omniscience Accuracy ⓘ

Proportion of correctly answered questions

46.0%

AA-Omniscience Non-Hallucination Rate ⓘ


Rate of avoiding hallucination among non-correct responses

49.1%

Metrics sourced from [Artificial Analysis](#)

Compare

2.  [Claude Code](#) > 2,34B tokens
Claude Code is Anthropic's agentic coding tool t...
3.  [Oh-My-Pi](#) > 1,4B tokens
new
4.  [pi](#) > 1,15B tokens
There are many coding agents, but this one is you...
5.  [Kilo Code](#) > 506M tokens
Kilo Code is an open-source AI coding agent that ...



Активность

Объем токенов и трафик запросов к этой модели с течением времени.


Tokens



Сравнить



Compare



Prompt	31,9B
Reasoning	598M
Completion	186M

Prompt tokens measure input size. Reasoning tokens show internal thinking before a response. Completion tokens reflect total output length.

Быстрый старт

Готовый код для вызова этой модели. API OpenRouter совместим с OpenAI — большинство SDK работают, просто заменяя базовый URL. Единственное, что меняется в разных моделях, — это идентификатор модели, указанный ниже.

1 Get your API key

Create an API key from your OpenRouter dashboard and set it as an environment variable:

Create API Key

```
export OPENROUTER_API_KEY=sk-or-v1- ...
```

Copy

2 Make your first request

Use moonshotai/kimi-k3 with the OpenRouter API:

Сравнить

`reasoning_details` array in the response to see the model's internal reasoning before the final answer. When continuing a conversation, preserve the complete `reasoning_details` when passing messages back to the model so it can continue reasoning from where it left off

🔍 Compare

In the examples below, the OpenRouter-specific headers are optional. Setting them allows your app to appear on the OpenRouter leaderboards.

TypeScript SDK Python TypeScript (fetch) cURL Python (OpenAI) TypeScript (C

```
import { OpenRouter } from "@openrouter/sdk";

const openrouter = new OpenRouter({
  apiKey: "<OPENROUTER_API_KEY>"
});

// Stream the response to get reasoning tokens in usage
const stream = await openrouter.chat.send({
  chatRequest: {
    model: "moonshotai/kimi-k3",
    messages: [
      {
        role: "user",
```

📄 Copy

Using third-party SDKs

For information about using third-party SDKs and frameworks with OpenRouter, please see our [frameworks documentation](#).

3 Enable streaming

Add `"stream": true` to your request body to receive responses as server-sent events:

```
curl -N https://openrouter.ai/api/v1/chat/completions \
-H "Content-Type: application/json" \
-H "Authorization: Bearer $OPENROUTER_API_KEY" \
-d '{
  "model": "moonshotai/kimi-k3",
  "stream": true,
  "messages": [
    {"role": "user", "content": "Hello"}
  ]
}'
```

📄 Copy

Endpoint

Сравнить 🔍

POST https://openrouter.ai/api/v1/chat/completions

 Compare

Content-Type	application/json
HTTP-Referer	optional – your site URL, for rankings
X-Title	optional – your site name, for rankings
Model	moonshotai/kimi-k3

Creates a streaming or non-streaming response using the OpenAI Responses API format. [Docs](#)

POST https://openrouter.ai/api/v1/responses

Authorization	Bearer \$OPENROUTER_API_KEY
Content-Type	application/json
HTTP-Referer	optional – your site URL, for rankings
X-Title	optional – your site name, for rankings
Model	moonshotai/kimi-k3

Creates a message using the Anthropic Messages API format. Supports text, images, PDFs, tools, and extended thinking.

[Docs](#)

POST https://openrouter.ai/api/v1/messages

Authorization	Bearer \$OPENROUTER_API_KEY
Content-Type	application/json
HTTP-Referer	optional – your site URL, for rankings
X-Title	optional – your site name, for rankings
Model	moonshotai/kimi-k3

Parameters

Name	Type	Default	Description
reasoning	map	—	Controls reasoning behavior for moc
max_tokens	integer	—	This sets the upper limit for the numb

Сравнить 

Name	Type	Default	Description
Compare			
presence_penalty	float	0	Adjusts how often the model repeats
response_format	map	—	Forces the model to produce specifi
tool_choice	string or object	—	Controls which (if any) tool is called b
tools	array	—	Tool calling parameter, following Op

Другие модели от moonshotai

Kimi K2.7 Code

MoonshotAI: Kimi K2.7 Code — это модель, ориентированная на кодирование, из семейства Kimi...

MoonshotAI Kimi Latest

Эта модель всегда перенаправляет на последнюю модель семейства MoonshotAI ...

Kimi K2.6

Kimi K2.6 is Moonshot generation multimodal designed for long-l



© 2026 OpenRouter, Inc

Продукт	Компания
Чат	О нас
Рейтинги	Блог
Приложения	Вакансии Подбор персонала
Модели	Конфиденциальность
Провайдеры	Условия предоставления услуг
Цены	Поддержка
Корпоративные решения	Состояние искусственного интеллекта
Лаборатории	Работает с OR

Сравнить

Developer

Documentation

Connect

Discord

 Compare

SDK

LinkedIn

Status

X

YouTube

Сравнить 