
[ГЛАВНАЯ](#) > [ТЕХНОЛОГИИ](#) > [ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ](#)

Обновленный Gemini 3.5 Pro не уложился в третий срок: Google рассматривает возможность временного выпуска

Из-за галлюцинаций релиз 17 июля был сорван; временные модели Flash теперь в очереди Google.

Автор: [Элоиза Джонс](#)

Опубликовано: 16 июля 2026, 13:28 EDT



Google Gemini (PHOTO: GOOGLE.COM)

Gemini 3.5 Pro от Google DeepMind уже три раза подряд не достигала запланированного запуска — в июне, затем 17 июля и далее — из-за того, что Geeky Gadgets сообщили в среду, что восстановленная модель по-прежнему страдает от галлюцинаций и непоследовательных выходных данных, которые не позволяют ей соответствовать базовым стандартам надежности. На сегодняшний день разработчики, ориентирующиеся на дату 17 июля,

выпуск Pro, обещанный на конференции I/O в мае, растёт.

Конференция Google I/O породила ожидания, которые не оправдались за три месяца

Все началось 19 мая на конференции Google I/O, когда Сундар Пичаи обратился к толпе разработчиков — которые, как сообщается, ответили ему громким стоном — со словами: «Дайте нам до следующего месяца, чтобы мы вам это предоставили». Под следующим месяцем подразумевался июнь. Июнь закончился без запуска. Google перенесла его на июль. Несколько сторонних изданий, в том числе HackerNoon и Geeky Gadgets, впоследствии сообщили, что задержка была связана не с рутинной доработкой, а с чем-то более серьёзным: Google DeepMind отказалась от почти готовой модели и приказала начать предварительное обучение с нуля на основе Gemini 3.

Различие между этими двумя понятиями имеет огромное значение. Предварительное обучение — это начальный и самый дорогостоящий этап создания передовой модели искусственного интеллекта, в ходе которого модель обучается на огромном массиве данных, что позволяет определить фундаментальный потолок ее возможностей. Тонкая настройка и обучение с подкреплением на основе обратной связи от человека могут улучшить модель в рамках этих возможностей, но не поднять потолок. Когда Google, по некоторым данным, решила перезапустить предварительное обучение, а не продолжать тонкую настройку, это означало признание того, что потолок возможностей исходной модели был установлен неправильно — это была структурная проблема, а не проблема доработки.

Подробнее: [Gemini 3.5 Pro выйдет 17 июля после полной переработки: все характеристики пока не подтверждены](#)

Что на самом деле означает решение о перестройке

По данным издания HackerNoon, ссылающегося на неназванные внутренние источники, в отмененной версии Gemini 3.5 Pro были выявлены два конкретных режима сбоя: система не могла поддерживать структурную целостность при создании сложных, многоуровневых макетов сцен в формате SVG и не справлялась со сложными рекурсивными вызовами инструментов — многоэтапными цепочками, в которых агент вызывает один инструмент, использует результат для вызова другого и продолжает действовать в соответствии с десятками последовательных решений.

Ни то, ни другое не является косметическим дефектом. Стабильность рекурсивных вызовов инструментов — определяющая характеристика модели агентного программирования, а агентное программирование — это тот вариант использования, который, по замыслу Google, должен был стать отличительной чертой всего поколения 3.5. Gemini 3.5 Flash уже продемонстрировал, что эта категория достижима: он превзошел Gemini 3.1 Pro по

худшие результаты в тех же тестах, не стала бы флагманской.

Сообщается, что перестройка была нацелена на контекстное окно в 2 миллиона токенов, что вдвое превышает лимит в 1 миллион токенов в Gemini 2.5 Pro; на уровень рассуждений Deep Think для многоэтапной логики; а также на возможности автономного рабочего процесса для объединения в цепочку сложных задач, связанных с кодированием и использованием инструментов. Все эти сведения взяты из сторонних источников и утечек, а не из официальной документации Google. По состоянию на 13 июля в общедоступной документации Gemini API не было ни карточки модели, ни страницы с ценами, ни [gemini-3.5-pro](#) списка. Единственные подтверждённые факты о Gemini 3.5 Pro — это то, что он существует, что Google использует его внутри компании и что он трижды подряд не уложился в внешние сроки.

Размер контекстного окна — это не то же самое, что качество контекстного окна

Утверждение о том, что контекстное окно может охватывать 2 миллиона токенов, если оно подтвердится, станет значимым инженерным достижением. Но размер контекстного окна и качество контекстного окна — это две разные характеристики, и независимые исследования неизменно показывают, что разница между ними велика.

[Исследование Context Rot, проведенное компанией Chroma в 2025 году](#), в ходе которого были протестированы 18 передовых моделей, показало, что качество работы каждой модели ухудшается по мере увеличения объема контекста — без исключений — и что самое резкое ухудшение часто происходит задолго до достижения заявленного потолка. Эта закономерность также описана в научной литературе: исследование «Lost in the Middle» показало, что при выполнении задач с большим объемом контекста результаты часто оказывались значительно хуже, если релевантная информация появлялась в середине текста, а не в начале или в конце. Gemini 3.1 Pro уже демонстрирует эту закономерность на практике: он поставляется с окном в 1 миллион токенов, но независимые тесты показали, что качество воспроизведения контекста в нескольких диапазонах резко падает после 128 тысяч токенов и составляет примерно 26 % при полном диапазоне в 1 миллион токенов. Разработчикам следует в первую очередь проверить, улучшилось ли качество воспроизведения контекста в модели 3.5 Pro, а не только размер окна.

Третья задержка: галлюцинации и проблемы с надёжностью

Самое значительное обновление на сегодняшний день — это третья задержка, о которой стало известно. В среду, 15 июля, издание Geeky Gadgets со ссылкой на World of AI сообщило, что Gemini 3.5 Pro не смог сравняться с GPT-5.6 в ключевых бенчмарках. Среди конкретных проблем — частые «галлюцинации» в сгенерированных результатах и нестабильная производительность в реальных рабочих процессах. Это не те проблемы, которые привели к первому решению о перевыпуске, — проблемы с SVG и рекурсивным вызовом

недостаточной надежностью в реальных условиях, — которые препятствуют ее запуску.

В том же отчете отмечается, что Google DeepMind зарегистрировала названия моделей, в том числе Gemini 3.6 Flash и Gemini 3.5 Flash Light, что позволяет предположить, что компания готовит промежуточные релизы, призванные выиграть время для дальнейшей разработки Pro. Это не подтвержденные релизы — регистрация названий моделей часто происходит за несколько месяцев до выхода продукта, а иногда и вовсе отражает отмененные направления. Но за этой тенденцией стоит понаблюдать: если промежуточный вариант Flash выйдет раньше Pro, это будет означать, что Google смирилась с более длительными сроками выпуска своего флагмана и пытается сократить отставание от конкурентов с помощью релиза, который действительно может выйти.

Согласно анализу Geeky Gadgets, компания может вообще отказаться от выпуска поколения 3.5 Pro и сосредоточить ресурсы на Gemini 4.0 Flash. Это был бы необычный шаг для компании, которая публично анонсировала модель и назвала сроки ее выпуска на уровне генерального директора, но такое случается в отрасли, где из-за конкуренции выход продукта на несколько месяцев позже может восприниматься как возвращение в прошлое.

Конкуренты уже в деле

С июня конкурентная среда значительно ужесточилась. Claude Fable 5 был запущен 1 июля после снятия ограничений на экспорт. GPT-5.6 стал общедоступным 9 июля в ChatGPT, Codex и API OpenAI в трех тарифных планах: Sol — 5 долларов за миллион входных токенов и 30 долларов за миллион выходных токенов, Terra — 2,50 доллара и 15 долларов, Luna — 1 доллар и 6 долларов. Все три уровня имеют общее контекстное окно в 1,05 миллиона токенов. OpenAI подтвердила, что Sol устанавливает новый уровень в Terminal-Bench 2.1, согласно [объявлению о запуске от 9 июля](#).

Grok 4.5 от SpaceXAI (объединенной компании xAI и SpaceX) был запущен 8 июля, согласно [странице запуска Grok 4.5 от SpaceXAI](#). Его стоимость составляет 2 доллара за миллион входных токенов и 6 долларов за миллион выходных токенов. Он основан на том, что Илон Маск назвал базой V9 с 1,5 триллионами параметров, хотя в собственной документации SpaceXAI количество параметров не указано, и эту цифру следует воспринимать как заявление Маска, а не как подтвержденную информацию. Модель была обучена совместно с данными о сессиях разработчиков из Cursor — редактора кода, который SpaceX согласилась приобрести в июне 2026 года. Модель ориентирована на агентное кодирование. Независимая организация по тестированию искусственного интеллекта Artificial Analysis на момент запуска поставила Grok 4.5 на четвертое место в своём рейтинге Intelligence Index.

Таким образом, Google остается единственной крупной передовой лабораторией, у которой к обещанному ее генеральным директором сроку — 2026 году — не будет флагманской модели в серийном производстве.

Рынки прогнозов отражают накопившийся скептицизм

Рынки прогнозов восприняли третий сигнал о задержке. Согласно последним доступным данным, на рынке [прогнозов Gemini Pro от Polymarket](#) «Новый флагманский продукт Gemini» с объемом торгов более 323 000 долларов США имеет 81% вероятности того, что доставка состоится 31 июля. Отдельный график "Следующая модель Google Gemini Pro, выпущенная" показывает, что "7 августа" лидирует с 73%, что отражает растущую уверенность рынка в том, что ни 17, ни 24 июля запуск не состоится.

Это рынки финансовых убеждений, а не опросы. Трейдеры, покупающие "7 августа", делают на это ставку реальными деньгами.

Flash справляется с производственными нагрузками

Пока идет перестройка Pro, Gemini 3.5 Flash справляется с производственными нагрузками с момента своего запуска 19 мая. Google подтвердила результаты тестирования производительности Flash в [официальном посте о запуске Gemini 3.5](#): 76.2 % на Terminal-Bench 2.1, 83,6 % на MCP Atlas и 84,2 % на CharXiv Reasoning — по всем трем показателям модель превосходит Gemini 3.1 Pro — и при этом работает в четыре раза быстрее, чем сопоставимые передовые модели, с затратами 1,50 доллара за миллион входных токенов и 9 долларов за миллион выходных токенов. Flash создан для оптимизированного по скорости выполнения больших объемов задач: циклов агентов, пропускной способности при генерации кода и цепочек задач, выполняемых за доли секунды, что требуется для корпоративных инструментов. Роль Pro, когда бы она ни появилась, заключается в выполнении сложной работы, требующей более длинных цепочек умозаключений: многофайловой модификации кода, анализа документов с большим контекстом и сложных логических задач, от которых намеренно отказывается оптимизированная для скорости архитектура Flash.

Подробнее: [Gemini 3.5 Pro выйдет 17 июля, а крайний срок перехода на DeepSeek — 24 июля — уже на пороге](#)

Крайний срок перехода на DeepSeek — 24 июля — не может ждать Gemini

Единственное решение, которое разработчики не могут отложить до выхода новой версии от Google, — это миграция на DeepSeek API. Устаревшие псевдонимы моделей `deepseek-chat` и `deepseek-reasoner` перестанут работать 24 июля, и никаких отсрочек не предусмотрено. Командам, использующим эти псевдонимы, необходимо до этой даты перейти на `deepseek-v4-pro` или `deepseek-v4-flash` — для этого нужно изменить всего один параметр в существующем коде.

Одно замечание для команд, рассматривающих DeepSeek V4 в качестве долгосрочного решения: штаб-квартира DeepSeek находится в Китае, и компания подчиняется китайскому Закону о национальной разведке (2017), который требует от всех организаций и граждан сотрудничать с органами национальной разведки по первому требованию. Это юридическое обязательство действует независимо от того, где находятся серверы компании и

пользовательской информации.

Что разработчикам нужно сделать до понедельника

Для команд, которые строили планы на основе релиза Gemini 3.5 Pro 17 июля, ситуация такая же, как и в июне: модель может выйти в любой момент, но не стоит воспринимать ее как жесткую зависимость. Официальным сигналом к отслеживанию остается **gemini-3.5-pro** появление общедоступной модели в публичной документации по API Gemini. Регистрация названия модели, утечки и неназванные внутренние источники не являются признаками релиза.

Разработчикам Vertex AI, которым нужны возможности уровня Pro, следует уточнить у своего менеджера по работе с аккаунтами Google, как получить доступ к предварительной версии для корпоративных пользователей. Для команд, чьи рабочие нагрузки укладываются в контекст 1 миллиона токенов, производственными вариантами на сегодняшний день являются Gemini 3.5 Flash, GPT-5.6 Terra или Claude Fable 5.

Что касается DeepSeek, то миграцию необходимо завершить до 24 июля, независимо от действий Google.

Google's Strategic Position

Beyond the near-term timing, the broader question now is whether Google's distribution advantage — Search, Android, Workspace, Vertex AI — can bridge the gap created by three consecutive missed deadlines in a product category where developers are standardizing their stacks in real time. Google does not need to top every benchmark to capture a large share of enterprise API spend. But it does need to ship a model that is reliably good enough at a defensible price point — and it needs to ship it before the teams currently evaluating their options have made decisions they are unlikely to revisit before the end of the year.

time for OpenAI. Nobel laureate John Jumper, who contributed to AlphaFold, joined Anthropic the following day. Jonas Adler, who worked on Google's AI coding efforts, and Alexander Pritzel, a pretraining specialist, also left for Anthropic within the same week. [Alphabet's stock fell roughly 5-7%](#) in the aftermath, wiping an estimated \$225 billion in market capitalization. DeepMind CEO Demis Hassabis said at Cannes that Google has "by far the biggest and broadest research bench of any of the labs out there." He is not wrong on headcount. The question is whether headcount is what determines who ships first.

The rebuild decision — if the reporting holds — remains the most significant data point in this story regardless of the launch date. It tells developers that Google's internal evaluation concluded the competitive gap was real enough to justify a costly intervention. Whether that intervention produced a model that closes the gap against GPT-5.6 Sol and Fable 5 is a question only the official model card and independent benchmarking can answer.

Frequently Asked Questions

Has Gemini 3.5 Pro launched as of today, July 16?

No. As of today, Gemini 3.5 Pro is not listed as a generally available model in the public Gemini API documentation. The API currently lists [gemini-3.5-flash](#) and [gemini-3.1-pro-preview](#). A limited enterprise preview has been running on Vertex AI. The July 17 date was a widely reported target from leaks and unnamed internal sources, not an official Google announcement — and reporting from July 15 suggests the model has encountered a third delay due to hallucinations and reliability gaps.

Why has Gemini 3.5 Pro been delayed three times?

Each delay reflects a different class of problem. The first delay (June to July) was attributed to quality refinements after early enterprise testing, specifically token efficiency, coding performance, and multi-step reasoning. The second delay (the pre-training restart) was more fundamental: Google reportedly concluded that the original model had structural failures in recursive tool-calling and SVG generation that couldn't be fixed through fine-tuning alone, and ordered a ground-up rebuild. The third delay, reported July 15, appears to reflect that even the rebuilt model has not cleared hallucination rates and real-world reliability standards to match GPT-5.6. Each represents a genuine engineering challenge, not a scheduling error.

How does the reported \$15 per million input tokens pricing compare to competitors already shipping?

The \$15/\$60 per million input/output token figure for Gemini 3.5 Pro remains unconfirmed by Google and should be treated as a third-party estimate. For context: GPT-5.6 Sol (OpenAI's flagship, currently in production) costs \$5 per million input tokens and \$30 per million output tokens. Claude Fable 5 (Anthropic's current top tier) is priced above that range.

above all current production competitors — a premium that would require strong benchmark differentiation to justify, particularly given that GPT-5.6 Sol launched at \$5/\$30 with competitive coding benchmark scores.

What is the one deadline developers cannot ignore regardless of when Gemini 3.5 Pro ships?

July 24. DeepSeek’s legacy API aliases — [deepseek-chat](#) and [deepseek-reasoner](#) — stop responding at 15:59 UTC on July 24, with no announced extension. Any team calling either alias in production needs to migrate to [deepseek-v4-pro](#) or [deepseek-v4-flash](#) before that date. The change is a single parameter swap in existing code. This deadline is firm and independent of anything Google does.

© 2026 TECHTIMES.com All rights reserved. Do not reproduce without permission.

Tags: [Google Deepmind](#) [AI](#) [Google](#) [OpenAI](#) [Artificial Intelligence](#)

Tech Times

Find the latest tech news!
