



← Опубликовать пост



@willdepue

«Звездные врата» для Data Labs к 2030 году будут тратить на данные более 100 миллиардов долларов в год. Приступая к вычислительному проекту стоимостью в триллион долларов, мы должны подумать о том, какие усилия цивилизационного масштаба потребуются для другого ключевого компонента — данных. В основе революции масштабирования лежит простой эмпирический закон: качество работы глубоких нейронных сетей плавно, почти волшебным образом улучшается по мере пропорционального масштабирования двух параметров: (1) размера модели и (2) объема данных, на которых она обучается. И несмотря на то, что законы масштабирования неумолимо приближают нас к пределу, мы успешно преодолели трудности логарифмического масштабирования с экспоненциально растущими кластерами и наборами данных и взамен получили невероятные новые возможности. Но экспоненциальное масштабирование неизбежно достигнет определенных пределов. Как ни странно, вычислительные мощности росли довольно плавно и без ограничений, а в создание гиперкластеров вкладывались триллионы. Однако сейчас мы сталкиваемся с экспоненциальным ростом спроса на данные. Прошли те времена, когда мы работали в режиме, ограниченном вычислительными мощностями, когда у нас были практически бесконечные интернет-данные, но не хватало графических процессоров. Теперь мы вступаем в режим, ограниченный данными. К счастью, это ограничение совпадает по времени с ошеломляющим прогрессом в возможностях искусственного интеллекта. Невероятно, но, похоже, у нас есть реальный шанс автоматизировать большую часть интеллектуальной работы с помощью имеющихся у нас сегодня методов. Обучение с подкреплением + предварительное обучение и данные для каждого из этих методов в целом будут достаточны для решения большинства экономически значимых задач при условии некоторого минимального прогресса в алгоритмах и дальнейшего масштабирования вычислительных мощностей. В мире, где объем данных ограничен, экономический прогресс и ускорение научных исследований будут напрямую зависеть от нашего охвата в каждой области. Мы должны рассматривать сбор данных как насущную необходимость, достойную тех же цивилизационных амбиций, которые мы приложили к вычислительной технике. Интернет как единовременная субсидия Недооценено то, насколько прогресс в области искусственного интеллекта обязан интернету — этой единовременной цивилизационной субсидии для глубокого обучения, десятилетиям непреднамеренного накопления идеального набора данных: каждой книге, посту в блоге, изображению, видео, статье, обсуждению и т. д. Все оцифровано и находится в свободном доступе. Без интернета мы, скорее всего, не добились бы такого прогресса в области искусственного интеллекта. На самом деле, если вы обратите внимание на то, где системы в настоящее время работают хуже всего, то почти всегда это будет сфера, где покрытие интернетом ограничено, а данные являются частными, дорогими, не оцифрованными или вовсе

Don't miss what's happening

Пользователи X узнают обо всем первыми.

[Войти](#)

[Зарегистрироваться](#)

удовлетворить потребности масштабирования. Вскоре мы достигнем предела возможностей использования общедоступных данных для предварительного обучения. И хотя появление обучения с подкреплением дало нам отсрочку — для обучения с подкреплением, основанного на цепочке рассуждений, требовались новые формы неизведанных данных, а также оцениваемые математические задачи и задания по программированию, которые также доступны в интернете, — мы быстро исчерпаем и сложные задачи для обучения с подкреплением. Зачем нам вообще нужно столько данных? Люди обучаются гораздо быстрее, им достаточно одного учебника, в то время как языковым моделям для изучения новой темы могут потребоваться сотни. Возможно, мы откроем методы, которые будут гораздо эффективнее использовать данные — синтетические данные, архитектуры, оптимизированные для работы с данными, другие экзотические алгоритмы, — но фундаментальный прогресс идет медленно и крайне непредсказуемо, а наш нынешний подход просто работает. И хотя я не хочу углубляться в эту тему, даже произвольная оптимизация использования данных не может заменить данные, которых просто не существует. В сети огромное количество недостающей информации: темная материя интернета — неявные знания, недокументированные процессы и т. д. — большая часть из них никогда не публиковалась и существует только внутри организаций, в физическом мире или просто в головах людей. Я оставляю это здесь и скажу, что по причинам, которые я не смогу изложить в этом посте [1], лучше исходить из того, что наше ненасытное стремление к данным останется таким же, как в последнее десятилетие. К 2030 году расходы на данные превысят 100 миллиардов долларов в год. Конечно, мы еще не обречены. Лишь малая часть полезных данных в мире находится в открытом доступе в интернете, остальное хранится в частных базах данных, корпорациях, личных архивах, университетах, государственных органах и т. д. Лаборатории могут и будут продолжать лицензировать эти частные базы данных или создавать их с нуля, как, например, проект Anthropic по сканированию книг. Мы будем все чаще поручать экспертам создавать новые высококачественные данные, и уже сейчас большая часть сложных задач для обучения с подкреплением решается именно таким образом. Но сбор этих данных, в отличие от прежних времен, будет стоить дорого. По мере того как бесплатный интернет становится все менее доступным, а спрос на данные растет, мы должны увидеть, что лаборатории будут инвестировать в данные столько же, сколько и в вычислительные ресурсы, и, вероятно, тратить значительную часть своих вычислительных бюджетов на данные. Учитывая, что на вычислительные ресурсы тратятся триллионы долларов, можно ожидать, что на данные (человеческие данные и бюджеты на их сбор) будут тратиться сотни миллиардов, учитывая их равнозначную важность. Примечательно, что расходы на данные уже растут в этом направлении: общие расходы на данные у всех поставщиков, не считая внутренних ресурсов лабораторий, уже составляют примерно 7 миллиардов долларов в год. Вполне вероятно, что к 2030 году мы увидим рост более чем в 10 раз. Данные — это ров. Данные, становящиеся все более частными, также существенно изменят конкурентную среду. В то время как вычислительные системы являются товаром — все покупают одни и те же чипы и создают одни и те же кластеры, — данные на самом деле таковыми не являются. Основная причина, по которой модели

По мере того, как лаборатории переходят к более эксклюзивным корпусам, собранным вручную, я думаю, что модели начнут все больше расходиться. То, что OpenAI опережает Anthropic в математике, а Anthropic — в кибербезопасности, не случайно. Я действительно считаю, что видимый прогресс за последний год во многом обусловлен целенаправленным сбором высококачественных токенов для среднего обучения, пользовательских задач в области обучения с подкреплением, сред и целенаправленными исследованиями. У Джеймса Беткера есть отличный блог о том, что «главное в модели — это набор данных»: архитектура модели и вычислительные ресурсы обеспечивают эффективность и производительность на порядок выше, но, в конечном счете, модели любой архитектуры настолько точно аппроксимируют свой набор данных, что суть модели сводится именно к этому и ни к чему другому. Данные — это серьезное конкурентное преимущество. AGI — лонг, ASI — шорт. Как я уже писал в Твиттере, я уверен, что, несмотря на сложившееся мнение, индустрия разметки данных продолжит приносить прибыль крупным компаниям и станет отличным примером того, как AGI — лонг, а ASI — шорт. Аргумент прост: к тому времени, когда лабораториям AGI больше не будут нужны данные, вероятно, все остальное тоже прекратит свое существование [2]. В таком случае последними должны уйти компании, работающие с данными, поскольку они поглотят последние крупницы экономически значимых данных. И эти компании уже входят в число самых быстрорастущих в истории: по слухам, выручка Mercor, основанной три года назад, составляет 2 миллиарда долларов, а по контракту с ней работают несколько миллионов специалистов по маркировке. Несмотря на то, что эти отрасли очень нестабильны и потребность в тех или иных данных постоянно меняется, я не думаю, что это умаляет их ценность. «Длинный хвост» экономики очень длинный, и ценность не уменьшается по мере того, как вы углубляетесь в более малоизвестную информацию: по мере того, как модели становятся все более функциональными, ценность маргинальных наборов данных возрастает, а не снижается. Автоматизация всей работы означает охват всех задач, инструментов, пограничных случаев и долгосрочных циклов. В этом есть некая логика уплотнительных колец: набор данных, который увеличивает производительность на 1%, может оправдать ранее неоправданные затраты на сбор данных, если это разница между системой, которая выполняет 99% работы, и системой, которая выполняет ее полностью [3]. Конкурентная динамика в индустрии данных все еще развивается, но по мере того, как спрос на данные становится все более нишевым, а сами данные — все более высококачественными и генерируемыми экспертами, я думаю, мы увидим настоящую консолидацию. Опять же, вопреки распространенному мнению, мы, вероятно, увидим настоящую конкурентную дифференциацию, основанную на бренде, контроле качества данных (которое, исходя из личного опыта, может сильно варьироваться), а также на сетевых эффектах, возникающих со временем в самих профессиональных сообществах. Мы уже видели, как быстро меняющийся спрос на определенные типы данных сыграл на руку старожилам рынка, принес пользу тем, кто заранее знал, куда движется рынок. Ограничение на связывание. Удивительно, что у нас, похоже, есть рецепт — предварительное обучение + обучение с подкреплением — для решения большинства экономически значимых задач, несмотря на то, что он далек от того, что мы ожидали от «искусственного общего интеллекта». Точно

экономики (в том числе физическая, которая отстает всего на ~3 года!) устроены одинаково. Если появится рекурсивное самосовершенствование или какой-то другой алгоритмический прорыв, это будет замечательно, но нам не обязательно его ждать. Главное препятствие на пути к автоматизированной экономике — это охват данных: каждое приложение, рабочий процесс, пограничный случай, процесс и т. д. хранятся в частных хранилищах или в чьей-то голове. В конечном счете, несмотря на то, что мы добиваемся огромных успехов в создании более эффективных моделей, а такие кластеры, как Stargate, обеспечивают нас вычислениями в масштабе зеттафлопс, мы не так быстро продвигаемся в сборе недостающих данных. Скоро мы будем жить в мире, где у нас будут методы и вычислительные мощности для ускорения научного прогресса или экономического роста, но не будет данных. И мы уже на этом этапе: передовые модели, несомненно, были бы так же хороши в бухгалтерском учете, решении многих медицинских задач и юридических консультациях, как и в разработке программного обеспечения, если бы у нас было такое же покрытие для предварительного обучения и обучения с подкреплением, как для кода. Я действительно хочу заострить на этом внимание: скорость, с которой мы автоматизируем экономику, будет напрямую зависеть от нашей способности собирать данные о ней. Стоит отметить, что при таком подходе, когда данные являются защищенным активом и напрямую связаны с экономическим и научным прогрессом, их также следует рассматривать как национальный стратегический актив, наравне с вычислительными мощностями. Представьте, что бы мы делали в мире, где у нас был бы аналог «Манхэттенского проекта» в области искусственного интеллекта и нам пришлось бы мобилизовать усилия по сбору данных, поскольку это был бы ограничивающий фактор. Нам стоит опасаться, что Китай, обладающий большими государственными возможностями и авторитарным экономическим контролем, способен мобилизовать усилия по сбору данных в национальном масштабе, что в перспективе может привести к более быстрому росту его экономики и научных достижений по сравнению с нами. Звездные врата для данных Я оставляю свои идеи для будущего поста, так как этот и так слишком длинный, но мне бы очень хотелось задать вопрос здесь. Проект «Звездные врата» существует, потому что мы вложили триллионы долларов, международную стратегию и гигаватты в вычислительные мощности как в фундаментальный компонент. Как бы выглядели аналогичные амбиции в отношении данных? Очевидно, что масштабирование сбора данных, разнородной массы информации по всей экономике, не будет таким же простым, как масштабирование вычислительных мощностей, как однородная инфраструктурная задача. Во-первых, это будет основное направление — охват всех неописанных знаний в экономике, науке, физике и во всем, что просто не зафиксировано, — и, во-вторых, увеличение объема данных в тех областях, которые мы уже изучаем: больше сложных математических задач, больше высококачественных веб-текстов, гораздо больше данных о программировании, больше юридических документов и т. д. Скоро я опубликую пост, в котором подробно изложу свои предложения. Здесь есть много возможностей для творчества. Если вкратце, то, вероятно, нам стоит начать с тщательного анализа того, что у нас есть и чего нам не хватает, спрогнозировать, в чем модель 2030 года все еще будет несовершенна, и отталкиваясь от этого решить, что нам следует собирать уже

Don't miss what's happening

Пользователи X узнают обо всем первыми.

[Войти](#)

[Зарегистрироваться](#)

фирмами носит состязательный характер, поэтому для того, чтобы сделать это правильно, требуется много инженерных решений. Нам нужно убедить крупные компании отказаться от политики удаления данных, даже если мы пока не покупаем у них продукцию. Маховик данных в потребительских товарах будет огромным. Конфиденциальное обучение, государственное регулирование исследований, финансируемых за счет грантов, вынужденное предоставление компаниям данных в обмен на прибыль и т. д. Мы движемся к сотням миллиардов долларов расходов, национальному приоритету и серьезным ограничениям в работе с данными. У нас есть прекрасная возможность творчески подойти к вопросу о том, как мог бы выглядеть мегапроект в сфере данных: как нам, на этот раз целенаправленно, создать новый объем данных, достойный интернета? Сноски: [1]: Вероятно, вскоре я опубликую гораздо более подробный пост, в котором объясню свою позицию по поводу эффективности данных и объясню, почему ценность этих данных в большинстве миров по-прежнему довольно высока, несмотря на появление новых алгоритмов. [2]: Ставка на «свободный полет» искусственного интеллекта: если выпадет «орел», вы выиграете, а если «решка», то искусственный интеллект все равно перевернет мир с ног на голову. [3]: Мы уже видим подтверждение этой точки зрения, учитывая, что рынок данных все больше ориентируется на сверхкачественные агентные данные, а не на неквалифицированную разметку — нишевые экспертные рабочие процессы, работу в реальных условиях и оценку, требующую все более редких навыков и знаний, — но при этом демонстрирует рост, а не снижение доходов.

17:07 · 6 июл. 2026 г. · **853,8 тыс.** Просмотры

 110

 128

 1 тыс.

 2 тыс.



Читать 110 ответов

Don't miss what's happening

Пользователи X узнают обо всем первыми.

Войти

Зарегистрироваться