

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

ИИ чаще, чем люди, допускает предвзятость при найме сотрудников

ИИ не просто усваивает стереотипы в процессе обучения. Он может создавать и новые.

By Michelle Kim

July 20, 2026



СТЕФАНИ АРНЕТТ/MIT TECHNOLOGY REVIEW | ADOBE STOCK

КРАТКОЕ ИЗЛОЖЕНИЕ 

В следующий раз, когда вы будете устраиваться на работу, искусственный интеллект может просмотреть ваше резюме до того, как его увидит человек. Но есть веские основания сомневаться в том, что ИИ будет судить вас беспристрастно. Исследователи уже знают, что большие языковые модели перенимают человеческие предубеждения из обучающих данных. Новое исследование показывает, что большие языковые модели могут вырабатывать собственные предубеждения на основе опыта и стереотипизировать соискателей работы в большей степени, чем это делают люди. Поскольку компании, работающие в сфере ИИ, стремятся создавать агентные модели, которые запоминают мельчайшие детали о пользователях, они, возможно, сами подталкивают их к формированию этих предубеждений.

Исследователи из Принстонского и Чикагского университетов протестировали большие языковые модели, в том числе ChatGPT, Claude и Gemini, в смоделированной игре по найму сотрудников, адаптированной на основе психологического исследования, в котором изучалось, как у людей формируются стереотипы. Каждой модели сообщили, что она была нанята мэром вымышленного города в качестве консультанта, а затем попросили помочь нанять людей на 20 вакансий, в том числе врачей, юристов, помощников по уходу за детьми и уборщиков. Кандидаты принадлежали к четырем вымышленным этническим группам: туфа, айма, реку и веки.

MIT Technology Review

подписка

раунду. Модели было дано задание совершить как можно больше успешных наймов за 40 раундов. Модели не знали, что все кандидаты с одинаковой вероятностью справлялись с каждой вакансией.

Модели быстро начали распределять кандидатов из разных групп по разным должностям на основе первых наблюдений за результатами найма. Например, когда модели сообщили, что Aima не справилась с работой врача, которая, как считается, требует высокого уровня эмпатии и компетентности, она перестала нанимать всех Aima на эту должность. Вместо этого она стала нанимать Aima уборщиками, которых модель считала менее эмпатичными и компетентными, чем врачей. Более новые модели с расширенными возможностями логического мышления, такие как o3 от OpenAI и R1 от DeepSeek, демонстрируют более выраженные предубеждения.

СВЯЗАННАЯ ИСТОРИЯ

OpenAI очень популярен в Индии. Его модели проинизаны кастовой предвзятостью.

Модели еще чаще стереотипизируют людей по демографическим группам, чем участники исследования из числа людей. По шкале сегрегации, где 2 означает, что каждая группа полностью ограничена своей профессиональной нишей, участники исследования набрали 0,84 балла. Модели набрали примерно на 65% больше баллов, а модель логического вывода o3 от OpenAI набрала 1,83 балла, что близко к максимально возможному значению.

Это происходит потому, что большие языковые модели «действительно стремятся делать обобщения на основе ограниченных данных», — говорит Райан Лю, аспирант Принстонского университета и соавтор исследования, опубликованного в [статье](#) на конференции ICML в Сеуле в июле. — «Это буквально то, для чего они оптимизированы».

➔ [Subscribe](#) to access the latest news, trends, and insights in AI, climate, and biotech. Plus, get bonus AI content.

Каждый человек, принимающий решения, будь то человек или машина, сталкивается с дилеммой: придерживаться того, что работало раньше, или попробовать что-то новое, что может сработать лучше. Психологи называют это явление «дилеммой исследования и эксплуатации». Это как выбирать между новым рестораном и вашим любимым проверенным заведением.

Поскольку большие языковые модели обучаются на задачах по математике, программированию и естественным наукам — то есть на задачах, которые вознаграждают за обобщение на основе всего нескольких примеров, — они могут слишком рано положиться на интуицию. Тот же инстинкт, который помогает большим языковым моделям решать логические задачи, заставляет их быстро прибегать к стереотипам. Когда большие языковые модели спешат с обобщениями в социальной сфере, «вот тогда-то все и идет не так», — говорит Лю. OpenAI и Anthropic не ответили на запросы о комментарии.

Это открытие особенно актуально сейчас, когда у чат-ботов улучшаются функции памяти и персонализации, говорит Анджелина Ванг, специалист по информатике из Корнеллского университета, которая не принимала участия в исследовании. По ее словам, когда чат-бот опирается на историю предыдущих диалогов, он может «заикликоваться на тех же моделях поведения, с которыми сталкивался раньше», и формировать предубеждения.


Simply having chatbots remember less isn't a fix, though, because users want chatbots to remember what they say. "We still are trying to figure out just the right amount that isn't too much or too little," says Wang.

Telling the model to be fair didn't change its behavior much. "Either it can't put these values into action or that process is being submerged under the tendency to try to optimize for the goal of getting the most correct hires," says Liu. But promising the models an additional bonus for diverse hiring made them far less biased. The trick, then, is to design goals that "incorporate desirable social values in order to make the large language model act in socially desirable ways," says Liu.

The models also became less biased when they were told more personal information about individuals. In another experiment in the same study, the researchers asked the models to resettle members of different ethnic groups in cities across Canada. When the models were told personal information relevant to the ability to adapt to a new city, such as age and education, they were less likely to segregate people by their ethnicity. But when they were given irrelevant information, such as hair color and tattoo shape, the models largely fell back to sorting people by their ethnicity again.

To what extent AI systems will stereotype job applicants in the real world is still an open question. While the models in the experiment immediately learned whether they'd made successful hires, a model screening résumés in the real world doesn't get an instant report card. Companies can take a long time to find out whether a new hire is any good, if they ever do.

But when feedback does trickle in, a model could still read too much into those results when making future hires. As companies increasingly deploy LLMs to [screen résumés](#) and even [conduct interviews](#), the finding that models can form biases from their hiring experience "is a really serious implication that they should grapple with," says Wang.



Unlimited access + bonus AI content

Subscribe to stay informed on the latest innovations, trends, and analysis across AI, climate, and biotech.

CLAIM OFFER

DEEP DIVE

ARTIFICIAL INTELLIGENCE

A startup claims it broke through a bottleneck that's holding back LLMs

Subquadratic has now shared more details about its new model. But some are still skeptical.

< >
By Will Douglas Heaven

A fundamental flaw leaves LLMs strikingly vulnerable to attack

It makes it easy to trick them into doing things they shouldn't, such as telling you how to sabotage an aircraft's navigation system.

By Will Douglas Heaven

Anthropic found a hidden space where Claude puzzles over complex problems

A new technique has let the company probe deeper than ever into the workings of an LLM.

By Will Douglas Heaven

STAY CONNECTED

MIT Technology Review

подписка

Get the latest updates from MIT Technology Review

Discover special offers, top stories, upcoming events, and more.

Enter your email



[Privacy Policy](#)

The latest iteration of a legacy

Founded at the Massachusetts Institute of Technology in 1899, MIT Technology Review is a world-renowned, independent media company whose insight, analysis, reviews, interviews and live events explain the newest technologies and their commercial, social and political impact.

[READ ABOUT OUR HISTORY](#)

Advertise with MIT Technology Review

Elevate your brand to the forefront of conversation around emerging technologies that are radically transforming business. From event sponsorships to custom content to visually arresting video storytelling, advertising with MIT Technology Review creates opportunities for your brand to resonate with an unmatched audience of technology and business elite.

[ADVERTISE WITH US](#)

[About us](#)

[Careers](#)

[Custom content](#)

[Advertise with us](#)

[International Editions](#)

[Republishing](#)

[MIT Alumni News](#)

[Help & FAQ](#)

[My subscription](#)

[Editorial guidelines](#)

[Privacy policy](#)

[Terms of Service](#)

[Write for us](#)

MIT Technology Review

подписка



