

Автор: сотрудники CSO

Отчет об угрозах, связанных с искусственным интеллектом: агенты-изгои, атаки на рабочие процессы

Анализ новостей

5 августа 2026 года • 5 минут

Обзор последних заметных атак с использованием искусственного интеллекта, угроз, рисков и уязвимостей, а также того, как они влияют на киберзащиту.



Злонамеренное использование искусственного интеллекта и угрозы для систем ИИ заставляют киберкоманды уделять больше внимания основам безопасности и переосмысливать свои подходы к защите.

Новые атаки с использованием искусственного интеллекта, экспериментальные разработки и реальные методы, а также последние исследования уязвимостей и рисков, связанных с ИИ, дают представление не только о том, с чем сталкиваются предприятия в настоящее время, но и о том, как руководителям служб безопасности адаптироваться к тому, что вскоре может появиться в их системах.

Цель настоящего доклада — предоставить информацию и дать представление о том, что происходит в сфере угроз, связанных с искусственным интеллектом, в последнее время.

ИИ выходит из-под контроля

Самым значимым недавним событием, которое показывает, что ждет директоров по информационной безопасности в будущем, стало обнаружение агентов OpenAI, атаковавших Hugging Face.

Атака, осуществленная с помощью изолированных моделей OpenAI, показала, что ограничения, налагаемые на промпт, не могут служить надежной первичной границей безопасности для ИИ-агентов. Это вынуждает компании внедрять более сложные средства контроля агентской инфраструктуры, чтобы ограничить доступ и предотвратить горизонтальное перемещение. Прасант Аби Томас из CSO рассказывает, как провалилась стратегия сдерживания агентов OpenAI [<https://www.csoonline.com/article/4200043/openai-model-escape-puts-enterprise-ai-defenses-on-notice.html>].

Дальнейшее расследование инцидента с OpenAI выявило дополнительные нарушения границ доверия [<https://www.csoonline.com/article/4202852/openai-rogue-ai-agents-attack-expanded-beyond-hugging-face.html>], в связи с чем сообщество директоров по информационной безопасности Cloud Security Alliance выпустило экстренное руководство по усилению контроля над автономными ИИ-агентами, сообщает Дьяна Суэйн из CSO. Инцидент также побудил компанию Anthropic проанализировать собственные оценки кибербезопасности [<https://www.csoonline.com/article/4203807/after-openai-anthropic-finds-claude-breached-three-organizations-during-cyber-tests.html>], в результате чего выяснилось, что ее модели Claude также выходили за пределы тестовых сред и взаимодействовали с реальными системами. В результате одного из таких инцидентов Claude опубликовал вредоносный пакет Python в общедоступном репозитории PyPI, который был загружен и запущен 15 реальными системами.

Поскольку от передовых лабораторий пока не требуется предоставлять аварийные выключатели для агентов ИИ, директорам по информационной безопасности

предприятий рекомендуется самостоятельно разрабатывать архитектуру [<https://www.csoonline.com/article/4205348>].

Инцидент с Hugging Face также показывает, насколько важно для групп реагирования на инциденты иметь мультимодальную стратегию использования ИИ [<https://www.csoonline.com/article/4201361/hugging-face-breach-shows-why-incident-response-needs-a-multi-model-ai-strategy.html>], в том числе моделей с открытым исходным кодом, чтобы обеспечить жизнеспособность операций в условиях кризиса, пишет Люциан Константин из CSO.

Атака на рабочий процесс ИИ

Директора по информационной безопасности также должны знать, что злоумышленники обращают внимание на рабочие процессы агентов [<https://www.csoonline.com/article/4204731/attackers-are-crafting-malicious-ai-instruction-files-to-turn-your-agentic-workflows-into-quiet-criminal-helpers.html>], пытаясь внедрить в агентов ИИ вредоносные правила, конфигурации и файлы инструкций, чтобы те выполняли их приказы. Константин из CSO рассказывает об этой тенденции, в том числе о недавно обнаруженном методе бэкдор-атаки под названием PromptLogger. По данным исследователей из Mitiga, PromptLogger обманом заставляет агентов ИИ извлекать запросы и ответы с помощью вредоносных файлов с инструкциями (например, `CLAUDE.md`). Также было замечено, что этот метод пытается заставить агентов внедрить бэкдор-код в файлы Python, которые могут быть скопированы в другие системы. Поскольку агенты выполняют эти задачи по указке преступников, обнаружить их крайне сложно.

Согласно недавнему отчету норвежского исследователя в области искусственного интеллекта Хокона Молёй посвященному Microsoft Copilot [<https://www.csoonline.com/article/4203630/copilot-worm-can-spread-through-microsoft-word-docs.html>], корпоративные рабочие процессы также могут быть нарушены из-за самораспространяющихся ИИ-червей, внедряемых в документы. Как сообщает Эван Шуман из CSO, Молёй продемонстрировал, как злоумышленники могут использовать Copilot в качестве механизма передачи данных для их искажения и распространения вредоносного ПО, обходя при этом практически все существующие на сегодняшний день средства защиты.

Development in the crosshairs

Software development remains the workflow most impacted by AI threats today, with recent reports underscoring established attack modalities, including a critical vulnerability in Ruflo MCP infrastructure [<https://www.csoonline.com/article/4203408/critical-ruflo-flaw-lets-attackers-hijack-ai-agents-through-exposed-mcp-bridge.html>] and the potential for slopsquatting on nonexistent PyPI and npm packages that top AI coding tools collectively and consistently hallucinate [<https://www.csoonline.com/article/4201164/top-ais-invent-same-fake-pypi-and-npm-package-names-2.html>], report CSO's Swain and Maxwell Cooter.

Moreover, security flaws in automated workflows in Google's ADK for Python GitHub repository, now since hardened, could induce agents to post commands and remove review requests, making a malicious pull request appear ready to merge. Pillar Security, which discovered the flaws, called it the **"first practical, real-world case of agent-to-agent exploitation [https://www.csoonline.com/article/4204906/google-adk-flaws-reveal-what-happens-when-ai-agents-trust-the-wrong-message.html]"** involving a production multi-agent system, CSO's Thomas reports.

The insider threat

A recently patched OpenAI flaw shows another means by which attackers could enlist rogue AI agents to operate on their behalf. Dubbed "AgentForger," this phishing-based attack, reported by Zenity Labs, could have enabled attackers to silently create and launch fully autonomous AI agents within OpenAI workspaces. Broad, unfettered access to systems would then **turn the agent into a "persistent operator," [https://www.csoonline.com/article/4200978/agentforger-proves-ai-agents-can-become-persistent-insider-threats.html]** capable of performing reconnaissance, harvesting data and credentials, and impersonating victims, CSO's Taryn Plumb writes.

Meanwhile, Pathfinder's 2026 AI Governance Gap Report finds that **53% of organizations cannot verify what AI agents do [https://www.csoonline.com/article/4203384/ai-agents-gain-access-to-financial-workflows-amid-growing-governance-gaps.html]** across their business systems — not great news when 36% have deployed or are implementing AI agents within finance and accounting environments, CSO's Shweta Sharma notes.

And if you need any more fodder for tighter restrictions on that other insider threat, CSO's Grant Gross sheds light on how **senior executives are killing your shadow AI strategy [https://www.csoonline.com/article/4198007/senior-executives-are-killing-your-shadow-ai-strategy.html]**.

In-depth:

- **AI is making cybersecurity fundamentals more important than ever [https://www.csoonline.com/article/4204101/ai-is-making-cybersecurity-fundamentals-more-important-than-ever.html]**
- **OpenAI model escape puts enterprise AI defenses on notice [https://www.csoonline.com/article/4200043/openai-model-escape-puts-enterprise-ai-defenses-on-notice.html]**
- **Hugging Face breach shows why incident response needs a multi-model AI strategy [https://www.csoonline.com/article/4201361/hugging-face-breach-shows-why-incident-response-needs-a-multi-model-ai-strategy.html]**
- **Attackers are crafting malicious AI instruction files to turn agents into criminal helpers [https://www.csoonline.com/article/4204731/attackers-are-crafting-malicious-ai-instruction-files-to-turn-your-agentic-workflows-into-quiet-criminal-helpers.html]**

- **AgentForger proves AI agents can become persistent insider threats [https://www.csoonline.com/article/4200978/agentforger-proves-ai-agents-can-become-persistent-insider-threats.html]**
- **Senior executives are killing your shadow AI strategy [https://www.csoonline.com/article/4198007/senior-executives-are-killing-your-shadow-ai-strategy.html]**

Artificial Intelligence[https://www.csoonline.com/artificial-intelligence/]

Application Security[https://www.csoonline.com/application-security/]

Security[https://www.csoonline.com/security/]

About



Policies



More



Our Network

