



Автор: Анирбан Гошал
Старший писатель

AMD хочет сделать корпоративный логический вывод дешевле и быстрее с помощью чипов от Taalas

Новости

7 августа 2026 года • 4 минуты

AMD делает ставку на то, что предприятия будут использовать чипы, предназначенные для работы с одной моделью ИИ, по более низкой цене, но, по мнению аналитиков, недостаточная гибкость этой технологии означает, что она подходит только для устоявшихся, высокопроизводительных рабочих нагрузок.



Источник: JHVEPhoto / Shutterstock [<https://enterprise.shutterstock.com/image-photo/austin-texas-usa-march-17-2022-2147037455>]

В то время как компании ищут способы сократить расходы на использование моделей искусственного интеллекта в производственных процессах, AMD делает ставку на то, что не для каждой задачи ИИ нужен энергоёмкий графический процессор общего назначения.

Компания AMD согласилась купить Taalas, канадского разработчика чипов, которые позволяют навсегда встраивать веса обученной ИИ-модели в специализированный кремний, а не загружать их из памяти во время логического вывода, как это делают обычные графические процессоры [<https://www.networkworld.com/article/3966130/what-are-gpus-inside-the-processing-power-behind-ai.html>].

По словам представителей Taalas, их подход сокращает время и энергопотребление, необходимые для перемещения весов модели между памятью и вычислительными блоками, что позволяет ускорить и удешевить процесс.

В результате получается узкоспециализированный процессор логического вывода, оптимизированный для одной модели. Гибкость программируемого оборудования принесена в жертву ради значительно более высокой пропускной способности и энергоэффективности.

Компромиссы в работе

Хотя AMD планирует интегрировать эти чипы в свою дорожную карту **Instinct GPU** [<https://www.amd.com/en/products/accelerators/instinct.html>], ориентированную на решения для логического вывода на системном уровне в центрах обработки данных, аналитики по-

прежнему скептически относятся к тому, что предприятия с готовностью примут оборудование, привязанное к конкретной модели ИИ.

По сути, компании будут покупать и чип, и модель, потому что, в отличие от графических процессоров, которые можно перепрофилировать для работы с разными моделями ИИ с помощью обновлений программного обеспечения, чипы Taalas привязаны к конкретной обученной модели. Это означает, что для поддержки различных задач логического вывода потребуется разное оборудование, сказал **Амит Кумар Джена** [<https://www.linkedin.com/in/znमित/>], менеджер по развитию ИИ в IT-консалтинговой компании Kanerika.

Или, как выразился главный аналитик Forrester **Чарли Дай** [<https://www.forrester.com/analyst-bio/charlie-dai/BIO5344>], «самый большой риск — это негибкость».

По словам Дзя, необходимость менять оборудование для переключения между задачами создаст новые проблемы, связанные с затратами, управлением, планированием мощностей, жизненным циклом и зависимостью от поставщиков, особенно для компаний, работающих с несколькими ИИ-нагрузками.

Манодж Чандра Джа [<https://www.linkedin.com/in/manoj-chandra-jha-b5ab0a13>], главный аналитик Nord-IQ Research, сказал, что риск объединения чипа и модели в один компонент выше, чем может показаться, поскольку «из-за раннего устаревания моделей они становятся неразрывно связаны, поэтому их следует рассматривать как один актив с более коротким сроком службы, а не как два актива с независимой амортизацией».

Компания Taalas утверждает, что может обновить модель, изменив всего два металлических слоя чипа, а не перепроектировать его с нуля, но это касается только чипов, которые еще не покинули завод, а не тех, что уже используются.

Это означает, что предприятиям по-прежнему придется планировать циклы обновления оборудования, измеряемые неделями или месяцами, и использовать программируемые графические процессоры для часто меняющихся рабочих нагрузок, считает **Парикх Джайн** [<https://pareekh.com/about/>], главный аналитик Pareekh Consulting.

По словам Джа, это также означает, что то, что обычно является программным решением, для клиентов Taalas становится вопросом капитальных затрат, поскольку замена или переключение рабочих нагрузок или моделей может потребовать инвестиций в новое оборудование, а не просто обновления программного обеспечения.

Где применим кремний, оптимизированный под конкретную

МОДЕЛЬ

Эти компромиссы значительно сужают круг корпоративных задач, для которых кремний, оптимизированный под конкретную модель, может быть экономически целесообразным.

Dai sees the technology as best suited for mature, predictable inference workloads that run at massive scale and rely on relatively stable AI models, such as customer service automation, fraud detection, industrial computer vision, network operations, edge AI, and embedded copilots.

For CIOs, that effectively limits model-specific silicon to a small subset of enterprise AI deployments, rather than a wholesale replacement for GPU infrastructure, he said. “GPUs will remain the preferred enterprise platform because most enterprises value flexibility, multi-tenancy, and rapid model evolution over maximum efficiency.”

*This article first appeared on **Network World** [<https://www.networkworld.com/article/4206674/ai-md-to-buy-taalas-maker-of-model-specific-ai-chips-for-enterprise-inference.html>].*

Artificial Intelligence[<https://www.cio.com/artificial-intelligence/>]

Data Center Design[<https://www.cio.com/data-center-design/>]

Data Center[<https://www.cio.com/data-center/>]

Sponsored Links

Build, buy, or borrow? A CIO guide to agentic AI strategy

See Why Five9's AI-Powered CX Platform Drives Real Results

From pilots to performance: AI-driven growth with EY Consulting.

The fastest PCs with multi-day battery life for your business.

About



Policies



More



Our Network



FOUNDRY



© 2026 FoundryCo, Inc. All Rights Reserved.