

22 часа назад - Технологии

Специалисты по тестированию безопасности обнаружили новые примеры взлома моделей OpenAI и Anthropic в ходе тестирования




Сэм Сэйбин



Добавьте Axios в Google

Добавьте Axios в список предпочитаемых источников, чтобы видеть больше наших материалов в Google.



Во вторник две независимые компании, занимающиеся тестированием, заявили, что в прошлом месяце они выявили новые случаи, когда [Anthropic](#) и [OpenAI](#) использовали свои самые продвинутые модели для взлома сторонних систем — и иногда им это удавалось.

Почему это важно: эти инциденты дополнили растущий список случаев, когда передовые [ИИ](#)-модели предпринимали несанкционированные действия в отношении людей, организаций и онлайн-сервисов, пытаясь провести оценку кибербезопасности.

Текущая ситуация: Британский институт безопасности искусственного интеллекта, который занимается оценкой передовых систем искусственного интеллекта, [заявил во вторник](#), что зафиксировал 19 попыток Mythos 5 от Anthropic и GPT-5.6 Sol от OpenAI скомпрометировать реальных людей и организации во время тестирования кибербезопасности в прошлом месяце.

- На долю Mythos пришлось 17 действий, а за двумя другими стоял GPT-5.6 Sol. По словам исследователей, все эти действия были связаны с «несколькими повторяющимися моделями поведения», а не представляли собой 19 разных случаев.
- По данным института, во время тестирования модели создавали поддельные аккаунты на GitHub, манипулировали коммиттерами, внедряли подсказки и отправляли вводящие в заблуждение электронные письма.
- GitHub подтвердил, что это нарушило условия предоставления услуг.
- Институт безопасности совместно с GitHub удалил артефакты, оставленные агентом, и уведомил

пользователей GitHub, с которыми взаимодействовала модель.

OpenAI также сообщила во [вторник в своем блоге](#), что ее сторонний партнер по обеспечению безопасности, компания Irregular, выявила случай, когда ее моделям по ошибке предоставили доступ к интернету, и они взломали реальный сайт, название которого совпадало с названием вымышленной компании в смоделированной среде.

- Инцидент с Irregular от OpenAI очень похож на случай с Anthropic, о котором стало известно на прошлой неделе. В заявлении представителя компании говорится, что «независимое тестирование необходимо для понимания того, как ведут себя все более совершенные модели».
- Источник, знакомый с ситуацией, сообщил Axios, что в «песочнице» в этих случаях был доступ к интернету, чтобы специалисты по оценке могли получить реалистичное представление о возможностях модели, но поскольку компании не пришли к единому мнению относительно точных процедур тестирования и мер предосторожности, возникали неясности в том, как каждая из сторон представляла себе проведение таких оценок с доступом к интернету.
- Инцидент произошел во время тестирования с «ослабленными мерами предосторожности в условиях, не соответствующих обычному использованию», — добавил представитель OpenAI.

Увеличить: Во время тестирования на безопасность в Великобритании модели предприняли 19 попыток взлома сторонних ресурсов, в том числе пытались внедрить вредоносный код в проект с открытым исходным кодом и создать поддельные онлайн-идентификаторы в рамках атаки с использованием методов социальной инженерии.

- Британские исследователи намеренно предоставили моделям доступ к интернету и отключили классификаторы кибербезопасности во время тестирования. В институте заявили, что моделям не давали указаний избегать подключения к интернету.
- Исследователи также отметили, что пока неясно, «когда агент понял, что совершает действия в реальном мире, и в какой степени он считал, что находится в вымышленном тестовом сценарии».
- В заявлении Anthropic говорится, что этот инцидент «подчеркивает необходимость более широкого обсуждения того, как безопасно оценивать все более способные ИИ-системы», и что компания «с нетерпением ждет возможности сотрудничать с Управлением по искусственному интеллекту Великобритании, чтобы узнать больше об этом инциденте в ходе нашего собственного расследования.»

The big picture: The cyber capabilities of frontier AI models are catching top researchers off-guard, requiring them to reinvent their security protocols.

- Both [OpenAI](#) and [Anthropic](#) have said in the last month that they've seen their models hacking into real organizations and websites during standard pre-deployment safety testing.

What to watch: The institute is building new network controls for its cyber tests to restrict when agents have access to the internet. It's also rolling out real-time activity monitoring that should detect and block malicious agents before they can interact with outside systems.

- OpenAI also said it's working with Irregular on a white paper about best practices for containing and securing models during testing.

This story has been updated with details throughout.



What to read next

Smarter, faster on what matters.

Explore Axios Newsletters

[About Axios](#)

[Advertise with us](#)

[Careers](#)

[Contact us](#)

[Newsletters](#)

[Axios Entertainment](#)

[Axios Live](#)

[Axios HQ](#)

[Privacy policy](#)

[Terms of use](#)

[Your Privacy Choices](#) 