

Кодирование на б... · [Подписаться на публикацию](#)

★ История только для участников

ИИ +

Искусственный Интеллект +

Наука о данных +

Машинное обучение +

Питон +

Создание модели GLM 5.2 744B на языке C для работы на 25 ГБ оперативной памяти

Квантовать его до int4, запускать экспертов с диска и обслуживать их с одного компьютера

72 мин чтения · 15 июля 2026 года



Фарид Хан

[Подписаться](#)


Слушай



Поделиться

Прочитайте эту статью бесплатно: [ссылка](#)

GLM 5.2 имеет 744 миллиарда параметров параметров, поэтому для каждого токена срабатывают только 8 из 256 экспертов на каждом уровне, а большая часть модели находится в спящем режиме. Если мы будем хранить в памяти небольшую часть, которая всегда активна, и загружать спящих экспертов с диска, рабочий набор останется небольшим, несмотря на то, что модель на диске огромна. Таким образом, он может работать на Mixture of Experts, используя движок, который мы создали с нуля на чистом языке C. ноутбук с 16 гигабайтами оперативной памяти и без графического процессора, используя движок, который мы создали с нуля на чистом языке C.



Архитектура GLM 5.2 на языке C (создано [Фаридом Ханом](#))

Вот все, что мы создали, — в одном файле на языке C, без BLAS и фреймворков, сверху донизу, по одному компоненту за раз:

- **Настройка и сборка:** проверяем коробку и модель, затем компилируем

Чтобы прочитать статью полностью, создайте аккаунт.

Автор сделал эту статью доступной только для участников Medium.

Если вы впервые на Medium, создайте новую учетную запись, чтобы прочитать эту статью.

Продолжить в приложении

Или продолжить в мобильной версии сайта



Зарегистрируйтесь в Google



Зарегистрируйтесь на Facebook



Зарегистрируйтесь по электронной почте

У вас уже есть аккаунт? [Войти](#)



Подписаться

Опубликовано в Level Up Coding

352 тыс. подписчиков · Опубликовано 2 дня назад

Обучающие материалы и новости о программировании. Домашняя страница разработчика gitconnected.com && skilled.dev && levelup.dev



Follow

Автор: Фарид Хан

76 Тысяч подписчиков · 0 подписчиков

Я пишу об искусственном интеллекте, <https://www.linkedin.com/in/fareed-khan-dev/>

