

Кодирование на б... · [Follow publication](#) История только для участников

ИИ +

Искусственный Интеллект +

Наука о данных +

Машинное обучение +

Питон +

Сборка модели Kimi K3 2.8T на языке C для работы с 8 ГБ оперативной памяти

Потоковая передача модели с диска вместо хранения в памяти

94 мин чтения · 4 дня назад



Фарид Хан

Follow



Слушай



Поделиться

Прочитайте эту статью бесплатно: [ссылка](#)

Недавно я развернул Kimi K3 на 32 графических процессорах H100 для своей компании, но кластер есть почти у всех. Kimi K3 имеет 2,78 **триллиона параметров** и занимает 1,56 **терабайта** даже в исходном виде, так что ни одна потребительская машина не сможет его вместить, и ждать дольше не имеет смысла, потому что проблема не в скорости, а в объеме. Но это смесь экспертов, поэтому только 16 из 896 экспертов на каждом уровне запускаются для каждого токена, а остальные «спят» на диске. У C есть преимущество в этом плане. Часть, которая всегда активна, хранится в памяти, а «спящие» эксперты запускаются по мере необходимости. Все это уместается в 8,24 **гигабайта** на одном процессоре без графического процессора, который мы создали с нуля на чистом C.



KIMI K3 IN C ENGINE

2.78 TRILLION PARAMETERS • MIXTURE-OF-EXPERTS • CPU ONLY • FROM SCRATCH IN C



1



MXFP4 FORMAT
0.53 bytes per weight

2



SPARSE ROUTING
16 of 896 fire

3




FIXED-SIZE STATE
context costs nothing extra

4



STREAM THE TRUNK
a dial, not a floor




Оптимизированная архитектура Kimi K3 на языке C для работы на потребительском оборудовании (создано Фаридом Ханом)

К концу этого поста мы создадим каждый блок на этой схеме с нуля, по одному компоненту за раз, и запустим готовые подсказки через движок на одном процессоре.

Вот что нам дает все это, и это единственный показатель, ради которого существует остальная часть поста.

How a model far too big for any desk ends up running on one



Create an account to read the full story.

The author made this story available to Medium members only.
If you're new to Medium, create a new account to read this story on us.

Continue in app

Or, continue in mobile web



Sign up with Google



Sign up with Facebook



Sign up with email

Already have an account? [Sign in](#)



Follow

Опубликовано в Level Up Coding

352 тыс. подписчиков · Последнее обновление 16 часов назад

Обучающие материалы и новости о программировании. Домашняя страница разработчика gitconnected.com && skilled.dev && levelup.dev



Follow

Автор: Фарид Хан

76 Тысяч подписчиков · 0 подписчиков

Я пишу об искусственном интеллекте, <https://www.linkedin.com/in/fareed-khan-dev/>
