

Представляем Silico — вашу платформу для амбициозных исследований в области искусственного интеллекта



GOODFIREProduct ▾

Pricing

Research

About ▾

Request Demo

Get Silico

Анализ и отладка вашей модели ИИ

Нейронные сети обладают удивительной математической структурой и геометрией. Мы помогаем вам выявить скрытые представления в вашей модели, чтобы исключить догадки при обучении ИИ — перейти от алхимии к точной инженерии.

Получить Silico

Запросить демонстрацию



Используется командами
искусственного
интеллекта в



BCR BASECAMP
RESEARCH



Microsoft PRIMA MENTE



PRIME



ссия

чите
чные
овы
ронных
сетей,
чтобы мы
могли
целенаправл
разработ

разрабатываю

ИСКУССТВЕННЫЙ ИНТЕЛЛЕКТ

Мы считаем, что
искусственный интеллект —
самая значимая технология
нашего времени, однако
сегодня мы обучаем модели,
практически не понимая
природы их интеллекта.

Мы — исследовательская
лаборатория, занимающаяся
разработкой научных и
технологических решений
для изменения ситуации.

Платформа для осознанного проектирования моделей

Silico позволяет создавать модели искусственного
интеллекта с точностью написанного программного
кода. Смотрите, чему научились модели, выявляйте

нежелательное поведение и вносите точечные изменения для повышения эффективности.

Узнать больше

Silico работает со всеми типами моделей искусственного интеллекта

Получить Silico


Запросить демонстрацию



Силикон для



Silico для р



Silico для б

Программа намеренного проектирования

Новые методы понимания, отладки и разработки вашей модели искусственного интеллекта



Understanding

Reverse engineer the causal mechanisms of AI to reveal its internal structure, uncovering novel science and validating when predictions reflect true understanding.

Discovering a novel class of Alzheimer's biomarkers

We identified a novel class of biomarkers for Alzheimer's detection by interpreting an epigenetic model, the first major finding in the natural sciences obtained from reverse-engineering a foundation model.

[Read more →](#)

Interpreting Evo 2

We decoded the internal representations of Arc Institute's Evo 2 genomic model, finding features that map onto biological concepts from coding sequences to protein secondary structure. Published in Nature.

[Read more →](#)

Explaining 4.2 million genetic variants

We used embeddings to predict whether a variant is pathogenic, how gene variants cause disease, achieving state-of-the-art performance and interpreting by-design predictions.

[Read more](#)



Debug

Precisely debug issues with model behavior, identify and remove confounders, and diagnose failures before they occur in production.

Detecting performative chain-of-thought

We tracked “performative chain-of-thought”: when models “know” their final answer but continue to generate chain-of-thought anyways. We showed that probes can enable early exit from reasoning traces, saving up to 68% of tokens with minimal accuracy loss.

Validating whether a cardiac vision model learned real medicine

We analyzed the latent space of EchoJEPa, a vision model trained on cardiac echocardiography video, revealing which features encoded real clinical understanding of motion and anatomy.

Identifying bottlenecks to a robotic model's performance

We worked with a robotics team to identify information bottlenecks, inspecting learned policy structure and representational geometry directly. We traced unstable behaviors to brittle internal features.



Design

Control training precisely to ensure your model learns what you want with less data and fewer off-target effects.

Read more about

Reducing hallucinations with features as rewards

We cut hallucinations in an LLM by 58% by using interpretability to guide model training. Our approach was ~90x lower cost per intervention

Accelerating materials discovery with self-correcting search

We gave a diffusion model a feedback loop from its own internals, resulting in ~30% more

Intentional design for the future of AI

Our essay on intentional design describes a vision for interpretability-guided model training – from guesswork to

than LLM-as-judge, with no degradation in standard benchmarks.

[Read more](#) →

viable candidate materials with target properties.

[Read more](#) →

check to c
loop conti

[Read m](#)



Research

We're investing in fundamental research to uncover how neural networks work at their core

The World Inside Neural Networks

May 7, 2026

Atticus Geiger, 
Ekdeep Singh Lubana,
Thomas Fel,
Jack Merullo,
Michael Byun,
Owen Lewis,
Thomas McGrath

Steering Along Manifolds to Control Neural Networks

May 7, 2026

Daniel Wurgaft, 
Can Rager,
Matthew Kowal,
Vasudev Shyam,
Sheridan Feucht,
Usha Bhalla,
Tal Haklay,
Eric Bigelow,
Raphaël Sarfati,
Thomas McGrath,
Owen Lewis,
Jack Merullo,
Noah Goodman,
Thomas Fel,
Atticus Geiger,
Ekdeep Singh Lubana

Interpreting Language Model Parameters

May 5, 2026

Lucius Bushnaq, 
Dan Braun,
Oliver Clive-Griffin,
Bart Bussman,
Nathan Hu,
Michael Ivanitskiy,
Linda Linsefors,
Lee Sharkey



Contact us


Interested in partnering with Goodfire?

[Get Silico](#)

[Request Demo](#)

Company
Research
Blog

Product
Careers
Contact
Trust & Security



Terms of Use Privacy Policy ©2026 All rights reserved