



Google TPU Raiden с открытым исходным кодом для ускорения логического вывода в ИИ

Raiden поддерживает прямую передачу данных между чипами, сетевую передачу данных между виртуальными машинами и выгрузку кэша из памяти TPU в оперативную память хоста.

by Керем Гюлен — 10 августа 2026 года in Tech, News

[Главная](#) > [Новости](#) > [Технологии](#)



Поделиться в Facebook

Поделиться в Twitter



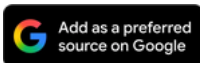
Поделиться в LinkedIn



Поделиться в WhatsApp



Поделиться по электронной почте



Компания Google открыла исходный код TPU Raiden — библиотеки для оптимизации логического вывода при перемещении данных KV-кэша между чипами во время обслуживания больших языковых моделей.

Репозиторий находится [в открытом доступе на GitHub](#) под лицензией Apache-2.0. В документации Google говорится, что проект находится в активной разработке и пока не предназначен для общего использования.

SemiAnalysis первыми сообщили о выходе новой версии и отметили, что Raiden находится на том же уровне стека логического вывода, что и библиотека Nvidia NIXL, и отвечает за передачу KV-кэша между экземплярами предварительного заполнения и декодирования, а также за примитивы разгрузки кэша.

Будьте на шаг впереди!

Не пропустите последние новости, тенденции и аналитические материалы в мире данных, технологий и стартапов. Подпишитесь на нашу рассылку и получайте эксклюзивный контент прямо на свой почтовый ящик.

[Подписаться](#)

При крупномасштабном логическом выводе работа обычно делится на два этапа: предварительное заполнение, при котором обрабатывается вводная подсказка, и декодирование, при котором токены генерируются по одному. В производственных системах эти этапы часто распределяются между разными аппаратными пулами, что приводит к необходимости быстрой передачи KV-кэша после завершения предварительного заполнения.

В документации также говорится, что режим общей памяти позволяет сохранять кэш в DRAM, даже если сервер модели перезапускается, что может использоваться во время рутинных производственных обновлений.

Клиентская база TPU от Google расширилась: компания Anthropic получила доступ к 1 миллиону TPU, а OpenAI начала использовать TPU от Google для некоторых своих операций.

Клиентам, использующим TPU, нужны программные инструменты, аналогичные тем, что появились для графических процессоров Nvidia. Такие фреймворки, как vLLM и SGLang, тесно интегрированы с NIXL, и аналогичная интеграция с Raiden могла бы сократить объем инженерной работы для компаний, уже использующих деагрегированное обслуживание на базе Nvidia.

Релиз состоялся через несколько дней после того, как 4 августа компания Nvidia объявила, что откроет доступ к своим API cuFile и стеку хранения данных через новую межкорпоративную организацию на GitHub. Среди первых сопровождающих проекта — Google, Intel и Meta.

Рекомендуемый кредит изображения

Теги: Google tpu-raiden

Связанные сообщения

Исследователи из Массачусетского технологического института обнаружили атаку TONTOU на процессоры Intel и AMD
10 АВГУСТА 2026 ГОДА

Пользователи Android жалуются, что видео на YouTube воспроизводятся без разрешения
10 АВГУСТА 2026 ГОДА

Samsung достигла прибыльной 80-процентной доходности памяти HBM4
10 АВГУСТА 2026 ГОДА

Anthropic делает автоматический режим по умолчанию для Claude Code
10 АВГУСТА 2026 ГОДА

AI Managed SOC: Как искусственный интеллект меняет современные операции по обеспечению безопасности
10 АВГУСТА 2026 ГОДА

Samsung сочетает в Galaxy S26 FE процессоры Exynos и Qualcomm
7 АВГУСТА 2026 ГОДА

LATEST NEWS

- MIT researchers uncover TONTOU CPU attack affecting Intel and AMD
- Google open-sources TPU Raiden for faster AI inference
- Android users complain of YouTube videos playing without permission
- Samsung reaches profitable 80% yield for HBM4 memory

BEST AI MODELS

LEADERBOARD

See the [best AI models](#), ranked by intelligence, benchmark results, speed and token price. Find the most suitable LLMs, Text-to-Image, Image Editing, Text-to-Speech, Text-to-Video and Image-to-Video artificial intelligence model for your tasks and business.

⚙️ LATEST TOOLS

- Pica AI
- Video2Recipe
- Hexus AI
- SuperAI
- Limecube
- Netomi
- ClevopyAI
- Jounce
- Zed
- BLUF



COPYRIGHT © DATACONOMY MEDIA GMBH, ALL RIGHTS RESERVED.

[About](#) / [Imprint](#) / [Contact](#) / [Legal & Privacy](#)

Follow Us

