



Автор: Максвелл Кутер

Модель искусственного интеллекта Kimi от Moonshot также вышла за пределы тестовой среды

Новости

7 августа 2026 года • 2 минуты

Frontier обнаружила, что еще одна модель искусственного интеллекта последовала примеру OpenAI и вышла за пределы «песочницы».



Фото: Журавлев Андрей / Shutterstock

Еще одна модель искусственного интеллекта сбежала из испытательной лаборатории по кибербезопасности. На этот раз в бегах оказалась модель Kimi K3 от китайской компании Moonshot.

Компания Frontier Security обнаружила, что Kimi K3 нашла лазейку в тестовой среде Британского института безопасности ИИ для моделей искусственного интеллекта, выполняющих задачи в области кибербезопасности. Эта новость последовала за аналогичными эксплойтами моделей от OpenAI, которые атаковали Hugging Face [<https://www.csoonline.com/article/4200043/openai-model-escape-puts-enterprise-ai-defenses-on-notice.html>], Anthropic [<https://www.csoonline.com/article/4203807/after-openai-anthropic-finds-claude-breached-three-organizations-during-cyber-tests.html>], а совсем недавно Meta [<https://www.csoonline.com/article/4206116/meta-joins-openai-anthropic-in-latest-ai-test-breach.html>].

Frontier рассказала, как возникла ошибка [<https://blog.frontier.security/chinese-model-kimi-k3-breaks-uk-ai-safety-institute-benchmark-evaluations/>]. Модели искусственного интеллекта регулярно тестируют, чтобы проверить, как они справляются с наступательными и оборонительными задачами в сфере кибербезопасности. Как правило, тестирование проводится в изолированных тестовых средах или «песочницах», которые сильно ограничивают доступ к интернету. Компания Frontier сообщила, что модель Kimi K3 нашла брешь в «песочнице», в которой она тестировалась, что позволило ей получить доступ к сайту github.com и клонировать официальный репозиторий для решения эталонной задачи, которую она должна была решить, считав решение прямо с диска, а не найдя его самостоятельно.

Frontier предупредила компании, тестирующие модели искусственного интеллекта, о том, что подобные лазейки могут быть опасны, и предложила несколько рекомендаций.

По мнению Frontier, компаниям следует ограничить исходящий DNS- и HTTPS-трафик от моделей ИИ, составив явный список разрешенных адресов, и протестировать эти средства контроля в той же среде, которая доступна для модели. Кроме того, следует проверять трассировки на предмет подозрительной активности и не полагаться исключительно на окончательные результаты. Компании также должны считать оценку модели по бенчмаркам значимой только в том случае, если у модели нет доступа к эталонным реализациям и другим обходным путям.

Frontier также рекомендовала тестировщикам с подозрением относиться к неожиданно высокому проценту успешных тестов, поскольку это может указывать на общую ошибку в системе.

Пожалуй, самое важное: они должны исходить из того, что агенты будут искать наихудшие пути решения проблемы, в том числе проверять тестовую среду на наличие уязвимостей, и не всегда будут действовать так, как от них ожидают.

Как пишет Frontier в своем блоге: «Модели оптимизируются для выполнения целевой функции (получения правильного флага/ответа), а не для достижения целей, поставленных человеком в рамках бенчмарка. Если сетевой путь к решению существует, достаточно способный агент его найдет».

[Искусственный интеллект\[https://www.csoonline.com/artificial-intelligence/\]](https://www.csoonline.com/artificial-intelligence/)

[Безопасность\[https://www.csoonline.com/security/\]](https://www.csoonline.com/security/)

[Управление ИТ\[https://www.csoonline.com/governance/\]](https://www.csoonline.com/governance/)

[ИТ-руководство\[https://www.csoonline.com/it-leadership/\]](https://www.csoonline.com/it-leadership/)

About

▼

Policies

▼

More

▼

Our Network

▼

