

[Подписаться](#)[Войти](#)

Запускаю сегодня



шлюз искусственного интеллекта ngrok

Один приватный шлюз для каждой модели ИИ

589 подписчиков



[Посетить веб-сайт](#)

Инструменты инфраструктуры искусственного Интеллекта

ngrok AI Gateway предоставляет один хостинговый шлюз для каждой модели: общедоступных провайдеров, пользовательских конечных точек и моделей, которые вы...

[Показать еще](#)

Обзор



Требуемая оплата

Запускаю сегодня

#4

Дневной Ранг



Upvote • 262 балла



Подписаться



Создавайте и публикуйте профессиональные сайты с помощью ИИ

Попробуйте Framer AI Agents

Повышен в должности

Что вы думаете? ...



Войдите в систему, чтобы прокомментировать



Ниджи



Создатель



Привет, Product Hunt! 🙌

Я Ниджи, менеджер по продуктам в ngrok. Сегодня мы запускаем **ngrok.ai**, шлюз искусственного интеллекта ngrok.

На протяжении многих лет ngrok помогал разработчикам подключать свои приложения и сервисы за минуты, а не за дни.

Когда я начал работать с искусственным интеллектом, я столкнулся с аналогичными проблемами в инфраструктуре на уровне приложений.

Приложение может начинаться с OpenAI, а затем переключаться на Claude для другого сценария использования. По мере появления новых более быстрых или доступ-

[Показать больше](#)

👍 (15) 🚩 📌 6 дней назад ...




свати паливал

[@nijikokun](#) Как, по вашему мнению, команды принимают решение о том, куда на-

Запускаю сегодня

#4

Дневной Ранг



[Подписаться](#)

сценария. Обычно это зависит от того, насколько важна модель для продукта, достаточно ли она эффективна, оправданы ли затраты и может ли команда обслуживать ее и поддерживать ее качество. Затем они устанавливают политики маршрутизации в зависимости от запроса, например отправляют конфиденциальные рабочие нагрузки, а также рабочие нагрузки, чувствительные к задержкам или специфике использования, на собственные модели, а для более качественного обслуживания, удовлетворения более широких потребностей или увеличения мощности используют модели на хостинге.

[Показать больше](#)

(1) 4 часа назад ...

**фмерский**

Охотник

[@ngrok](#) снова с нами.

Если вам когда-либо нужно было поделиться локальным приложением или провести онлайн-демонстрацию, вас наверняка поразит одна особенность этого продукта. Разработчики *любят* его. Я имею в виду миллионы разработчиков — посмотрите на эту [стену любви](#) — в том числе сотрудников [@GitHub](#), [@OpenAI](#), [@Vercel](#) и многих, многих других.

[@cassidoo](#) сказал просто: "ngrok экономит мне столько времени при разработке. Какой же это инструмент."

рад, что они вернулись [на Product Hunt]. S/O [?makers](#), уже жду ваших будущих релизов

[Показать больше](#)


(8) 18 часов назад ...

**Гокул Чандрасекаран**

[@fmerian](#) [@cassidoo](#) ngrok уже очень давно является основой моей системы разработки для тестирования реальных сценариев использования приложений в

Запускаю сегодня**#4**

Дневной Ранг





Подписаться

gateway/reviews/new

(2) 8 часов назад ...



Джоэл Ханс



Создатель

@gokuljd Большое спасибо за то, что пользуетесь ngrok так долго! Если есть что-то, что вы хотели бы видеть исправленным или что мы могли бы добавить (кроме этого шлюза с искусственным интеллектом, конечно!), я буду рад об этом услышать.

(1) 5 часов назад ...



Itohan Eigbadon

What strikes me most is the self-hosted piece. I've run models on my own infrastructure before and connecting them through it's network instead of exposing a public endpoint solves a real security headache I've dealt with firsthand. That alone makes this worth testing on my end.

(10) 6h ago ...



Joel Hans



Maker



@itohan_blessing_eigbadon Thanks for the comment! We have people interested in exactly what you're saying, production apps needing private connectivity to self-hosted inference, but we're also seeing a newer trend of people wanting that same simple infra for connecting their *coding agents to self-hosted models*, which is pretty dope. It's kinda the panacea if you care about software that's open, flexible, and "ownable."

We created a guide for Cursor, OpenCode, Pi, and Zed: <https://ngrok.com/docs/ai-gateway/guides/use-with-coding-agents>

Would love thoughts on what else we should cover!


Show more

(2) 5h ago ...

Запускаю сегодня

#4

Дневной Ранг





Подписаться

environments. we're still hard at work making the existing features better / easier to use, and and adding new ones each week :)

Show more

🖼️ 🚩 📤 2h ago ...

 **Sana Silhah**

I keep wondering about pricing at scale. One gateway is great in theory but does routing overhead add noticeable latency once you're pushing serious volume through it?

🖼️ (7) 🚩 📤 5h ago ...



Alice Wasko



Maker

⊖ @sana_silhah

we're looking into getting our performance benchmarks added alongside other publicly published ones, but from running those suites ourselves, the latency and time to first token / token throughput of our gateway is nearly tied with going directly to upstream providers (ex: anthropic). we try as much as possible to minimize added latency and processing overhead.

🖼️ 🚩 📤 1h ago ...

 **Sagar Deore**

The option to connect self-hosted models without exposing them to the public internet caught my attention. Have you seen more teams using their own models recently, or are most customers still relying mainly on hosted providers?

🖼️ (2) 🚩 📤 6h ago ...



Niji




Maker

⊖ @sagar_deore good question, honestly a mix of both. However, I have definitely seen a rise in hosted models more as of late with all of the local advancements that are happening. At the least there is always interest in experimentation as new models come

Запускаю сегодня

#4

Дневной Ранг





Подписаться

models, others have different concerns such as control over the lifecycle of sensitive data. our goal is to make a single unified place to let users easily access whatever kind of inference they need to, and take as much friction and pain out of the experience of working with LLMs as possible.

Show more

🖼️ 🚩 ⬆️ 2h ago ...



Anthony Adams 

How easy is it to switch traffic between providers if one model has highest latency or goes offline?

🖼️ (2) 🚩 ⬆️ 9h ago ...



fmerian  

Hunter

good q. [@ngrok AI Gateway](#) is designed for automatic failover. if one provider/model fails, times out, returns an HTTP error, or has a connection issue, the gateway automatically tries the next candidate instead of requiring your app to switch providers itself.

read the docs for more details on how it works: ngrok.com/docs/ai-gateway/how-it-works

hope it clarifies!

🖼️ (2) 🚩 ⬆️ 8h ago ...



Joel Hans 


Maker

[@anthony_adams_](#) Thanks for the question! Well, I think it's pretty darn easy. [@fmerian](#) got the gist of it, but here's a bit more specificity. In your app (I'll use a JS example), you already specify a model, but now you can add a models key to list the order in which you'd like to fall back to other providers and models.

Запускаю сегодня

#4

Дневной Ранг



[Подписаться](#)**Alice Wasko**

Maker

[@anthony_adams_](#)

we've got options to per model timeouts to limit how long you wait for one of them to respond before moving on to the next one, options to configure fallback behaviour with models and/or keys if you're bringing your own keys.

on our roadmap is a way to let users define their own model groups or pick an automatic group of models by category. for example:

- the most responsive models
- models with the highest fidelity output
- models good for a specific task such as programming / research / etc.

if you've got a particular pain that's not being solved or a feature that you'd like to see

[Show more](#)

2h ago ...

**Henry Habib**

I like that you can start with your own provider keys and still get a single place to track usage, latency, and costs. Jumping between multiple dashboards gets old fast, so having that consolidated is a practical improvement.



(3)



6h ago ...

**Joel Hans**

Maker




[@henry_habib](#) Yep yep, you have complete control over whether you bring your existing providers keys (BYOK) or use ngrok-managed ones. Either way, it all ends up on the same request/usage logs.

We actually *just* added more detailed breakdowns of usage data we were already collecting, so now it's really easy to see things like the average cost per request or per-

Запускаю сегодня**#4**

Дневной Ранг





Подписаться

<< < 1 2 3 4 >



Company Info

ngrok.ai

ngrok AI Gateway Info

Launched in 2026

Forum

p/ngrok-ai-gateway

Social

X

Similar Products



OpenAI

APIs and tools for building AI products

★ 5.0 (814 reviews)

LLMs

Foundation Models



Eden AI

Seamlessly Merging the Top AI APIs into One

★ 4.8 (22 reviews)


No-code Platforms

Unified API

Запускаю сегодня

#4

Дневной Ранг





Подписаться

★ 5.0 (23 reviews)

Unified API

AI Infrastructure Tools



Opper AI

The European AI gateway for agents

★ 5.0 (2 reviews)

Unified API

AI Infrastructure Tools

View more →

Top Product Categories

Engineering & Development



LLMs



Productivity



Marketing & Sales



Design & Creative



Social & Community



Finance



AI Agents



Trending categories



Top reviewed



Trending products




Top forum threads



Запускаю сегодня

#4

Дневной Ранг





 Подписаться

Запускаю сегодня

#4

Дневной Ранг

