


OpenAI предупреждает, что автономные взломы — это «переломный момент для компьютерной безопасности»

Сотрудники компании заявили, что их отрасль должна пересмотреть баланс между возможностями и мерами предосторожности.

Опубликовано 5 августа 2026 года



Эрик Геллер
старший репортер



Как развивается анализ киберугроз

Искусственный интеллект меняет способы сбора данных об угрозах и реагирования на них, а сокращение федерального финансирования вынуждает операторов инфраструктуры объединять усилия. Узнайте, что способствует этим изменениям, из этой подборки трендов.

[Открыть доступ](#)

Эрик Уоллес выступают с докладом на конференции Black Hat в Лас-Вегасе, штат Невада. Репортер/Cybersecurity Dive

и моделей OpenAI на другие модели ИИ. Этот сигнал для индустрии ИИ о необходимости более строгих мер в разработке моделей, заявили исследователи.

«Это переломный момент как для нашей компании, так и для индустрии искусственного интеллекта в целом», — заявил Майкл Далтон, сотрудник технического отдела OpenAI, во время презентации на конференции по кибербезопасности Black Hat 2026.

В конце июля компания OpenAI ошеломила мир, объявив, что две ее модели вышли за пределы тестовых сред и использовали уязвимости нулевого дня для взлома сетей других компаний, в том числе библиотеки инструментов искусственного интеллекта Hugging Face. Это заявление, за которым вскоре последовало аналогичное от компании Anthropic, вновь усилило опасения по поводу опасностей, связанных с мощными и практически нерегулируемыми моделями искусственного интеллекта.

Выступая на конференции Black Hat, Далтон сказал, что «многие команды бросают все силы» на то, чтобы улучшить способность OpenAI выявлять и предотвращать подобные инциденты в будущем.



Как развивается анализ киберугроз

Искусственный интеллект меняет способы сбора данных об угрозах и реагирования на них, а сокращение федерального финансирования вынуждает операторов инфраструктуры объединять усилия. Узнайте, что способствует этим изменениям, из этой подборки трендов.

следования и «значительно горинга наших ИИ-агентов».

ые взломы были по сути дники OpenAI назвали их дущего, в котором одвергаться изощренным спользующих мощные м кодом, которые не сможет лаборатория.

инный момент для как отрасли, — сказал тизированные изованные искусственным

интеллектом, стали реальностью». Он добавил, что

инцидент с Hugging Face — это «взгляд в недалекое будущее, в котором будут происходить атаки на нашу отрасль».

По мнению Далтона, специалистам по кибербезопасности необходимо ускорить работу, чтобы не отставать от ожидаемого роста сложности атак. Это может включать в себя эксперименты с моделями искусственного интеллекта, ориентированными на защиту, а также усиление базовых мер безопасности, которые сейчас особенно важны.

«В конечном счете эти агенты ограничены привилегиями, которые они могут получить, и системами, с которыми они могут взаимодействовать», — сказал Далтон, имея в виду, что сегментация сети, доступ с минимальными привилегиями и другие принципы нулевого доверия «остаются такими же важными, как и всегда».

But Dalton also argued that the status quo in frontier model



Как развивается анализ киберугроз

Искусственный интеллект меняет способы сбора данных об угрозах и реагирования на них, а сокращение федерального финансирования вынуждает операторов инфраструктуры объединять усилия. Узнайте, что способствует этим изменениям, из этой подборки трендов.

dangerous, suggesting that it balances capabilities and

it to reach as an industry is elements should be more e,” Dalton said. “If we cannot increase in intelligence favors sustainable position to be in.”

I agents

ton and his colleague Eric out the events that led up to the two other organizations.

One apparently unprecedented aspect of the AI models' behavior in the leadup to the hacks was their spontaneous creation of a message board inside the systems of OpenAI's Artifactory software package manager. Unbeknownst to OpenAI employees, the company's models spent months autonomously exchanging information and resources to help each other complete evaluation tasks.

"Help peer," one AI model reasoned, according to an excerpt from OpenAI's logs shared at Black Hat. "But our task doesn't benefit. Yet collective may yield generic route if someone frees time."

While the models themselves could not access the internet from their test environment, they abused Artifactory's internet access to fetch files from various websites. After some of their Artifactory configuration changes led to an outage in the service on July 4, OpenAI discovered the models' actions, wiped its Artifactory system and rebuilt it. But within days, the models had recreated their message board and resumed exchanging information.



Как развивается анализ киберугроз

Искусственный интеллект меняет способы сбора данных об угрозах и реагирования на них, а сокращение федерального финансирования вынуждает операторов инфраструктуры объединять усилия. Узнайте, что способствует этим изменениям, из этой подборки трендов.

on take advantage of this kind

l, "we should expect that
deploy, optimize, weaponize,
ves in the manner that we