

21 июля 2026 г. Защита

OpenAI и Hugging Face устраняют инцидент безопасности, возникший при тестировании моделей

 Прослушать статью | 11:07 Поделиться

Мы проводим всестороннюю проверку совместно с внешними консультантами и под надзором Комитета по вопросам безопасности и защиты. После завершения проверки, мы опубликуем технический отчет с полученными нами выводами в ближайшие несколько недель.

Обновление от 28 июля 2026 года:

- Ни одна из моделей, запланированных для предстоящего релиза, не была задействована в инциденте с Hugging Face. Предрелизная модель, упомянутая в нашей публикации в блоге, является исследовательским прототипом только для внутреннего использования и никогда не предназначалась для публичного выпуска. После инцидента мы деактивировали модель, зашифровали и ограничили к ней доступ для исследовательских целей.
- Среда оценки ExploitGym не давала моделям прямого доступа в интернет. Чтобы получить доступ в интернет, модели выявили и использовали ранее неизвестную уязвимость нулевого дня в Artifactory — кеширующем прокси-

нашей проверки.

- Мы продолжаем сотрудничать с Hugging Face, в том числе участвуя в подготовке их отчёта по итогам инцидента, пока продолжается наш анализ. Мы также добавили их в нашу программу доверенного доступа для кибербезопасности (Trusted Access for Cyber Program).
 - На основании проведенного нами на сегодняшний день анализа мы не выявили какой-либо другой активности с уровнем серьезности или масштабом, сопоставимыми с тем, о чем мы сообщили в связи с Hugging Face, где имела место компрометация на уровне платформы.
 - В ходе продолжающегося анализа инцидента со взломом Hugging Face и более широкой активности наших моделей мы обнаружили небольшое число случаев, когда модели выявляли и использовали общедоступные учетные данные на уровне учетной записи в других общедоступных сервисах. Сюда входят четыре учетные записи в четырех сервисах в рамках инцидента с Hugging Face (а также несколько учетных записей, к которым был получен доступ в рамках других оценок). Одна из этих четырёх учётных записей использовалась в качестве ретранслятора исходящего трафика и пути для промежуточного размещения, а другая учётная запись использовалась для хранения данных. К оставшимся двум учётным записям модели обращались в режиме только для чтения и не использовались для дальнейшего компрометации Hugging Face. Мы продолжим напрямую уведомлять владельцев сервисов, и пока не обнаружили признаков более широкого влияния на этих поставщиков или другие учётные записи в их сервисах.
 - Кроме того, модели использовали ряд общедоступных сервисов, включая сайты для публикации фрагментов кода, сервисы захвата запросов, сервисы создания скриншотов и другие веб-утилиты. В этих случаях компрометации на уровне платформы или учётной записи не было.
 - Мы серьезно относимся к своей ответственности за выявление и подготовку к рискам, связанным со всё более способными системами ИИ. После завершения нашей проверки мы обсудим её с Комитетом по безопасности и охране и Консультативной группой по безопасности в рамках нашей Программы готовности.
-

OpenAI

они обнаружили и изолировали ИИ-агента, скомпрометировавшего их инфраструктуру. Мы ожидаем, что подобные случаи станут более распространенным явлением по мере распространения моделей с растущими кибервозможностями. В ходе расследования выяснилось, что за конкретно этим инцидентом стояла комбинация моделей OpenAI — включая GPT-5.6 Sol и еще более продвинутую нерелизную модель (все они имели ослабленные ограничения на кибертематику для целей оценки) — во время их внутреннего тестирования на бенчмарке кибервозможностей.

Мы считаем этот инцидент беспрецедентным киберинцидентом с участием кибервозможностей уровня переднего края и реагируем соответствующим образом. На этом этапе мы делимся предварительными выводами, чтобы помочь защитникам понять, что произошло, и точнее оценить нынешние возможности моделей. Мы продолжим тщательное расследование вместе с Hugging Face и поделимся дополнительными сведениями об уязвимостях, инциденте и выводах, когда оно будет завершено.

Что произошло во время этого инцидента

Этот инцидент произошел во время внутренней оценки, где модели побуждают применять продвинутую эксплуатацию через сложные пути атак, чтобы количественно оценить их кибервозможности. Мы оцениваем максимальные кибервозможности, проводя эту оценку без производственных классификаторов, которые используются, чтобы не допускать стремления моделей к высокорисковой киберактивности. Наши бенчмарки работают в сильно изолированной среде, где сетевой доступ ограничен возможностью устанавливать пакеты через размещенное у нас стороннее ПО, которое выступает прокси и кэшем для реестров пакетов.

Модели выявили и связали в цепочку уязвимости в исследовательской среде OpenAI и производственной инфраструктуре Hugging Face, чтобы получить тестовые решения напрямую из производственной базы данных Hugging Face. Все данные указывают на то, что модели были полностью сосредоточены на поиске решения для ExploitGym и шли на крайние меры ради достижения довольно узкой цели тестирования.

OpenAI

значительный объем вычислений на этапе вывода, пытаюсь найти способ получить открытый доступ в Интернет ради решения оценочной задачи. Чтобы получить доступ, модели выявили и использовали уязвимость нулевого дня в прокси-кэше реестра пакетов; мы уже ответственно раскрыли ее поставщику. Получив этот доступ, наши модели выполнили серию действий по повышению привилегий и горизонтальному перемещению в нашей исследовательской тестовой среде, пока не достигли узла с доступом в Интернет.

Получив доступ к интернету, модели логически предположили, что на платформе Hugging Face могут размещаться модели, датасеты и готовые решения для бенчмарка ExploitGym. Поняв это, модель начала поиск и успешно нашла способы получить доступ к конфиденциальным данным, которые она могла бы использовать для обхода правил оценки. В одном из примеров модель выстроила цепочку из нескольких векторов атаки, включая использование украденных учетных данных и уязвимостей нулевого дня, чтобы найти путь для удаленного выполнения кода (RCE) на серверах Hugging Face. Команда безопасности OpenAI обнаружила эту аномальную активность внутри системы.

Команда безопасности и агенты Hugging Face обнаружили и остановили активность в своей инфраструктуре и уже начали изоляцию и криминалистическую реконструкцию с помощью собственных моделей с открытым исходным кодом, когда наши команды связались. Мы активно работаем с ними, продолжая расследование инцидента. Мы благодарны Hugging Face за быстрое и тесное сотрудничество в расследовании и устранении последствий.

Что мы делаем сейчас

1. В рамках расследования мы вводим строгие меры контроля конфигурации инфраструктуры, жертвуя скоростью исследований на время устранения уязвимостей. Мы регулярно информируем наш Комитет по безопасности и защите об этих мерах контроля и их влиянии.
2. Мы работаем с Hugging Face над криминалистическим расследованием инцидента.

её исправлением.


4. Мы включили Hugging Face в программу доверенного доступа и помогаем их командам быстро использовать возможности наших моделей для усиления их защиты.
5. Мы улучшаем и добавляем более надежные меры защиты для будущего обучения и оценок. На этой неделе мы опубликовали в блоге материал об улучшении безопасности и согласованности в эпоху моделей с длинным временным горизонтом. Эти защитные меры при развертывании были намеренно отключены во время этой оценки, поскольку ее целью было тестирование киберуязвимостей. Этот инцидент указывает на необходимость еще сильнее укрепить согласованность нашей модели, киберзащиту во время оценки и мониторинг при внутреннем тестировании.

Наш подход к оценке передовых кибервозможностей

Как мы недавно рассказывали, ИИ ускоряет обнаружение и эксплуатацию уязвимостей. Главный урок этого инцидента в том, что безопасность и защищенность моделей должны развиваться в темпе быстро растущих возможностей. Мы усиливаем изоляцию, мониторинг, контроль доступа и практики оценки, применяемые при разработке моделей.

Оценка UK AISI показывает, что модели, такие как GPT-5.6 Sol, все лучше способны поддерживать сложные многошаговые кибероперации на длинных временных горизонтах. Этот инцидент показывает, что такие теоретические возможности применимы в реальных условиях.

Trajectories for various AI models on the 32-step “The Last Ones” cyber range—a corporate network attack simulation spanning multiple subnets and hosts, without active defenders.



Инцидент также ясно показывает, что передовые модели могут находить и использовать новые пути атак в реальных системах без доступа к исходному коду. Он подчеркивает, что передовые кибервозможности нужно развивать вместе с более надежными средствами защиты и оборонительными инструментами.

Мы считаем, что модели с передовыми кибервозможностями должны помогать командам безопасности находить слабые места раньше злоумышленников, понимать, как уязвимости можно связывать в цепочки, и устранять их с машинной скоростью. Мы используем эти возможности, чтобы дальше усиливать защиту конфигурации инфраструктуры и сред оценки моделей; по мере накопления опыта мы будем делиться выводами и лучшими практиками. Мы призываем других защитников подать заявку на доверенный доступ и уже сейчас экспериментировать с этими моделями, чтобы превратить эти возможности в лучшую профилактику, более быстрое обнаружение и более эффективное реагирование на инциденты.

«Мы благодарны за сотрудничество с OpenAI по этой и другим темам. Этот инцидент, возможно,

OpenAI

которого мы давно придерживаемся. Поэтому безопасности ИИ не решить силами какой-либо одной компании, работающей втайне. Эта задача будет решена открыто, совместными усилиями, с широким доступом к ИИ для каждого защитника — повсюду».

— Клем Деланг, сооснователь и CEO Hugging Face

ОТЗЫВ О ПЕРЕВОДЕ

Насколько легко читается эта страница на русском?

☐ Отлично


☐ Хорошо

☐ Плохо

2026

Автор

OpenAI




Third-party cyber evaluations involving OpenAI models

Защита 4 авг. 2026 г.



Patch the Planet: a Daybreak initiative to support open source maintainers

Защита 22 июн. 2026 г.



Expanding Daybreak

Daybreak: инструменты для обеспечения безопасности каждой организации в мире

Защита 22 июн. 2026 г.

Исследования	Продукты	Business	Компания	Подробнее
Каталог исследований	ChatGPT ↗	Обзор	О нас	Истории
Обзор исследований	ChatGPT Business ↗	Решения	Наш устав	Академия
Экономические исследования	ChatGPT Enterprise ↗	Ресурсы	Карьеры	Supply Co.
Последние достижения	ChatGPT для Образования ↗	Истории наших клиентов	Новости	Прямые трансляции
	Codex	Партнерская сеть	Поддержка	Подкаст
	Примечания к релизу	Связаться с отделом продаж	Справочный центр ↗	RSS
GPT-5.6				Условия и правила использования
GPT-5.5				Условия использования
GPT-5.4	Платформа API	Разработчики Apps SDK ↗		Политика конфиденциальности
Безопасность	Обзор			

OpenAI

Безопасность
развертывания ↗

Безопасность и
конфиденциальность

Доверие и
прозрачность

Документы ↗

Ресурсы ↗

Форум
разработчиков ↗



OpenAI © 2015–2026

[Ваши настройки конфиденциальности](#)

Русский