



← Опубликовать пост




Qwen

@Alibaba_Qwen

...

📢 Познакомьтесь с Qwen3.8-Max — нашей самой мощной моделью на сегодняшний день. На следующей неделе будут опубликованы открытые веса Qwen3.8-Max, а Qwen3.8-27B также станет открытой моделью, чтобы вы могли с ней познакомиться! 🎉 Qwen3.8-Max — новый уровень программирования и совместной работы с параметрами 2,4 T: – Автономное программирование: более 10 дней самостоятельной разработки, от пустой папки до продакшена без подсказок, полная история проекта на GitHub: github.com/qwen-code-dev-... – Реальная работа, реальные результаты: продукты промышленного качества для сотен профессий. – Долгосрочное совершенствование: автономное планирование на системном уровне с адаптивным обучением по замкнутому циклу, обеспечивающее более 500 циклов оптимизации конструкции чипа и 365 дней стратегии развития электронной коммерции. – Встроенный мультимодальный интеллект: визуализация — это не просто ввод данных, а непрерывный цикл обратной связи для планирования, реализации и самокоррекции. 💰 Ценообразование: Ввод: 2,0 доллара США / млн токенов. Вывод: 6,0 долларов США / млн токенов. Неявное кэширование: 0,25 доллара США / млн токенов. Начните создавать с помощью Qwen3.8-Max! 🚀 📖 Блог: qwen.ai/blog?id=qwen3.8 ✅ Qwen Studio: chat.qwen.ai/?models=qwen3... ⚡ API: qwencloud.com/models/qwen3.8...



2:15 · 3 авг. 2026 г. · 4,7 млн Просмотры

🗨 1 тыс.

↺ 2 тыс.

❤ 20 тыс.

🔖 4 тыс.





Qwen 🏆 @Alibaba_Qwen · 15 ч

...

LM Performance

	Opus4.8	Fable5	GPT5.6 SoI (max)	Qwen3.7-Max	Qwen3.8-Max
Coding Agent					
Terminal Bench 2.1	84.6	84.6	88.8	74.5	86.6
SWE-bench Pro	69.2	80.0	64.6	60.6	67.7
DeepSWE 1.1	59.0	70.0	73.0	21.6	56.6
NL2Repo-Bench	69.4	---	---	47.2	55.9
FrontierSWE	70.0	88.8	---	40.7	73.5
MLS-Bench-Lite	42.8	49.9	46.2	31.7	41.0
PaperBench	80.3	88.8	90.5	64.8	93.0
AndroidBench	69.8	84.5	74.0	56.5	75.1
QwenQWERBench	84.0	86.3	73.5	63.4	80.7
QwenCoderBench	62.7	63.1	53.8	36.8	58.4
QwenReactBench	1694	1770	1564	1538	1724
QwenGVGBench	1648	1690	1768	1499	1713
General Agent					
CoWorkBench	72.3	75.9	71.5	64.6	74.8
WorkspaceBench	66.8	68.7	65.6	61.4	67.7
JobBench	48.4	57.4	45.4	31.3	53.4
SkillsBench	65.1	70.9	73.5	61.2	70.2
Agents' Last Exam (Pass / Score)	27.0 / 45.1	--- / ---	30.6 / 53.6	11.8 / 31.1	27.0 / 52.4
Automation-Bench (Pass@1)	27.2	29.1	29.7	14.2	27.3
Toolathon Verified (Pass@1)	76.2	77.9	74.9	49.7	72.5
WideSearch	72.9	81.2	---	75.2	81.9
HLE w/ tools	57.9	64.5	58.0	53.5	56.2
General Capabilities					
GQA Diamond	92.0	92.6	94.1	92.4	92.6
HLE	45.7	53.3	47.2	41.4	43.6
IFBench	62.2	63.5	72.7	79.1	82.6
\$OneMillion-Bench (export score)	41.8	55.9	53.8	44.4	52.5
HealthBench	52.4	---	55.3	54.5	60.2
PLawBench	69.6	70.2	72.3	58.9	73.2
PRBench-Legal	52.7	57.6	57.6	48.5	57.6
PRBench-Finance	51.9	55.8	55.5	46.8	58.3
MRQR v2 256K (8-needle)	83.2	---	93.8	86.7	92.9
LongBench v2	69.1	---	67.1	65.3	66.3

1. Fable5 的结果可能包含虚假信息。
2. Terminal Bench 2.1: 使用 Claude Code (gpt4o) 评估。耗时约 5 小时。max_tokens=32,072。对于数据所有错误。我们根据各评测数据中已有的最佳得分: Claude Opus 4.8 和 Claude Fable 5 使用 Artificial Analysis Pro Terminal 2.1 (<https://artificialanalysispro.com/terminalbench-v2-1/>)。GPT-4.8 SoI 使用 CodeL (<https://openai.com/index/gpt4o-gpt-4-gpt-4o/>)。
3. SWE-bench Pro: 使用 Claude Code 评测结果。temp=0.5, top_p=0.95, 上下文窗口 256K。已经存在问题的列表。并在修正后的数据集上重新评估所有基准结果。
4. DeepSWE 1.1: 使用 Claude Code 和 min-SWE-agent 评测结果。temp=0.5, top_p=0.95, 上下文窗口 256K。我们使用两个模型中最高得分。使用 SWE-agent。Claude 3.8-Max 在 Claude Code 上表现最佳。
5. NL2Repo-Bench: 使用 Claude Code 评测结果。为防止其他模型更改。我们使用了代码库特定令牌 (bash 令牌。和 pip download。pip install 和 git clone)。
6. FrontierBench: 使用 Claude Code 评测结果。其他所有模型使用 M4ANet 结果和 FrontierBench 官方评测 (<https://www.frontierbase.com/>)。数据截至 2025 年 8 月 3 日。使用分数的官方评测结果从原始数据集计算。
7. MLS-Bench-Lite: 使用 Claude Code 评估。耗时约 15 小时。max_tokens=32,072。我们使用各评测数据中已有的最佳得分。
8. PaperBench: 在 BaseAgent 使用 GPT-4.8 Code-Dev 模型评估。在 Claude Opus 4.8 模型。取 3 次运行的平均值 (每次运行最长 12 小时)。
9. AndroidBench: 在 65 个任务的公开数据集上评估。使用 gpt4o 模型。
10. QwenQWERBench: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 8 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
11. QwenCoderBench: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 6 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
12. QwenReactBench: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 7 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
13. QwenGVGBench: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 7 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
14. CodeBench: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 7 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
15. SkillsBench: 在公开的 SkillsBench v1.1 数据集上评估。使用 gpt4o 模型。耗时约 7 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
16. Automation-Bench: 在 600 个任务的公开数据集上评估。
17. WideSearch: 内部数据集。用于评估 GPT-4.8 上的用户问题。使用 Claude Code 评测结果。使用 gpt4o 模型。耗时约 7 小时。max_tokens=32,768, temperature=0.5, 上下文窗口 256K。
18. \$OneMillion-Bench: 使用 gpt4o-3.5-turbo-preview 评估。
19. PLawBench: 使用 gpt4o-3.5-turbo-preview 评估。
20. PRBench: 使用 gpt4o-3.5-turbo-preview 评估。
21. MRQR v2: 使用 gpt4o-3.5-turbo-preview 评估。

🗨️ 9

↻ 29

❤️ 744

📊 150 тыс.

🔖 ↗



Qwen 🏆 @Alibaba_Qwen · 15 ч

...

VL Performance

	OpenAI GPT-4o	Falout6	Gemini GPT-4o	GPT-4o	Gemini GPT-4o	Gemini GPT-4o
Multimodal Reasoning						
MMMU-Pro	75.6	81.2	80.5	83.0	79.0	82.3
Multimodal	81.7 / 81.1	82.7 / 86.6	81.4 / 85.7	80.8 / 87.8	80.3 / ---	80.2 / 81.7
ImageCaption	26.4 / 81.2	42.5 / 86.5	35.8 / 88.3	65.5 / 88.9	64.7 / 70.4	62.0 / 81.5
ImageCaption (w/ Text)	---	---	42.8	51.9	25.6	52.3
ZenBench (w/ Text)	17.0 / 34.0	20.0 / 48.0	11.0 / 23.0	22.0 / 35.0	16.0 / 16.0	24.0 / 48.0
ZenBench (w/ Text)	31.1	37.1	36.5	46.7	41.0	46.5
LogiQA	76.7	85.7	82.6	89.7	84.3	91.9
HPHQ	69.3	78.6	85.4	86.8	84.1	90.0
PhyX	54.2	71.7	76.4	78.1	80.0	83.5
SLATE	75.9	86.6	82.9	83.1	83.2	90.8
MathQA-GSM	71.7	80.0	80.7	81.5	71.0	80.4
PMC-VQA	59.2	63.2	62.5	62.3	63.4	66.2
Visual Agent & Coding						
CodeContest-Verified	83.4	86.0	76.2	83.2	73.3	86.1
CodeContest 2.0	20.6 / 54.8	---	1.8 / 30.6	---	2.8 / 21.5	16.4 / 46.7
ScreenSpot-Pro	82.3	87.3	88.1	81.3	79.0	84.5
WebArena-Verified	67.9	71.3	64.3	69.7	63.3	66.6
AutoBench	76.0	88.8	76.7	77.8	81.0	86.3
WebArena	67.5	85.5	56.1	76.9	51.2	77.9
CodeContest-AMM	73.3 / 73.8	81.2 / 77.6	50.5 / 65.2	61.2 / 76.9	57.4 / 60.1	77.2 / 74.8
VisualBench	62.4	70.5	---	62.1	42.1	69.0
OpenBenchBench	62.4	69.5	23.0	68.6	41.0	69.9
Parametric CAD Bench	85.1	87.5	72.5	86.2	73.8	91.5
ReasonBench	49.3	56.1	16.2	47.6	30.2	51.7
ReasonBench	80.9	78.9	56.4	82.9	63.7	79.6
Reasoning & Other Intelligence						
Charity-BIG	75.5 / 88.9	87.9 / 83.5	81.4 / 88.9	85.1 / 88.1	85.8 / 85.9	86.4 / 83.5
OpenBenchBench 1.0	86.5	89.5	90.0	86.7	91.4	92.1
OCR-Bench-V2 (EN/CH)	53.9 / 55.3	65.2 / 58.1	64.8 / 68.2	69.0 / 67.3	70.7 / 67.1	74.2 / 68.3
CC-OCR-Bench-V2	60.3	72.4	68.9	68.0	72.7	79.6
MTQA-Test	48.1	41.6	54.3	52.7	51.2	56.6
MTQA	66.8	86.0	81.1	87.8	87.1	91.8
GeminiBench	34.5	32.4	39.6	29.5	32.4	44.6
Real-World & Spatial Understanding						
RealWorldQA	76.6	85.9	83.5	83.7	86.9	88.0
ERQA	57.2	70.0	68.0	70.0	69.8	77.8
LongQA	73.8	77.4	66.8	72.6	62.4	84.8
SURFS	62.2	76.4	64.0	63.0	77.2	77.8
Visual Perception & Grounding						
SimpleQA	67.3	73.4	73.1	66.6	70.3	75.0
VisualQA	53.9	53.5	54.0	45.1	43.9	53.2
Midjourney	76.7	80.5	84.0	82.5	83.2	85.9
PerceptualBench	47.2	57.2	56.2	56.7	51.1	63.5
CountQA	41.3	63.1	72.8	66.6	77.0	82.4
Reflex-S	61.7	68.8	71.9	69.2	73.0	80.2
Dense200	20.8	31.1	69.7	56.3	60.7	87.0
COCO	50.7	56.4	72.4	61.2	74.2	78.7
VQFusion	20.1	54.5	36.5	62.8	42.8	60.8
VisualBench	42.8	61.2	74.1	58.8	36.6	66.3
Video Intelligence & Agents						
VideoMAE (w/ Sub.)	85.4	---	86.7	85.5	88.0	90.4
VideoMAE v2 (w/ Sub.)	49.0	52.2	66.9	71.1	59.7	66.3
VideoMAE	75.3	81.2	85.3	85.0	85.4	86.7
MMU	67.4	72.0	77.9	81.2	76.6	82.4
MLU (M-Avg)	53.4	---	84.7	87.6	87.4	90.8
PIBench	81.5	---	75.0	82.3	78.2	81.9
LiBench	67.3	---	75.1	78.8	76.2	81.9
LiBench (w/ Mem)	84.3	86.1	---	84.2	74.5	85.6
EgoLife (w/ Mem)	79.3	82.3	---	70.8	68.8	80.3
VideoRL (w/ Search)	65.6	77.1	---	71.3	41.0	73.2

6


21

488

106 тыс.

 **Qwen**  @Alibaba_Qwen · 15 ч

16 дней автономного кодирования



8

18

501

95 тыс.

 **Qwen**  @Alibaba_Qwen · 15 ч

Совместная работа: любая роль, развитие за пределами




1 10 371 79 тыс.  



Qwen  @Alibaba_Qwen · 15 ч



Динамические рабочие процессы для количественных стратегий




4 12 345 83 тыс.  



Qwen  @Alibaba_Qwen · 15 ч



Визуальный агентный интеллект



4 22 367 91 тыс. 1 1



Qwen @Alibaba_Qwen · 14 ч
Text Arena: arena.ai/leaderboard/te...

Text Arena Overall

View overall rankings across various AI models in text-to-text tasks across math, coding, creative writing, and other open-ended domains.

Aug 1, 2026 7,571,037 votes 27 labs 1 AutoEval

Show Filters Models Labs Q

Lab Rank	Lab	Model Score	Model Rank	Rank Spread
1	Anthropic claude-3.5-sonnet-3.5	1509 ±6	1	1 ↔ 4
2	Alibaba qwen3.8-max	1496 ±10 Preliminary	5	1 ↔ 17
3	Meta mistral-7b-instruct-v0.3	1490 ±6 Preliminary	9	4 ↔ 18
4	Google gemini-1.5-pro	1486 ±4	11	5 ↔ 19
5	Moondream mistral-7b-instruct-v0.3	1485 ±10 Preliminary	13	4 ↔ 30
6	OpenAI gpt-4o	1483 ±6	15	5 ↔ 28
7	SpaceXAI gpt-4o	1474 ±5	24	13 ↔ 39
8	Z.ai gpt-4o	1469 ±5	32	18 ↔ 46

5 6 284 69 тыс. 1 1



Unsloth AI @UnslothAI · 14h
Qwen3.8-27B? Thank you oh thank you Qwen team! A dream come true for all of us!! 🙏🙏

We can't wait to make quants so everyone can run it locally!

55 86 2 тыс. 65 тыс. 1 1

