



← Опубликовать пост



Адितья Гхай 
@aditya_ghai07

...



Мой опыт собеседования в @Cloudflare на должность инженера по искусственному интеллекту.

за пределами кампуса | холодные рассылки | без LeetCode

СТС: 44-58 LPA

Я отправил электронное письмо инженеру в @Cloudflare, мы немного обсудили вакансию и мой опыт, и через несколько дней я получил приглашение на собеседование со ссылкой для выбора времени.

Первый раунд проходил с участием ведущего штатного инженера с более чем 10-летним опытом работы и был посвящен **команде AI Workers**.

Стек искусственного интеллекта Cloudflare довольно интересен: модели запускаются на бессерверных графических процессорах по всей глобальной сети, а логический вывод осуществляется ближе к пользователям, при этом все чаще используются более крупные и передовые модели.

Я не очень хорошо знаком с этой стороной деятельности Cloudflare, поэтому мы некоторое время обсуждали, что создает команда и как они подходят к быстрому и эффективному масштабному логическому выводу с помощью ИИ.

Затем мы перешли к моему собственному опыту.

Во время стажировки я занимался развертыванием моделей, их оптимизацией и выводом данных для моделей на основе кодировщика, в основном для моделей повторного ранжирования и встраивания, которые работали на собственных графических процессорах.

Это были модели только с кодированием, в основном многослойные нейронные сети, поэтому обычный стек логического вывода больших языковых моделей ~~на основе механизма внимания~~, KV-кэша, vLLM или SGLang в этих случаях был не так актуален.

Мы довольно глубоко погрузились в тему:

как я подхожу к построению графиков и профилированию
выбору размера пакетов и оценке его влияния
масштабированию рабочих нагрузок логического вывода
выявлению узких мест в конвейере логического вывода
оптимизации задержки p50 и p99
TTFT и общей задержки отклика

Мы также обсудили, как я буду подходить к дальнейшей оптимизации после устранения очевидных узких мест.

Один вопрос мне особенно понравился:

Что для вас значит передовой искусственный интеллект?

~~Раунд прошел хорошо~~ и мы даже обсудили следующие раунды, которые включали бы практическое использование PyTorch.

В итоге не прошел. Думаю, они искали кого-то с большим практическим опытом логического вывода в больших языковых моделях. Я активно изучал логический вывод и системы на его основе, но в то время у меня не было большого практического опыта в этой области. Большая часть моей работы была связана с распределенным обучением, системами машинного обучения и инфраструктурой.

Тем не менее это был действительно полезный опыт собеседования. В ходе обсуждения я гораздо лучше понял проблемы, связанные с обслуживанием моделей искусственного интеллекта в масштабах Cloudflare.

16:03 · 9 авг. 2026 г. · **116,4 тыс.** Просмотров

16

29

1 тыс.

2 тыс.



Адितья Гхай  @aditya_ghai07 · 9 авг.

...

Я стараюсь преподавать сложные темы машинного обучения на YouTube. На этой неделе: трехчасовое глубокое погружение в распределенное обучение с нуля. FSDP, тензорное параллельное обратное распространение вручную, DeepSeek DualPipe — все с нуля, с объяснением основ. Вероятно, это будет самое полное видео о распределенном обучении [Показать полностью](#)



18

4 тыс.



Дейн Кнехт 🐼🔵 @dok2001 · 9 авг.



Продолжай идти!

1



31

3 тыс.

