

Автор: Эван Шуман
Участник

Локальная модель искусственного интеллекта от Meta заставляет компании пересмотреть соотношение затрат на оборудование и программное обеспечение

Новости

10 августа 2026 года • 7 минут

Необходимость как минимум 24 ГБ видеопамяти для запуска Muse Glimmer — лишь один из факторов, из-за которых сложно определить ценность этой игры.



Фото: Ascannio / Shutterstock

В понедельник компания Meta представила новую модель искусственного интеллекта с 30 миллиардами параметров, оптимизированную для работы на ПК или Mac с одним графическим процессором. Теперь можно запускать локальные агентские рабочие процессы без использования облака.

Компания назвала его Muse Glimmer. Однако из-за высоких требований к оборудованию, в том числе к графическому процессору с минимум 24 ГБ видеопамати, его может быть сложно масштабировать.

Хотя аналитики и консультанты сходятся во мнении, что у компаний огромный спрос на локальное выполнение моделей, вопрос о том, имеет ли смысл с финансовой точки зрения переводить больше систем из облака на локальные серверы, гораздо сложнее. Даже сегодня сложно подсчитать затраты на оборудование, поскольку объем видеопамати зависит от конкретных приложений, которые будут запускаться. Но гораздо важнее то, что невозможно предсказать, как изменятся цены на оперативную память в ближайшие 12–18 месяцев, и точно так же невозможно предугадать, как вырастут цены на облачные сервисы за тот же период.

Это делает невозможным выбор в пользу более выгодного финансового решения.

Агенты становятся капитальными, а не операционными затратами

Ноа Кенни [<https://www.linkedin.com/in/noah-m-kenney-27499a166/>], главный консультант Digital 520, отметил, что, поскольку за последние 12 месяцев стоимость оперативной памяти выросла «экспоненциально», поставщикам облачных ИИ-решений также придется повысить цены. Кроме того, ИТ-специалистам нужно предвидеть логистические проблемы. Ключевые вопросы, которые следует себе задать: «Как быстро вы сможете масштабироваться? Сможете ли вы вообще получить необходимое оборудование?»

«Meta просто превратила агентов в капитальные затраты, а не в операционные, — сказал Кенни. — В течение двух лет предприятия привыкли арендовать интеллектуальные ресурсы по токену в чужом дата-центре. Muse Glimmer запускает агента на собственном графическом процессоре, прямо на рабочем столе, и счетчик при этом выключен. Это прямой удар по бизнес-модели, на которой построены поставщики облачного ИИ, и исходит он от единственного игрока, которому не нужно защищать доходы от облачных API».

В своем посте [<https://research.meta.ai/blog/introducing-muse-glimmer-open-agentic-model>], посвященном новой модели, компания Meta отметила, что значительно упростила ее, чтобы сделать более эффективной и экономичной.

«При полной точности модель с 30 миллиардами параметров потребовала бы более 55 ГБ памяти — гораздо больше, чем может предложить любой потребительский графический процессор, — заявили в Meta. — Мы используем методы квантования, чтобы сжать веса модели примерно до 4-битной точности, уменьшив размер языковой модели до менее чем 20 ГБ. Это оставляет достаточно места для рабочей памяти модели, ее KV-кэша, кодировщика восприятия для понимания изображений и механизма спекулятивного декодирования, которые могут работать одновременно в рамках 24- или 32-гигабайтного пространства». Мы убедились, что такое сжатие практически не влияет на качество выполнения агентных задач.

Больше возможностей для предприятий

Майк Уилкс [<https://www.linkedin.com/in/eclectiquis/>], директор по информационной безопасности в компании Aikido Security, сказал, что решение Meta имеет большое значение, поскольку открывает перед предприятиями новые возможности.

«Самое важное в Muse Glimmer — это не то, что Meta создала еще одну эффективную модель, а то, что экономика и архитектура искусственного интеллекта начинают возвращаться к периферийным вычислениям, — сказал он. — Таким образом, финансовое сравнение сводится к капитальным затратам, которые можно амортизировать в течение нескольких лет, в отличие от фактически постоянных операционных расходов на облачные вычисления в пересчете на токен или запрос».

По его словам, это означает, что компания может рационально заплатить немного больше за оборудование, если это обеспечит предсказуемые затраты на ИИ,

возможность работы в автономном режиме, контроль над версиями моделей, а также защиту от внезапных изменений цен на API или доступа к ним.

Independent cybersecurity and risk advisor **Steven Eric Fisher** [<https://www.linkedin.com/in/steveneric/>] also noted that the specs published by Meta don't tell the full story.

The problem is that running locally versus in the cloud can generate a lengthy list of related expenses.

"Agentic workloads [in the cloud] can amplify consumption through reasoning, retries, tool calls, context growth, and evaluation, while local deployment [also] introduces hardware, power, lifecycle, support, and utilization costs," he said, adding that even the RAM requirements need a lot of context.

"Meta's stated 24GB and 32GB memory targets demonstrate that Glimmer can be loaded and executed on comparatively accessible hardware, but that is not the same as having sufficient capacity for meaningful agentic workloads," Fisher said, pointing out that once other factors are considered, practical memory requirements can move beyond the 32 GB available on an Nvidia RTX 5090 GPU.

"In enterprise terms, this still places Glimmer primarily in high-end developer, data science, or dedicated AI workstations rather than the standard corporate desktop or laptop," he said.

Better ROI not guaranteed

Justin Greis [<https://acceligence.com/talent/profiles/justin-greis/>], CEO of consulting firm Acceligence, agreed.

"I wouldn't assume that moving inference from the cloud to the endpoint automatically produces a lower total cost of ownership," he said, noting that variable cloud costs would be traded for the price of deployment, endpoint management, support, security, model updates, and potentially accelerated hardware refresh cycles for the local devices.

"Muse Glimmer is an important milestone because it makes local agentic AI technically viable. But technical viability and enterprise ROI are two different milestones," Greis said. "I think Meta has crossed the first one. I do not think they have fully crossed the second one yet."

However, Kenney argued that there are also other elements of the Meta rollout that make meaningful comparisons difficult.

"It is worth remembering that the local model is quantized, compressed to roughly 4-bit precision, while the cloud APIs you are comparing against typically serve full-precision models, so this is not a pure apples-to-apples cost comparison," he said. "The ROI question is not local versus cloud on price alone. It is also a question of whether a

company is willing to use a quantized model for the specific task. A cheaper agent that needs more retries or human correction can erase its savings fast.”

In addition, a local model often neglects to include every service that a cloud provider typically delivers.

“The cloud vendor was quietly handling updates, scaling, reliability, and security patching across your whole footprint. Bring the model in-house and every one of those becomes your problem, multiplied by every machine running it,” Kenney noted. “Most enterprises that consume AI as a service have no muscle for operating a fleet of local models, and that cost rarely gets adequate consideration in ROI conversations. The GPU is cheap. Patching a thousand of them is not.”

Sanchit Vir Gogia [<https://greyhoundresearch.com/svg/>], chief analyst at Greyhound Research, also stressed that it can be difficult for IT to comprehensively anticipate the different cost variables.

“Finance leaders are right to feel skeptical. An engine bought for one employee burns capital whether or not it runs. Meta has shown that a thirty-billion-parameter agent can run on a single machine, and that is a real engineering result. What it has not shown is that such an agent works reliably at enterprise scale, or that a fleet of them can be operated safely. Model fit and production fit are different claims. A laptop must still run the employee’s actual job,” Gogia said. “The economics turn on the incremental hardware premium, refresh timing and actual utilization, measured against the price of the remote inference being displaced.”

On the other hand, **Arun Chandrasekaran** [<https://www.gartner.com/en/experts/arun-chandrasekaran>], a distinguished VP analyst with Gartner, said that he found it “very interesting that they have decided to release a smaller model that operates on the edge” and especially liked Meta’s use of the popular Apache license. But he would have preferred that they had released more than just a model.

“Enterprise customers are asking for a car and Meta is delivering an engine,” Chandrasekaran said. “They should have built something more like a platform solution.”

About



Policies



More



Our Network

