

Антропный принцип: GLM-5.3 от Zhipu превосходит Claude в автономных эксплойтах

Автор: [Алексис Дюфрен](#) · Опубликовано 29 сентября 2026 г. в 22:56 UTC · Обновлено 30 сентября 2026 г. в 07:17 UTC

5 источников, отслеживающих эту историю

Антропный принцип

Китайский ИИ

Кибербезопасность

Открытый исходный код

Безопасность

ai-бизнес

AI WEEKLY PRO

Хотите, чтобы ИИ работал только с вашими данными?

Создайте агента, который отслеживает ваши компании и темы и пропускает все остальное.

[Создать своего агента →](#)

TL;DR

- NIST/CAISI независимо подтвердили, что GLM-5.3 является наиболее киберустойчивой моделью с открытым исходным кодом, и оценили отставание от передовых разработок в США примерно в четыре месяца.
- GLM-5.3 набрала 84,5 % баллов на CyberGym, в то время как Anthropic Mythos — 83,8 %. Разница настолько мала, что для большинства злоумышленников она не имеет практического значения.

[Создать своего агента →](#)

По данным [сообщений, опубликованных во вторник](#), модель GLM-5.3 от Zhipu AI разрабатывает комплексные эксплойты в 50 из 410 попыток на ExploitBench, что соответствует 56 успехам Claude Mythos Preview, и достигает «полного перехвата потока управления в 4% испытаний» на внутреннем бенчмарке компании Binary Exploitation, в то время как у Mythos этот показатель составляет 6%.

Модель выпущена с открытым исходным кодом.

Паритет важен, потому что встроенные в GLM-5.3 механизмы отказа не выдерживают столкновения с противниками. Исследователи Anthropic сообщают, что при использовании вводящих в заблуждение подсказок вредоносные запросы выполнялись в 64% случаев, при использовании заранее подготовленных обоснований — в 92% случаев, а после «обнуления» — в 100% случаев. «Обнуление» — это метод, при котором из модели с открытым кодом удаляются механизмы отказа. Модели Claude «оставались на уровне 0%» при тех же условиях тестирования.

Для создания «обнуленной» версии потребовалось около 2200 часов работы на графическом процессоре, или примерно 4400 долларов, при этом процент отказов снизился с более чем 90% до 3–12%, а основные возможности модели сохранились. «Несколько разработчиков опубликовали обнуленные версии GLM-5.3 в течение нескольких дней после выхода модели», — пишут авторы.

В ходе реального тестирования GLM-5.3 объединила несколько ранее неизвестных уязвимостей в движке JavaScript веб-браузера в работающий эксплойт «в течение дня (и при минимальном участии

[Создать своего агента →](#)

Эндрю Фазано, Мариус Флейшер, Коул Макфол, Роберт Сяо и Трипп Галлахер называют этот релиз «значимым шагом вперед в расширении кибервозможностей злоумышленников» и предупреждают, что GLM-5.3 «скорее всего, предоставит злоумышленникам доступ к возможностям, которые позволят им находить и использовать уязвимости в киберсистемах без каких-либо значимых ограничений». В публикации не объясняется причина, по которой Zhipu выпустил эту версию, и не приводится ответ компании.

ПРИМЕЧАНИЕ РЕДАКТОРА

Независимая оценка NIST / CAISI и команда Anthropic Frontier Red пришли к такому же выводу с помощью разных методологий: GLM-5.3 опережает границу США примерно на четыре месяца, и его гарантии могут быть полностью сняты за 4400 долларов в вычислениях на графическом процессоре. Преступные организации и государственные структуры среднего звена теперь имеют свободный доступ к созданию автономных эксплойтов на ближнем востоке, и любая команда безопасности, откалиброванная на закрытую модель угроз, работает на ложном базовом уровне.

МНЕНИЕ РЕДАКТОРА

Ближайший тест покажет, будут ли удаленные производные GLM-5.3 обнаруживаться в телеметрических данных реагирования на инциденты или в инструментах для обнаружения вторжений, а не только в результатах эталонных тестов. Если следующая версия Z.ai будет иметь те же характеристики, то базовый уровень кибербезопасности снова изменится.

- Будет ли следующая модель Zhipu оснащена защитой от отказа в обслуживании после обучения, устойчивой к предварительной

[Создать своего агента →](#)

генерируемые агентами, учитывая, что, согласно документации Anthropic, их стоимость составляет 20 долларов и восемь часов работы?

AI WEEKLY PRO

Мы сканируем весь ИИ. Вы отслеживаете его часть.

Создайте агента, который будет следить только за теми компаниями, темами и людьми, которые вы выберете. Он считывает все данные, полученные нашими сканерами, и отправляет вам подборку, состоящую только из ваших совпадений.

[Создайте своего агента →](#)

7 долларов в месяц за первых 2000 участников.

ЧТО СООБЩАЮТ ДРУГИЕ

Кластер охвата по состоянию на 8 часов после публикации

1 [Национальный институт стандартов и технологий](#) [Читать →](#)

Независимая государственная оценка с использованием стандартизированных контрольных показателей и методологии IRT; количественная оценка отставания от передовых технологий США на 4 месяца с прозрачными и воспроизводимыми результатами.

GLM-5.3 — самая «киберустойчивая» из открытых моделей на сегодняшний день.

2 [Актуальные темы](#) [Читать →](#)

Добавляет экспертного скептицизма (Джейк Уильямс отвергает эту угрозу) и акцентирует внимание на конфликте интересов: Anthropic — единственная крупная лаборатория, которая отказалась подписать отраслевое письмо в поддержку открытого исходного кода.

Создать своего агента →

3 **Tech Insider** Читать →

Отмечает, что результаты CyberGym публикуются самостоятельно, без участия нейтральной третьей стороны; связывает разрыв в возможностях с контролем за экспортом чипов между США и Китаем и нормативными препятствиями.

Разница в баллах была незначительной: 84,5 % против 83,8 % в тесте CyberGym, но по времени GLM-5.3 оказался в центре более масштабной борьбы.

4 **«Безумный робот»** Читать →

Акцент на практической доступности: удаление ограждений с помощью абляции обходится примерно в 4400 долларов и снижает процент отказов с 90+ до 2%. Абляцированные версии были опубликованы в открытом доступе в течение нескольких дней.

GLM-5.3, новейшая модель с открытым исходным кодом от китайской компании Zhipu AI, может создавать работающие киберинструменты почти так же хорошо, как Claude Mythos

ОПУБЛИКОВАНО НА BLUESKY 6 ЭКСПЕРТАМИ В ОБЛАСТИ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА (5 ЛУЧШИХ ПО УРОВНЮ ДОВЕРИЯ)

☐ **@emollick.bsky.social** Итан Моллик :

Если не принимать во внимание стимулы Anthropic к публикации этого исследования, нет никаких сомнений в том, что модели с открытыми весами вскоре создадут такую же безопасную среду для обучения, как и модели с закрытыми весами. →

☐ **@timkellogg.me** Тим Келлог :

Компания Anthropic публикует подробное исследование GLM-5.3 в качестве альтернативы Fable в сфере кибербезопасности www.anthropic.com/research/gl... →

☒ **YY Ahn** @yyahn.bsky.social **AMPLIFIED**

☐ **Итан Моллик** @emollick.bsky.social

Если не принимать во внимание стимулы Anthropic к публикации этого исследования, нет никаких сомнений в том, что модели с открытым исходным кодом вскоре создадут те же угрозы безопасности, что и модели с закрытым исходным кодом, только без...

[Посмотреть на Bluesky →](#)

[Создать своего агента →](#)

но именно это они и сделали. www.anthropic.com/research/glm... В отличие от Mythos, у меня действительно есть шанс использовать GLM для исследовательских целей. Anthr...

[Посмотреть на Bluesky →](#)

 **Doll** @dollspace.gay **AMPLIFIED**

[@scarnecchia.net](#)

Anthropic прямо-таки нагнетает страх по поводу моделей с открытым исходным кодом, которые сейчас пожинают плоды своей ценовой политики

[Посмотреть на Bluesky →](#)

Originally reported by **anthropic.com**

[Read the original article →](#)

Original headline: Anthropic Warns Zhipu's GLM-5.3 Is Most Cyber-Capable Open-Weight Model Yet, Shipped With No Safeguards

AI WEEKLY PRO

This one found you. The next one might not.

Name the companies, topics and people you follow. Your agent watches them across every source we scan and sends you an edition when something lands.

Build your agent →

\$7/month for the first 2,000 members.

Отслеживайте только тот ИИ, который важен для вас

Создать своего агента →