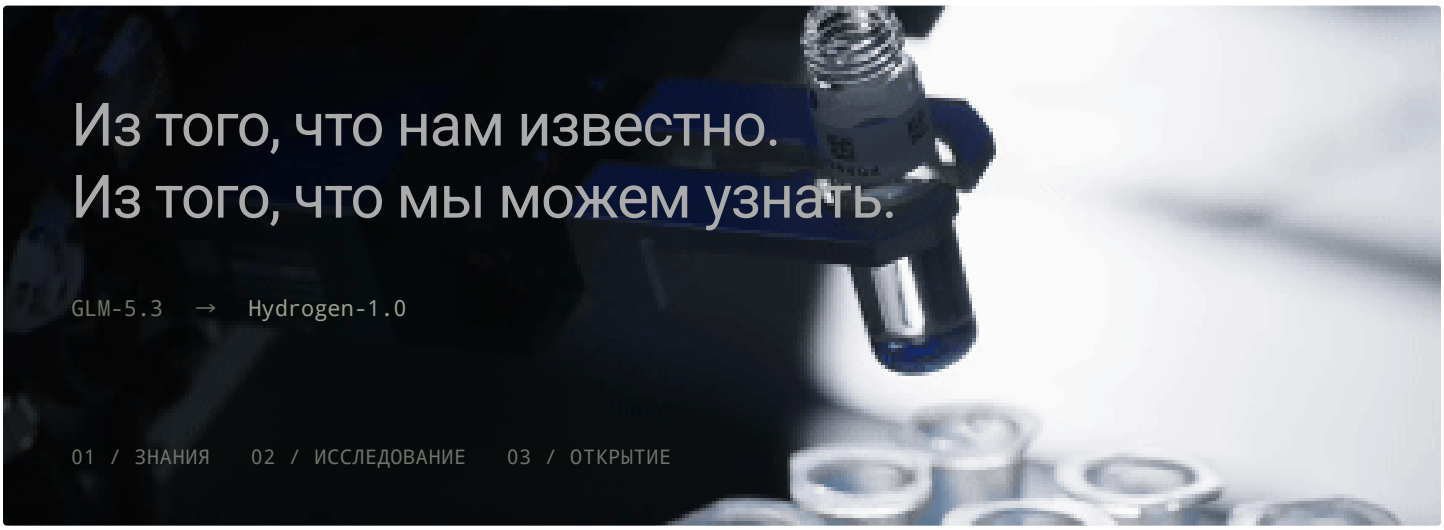
Представляем Hydrogen-1.0

Начало пути к сверхразуму для научных открытий



Научная постдипломная подготовка опирается на знания в предметной области, лабораторные записи и траектории научных открытий.

Сегодня мы представляем Hydrogen-1.0 — научную модель, созданную на основе пост-обучения GLM-5.3 с использованием предметных данных из области химии, материаловедения и наук о жизни, а также записей и траекторий агентов из наших собственных лабораторий.

Перейти к статье

Большие языковые модели начинают вносить свой вклад в научные открытия. Компания OpenAI сообщила о доказательстве сингулярности конечного времени в уравнениях Навье — Стокса, полученном с помощью ИИ и сопровождаемом формализацией Lean. Компания Anthropic выявила ферментную систему с CRISPR-подобными повторами с помощью геномного анализа и лабораторных исследований. Эти достижения показывают, как модели могут помочь исследователям изучать сложные проблемы, замечать незнакомые закономерности и разрабатывать идеи, которые можно проверить с помощью математических методов или экспериментов.

Однако модели, лежащие в основе этих примеров, являются проприетарными: их возможности по обнаружению закономерностей не представлены в виде открытых весов, а некоторые из них даже недоступны через публичный API. Создание сопоставимых, воспроизводимых научных открытий с помощью универсальных моделей с открытыми весами остается важным аспектом. Эффективная открытая модель позволила бы исследователям изучать и адаптировать базовую систему, тестировать ее методы и опираться на общие улучшения.

Совместный научный прогресс помогает связать гипотезы с фактическими данными. Моделирование и лабораторные эксперименты дают обратную связь по модельным гипотезам. Записи о гипотезах, действиях, наблюдениях и изменениях, включая неудачные попытки и неожиданные результаты, позволяют моделям понять, как исследовательские решения приводят к определенным результатам. Сохранение этого контекста позволяет связать общие возможности моделей с требованиями научной работы.

Hydrogen-1.0 применяет этот подход в химии, материаловедении и науках о жизни. Он обучается на основе научных знаний, лабораторных записей и траекторий открытий, чтобы связать рассуждения с решениями, принимаемыми в ходе исследований. Наша цель — создать модель с открытым весом, которая поможет ученым формулировать вопросы, разрабатывать информативные эксперименты и использовать полученные данные для дальнейших открытий.

01 Научное мышление ↗
Отправная точка для научной специализации.

02 Научные сценарии на практике ↗
Решения в области химии и материалов, которые имеют значение на практике.

03 Экспериментальный жизненный цикл ↗
От намерения до плана, протокола и анализа.

04 Открытые исследования ↗
Учимся выбирать, что пробовать дальше.

Перейти к статье

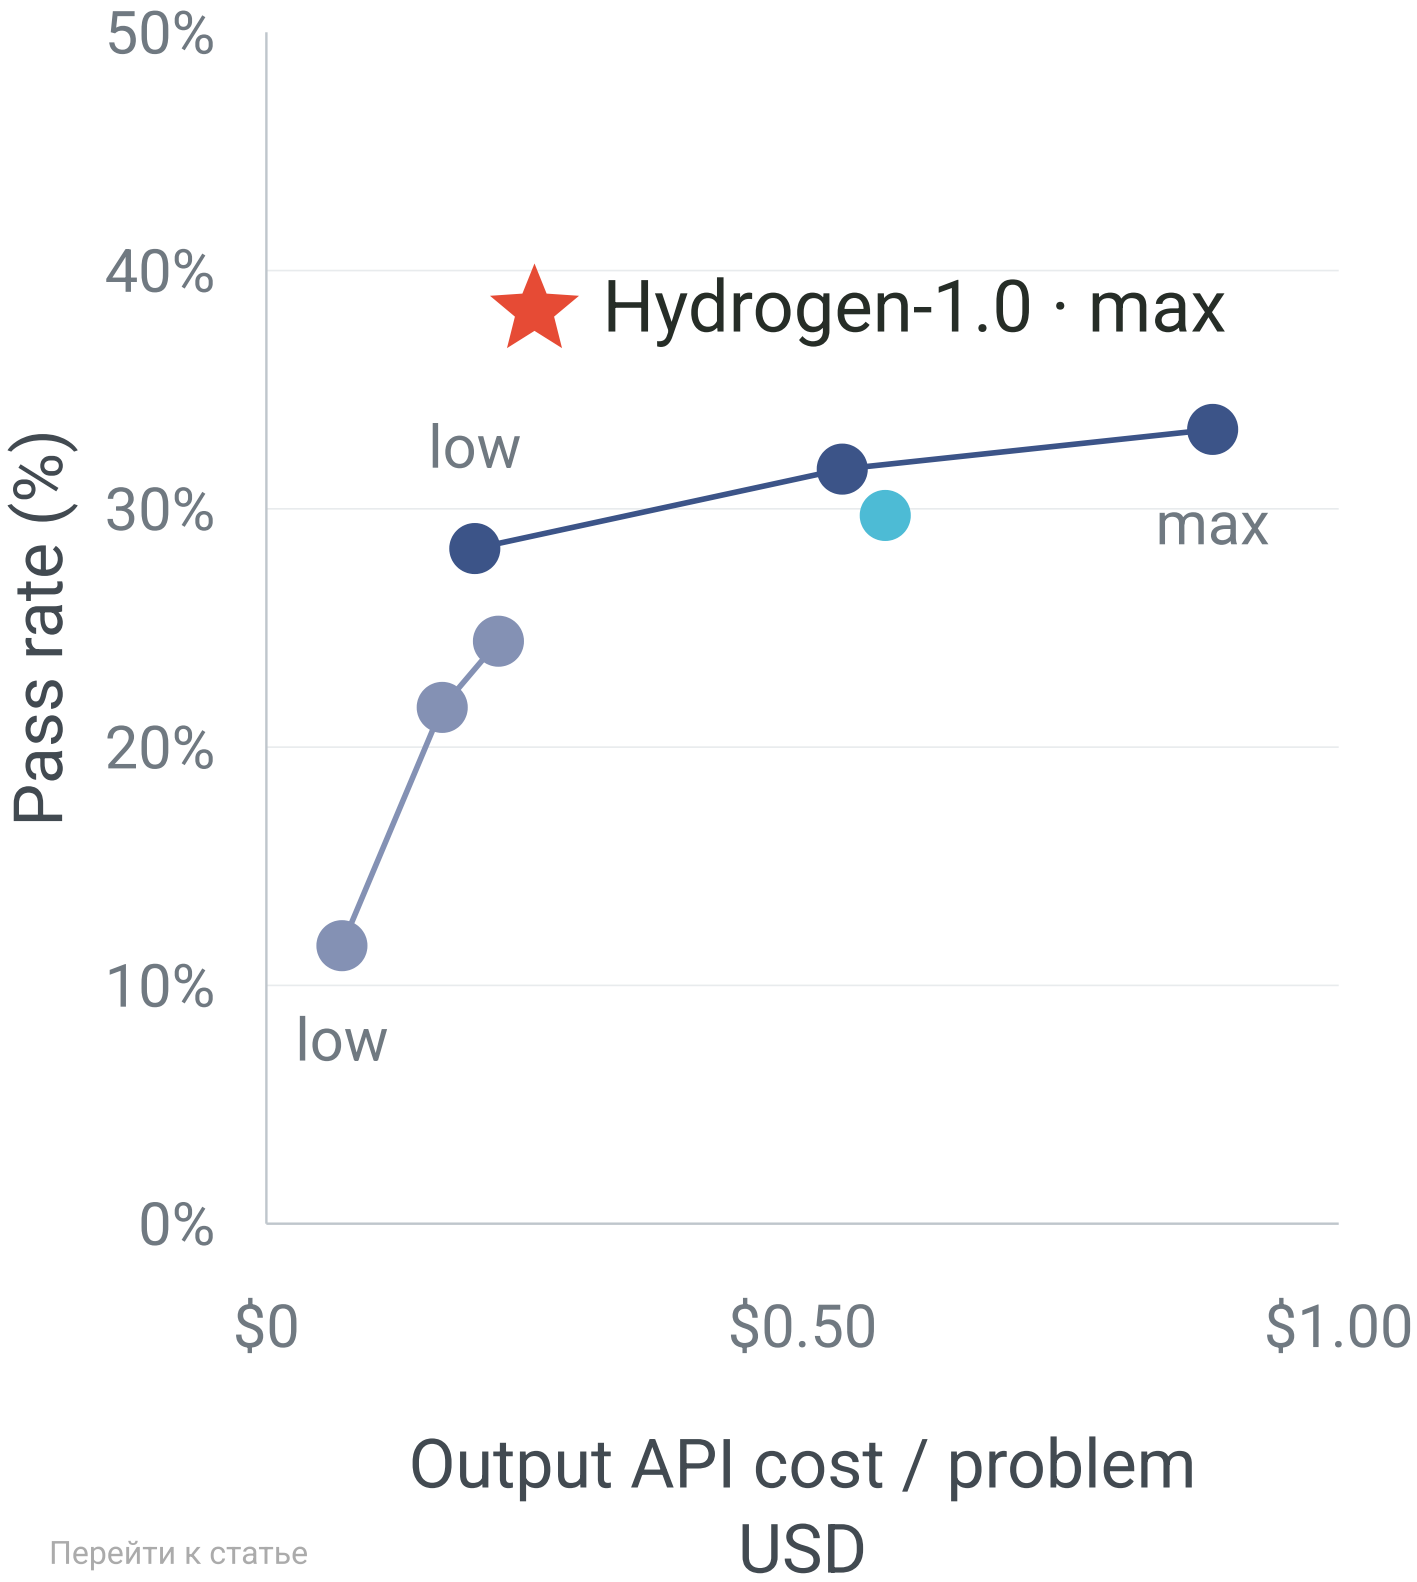
Научное мышление на основе открытого фундамента

Hydrogen-1.0 превосходит GPT-6-Astra в FrontierScience-Research (FSR) и GLM-5.3 в GPQA-Diamonds в наших оценках, примерно соответствуя открытой передовой модели Kimi-K3. Тесты проверяют научные знания и способность рассуждать на сложные научные темы. Успехи в обоих тестах подтверждают, что пост-обучение способных моделей с открытым весом может стать основой для практических исследований.

Перейти к статье

FrontierScience Research

FrontierScience Research проверяет, способна ли модель решать незнакомые многоэтапные исследовательские задачи в области физики, химии и биологии.



Перейти к статье

Научное обоснование после дообучения в предметной области. **Рисунок 1.** Производительность в сравнении со средней стоимостью API на стороне вывода для Hydrogen-1.0, его начальной контрольной точки GLM-5.3 и эталонных моделей Kimi K3 и GPT-6 Astra на FrontierScience Research (проходность) и GPQA Diamond (точность). При расчете затрат используются стандартные тарифы на выходные токены в долларах США, включая обоснование; для Hydrogen-1.0 используется ценообразование GLM-5.3. Затраты на ввод данных и оценку не учитываются. Чем выше оценка, тем лучше производительность.

Научные сценарии на практике

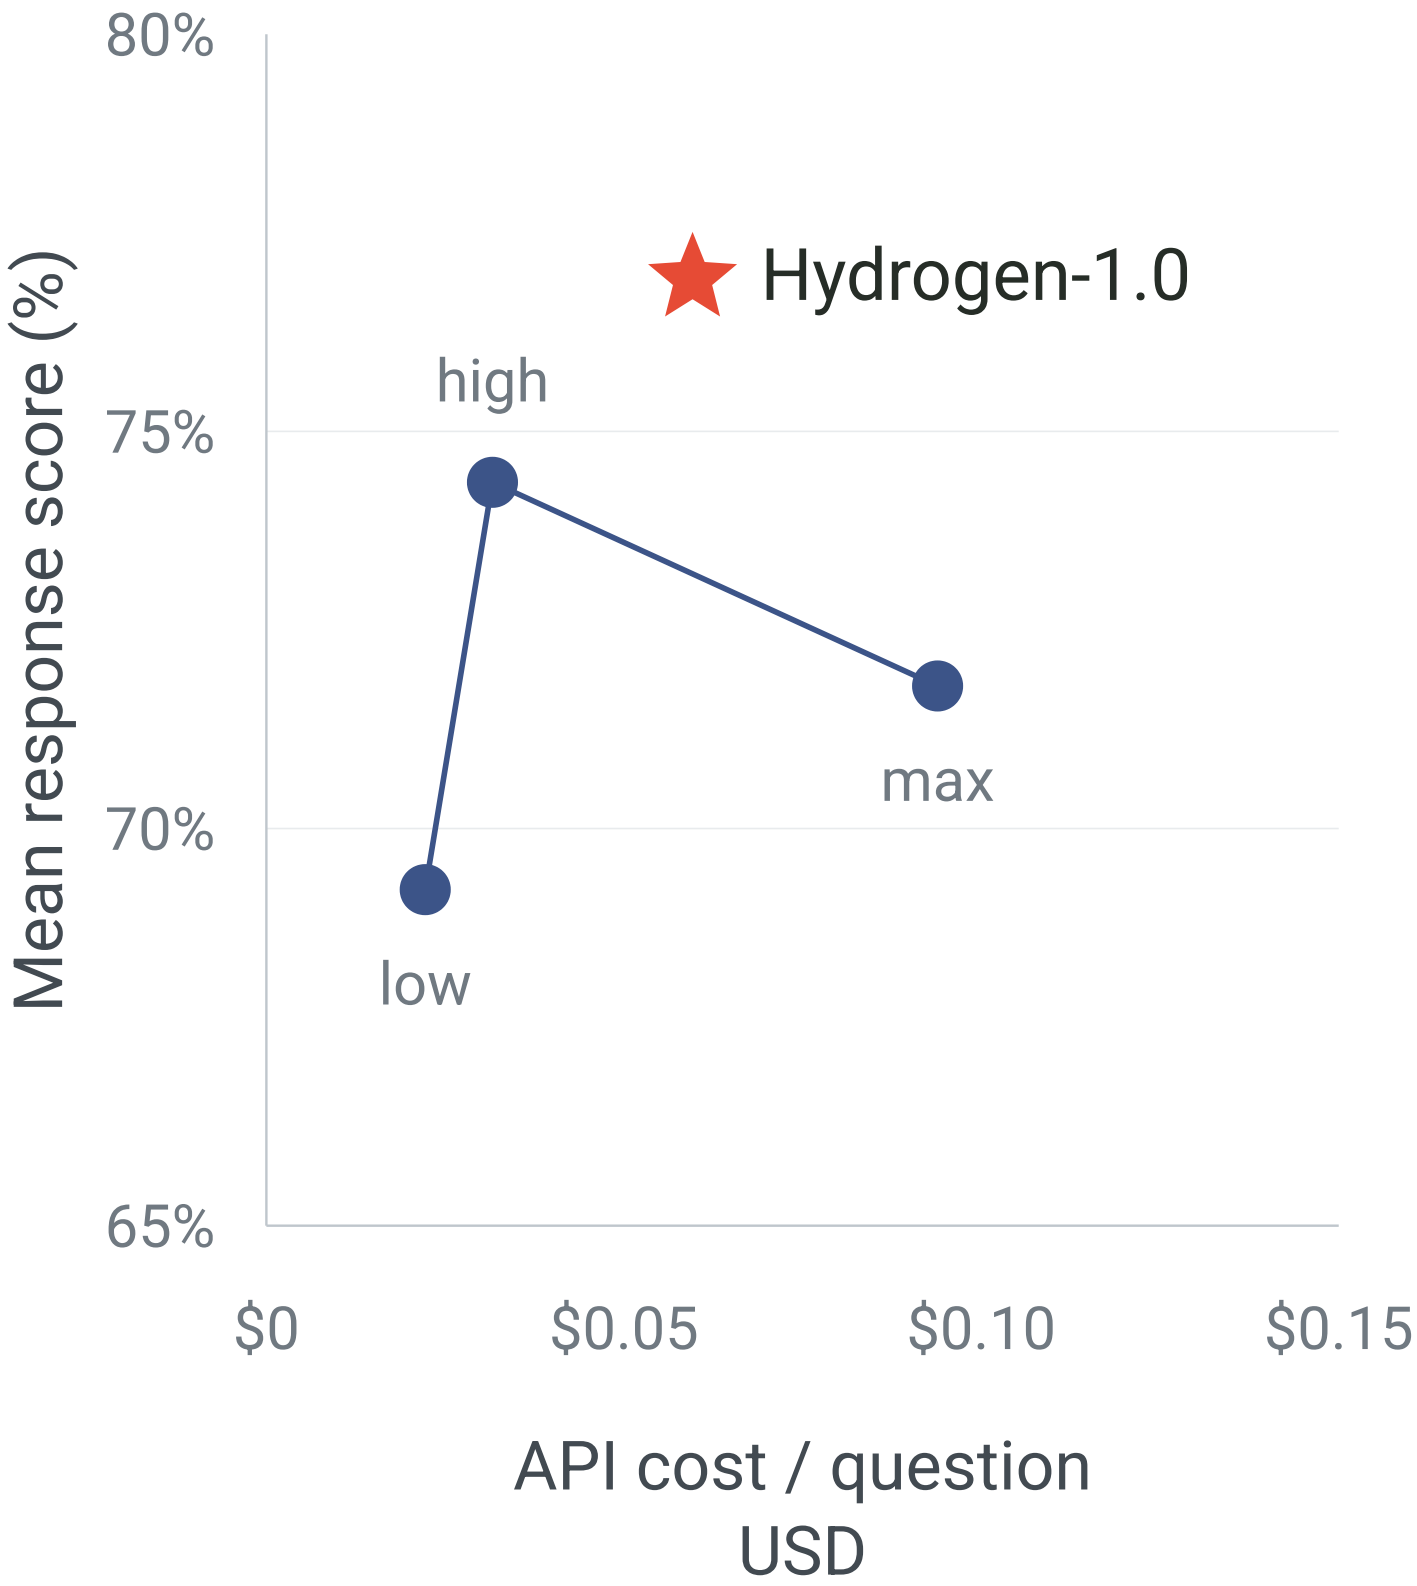
Общенаучные знания становятся полезными, когда модель может сделать правильный прогноз или принять верное решение в конкретной исследовательской среде. В ходе наших внутренних оценок мы сравнивали Hydrogen-1.0 и GPT-6-Astra в области научных вычислений, прогнозирования одностадийных реакций и определения структуры методом ядерного магнитного резонанса — в сценариях, с которыми часто сталкивается наша внутренняя исследовательская группа.

По этим показателям Hydrogen-1.0 превосходит GPT-6 Astra в научных вычислениях и прямых реакциях при каждом из трех режимов мышления. По сравнению с Astra в режиме максимального мышления его преимущество составляет **5,13 и 4,76 процентных пункта** соответственно. Astra в режиме максимального мышления по-прежнему опережает Hydrogen-1.0 в определении структуры методом ядерного магнитного резонанса на 3,33 балла. На рисунке эти показатели сравниваются со средней стоимостью ответа на вопрос. Различия в абсолютных показателях по разным заданиям отражают сложность внутренних кейсов и не должны восприниматься как прямое сравнение возможностей моделей.

Перейти к статье

Научные вычисления

В научных вычислениях используются численные методы и программное обеспечение для моделирования при изучении молекул и материалов.

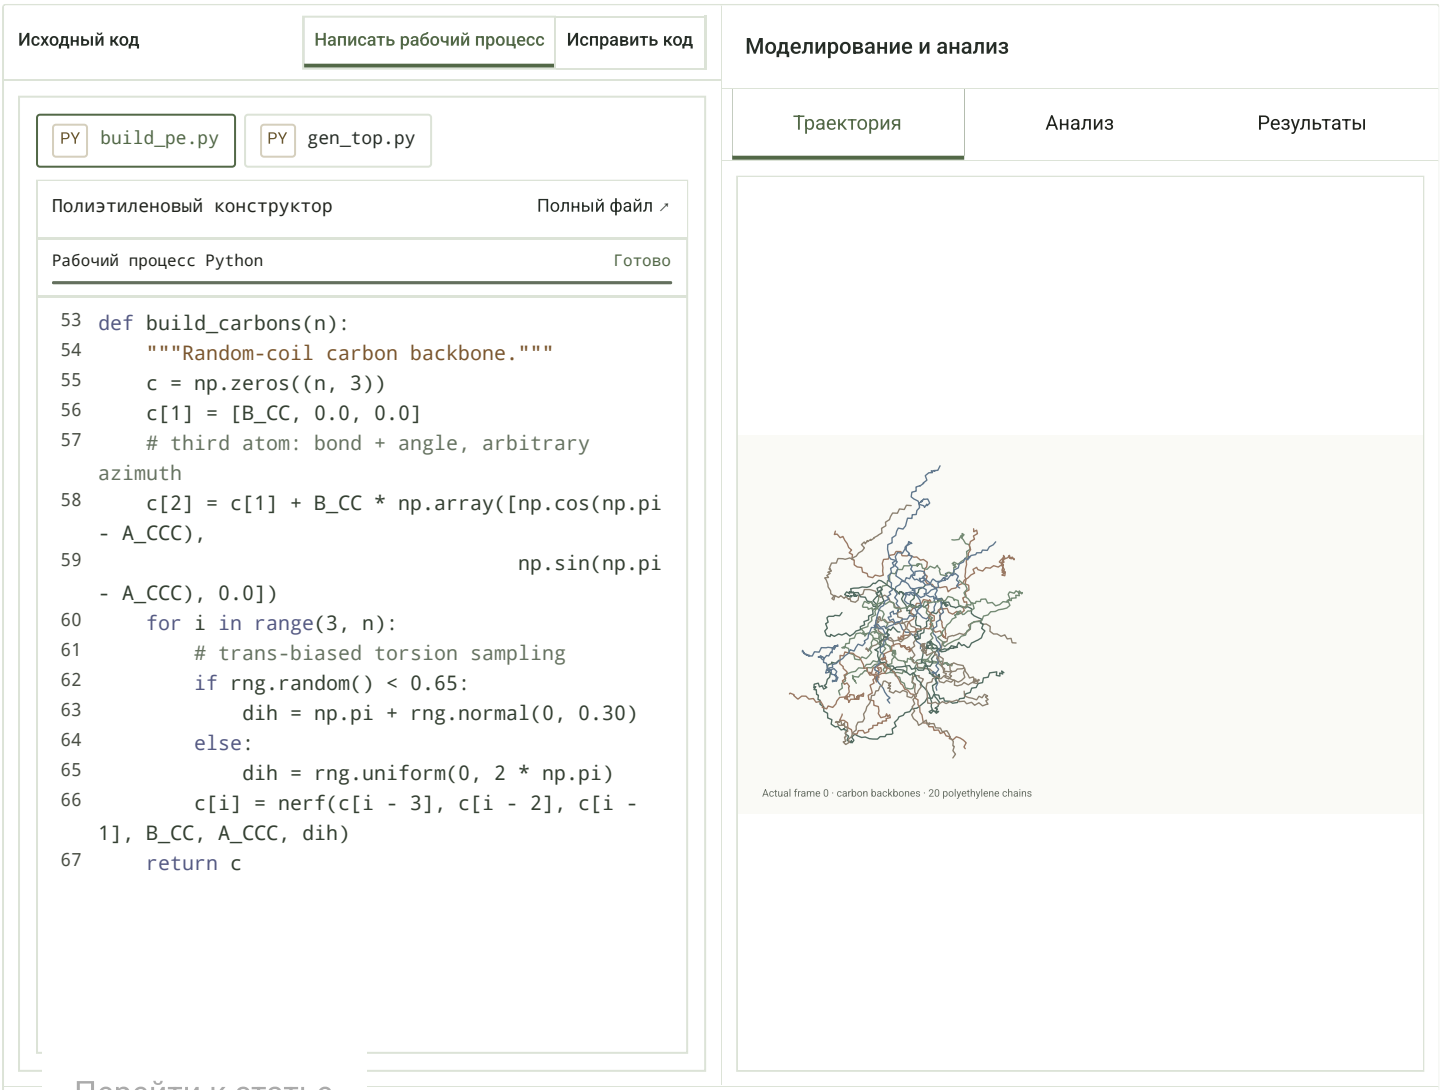


Перейти к статье

Производительность и стоимость при выполнении исследовательских задач. **Рисунок 2.** Средний балл за ответ в сравнении со средней стоимостью API за вопрос для Hydrogen-1.0 и GPT-6 Astra при низком, среднем и максимальном уровне мышления. При расчете стоимости используются стандартные тарифы на ввод и вывод данных в долларах США, включая скидки за рассуждения и использование кэша; для Hydrogen-1.0 используется ценовая политика GLM-5.3. Более высокие баллы указывают на лучшую производительность. Некоторые вопросы адаптированы из нашей предыдущей работы «Оценка научных открытий» (Scientific Discovery Evaluation, SDE).

Написание, отладка и запуск рабочего процесса молекулярной динамики полимеров

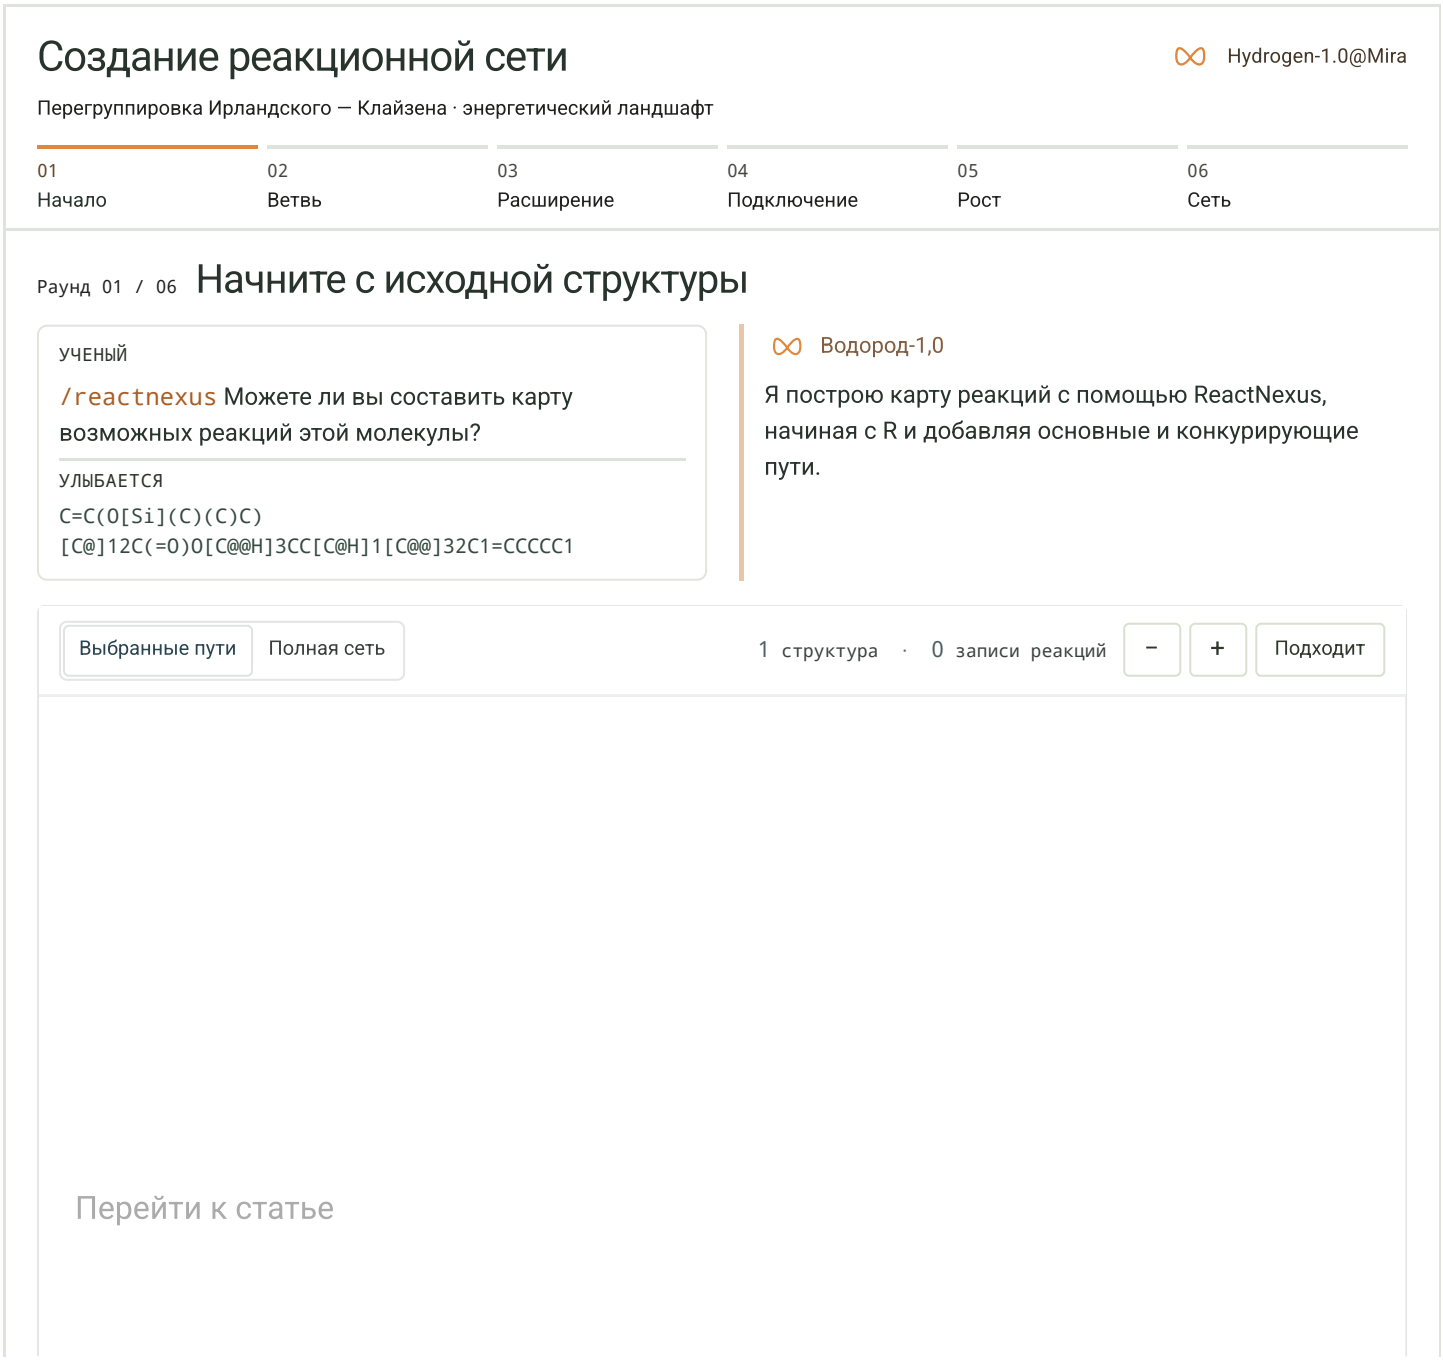
Hydrogen-1.0 превращает вопрос о материалах в рабочий процесс моделирования. В этом примере он пишет код на Python для создания расплава полиэтилена, запускает GROMACS, обнаруживает и исправляет ошибку топологии, а затем перезапускает моделирование. После этого он исследует исправленную траекторию длиной 40 нс, а также ее плотность, молекулярную упаковку, диффузию и размеры цепей.



Создайте и запустите симуляцию полиэтилена в GROMACS, а затем визуализируйте его структуру и свойства.

Расширение реакционной сети

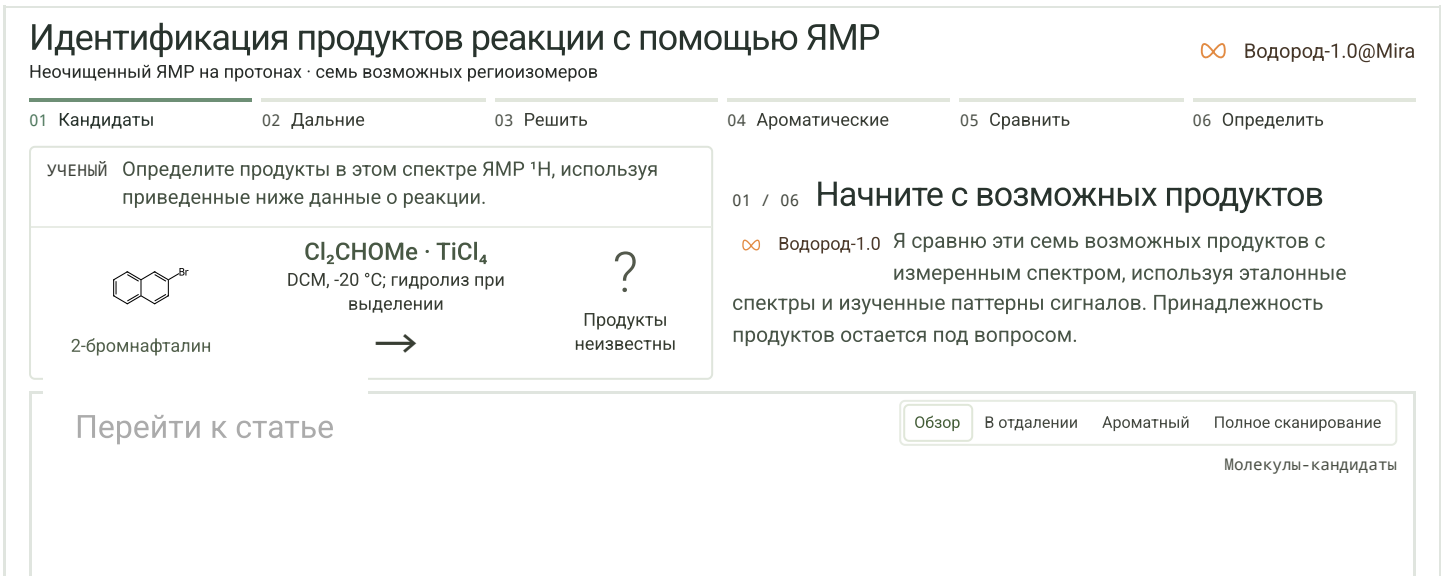
Научные исследования редко ограничиваются одним продуктом. Hydrogen-1.0 исследует сеть перегруппировок по Ирланду — Клайзену (IC), генерируя 27 молекулярных структур в результате 30 возможных реакций. Сеть включает в себя конкурирующие ветви и обратные пути, связанные с пятиступенчатой последовательностью перегруппировок по Коупу и Клайзену и силильных сдвигов. В выбранном для сравнения примере основной путь имеет более низкий электронный барьер, чем его альтернативный вариант на каждом этапе, в то время как у некоторых альтернативных вариантов барьеры примерно одинаковые. Сопоставление этих возможностей помогает исследователям выявлять потенциальные узкие места, сравнивать конкурирующие маршруты и определять приоритетные направления для дальнейшего изучения.

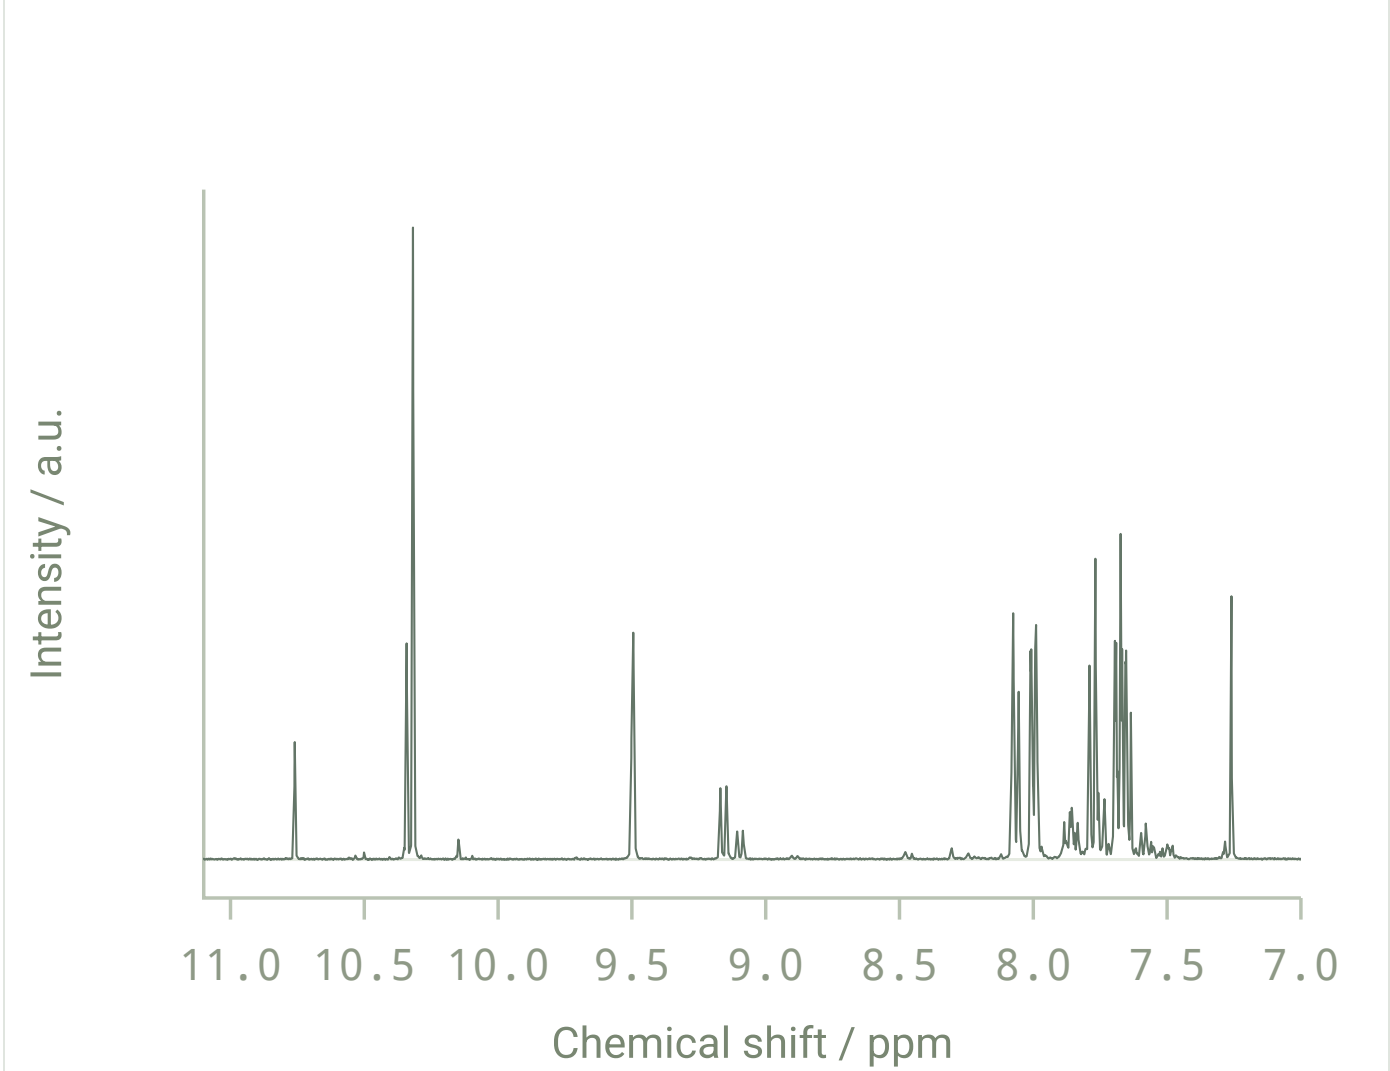




Определение структуры по спектру ЯМР

Реакционная сеть позволяет предположить, что может образоваться, а измеренный спектр помогает установить, что содержится в образце. В данном случае Hydrogen-1.0 начинает с семи возможных продуктов моноформилирования 2-бромнафталина и анализирует предоставленный спектр ЯМР ¹H, изучая сигналы в слабом поле и насыщенную ароматическими соединениями область, прежде чем оценить возможные структуры.





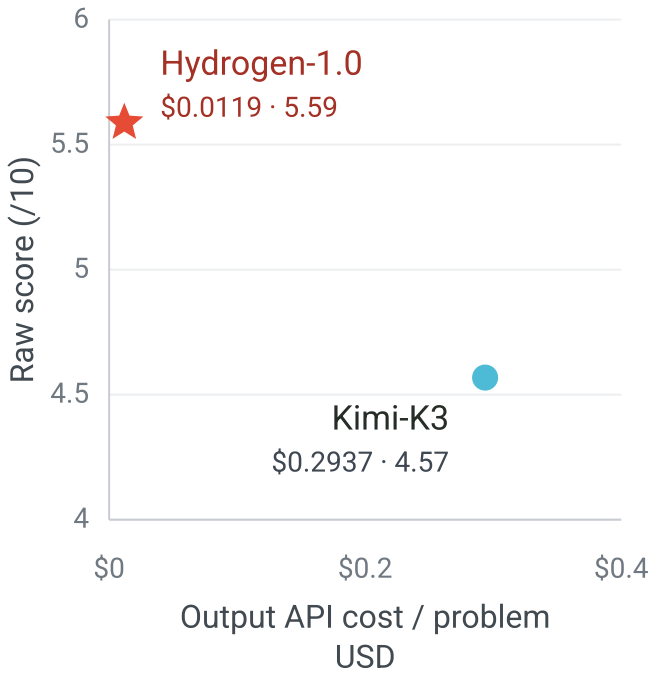
Извлечение уроков из всего эксперимента

Лабораторный журнал наиболее информативен, когда цель, процедура, наблюдения и результат остаются взаимосвязанными. Наши электронные лабораторные журналы (ELN), дополненные автоматизированной документацией Mira, сохраняют контекст на протяжении всего жизненного ци еный, как проводился эксперимент, что произошло и что исследовать да

Перейти к статье

Анализ этих записей повышает способность Hydrogen-1.0 преобразовывать запрос в одно предложение в план эксперимента, генерировать точные протоколы и интерпретировать результаты. Приведенное ниже сравнение демонстрирует преимущества Hydrogen-1.0 в планировании лабораторных экспериментов.

Experiment design and planning



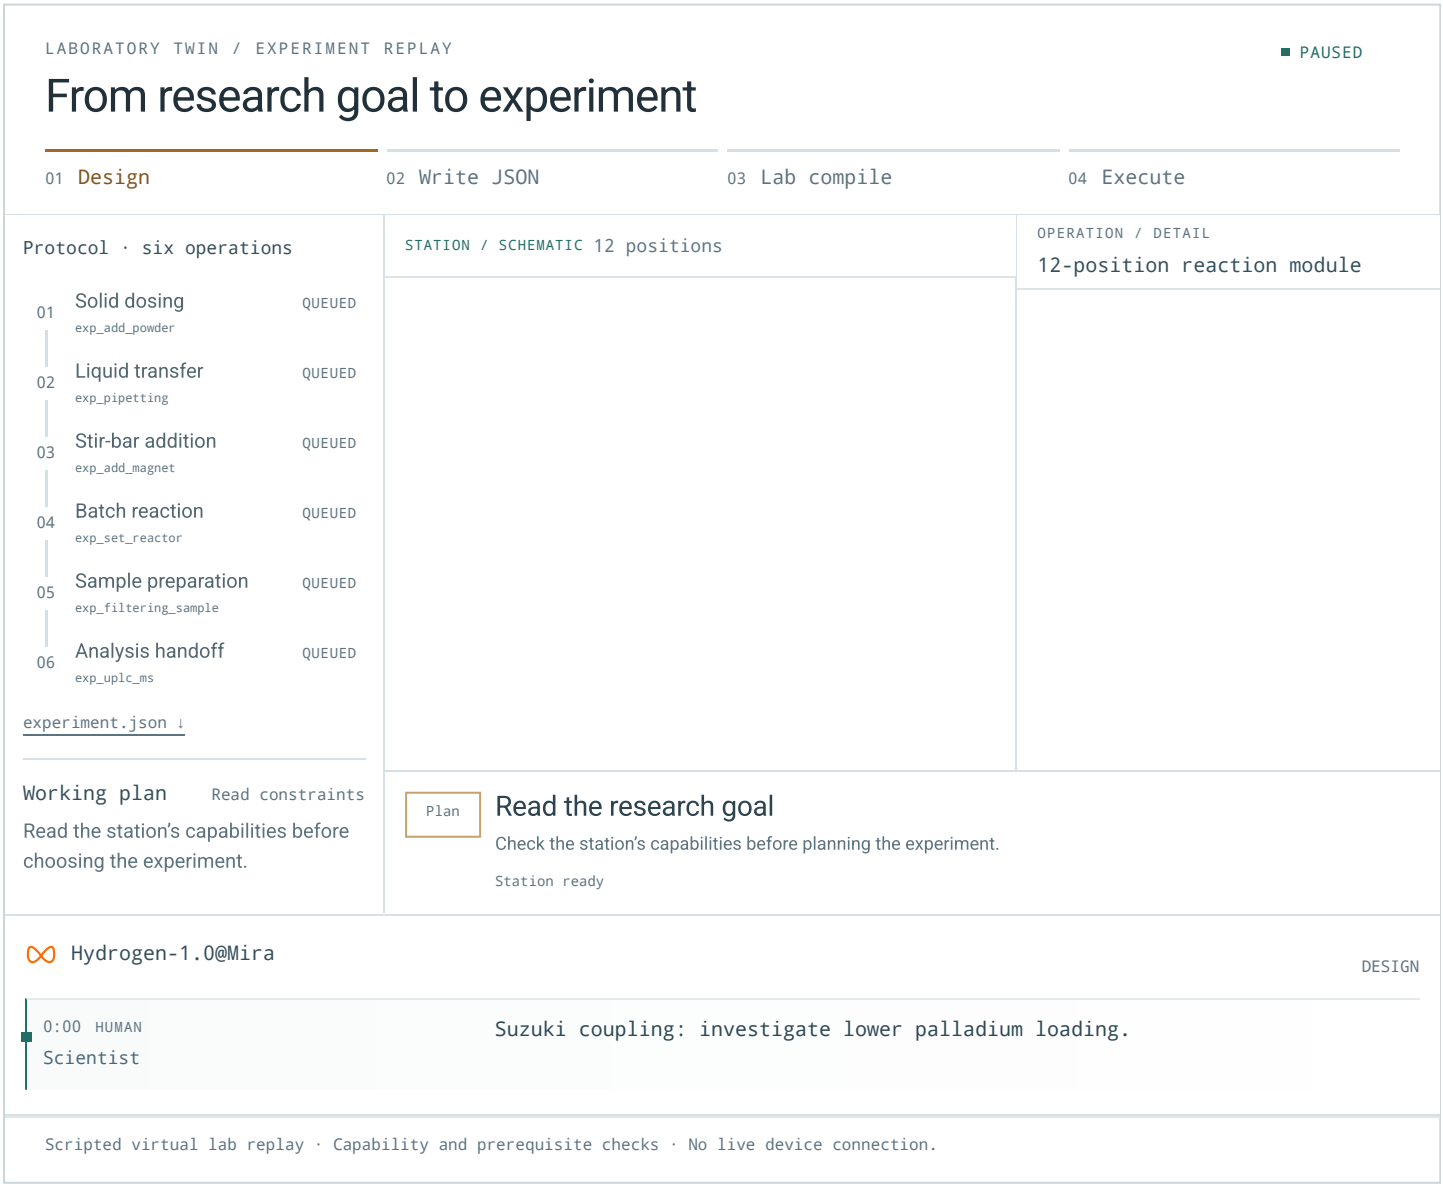
Разработка и планирование эксперимента. Рисунок 3. Средняя оценка по критериям (/10) в сравнении со средней расчетной стоимостью API для решения одной задачи для Hydrogen-1.0 и Kimi-K3 на основе 117 общих вопросов. При расчете стоимости использовались те же коэффициенты стоимости выходного токена в долларах США, что и на рисунке 1, включая обоснование; затраты на ввод данных и оценку не учитывались. Обе модели используют общий токенизатор. GPT-6-Astra и Opus-5.5 не включены в исследование, поскольку они отклонили более 50 % запросов. Чем выше балл, тем лучше результат.

От цели исследования до лабораторного эксперимента — через лабораторную компиляцию

По мере того как научные агенты переходят от предложения экспериментов к их проведению, их протоколы должны превращаться в проверяемые инструкции для конкретной лаборатории. Ограничения, связанные с оборудованием, состояние инструментов и порядок действий — все это вли ализации плана. Лабораторная компиляция проверяет эти требования в вид агенту возможность выявить ошибки, исправить инструкции и повторить попытку, прежде чем задействовать лабораторные ресурсы.

Перейти к статье

Hydrogen-1.0 создает протокол в формате JSON для исследования реакции Сузуки с использованием 12 пробирок. Виртуальная репетиция выявляет попытку аспирации без использования нового наконечника. Hydrogen-1.0 исправляет порядок действий и успешно компилирует измененный протокол перед окончательным выполнением и передачей результатов анализа. Локальные проверки охватывают возможности станции, зависимости и предварительные условия для выполнения действий. Выявление этих ошибок до начала выполнения действий помогает решить проблемы безопасности, связанные с повышением автономности ИИ в лаборатории.



Learning to discover new materials

Open-ended discovery requires choosing what to try when the answer is unknown. Scientists form hypotheses about a material, choose how to synthesize or evaluate it, and revise their expectations after seeing the result. We plicit discovery trajectories to learn these connections between choices, pro ies, and outcomes.

Перейти к статье

Turning trajectories into scientific intuition

We study whether this learning improves decisions on held-out material families: which candidate to explore, which synthesis path to consider, and which observation would be most informative. In transition metal complex (TMC) design, we examine how effectively a model uses successive evaluations to find complexes with a larger HOMO–LUMO gap.

In this comparison, each model starts from the same initial population and recommends new TMCs in each of five rounds. Then their paths diverge. Each model receives only the results of its own recommendations as feedback for the next round, keeping the evaluation histories independent. By round five, the mean best-so-far gap reaches **4.318 eV for Hydrogen-1.0**, compared with 3.689 eV for GPT-6-Astra and 3.353 eV for Kimi-K3. These results demonstrate the promise of finding materials with desired properties in fewer attempts.

```
Loading molecular search results…
```

How we train Hydrogen-1.0

Our training pipeline combines supervised fine-tuning (SFT) and reinforcement learning (RL) to help Hydrogen-1.0 learn from scientific work. We draw on domain data, task-specific feedback from our scientists, laboratory records, and complete discovery trajectories. SFT provides worked examples of reasoning, experiment planning, protocol design, and results analysis. RL trains the model to make better decisions using feedback on research outcomes.

01	Domain knowledge	Chemistry, materials science, and life sciences data build the scientific foundation.
02	Research scenarios	Task-specific feedback from our scientists sharpens decisions on research problems.
03	Laboratory records	Full-cycle records let the model learn how experiments unfold, not just their outcomes.
04	Discovery trajectories	Sequences of choices and feedback teach the model how to explore under uncertainty.

Full-model MoE post-training places different demands on the same hardware: optimizer state consumes memory during updates, long sequences retain activations, and a few lengthy RL responses can delay a rollout round. Building on Megatron and SGLang, our infrastructure adapts parallel execution and state placement acr ıD ROCm to support both SFT and RL.

Перейти к статье

SFT infrastructure RL scheduling

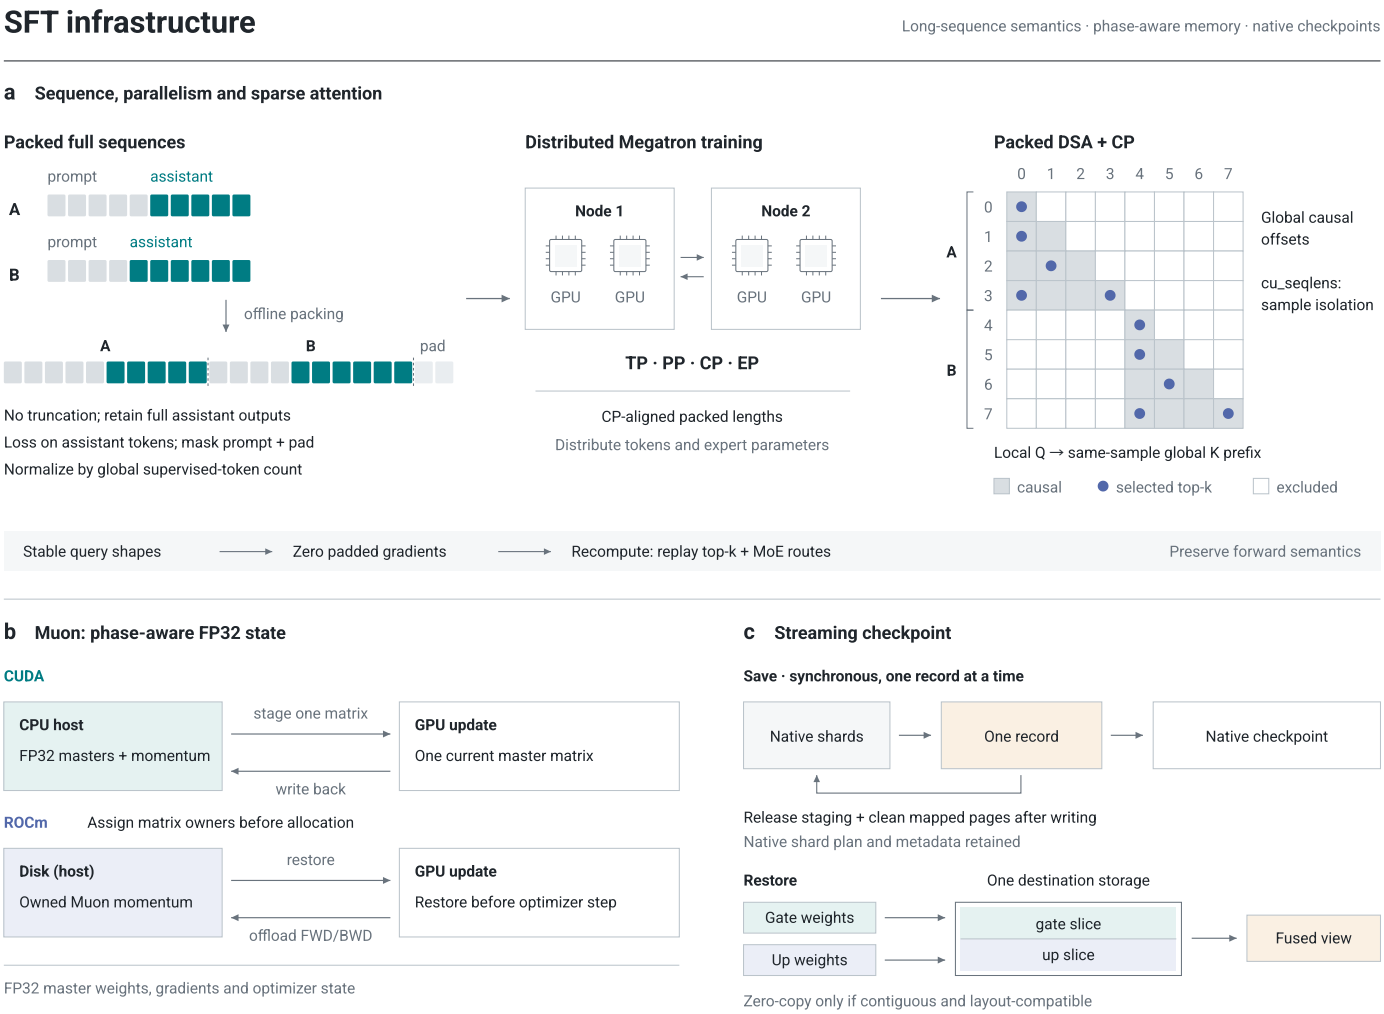


Figure 4. Distributed infrastructure for full-model supervised fine-tuning. Complete sequences are packed for Megatron training with tensor, pipeline, context and expert parallelism. The schematic shows causal sparse attention within each sample, optimizer state placement across CUDA and ROCm, and checkpoint records written individually and restored into shared storage. Hardware layouts and memory sizes are schematic.

Long-sequence training within memory limits

Preserving long-sequence supervision.

Ke Перейти к статье **ausal across shards.**

Moving Muon state with the computation phase.

Checkpointing within host-memory limits.

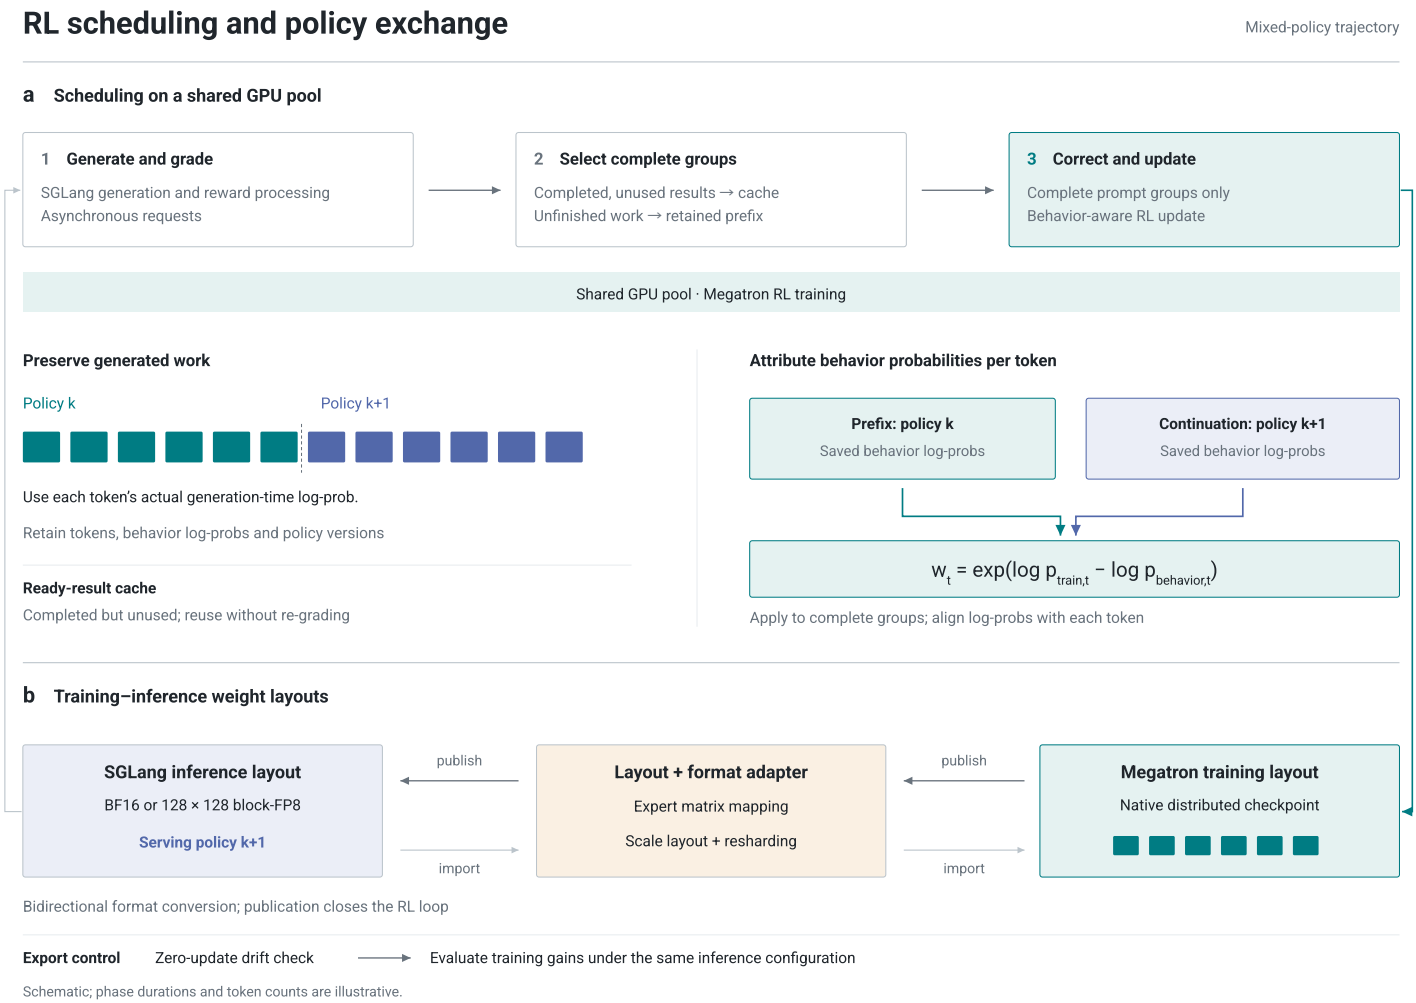


Figure 5. Resumable reinforcement learning on shared GPUs. Complete prompt groups enter training; unfinished responses retain their prefixes for a later rollout round. Token colours distinguish generating policies, and each token retains its original behaviour log-probability. Updated weights pass through a layout adapter before generation resumes. Two rounds are illustrated; durations and token counts are schematic.

Resumable rollouts and policy exchange

Alternating rollout and training

Перейти к статье

Co[illegible]t generated each token.

Controlling the training–inference boundary.

Availability

Hydrogen-1.0 is available through four access routes:

- Hugging Face — download the open weights.
- ModelScope — download the open weights.
- NeuroSpark — access the model directly through an API.
- Mira — use Hydrogen-1.0 in our AI Scientist.

Toward continually growing scientific intelligence

Hydrogen-1.0 connects domain knowledge and reasoning, concrete research scenarios, experimental workflows, and finally, new materials discovery. Our results suggest that the scientific data we choose and the feedback we preserve can substantially extend what a model is able to do in science.

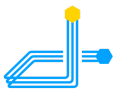
Our work on materials discovery makes this connection concrete. Reinforcement learning on complete agent trajectories toward specific discovery targets improves the model's ability to further pursue those targets. A trajectory connects the initial property objective to candidate selection, synthesis path design, evaluation, interpretation, and the choice of what to try next. Training on this sequence gives the model feedback on how its decisions contribute to progress over an entire discovery campaign. Unsuccessful candidates and revised hypotheses become part of the experience it can learn from.

This approach gives us a way to develop scientific judgment and, even intuition, over longer horizons: which candidates deserve investigation, which observations should change a hypothesis, and how to redirect a search when a promising approach fails. The next challenge is to extend what the model learns across discovery targets and material families, so that experience from one campaign improves its approach to the next.

Science is an open-ended endeavor in which AI can explore and create value indefinitely. Every discovery reveals new questions, and every advance in experimental capability makes new phenomena accessible. As AI helps push this frontier outward, the knowledge and methods a model needs will continue to change. A model trained on today's scientific record must be able to learn from tomorrow's observations, including discoveries it hel Перейти к статье ogress therefore requires a learning process that can grow alongside science itself.

We worked with UniPat and Mind Lab to build data, training pipeline, and infrastructure, and with NeuroSpark to build the training infrastructure. **We welcome collaboration with the open-model community to build better scientific models and help accelerate scientific discovery to tackle social challenges that AI itself introduces in this rapidly changing world.**

Building Hydrogen-1.0 is our path toward that goal.



Deep Principle

Building intelligence for scientific discovery. `Hydrogen-1.0 / Technical release`