

BFGS с ограниченной памятью

BFGS с ограниченной памятью (L-BFGS или LM-BFGS) - это [оптимизационный алгоритм](#) из набора [квази-ньютоновских методов](#), который аппроксимирует [алгоритм Бroyдена–Флетчера–Гольдфарба–Шанно](#) (BFGS) с использованием ограниченного объема [компьютерной памяти](#).^[1] Это популярный алгоритм оценки параметров в [машинном обучении](#).^{[2][3]} Целевой задачей алгоритма является минимизация $f(\mathbf{x})$ по неограниченным значениям действительного вектора, $\mathbf{x}$ где f - дифференцируемая скалярная функция.

Как и оригинальный метод BFGS, L-BFGS использует оценку обратной [матрицы Гессе](#) для управления поиском в пространстве переменных, но если BFGS хранит плотную $n \times n$ аппроксимацию обратной матрицы Гессе (n — количество переменных в задаче), то L-BFGS хранит лишь несколько векторов, которые неявно представляют аппроксимацию. Благодаря линейным требованиям к памяти метод L-BFGS особенно хорошо подходит для решения задач оптимизации с большим количеством переменных. Вместо обратного гессиана $\mathbf{H}_k$ алгоритм L-BFGS сохраняет историю последних m обновлений положения $\mathbf{x}$ и градиента $\nabla f(\mathbf{x})$, где размер истории m обычно невелик (часто $m < 10$). Эти обновления используются для неявного выполнения операций, требующих $\mathbf{H}_k$ -векторного произведения.

Алгоритм

Алгоритм начинается с начальной оценки оптимального значения, $\mathbf{x}_0$ и продолжается итеративно, чтобы уточнить эту оценку с помощью последовательности более точных оценок $\mathbf{x}_1, \mathbf{x}_2, \dots$. Производные функции $\mathbf{g}_k := \nabla f(\mathbf{x}_k)$ используются в качестве ключевого драйвера алгоритма для определения направления наиболее крутого спуска, а также для формирования оценки матрицы Гессе (второй производной) от $f(\mathbf{x})$.

L-BFGS во многом схож с другими квазиньютоновскими алгоритмами, но сильно отличается от них тем, как выполняется матрично-векторное умножение $\mathbf{d}_k = -\mathbf{H}_k \mathbf{g}_k$, где $\mathbf{d}_k$ — приближенное направление Ньютона, $\mathbf{g}_k$ — текущий градиент, а $\mathbf{H}_k$ — обратная матрица Гессе. Существует множество опубликованных подходов, использующих историю обновлений для формирования этого вектора направления. Здесь мы приводим распространенный подход — так называемую «двухконтурную рекурсию».^{[4][5]}

Мы принимаем как заданное $\mathbf{x}_k$ положение на k -й итерации, и $\mathbf{g}_k \equiv \nabla f(\mathbf{x}_k)$ где f - минимизируемая функция, а все векторы являются векторами-столбцами. Мы также предполагаем, что мы сохранили последние m обновлений формы

$$s_k = x_{k+1} - x_k$$

$$y_k = g_{k+1} - g_k.$$

Мы определяем $\rho_k = \frac{1}{y_k^\top s_k}$, и H_k^0 будет "начальным" приближением обратного гессиана, с которого начинается наша оценка на итерации k .

Алгоритм основан на рекурсии BFGS для обратного гессиана.

$$H_{k+1} = (I - \rho_k s_k y_k^\top) H_k (I - \rho_k y_k s_k^\top) + \rho_k s_k s_k^\top.$$

Для фиксированного k мы определяем последовательность векторов $q_{k-m}, \dots, q_k$ как $q_k := g_k$ и $q_i := (I - \rho_i y_i s_i^\top) q_{i+1}$. Тогда рекурсивный алгоритм вычисления q_i из q_{i+1} заключается в определении $\alpha_i := \rho_i s_i^\top q_{i+1}$ и $q_i = q_{i+1} - \alpha_i y_i$. Мы также определяем другую последовательность векторов $z_{k-m}, \dots, z_k$ как $z_i := H_i q_i$. Существует другой рекурсивный алгоритм для вычисления этих векторов, который заключается в определении $z_{k-m} = H_k^0 q_{k-m}$, а затем в рекурсивном определении $\beta_i := \rho_i y_i^\top z_i$ и $z_{i+1} = z_i + (\alpha_i - \beta_i) s_i$. Значение z_k - это, таким образом, направление нашего подъема.

Таким образом, мы можем вычислить [направление спуска](#) следующим образом:

$$q = g_k$$

$$\text{For } i = k-1, k-2, \dots, k-m$$

$$\alpha_i = \rho_i s_i^\top q$$

$$q = q - \alpha_i y_i$$

$$\gamma_k = \frac{s_{k-m}^\top y_{k-m}}{y_{k-m}^\top y_{k-m}}$$

$$H_k^0 = \gamma_k I$$

$$z = H_k^0 q$$

$$\text{For } i = k-m, k-m+1, \dots, k-1$$

$$\beta_i = \rho_i y_i^\top z$$

$$z = z + s_i (\alpha_i - \beta_i)$$

$$z = -z$$

Эта формулировка дает направление поиска для задачи минимизации, то есть $z = -H_k g_k$. Для задач максимизации следует использовать $-Z$. Обратите внимание, что начальный приближенный обратный гессиан H_k^0 выбирается в виде [диагональной матрицы](#) или даже в виде кратного значения единичной матрицы, поскольку это повышает эффективность вычислений.

Масштабирование исходной матрицы γ_k гарантирует, что направление поиска хорошо масштабировано и, следовательно, длина единичного шага принимается в большинстве

итераций. Поиск линии Вульфа используется для обеспечения выполнения условия кривизны и стабильности обновления BFGS. Обратите внимание, что некоторые программные реализации используют Armijo поиск линий с обратным отслеживанием, но не могут гарантировать, что условие кривизны $\mathbf{y}_k^T \mathbf{s}_k > 0$ будет выполнено выбранным шагом, поскольку для выполнения этого условия может потребоваться длина шага, превышающая 1. Некоторые реализации решают эту проблему, пропуская обновление BFGS, когда $\mathbf{y}_k^T \mathbf{s}_k$ значение отрицательное или слишком близко к нулю, но этот подход обычно не рекомендуется, поскольку обновления могут пропускаться слишком часто, чтобы позволить приближению Гессе $\mathbf{H}_k$ захватить важную информацию о кривизне. Некоторые решатели используют так называемое затухающее (L) обновление BFGS, которое изменяет величины $\mathbf{s}_k$ и $\mathbf{y}_k$ для того, чтобы удовлетворить условию кривизны.

The two-loop recursion formula is widely used by unconstrained optimizers due to its efficiency in multiplying by the inverse Hessian. However, it does not allow for the explicit formation of either the direct or inverse Hessian and is incompatible with non-box constraints. An alternative approach is the compact representation, which involves a low-rank representation for the direct and/or inverse Hessian.^[6] This represents the Hessian as a sum of a diagonal matrix and a low-rank update. Such a representation enables the use of L-BFGS in constrained settings, for example, as part of the SQP method.

Приложения

L-BFGS называют «оптимальным алгоритмом» для подбора лог-линейных моделей (MaxEnt) и условных случайных полей с ℓ_2 -регуляризацией.^{[2][3]}

Варианты

Поскольку BFGS (и, следовательно, L-BFGS) предназначен для минимизации гладких функций без ограничений, алгоритм L-BFGS необходимо модифицировать для работы с функциями, содержащими не-дифференцируемые компоненты или ограничения.

Популярный класс модификаций называется методами активного множества и основан на концепции активного множества. Идея заключается в том, что при ограничении на небольшую окрестность текущего итерата функция и ограничения могут быть упрощены.

L-BFGS-B

Алгоритм L-BFGS-B расширяет возможности L-BFGS для работы с простыми ограничениями в виде прямоугольных рамок (также известными как ограничения по границам) для переменных, то есть ограничениями вида $l_i \leq x_i \leq u_i$, где l_i и u_i — нижняя и верхняя границы для каждой переменной соответственно (для каждого x_i одна или обе

границы могут быть опущены).^{[7][8]} Метод работает путем идентификации фиксированных и свободных переменных на каждом этапе (используя простой метод градиента), а затем используя метод L-BFGS только для свободных переменных для получения более высокой точности, а затем повторяя процесс.

OWL-QN

Квазиньютоновский метод с ограниченной памятью по ортантам (OWL-QN) — это вариант метода L-BFGS для подбора ℓ_1 -регуляризованных моделей, использующий присущую таким моделям разреженность.^[3] Он минимизирует функции вида

$$f(\vec{x}) = g(\vec{x}) + C\|\vec{x}\|_1$$

где g — дифференцируемая выпуклая функция потерь. Этот метод относится к типу методов активного набора: на каждой итерации он оценивает знак каждого компонента переменной и ограничивает последующий шаг тем, чтобы все компоненты имели один и тот же знак. После того как знак зафиксирован, недифференцируемый $\|\vec{x}\|_1$ член становится гладким линейным членом, с которым можно работать с помощью метода Левенберга — Марквардта. После шага метода Левенберга — Марквардта метод позволяет некоторым переменным изменить знак и повторяет процесс.

O-LBFGS

Шраудольф и др. представляют онлайн-аппроксимацию как для BFGS, так и для L-BFGS.^[9] Подобно стохастическому градиентному спуску, этот метод можно использовать для снижения вычислительной сложности за счет оценки функции ошибки и градиента на случайно выбранном подмножестве всего набора данных на каждой итерации. Было показано, что метод O-LBFGS имеет глобальную почти верную сходимость^[10], в то время как онлайн-аппроксимация метода BFGS (O-BFGS) не обязательно сходится.^[11]

Реализация вариантов

Известные реализации с открытым исходным кодом включают:

- **ALGLIB** реализует L-BFGS на C++ и C#, а также отдельную версию BLEIC для задач с линейными ограничениями.
- R's `optim` универсальная функция оптимизации использует метод L-BFGS-B.
- **SciPy** также позволяет использовать L-BFGS-B.
- Julia's `Optim.jl` также реализует алгоритмы L-BFGS и L-BFGS-B.^[12]
- **Stan** реализует L-BFGS вместе с автоматическим дифференцированием в качестве опции для решения задач оценки максимального правдоподобия и максимальной апостериорной оценки.

- [Burn \(https://github.com/tracel-ai/burn\)](https://github.com/tracel-ai/burn) реализует алгоритм оптимизации L-BFGS в [Rust](#).

Среди известных реализаций с закрытым исходным кодом можно выделить следующие:

- Вариант L-BFGS-B также существует как алгоритм ACM TOMS 778.^{[8][13]} В феврале 2011 года некоторые авторы исходного кода L-BFGS-B опубликовали крупное обновление (версия 3.0).
- Эталонная реализация на [Fortran 77](#) (и с интерфейсом [Fortran 90](#)).^{[14][15]} Эта версия, а также более старые версии были переведены на многие другие языки.
- Реализация OWL-QN на C++ от его разработчиков.^{[3][16]}

Список использованной литературы

1. Лю, Д.К.; Нокедал, Дж. (1989). "О методе ограниченной памяти для крупномасштабной оптимизации" (<http://www.ece.northwestern.edu/~nocedal/PSfiles/limited-memory.ps.gz>) . *Математическое программирование В*. **45** (3): 503–528. doi:10.1007/BF01589116 (<https://doi.org/10.1007%2FBF01589116>) . Код S2CID 5681609 (<https://api.semanticscholar.org/CorpusID:5681609>) .
2. Малуф, Роберт (2002). "Сравнение алгоритмов оценки параметров максимальной энтропии" (<https://dl.acm.org/citation.cfm?id=1118871>) . *Материалы шестой конференции по изучению естественного языка (CoNLL-2002)*. С. 49–55. doi:10.3115/1118853.1118871 (<https://doi.org/10.3115%2F1118853.1118871>) .
3. Эндрю, Гален; Гао, Цзяньфэн (2007). "Масштабируемое обучение логит-линейных моделей с L_1 -регуляризацией" (<http://research.microsoft.com/apps/pubs/default.aspx?id=78900>) . *Материалы 24-й Международной конференции по машинному обучению*. doi:10.1145/1273496.1273501 (<https://doi.org/10.1145%2F1273496.1273501>) . ISBN 978-1-59593-793-3. S2CID 5853259 (<https://api.semanticscholar.org/CorpusID:5853259>) .
4. Мэттис Х., Стрэнг Г. (1979). "Решение нелинейных уравнений методом конечных элементов". *Международный журнал численных методов в технике*. **14** (11): 1613–1626. Bibcode:1979IJNME..14.1613M (<https://ui.adsabs.harvard.edu/abs/1979IJNME..14.1613M>) . doi:10.1002/nme.1620141104 (<https://doi.org/10.1002%2Fnme.1620141104>) .
5. Нокедал, Дж. (1980). "Обновление квази-ньютоновских матриц с ограниченным объемом памяти" (<https://doi.org/10.1090%2FS0025-5718-1980-0572855-7>) . *Математика вычислений*. **35** (151): 773–782. doi:10.1090/S0025-5718-1980-0572855-7 (<https://doi.org/10.1090%2FS0025-5718-1980-0572855-7>) .

6. Byrd, R. H.; Nocedal, J.; Schnabel, R. B. (1994). "Representations of Quasi-Newton Matrices and their use in Limited Memory Methods". *Mathematical Programming*. **63** (4): 129–156. doi:10.1007/BF01582063 (<https://doi.org/10.1007%2FBF01582063>) . S2CID 5581219 (<https://api.semanticscholar.org/CorpusID:5581219>) .
7. Берд, Р. Х.; Лу, П.; Ночедал, Дж.; Чжу, С. (1995). "Алгоритм с ограниченной памятью для ограниченной оптимизации" (<https://digital.library.unt.edu/ark:/67531/metadc666315/>) . *СИАМ Дж. Научные вычисления*. **16** (5): 1190–1208. Bibcode:1995SJSC...16.1190B (<https://ui.adsabs.harvard.edu/abs/1995SJSC...16.1190B>) . doi:10.1137/0916069 (<https://doi.org/10.1137%2F0916069>) . S2CID 6398414 (<https://api.semanticscholar.org/CorpusID:6398414>) .
8. Чжу, С.; Берд, Ричард Х.; Лу, Пейхуан; Ночедал, Хорхе (1997). "L-BFGS-B: Алгоритм 778: L-BFGS-B, подпрограммы FORTRAN для крупномасштабной ограниченной оптимизации" (<https://doi.org/10.1145%2F279232.279236>) . *Операции ACM с математическим программным обеспечением*. **23** (4): 550–560. doi:10.1145/279232.279236 (<https://doi.org/10.1145%2F279232.279236>) . Код S2CID 207228122 (<https://api.semanticscholar.org/CorpusID:207228122>) .
9. Шрауддольф Н., Ю Дж., Гюнтер С. (2007). *Стохастический квазиньютоновский метод для онлайн-выпуклой оптимизации*. AISTATS.
10. Мохтари, А.; Рибейро, А. (2015). "Глобальная конвергенция сетевых BFG с ограниченной памятью" (<http://www.jmlr.org/papers/volume16/mokhtari15a/mokhtari15a.pdf>) (PDF). *Журнал исследований машинного обучения*. **16**: 3151–3181. arXiv:1409.2045 (<https://arxiv.org/abs/1409.2045>) .
11. Мохтари, А.; Рибейро, А. (2014). "RES: регуляризованный стохастический алгоритм BFGS". *Транзакции IEEE по обработке сигналов*. **62** (23): 6089–6104. arXiv:1401.7625 (<https://arxiv.org/abs/1401.7625>) . Bibcode:2014ITSP...62.6089M (<https://ui.adsabs.harvard.edu/abs/2014ITSP...62.6089M>) . doi:10.1109/ITSP.2014.2357775 (<https://doi.org/10.1109%2FTSP.2014.2357775>) . КОД S2CID 15214938 (<https://api.semanticscholar.org/CorpusID:15214938>) .
12. «Официальная документация Optim.jl» (<https://julianlsolvers.github.io/Optim.jl/stable/>) . Документация *Optim.jl*.
13. "ТОМС Хоум" (<http://toms.acm.org/>) . *toms.acm.org*.
14. Моралес Х. Л., Носедаль Х. (2011). "Замечание к "алгоритму 778: L-BFGS-B: подпрограммы на Фортране для крупномасштабной оптимизации с ограничениями" ". *ACM Transactions on Mathematical Software*. **38**: 1–4. doi:10.1145/2049662.2049669 (<https://doi.org/10.1145%2F2049662.2049669>) . S2CID 16742561 (<https://api.semanticscholar.org/CorpusID:16742561>) .

15. "Код нелинейной оптимизации L-BFGS-B" (<http://users.iems.northwestern.edu/~nocedal/lbfgsb.html>) . *users.iems.northwestern.edu*.
16. "Квази-ньютоновский оптимизатор с ограниченной памятью по Ортанту для задач с регуляризацией L1" (<https://www.microsoft.com/en-us/download/details.aspx?id=52452>) . Центр загрузки *Microsoft*.

Дополнительная литература

- Лю, Д.К.; Ночедал, Дж. (1989). "О методе ограниченной памяти для крупномасштабной оптимизации" (<http://www.ece.northwestern.edu/~nocedal/PSfiles/limited-memory.ps.gz>) . *Математическое программирование В.* **45** (3): 503–528. doi:10.1007/BF01589116 (<https://doi.org/10.1007%2FBF01589116>) . Код S2CID 5681609 (<https://api.semanticscholar.org/CorpusID:5681609>) .
- Хагиги, Ария (2 декабря 2014 г.). «Численная оптимизация: понимание метода L-BFGS» (<http://aria42.com/blog/2014/12/understanding-lbfgs>) .
- Пытлак, Радослав (2009). "Квазиньютоновские алгоритмы с ограниченной памятью" (<https://books.google.com/books?id=RhRkaDPmwVoC&pg=PA159>) . *Алгоритмы сопряженных градиентов в невыпуклой оптимизации*. Springer. С. 159–190. ISBN 978-3-540-85633-7.