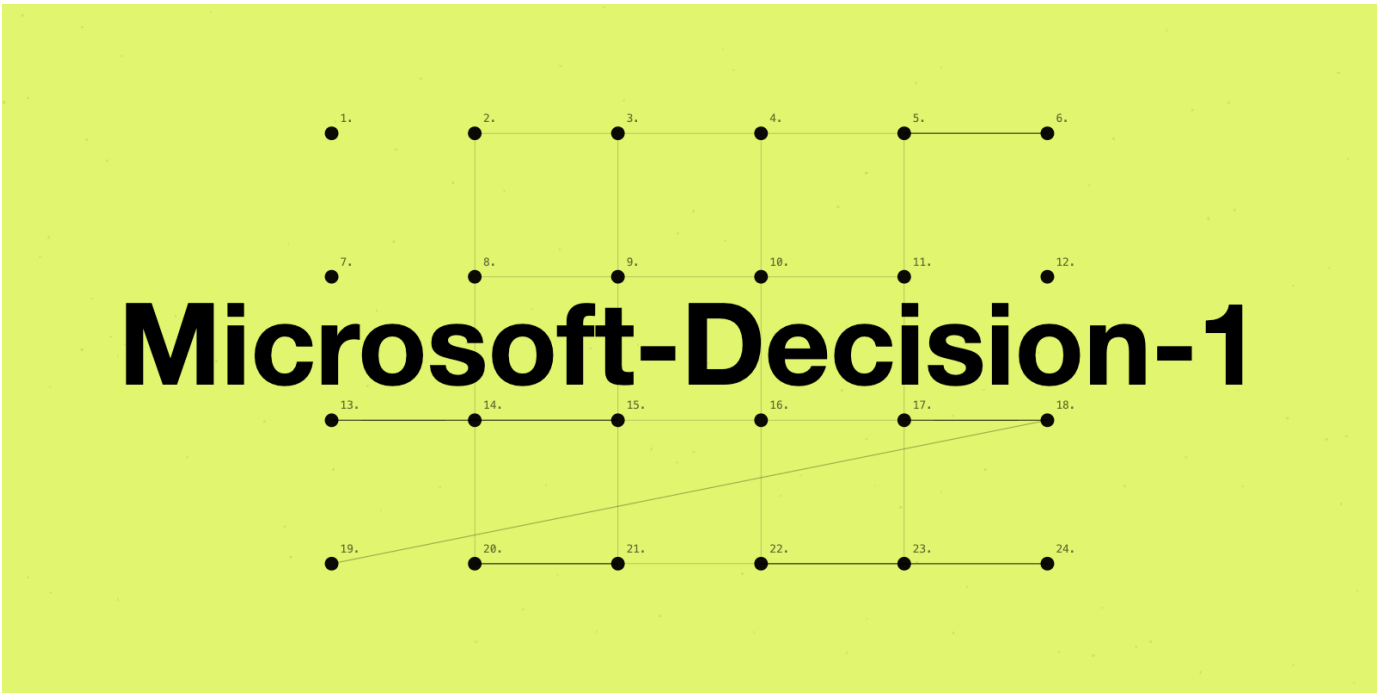


ГЛУБОКОЕ ПОГРУЖЕНИЕ

ПОДЕЛИТЬСЯ

Представляем Microsoft-Decision-1, нашу модель для быстрого принятия решений

Наша новая модель оценки решений обеспечивает максимальную производительность при минимальной задержке и высокое качество при решении структурированных задач, превосходя как большие языковые модели, так и другие модели принятия решений.

Ачинт Шривастава

2026.10.09

Модели принятия решений быстро становятся новой важной категорией в сфере искусственного интеллекта. В отличие от больших языковых моделей, которые предназначены для генерации текста или решения сложных задач, модели принятия решений создаются специально для получения структурированных результатов, на основе которых программное обеспечение может немедленно принимать меры. Как только вы осознаете эту возможность — принимать решения и классифицировать данные с очень низкими затратами и высокой производительностью, — перед вами откроются все виды полезных задач.

Перейти к основному контенту

Сегодня мы представляем **Microsoft-Decision-1**, нашу новую модель для быстрого принятия решений, доступную в Microsoft Foundry и через OpenRouter. Эта модель предназначена для маршрутизации, классификации, расстановки приоритетов, проверки и управления рабочими процессами, что упрощает внедрение системы анализа решений в существующие приложения, агентов и рабочие процессы в безопасной, заслуживающей доверия среде. Microsoft-Decision-1 обеспечивает высочайшую производительность по задержкам и качеству при решении структурированных задач принятия решений, превосходя как LLM, так и другие модели принятия решений.

Модель Microsoft-Decision-1 показала самую высокую точность в нашем сравнении по 36 бенчмаркам, охватывающим почти 150 000 вопросов, которые не использовались при обучении. Кроме того, в нашем бенчмарке она показала самую высокую скорость: в 2,5 раза быстрее, чем H2O-Lightning-4B v1.1, занявшая второе место, и в 35 раз быстрее, чем GPT-6 Sol.

Примечание редактора: этот пост был дополнен сравнительными тестами Jev на точность и калибровку.

Перейти к основному контенту

Accuracy, latency and calibration, side by side

Microsoft-Decision-1 GPT-6 Sol (reference) Other models

SORT BY Accuracy Latency Calibration

AVERAGE ACCURACY Higher is better · 36 benchmarks	MODEL	MEDIAN LATENCY Lower is better · per request	CALIBRATION 100 = perfect
83.5%	Microsoft-Decision-1	85 ms*	92.2
82.3%	Jev 1.13.0	240 ms	93.
81.9%	Quyet-1.0-Large #1 on JevBench	380 ms	93.
79.7%	Surogate Rune 26B-A4B #8 on JevBench	380 ms	91.8
79.4%	GPT-6 Luna Decisions #7 on JevBench	300 ms	89.9
77.8%	deck-31B #3 on JevBench	400 ms	83.5
77.2%	H2O-Lightning-4B v1.1 #5 on JevBench	210 ms	91.8
54.8%	Strands-Decider 2B AWS · 23 of 36 benchmarks**	not measured	not scored
not ranked	GPT-6 Sol	3.01 s	not scored

100% 50% 0 1 s 2 s 3 s 80 100

Microsoft-Decision-1 is first on accuracy and the fastest measured: **2.5×** quicker than H2O-Lightning-4B v1.1, the runner-up, and **35×** quicker than GPT-6 Sol. Third on calibration, **1.5** behind Jev. Hover or tap a row for the detail.

Accuracy: mean score across 36 benchmarks (147,137 questions); #n is the JevBench leaderboard position on 8 October 2026. ** Strands-Decider 2B: average of the 23 of 36 benchmarks it could answer.

Latency: JevBench v1.6.1 adjusted median (p50), checked Oct 7, 2026. * Microsoft-Decision-1 measured through Foundry in the same region.

Calibration: 100 means a model's confidence exactly matches how often it is right. “Not ranked”, “not measured” and “not scored” mark models absent from a dataset.

Перейти к основному контенту

Как работает Microsoft-Decision-1

Для создания Microsoft-Decision-1 мы использовали обученную модель Qwen3.5-9B для быстрого однопроходного принятия решений и вскоре переобучим ее на основе других моделей, в том числе Microsoft AI (MAI) и OpenAI. При наличии фиксированного набора вариантов ответа Microsoft-Decision-1 выдает калиброванную оценку вероятности для каждого варианта. Модель поддерживает варианты ответов «да/нет», множественный выбор и рейтинговую оценку, а также оценку ответов ИИ и действий агентов на основе критериев — и все это с помощью простого структурированного вызова API.

Чтобы создать надежную модель принятия решений, нам пришлось решить несколько задач:

1. Скорость

Каждое решение приводит к задержке, особенно если один шаг зависит от другого. Например, добавление всего 100 миллисекунд к каждому из 20 последовательных решений увеличивает общую продолжительность рабочего процесса на две секунды.

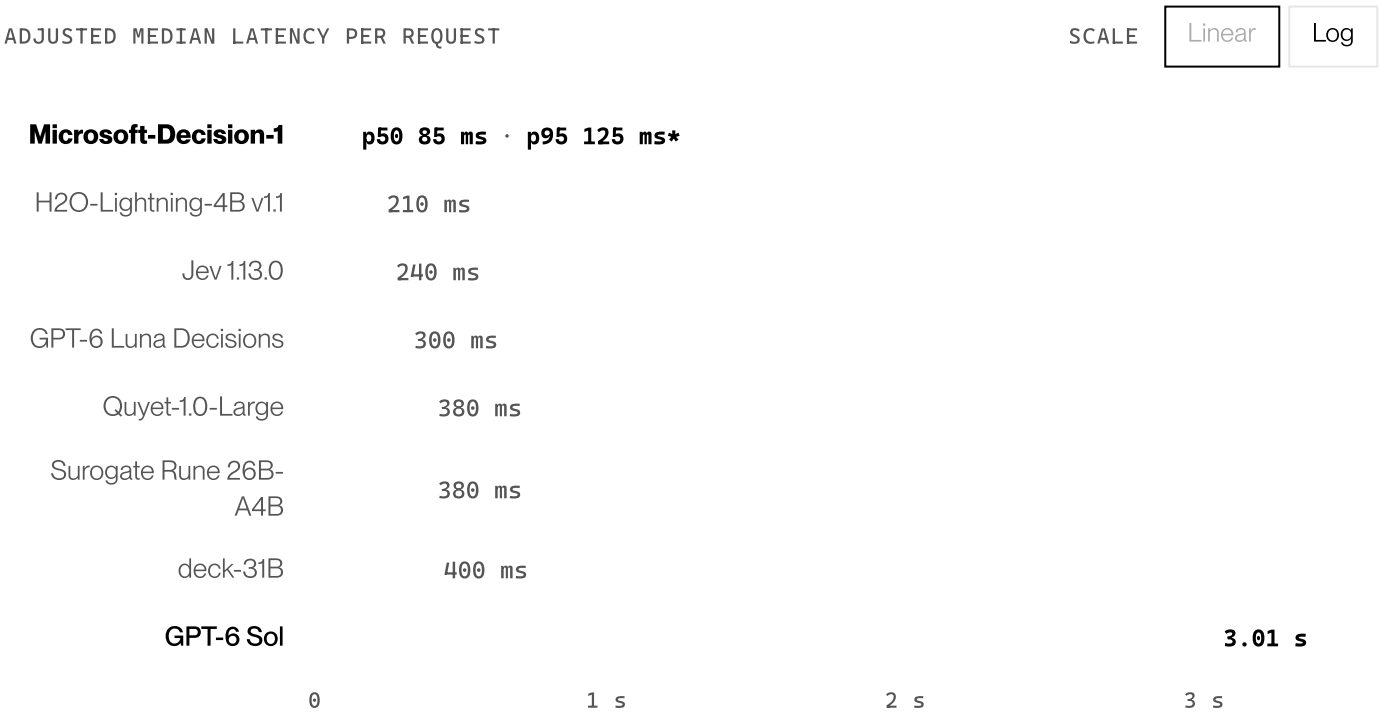
Задержка Microsoft-Decision-1 P50 примерно в 35 раз выше, чем GPT-6 Sol.

Перейти к основному контенту

LATENCY

Latency

Lower is better. Time to a decision per request, median across the JevBench suite.



Striped segment: Microsoft-Decision-1 p95 at **125 ms**. Switch to the log scale to compare the sub-second models.

Source: JevBench v1.6.1 adjusted median (p50) latency, checked Oct 7, 2026.

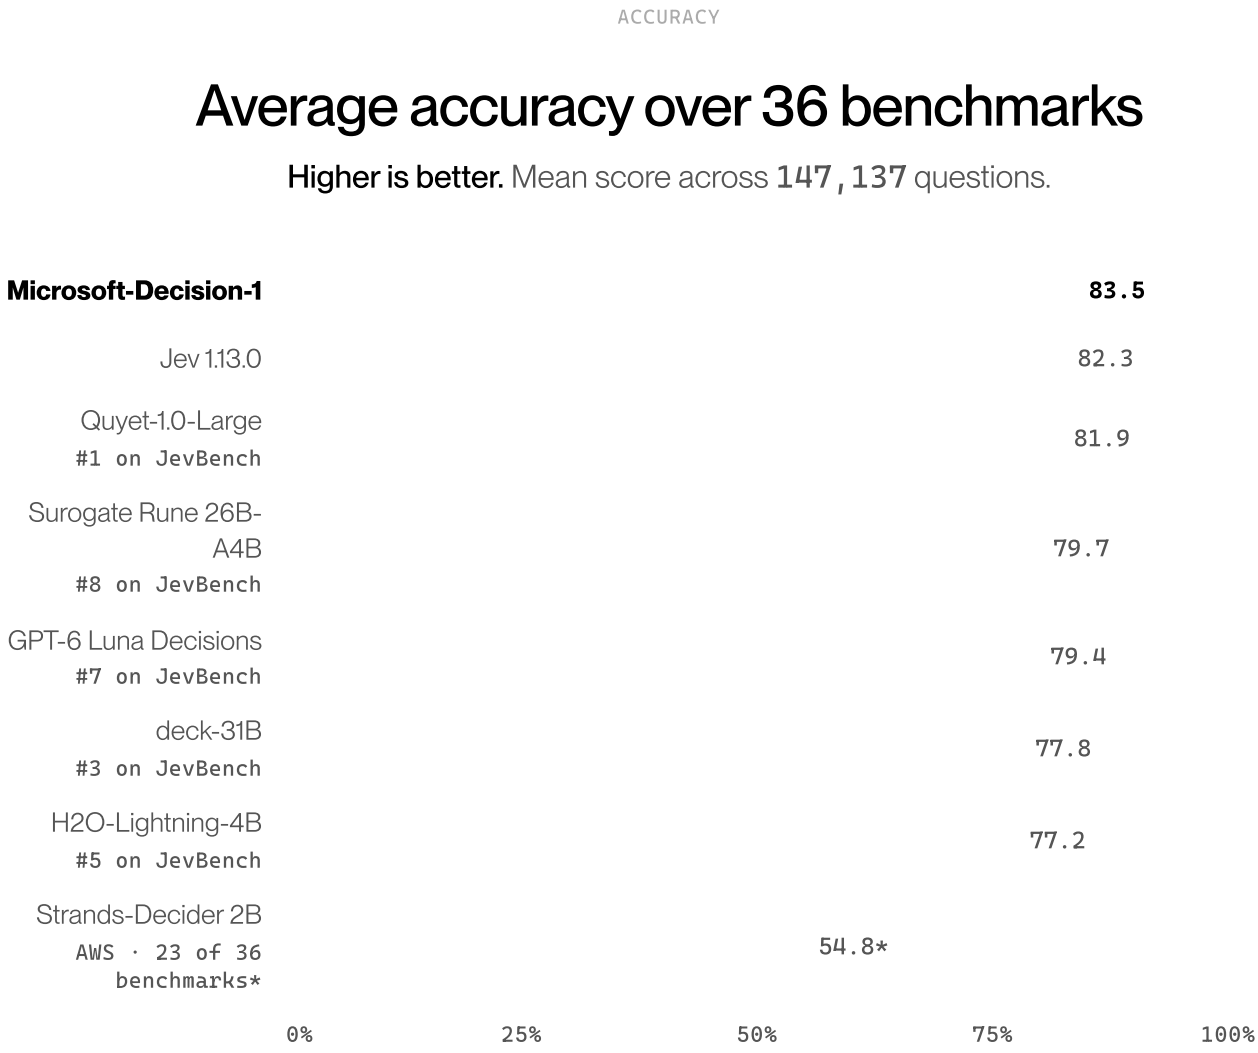
* Microsoft-Decision-1 measured through Foundry in the same region.

2. Качество, которое распространяется на другие задачи

Модель легко переобучить для одного бенчмарка или одного типа задач принятия решений. Нам нужно знать, распространяется ли это качество на различные задачи, для которых модель не обучалась. Поэтому мы протестировали Microsoft-Decision-1 на десятках бенчмарков, которые не использовались при обучении, включая маршрутизацию, ранжирование, задачи с большим контекстом, многоязычные задачи, задачи, выходящие за рамки распределения данных, задачи логического вывода и безопасности. Мы также взяли несколько лучших общедоступных моделей из популярной открытой таблицы лидеров

Перейти к основному контенту

JevBench и протестировали их в 36 дополнительных общедоступных и частных тестах. Решение Microsoft-1 показало наилучшие результаты по этим более широким наборам тестов, продемонстрировав сильное обобщение.



#n = position on the JevBench leaderboard, 8 October 2026.

* Strands-Decider 2B's score is its average over only the 23 of 36 benchmarks it could answer.

3. Устойчивость

Эквивалентные входные данные должны приводить к эквивалентным решениям. В процессе производства формулировки состояний и инструкций перефразируются, описания вариантов меняются, порядок выбора меняется, меняются ключи, появляется

безвредный форматирующий шум. Ни одно из этих изменений не должно существенно влиять на решение.

Мы изменяем один и тот же запрос восемью способами и измеряем, как часто меняется решение. Модель Microsoft-Decision-1 меняет свое решение в среднем в 1,3 % случаев при изменении описания варианта, а также при изменении порядка вариантов или их перемешивании.

4. Калибровка вероятности и достоверности

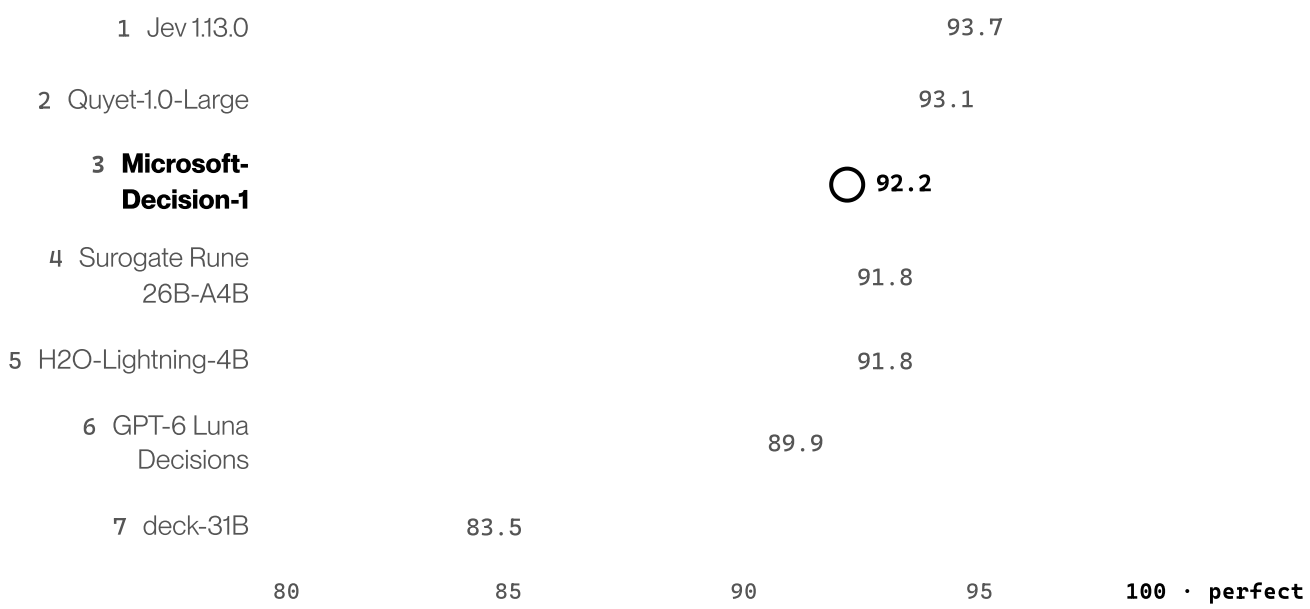
Сама вероятность является частью API, а не просто показателем ранжирования. Приложения используют показатель достоверности, чтобы решить, когда действовать, отложить решение или запросить проверку, поэтому прогноз с вероятностью 90 % должен быть верным примерно в 9 случаях из 10.

Перейти к основному контенту

CALIBRATION

Calibration score over 36 benchmarks

Higher is better. 100 means a model's confidence exactly matches how often it is right.



Microsoft-Decision-1 ranks third, **1.5** behind Jev 1.13.0 and **0.9** behind Quyet-1.0-Large, ahead of the other four models scored. The axis starts at 80: every model here is within 17 points of perfect.

Same 36 benchmarks as the accuracy ranking.

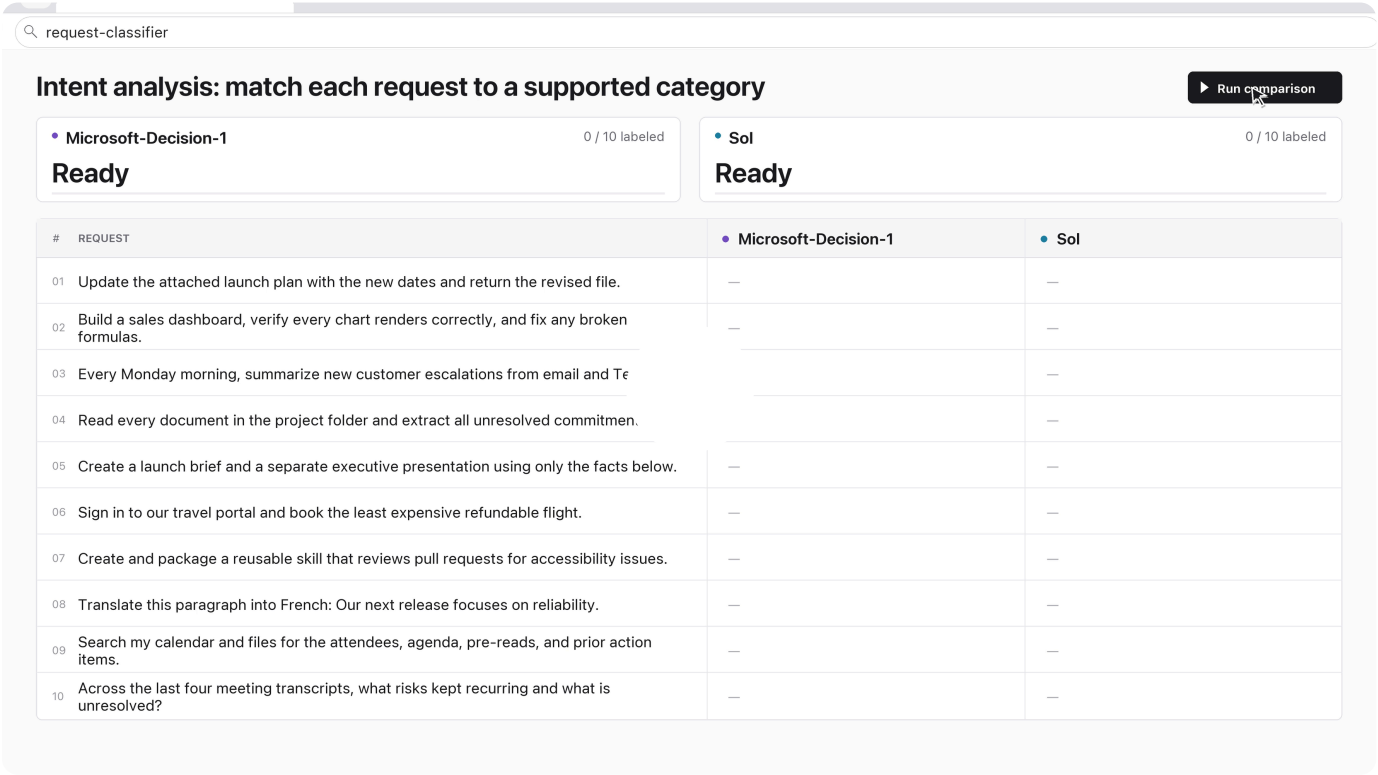
5. Безопасность

Модель принятия решений должна распознавать вредоносные запросы, не блокируя без необходимости безобидные. Мы протестировали Microsoft-Decision-1 на 5250 запросах в рамках 11 бенчмарков, охватывающих вредоносный контент, попытки джейлбрейка и внедрение команд, и обнаружили, что модель успешно блокирует вредоносное поведение, сохраняя при этом высокую степень полезности.

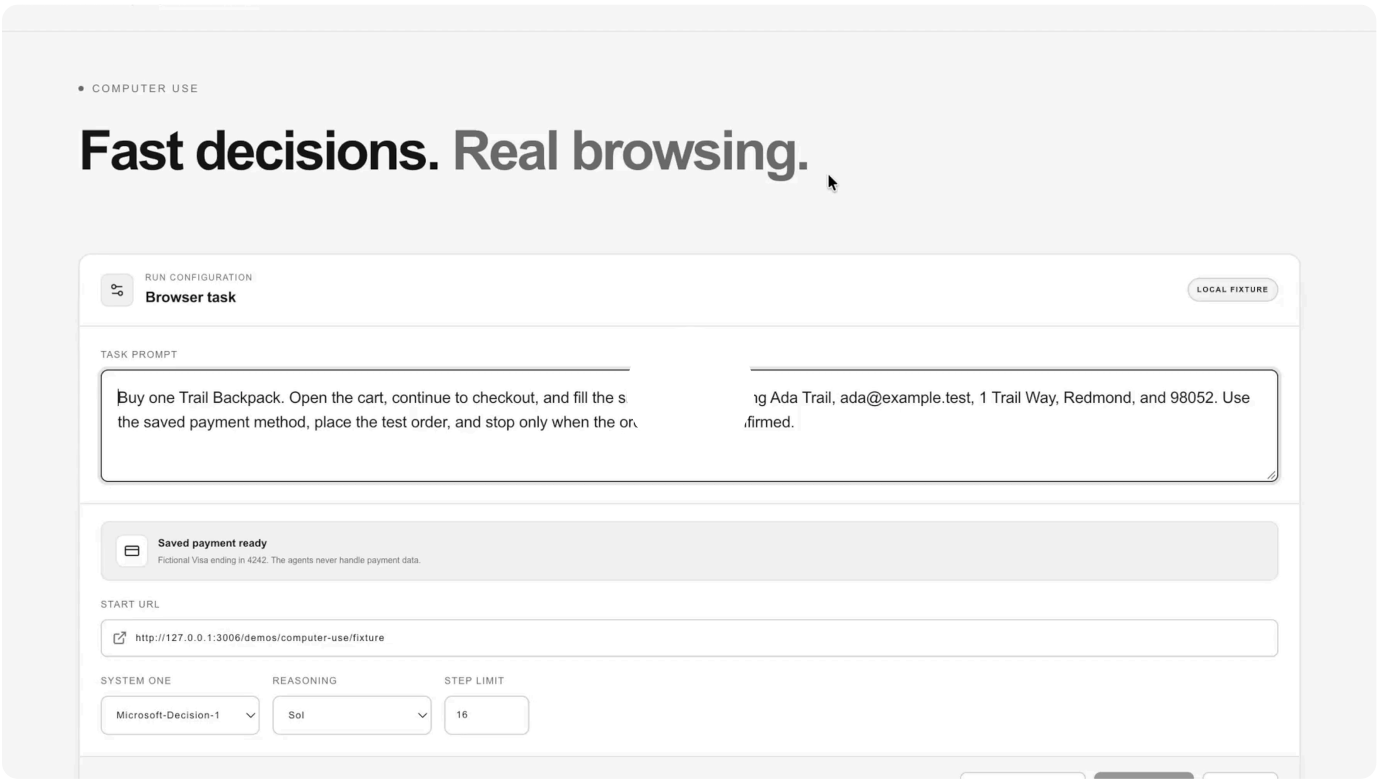
Демонстрационные примеры

Классификация — ключевой сценарий использования моделей принятия решений. Посмотрите, насколько точно и быстро Microsoft-Decision-1 может классифицировать

Перейти к основному контенту ению с GPT-6 Sol:



Модели принятия решений также могут быть эффективны в сценариях использования компьютера. В этой демонстрации показано, насколько быстро Microsoft-Decision-1 может выполнить задачу покупки рюкзака по сравнению с GPT-6 Sol:



Как мы тестируем Microsoft-Decision-1 внутри компании

Перейти к основному контенту

Вот некоторые из способов, которыми мы тестируем Microsoft-Decision-1 внутри компании, и это далеко не все.

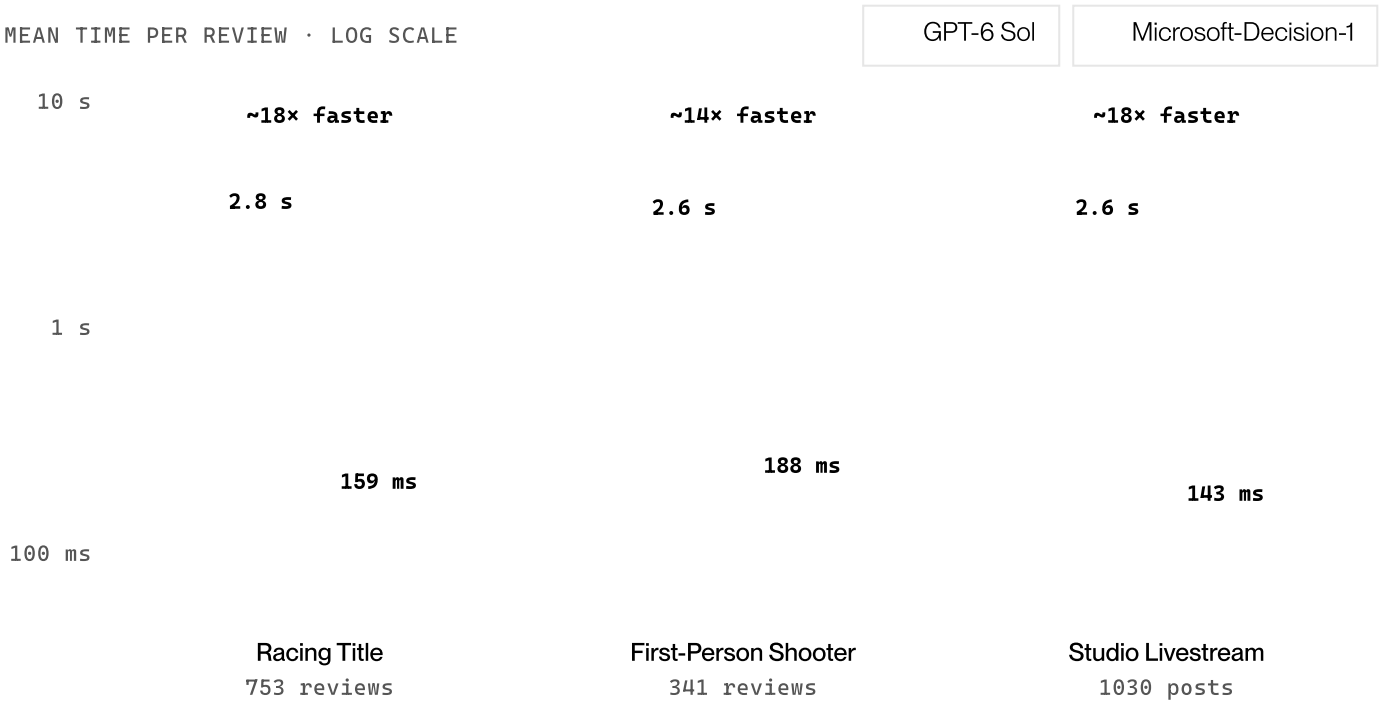
Разметка данных

XBOX Research использовала Microsoft-Decision-1 для обработки более 10 000 открытых отзывов и рецензий, полученных в ходе опросов, в STEAM и Twitter/X, и распределила их по фиксированному набору тем, установленных исследователями, чтобы понять, что люди говорят о различных играх, релизах, стримах и многом другом. Они выяснили, что Microsoft-Decision-1 по качеству не уступает GPT-6 Sol, но при этом работает в 14 раз быстрее и в 200 раз дешевле.

SPEED

Speed per classification

Lower is better. Mean wall-clock time to classify one text, on the same three datasets as the cost comparison.



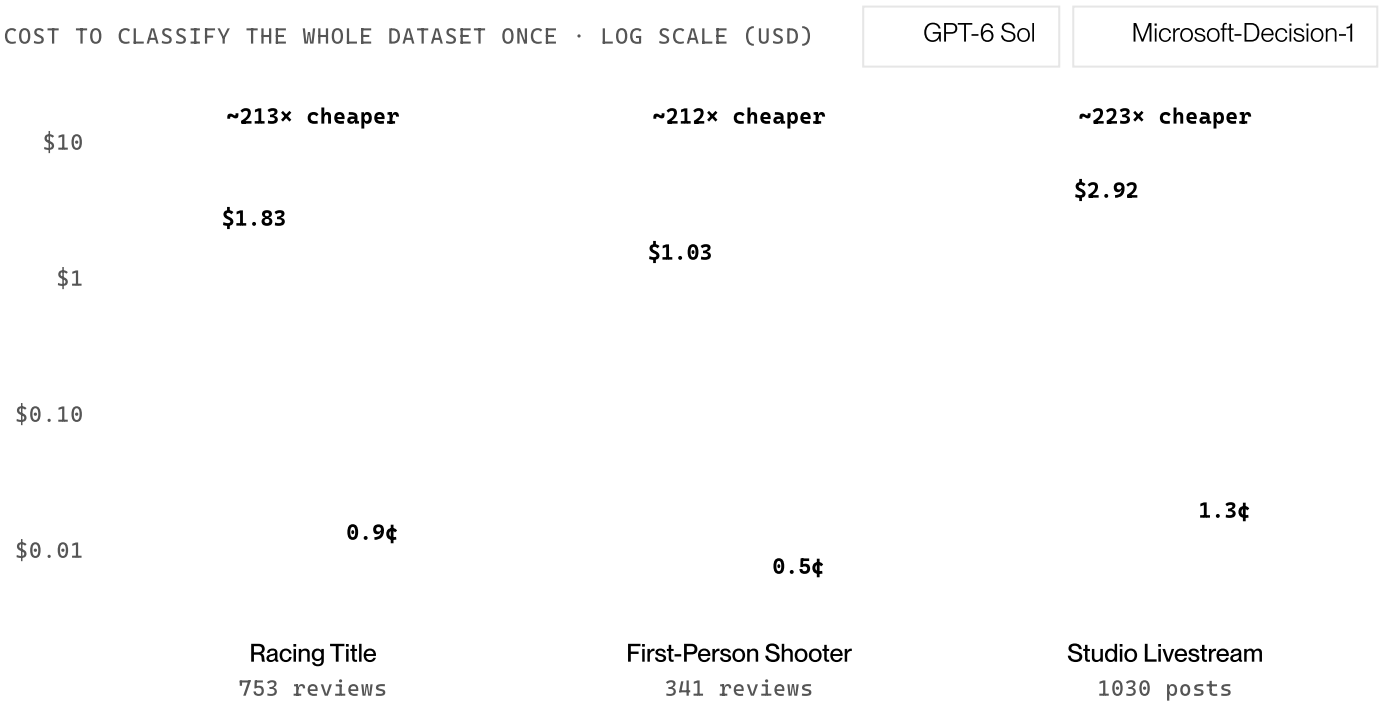
Bars are on a log scale, so each gridline is a tenfold change in time. Microsoft-Decision-1 answers every dataset in under **200 ms** per text; GPT-6 Sol takes between **2.6** and **2.8 s**.

Перейти к основному контенту

COST

Cost per run

Microsoft-Decision-1 classifies the same texts for a small fraction of the cost of GPT-6 Sol.



Bars are on a log scale, so each gridline is a tenfold change in cost.

Estimated. Both read the identical brief, so input tokens match; only GPT-6 Sol also pays for output.

Scaled to 1,000,000 texts: GPT-6 Sol about $2,434, Microsoft-Decision-1 about $11.

Контроль качества

Команда второго пилота измеряет качество ответов в чате и у агентов. Их тестирование показало, что Microsoft-Decision-1 конкурирует с GPT5.6 Luna и в 100 раз быстрее.

Реагирование на инцидент

Наши дежурные инженеры используют искусственный интеллект для получения соответствующих знаний для реагирования на текущие инциденты с помощью журналов

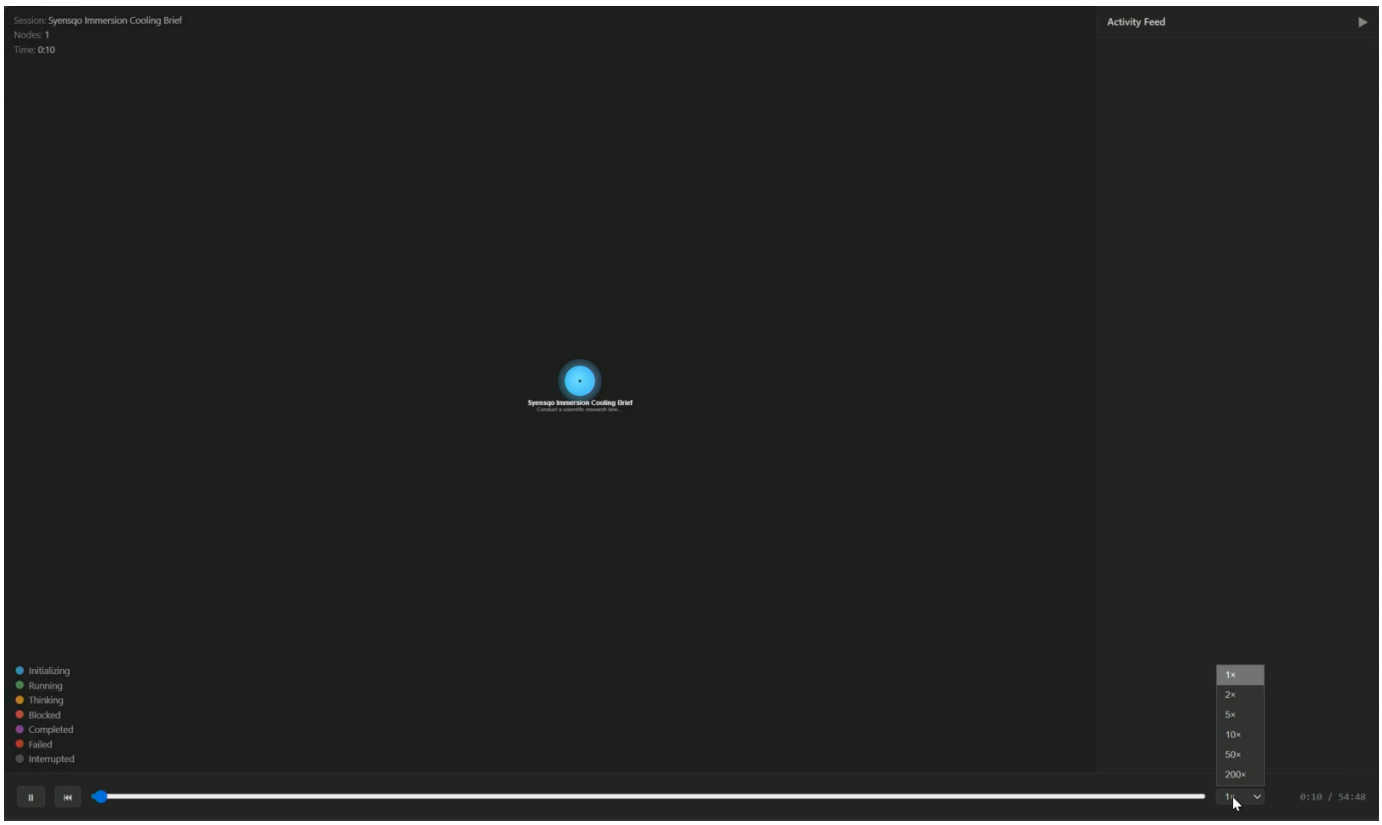
Перейти к основному контенту

и билетов, звонков, сообщений и других источников данных.

Модель Microsoft-Decision-1 показала лучшие результаты и работала быстрее, чем языковая модель для извлечения знаний.

Научные открытия

Microsoft Discovery реализует функцию адаптивного перепланирования, при которой агент оценивает предыдущий эксперимент, корректирует свой подход на основе оценок по критериям и повторяет процесс до тех пор, пока не достигнет поставленных целей. Модель Microsoft-Decision-1 показала в 46 раз более стабильные результаты, чем модель на основе языковой модели, и работала в три раза быстрее, а при адаптивном перепланировании — почти в четыре раза быстрее.



Более быстрое и надежное планирование может существенно повлиять на результаты долгосрочных научных экспериментов.

Это лишь несколько примеров. Существует множество других потенциальных вариантов использования Microsoft-Decision-1. Попробуйте сделать следующее:

- **Управление агентом:** Оцените предложенный агентом следующий шаг и примите решение о том, что делать дальше: продолжить, остановить, повторить попытку или передать задачу модели, инструменту или человеку.

Перейти к основному контенту

- **Маршрутизация моделей:** Оцените входящий запрос и выберите лучшую модель для выполнения задачи с учетом требований к качеству, стоимости и задержке.
- **Решения на основе навыков:** Применяйте правила, связанные с навыками агента, чтобы выбрать подходящее следующее действие, не обрабатывая повторно длинный список инструкций.
- **Разметка данных:** Присваивайте одинаковые метки постам в социальных сетях, отзывам клиентов и другим данным для анализа или обучения.
- **Оценка ИИ:** сравните ответ, сгенерированный ИИ, с заданными критериями качества и решите, принять его, отредактировать или отклонить.
- **Анализ намерений:** определите, чего пытается добиться пользователь, и сопоставьте его запрос с поддерживаемым намерением.
- **Маршрутизация реагирования на инциденты:** классифицируйте инцидент по типу и срочности, а затем направьте его в соответствующую команду или рабочий процесс.
- **Проверка данных:** Проверьте, соответствует ли введенная информация заданным требованиям, и решите, принять ее, отклонить или отправить на проверку.
- **Рекомендации:** Выберите наиболее подходящий элемент, предложение или следующее действие из набора вариантов.
- **Релевантность поиска:** Оцените, насколько результат поиска соответствует запросу, и присвойте ему метку релевантности или приоритет.
- **Классификация и фильтрация контента:** Распределите контент по темам или политикам и решите, показывать его, фильтровать или отправлять на проверку.
- **Сканирование кода:** Оцените код на соответствие определенным критериям и отметьте потенциальные дефекты или нарушения политик для проверки.
- **Проверка безопасности:** Классифицируйте запросы, результаты или предлагаемые действия по степени риска и решайте, разрешить их, заблокировать или передать на рассмотрение.
- **Использование компьютера и пользовательского интерфейса:** выберите следующее действие в интерфейсе из набора вариантов в зависимости от текущего экрана и задачи.

Перейти к основному контенту

- **Робототехника:** выберите одно из предустановленных действий робота в зависимости от наблюдений, целей задачи и эксплуатационных ограничений.
- **Научные открытия:** проверьте гипотезы, соединения или эксперименты на соответствие определенным критериям и расставьте их по приоритетности для дальнейшей оценки.

Getting started

Developers can get started with Microsoft-Decision-1 today in Microsoft Foundry here: https://ai.azure.com/catalog/models/Microsoft-Decision-1. You can also get started through OpenRouter here: https://openrouter.ai/microsoft/microsoft-decision-1.

Documentation is available here: https://learn.microsoft.com/en-us/azure/foundry/foundry-models/how-to/use-foundry-models-microsoft-decision.

Pricing

Input tokens cost $0.042 USD per million tokens. Output tokens are free.

Looking ahead

Now that agentic AI is a reality, we've seen that cost plays a major role in how people decide to use AI. And it's increasingly important to choose the right model for the right job. With agents taking action and making an impact in the real world, decision models have the potential to help people guide and control those agents through complex environments.

We look forward to seeing what developers build with Microsoft-Decision-1 and hearing their feedback. We'll continue to release updates to the model, including by incorporating evaluations and data to further optimize quality, confidence, and cost.

Appendix: Models benchmarked

Quyet-1.0-Large — https://huggingface.co/chinhnc/Quyet-1.0-Large
Surogate Rune 26B-A4B — https://huggingface.co/surogate/rune-26b-a4b-GGUF
GPT-6 Luna Decisions — https://developers.openai.com/api/docs/guides/decisions
deck-31B — https://github.com/krishna-gogineni-765/deck31b
H2O-Lightning-4B — https://huggingface.co/h2oai/h2o-lightning-4b
Strands-Decider 2B — https://github.com/strands-labs/strands-decider

Перейти к основному контенту

SHARE

Next Stop

Bringing local models and sandboxed tools to Windows and GitHub Copilot

DEEP DIVE

Coming soon, GitHub Copilot will determine when a task is best handled by on-device intelligence and when it should leverage cloud-scale models.

[read]

October 7, 2026

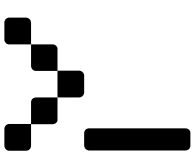
Beyond violation rates: Are your AI evaluations measuring the right things?

DEEP DIVE

Structured evaluation design can improve both the breadth of behaviors tested and the interpretability of the resulting failures, leading to practical advantages for generating diverse, traceable, and actionable evaluations.

[read]

October 5, 2026



Command Line



Перейти к основному контенту

Follow the systems work as it breaks and gets rebuilt.

Subscribe for updates

© 2026