

Введение в доверительные интервалы EGRET

Роберт М. Хирш, Лаура А. Де Чикко

17 апреля 2025 года

- Введение
 - Требуемые Фреймы данных
- Тест начальной загрузки WRTDS
 - Гистограммы
- Доверительные полосы
 - Введение
 - Предварительные шаги
 - Простой рабочий процесс
 - Параллельные вычисления
 - Графики результатов CI

Введение

Этот пакет **EGRETci** реализует набор подходов к анализу неопределенности, связанной с анализом трендов WRTDS, как это сделано в пакете **EGRET**. Все включенные сюда функции описаны в статье [Метод бутстрэппинга для оценки неопределенности трендов качества воды Хирш, Арчфилд и Де Чикко, 2015](#)

Пакет **EGRETci** предназначен для интерактивного или пакетного использования. Инструкции для обоих вариантов приведены здесь, в виньетке. Пакет позволяет пользователям задавать период анализа и различные параметры сглаживания для WRTDS. Для получения дополнительной информации по этим вопросам следует обратиться к виньетке **EGRET**. Более подробная документация доступна по адресу [EGRETci](#)

Пакет **EGRETci** предназначен для выполнения четырех типов задач.

1. Оцените динамику качества воды за определенный период и получите различные табличные результаты. Это делается с помощью короткого рабочего процесса, включающего функции: `runPairBoot` или `runGroupBoot`. Результаты представлены в трех формах: 1) вывод в консоль, в котором отображается процесс начальной репликации в процессе выполнения и результаты по завершении, а также набор выходных данных в именованном списке `eBoot`. Содержимое `eBoot` описано ниже.
2. Построение гистограмм значений величины тренда, выраженных в процентном изменении за указанный период, для нормализованной по потоку концентрации и нормализованного по потоку потока. Это делается с помощью функции `plotHistogramTrend`. Она зависит от выходных данных, содержащихся в `eBoot`. Обратите внимание, что на основе содержимого `eBoot` можно создать ряд пользовательских выходных данных, аналогичных этим гистограммам (например, какова вероятность того, что нормализованный по потоку поток уменьшился более чем на 2000 кг/год за период тренда). Для такого анализа пользователю потребуется написать небольшой скрипт.
3. Постройте доверительные интервалы вокруг вычисленных трендов нормализованной по потоку концентрации и нормализованного по потоку потока. Это делается с помощью функции `ciCalculations` и двух других функций, которые создают графики доверительных

интервалов для концентрации и потока соответственно (`plotConcHistBoot`, и `plotFluxHistBoot`).

4. Создайте интервалы прогнозирования на основе расчетных значений концентрации или потока для конкретных дней, месяцев или лет. Здесь нас интересуют оценки [WRTDS_K](#). Подробное описание того, как можно получить эти оценки, приведено в виньетке [Интервалы прогнозирования WRTDS с использованием метода Калмана](#).

Необходимые фреймы данных

В следующей таблице приведены определения четырех фреймов данных, составляющих именованный список **eBoot**

Фрейм данных	Колонна	Определение
Загрузка	Отклонить	Отклонить H_0 (нет тенденции к концентрации), ИСТИНА или ЛОЖЬ
	pValC	двустороннее p-значение для отсутствия тенденции в концентрации
	estC	Стандартная оценка изменения содержания ртути в питьевой воде по методу WRTDS в мг/л за период с начала до конца года
	Низкий уровень C90	Нижний предел достоверности (90 %) для тенденции концентрации
	upC90	Верхний доверительный предел (90 %) для тенденции изменения концентрации
	низкий уровень C50	Нижний предел достоверности (50 %) для тенденции изменения концентрации
	upC50	Верхний доверительный предел (50 %) для тенденции изменения концентрации
	Низкий уровень C95	Нижний доверительный предел (95 %) для тенденции концентрации
	upC95	Верхний доверительный предел (95 %) для тенденции изменения концентрации
	Симпатичная чашка	Вероятность того, что концентрация будет расти, высока
	Лайкдаун	Вероятность того, что концентрация будет снижаться, высока
	Отклонить	Reject H_0 , (нет тенденции к изменению), ИСТИНА или ЛОЖЬ
	pValF	Двустороннее p-значение для отсутствия тенденции в изменении потока
	estF	оценка изменения с начального по конечный год, в 10^6 кг/год
	Низкий уровень 90	Нижний предел достоверности (90 %) для тенденции изменения потока
	upF90	Верхний доверительный предел (90 %) для тенденции изменения потока

Фрейм данных	Колонна	Определение
	низкий уровень 50	Нижний предел достоверности (50 %) для тенденции изменения потока
	upF50	Верхний доверительный предел (50 %) для тенденции изменения потока
	Низкий уровень 95	Нижний предел достоверности (95 %) для тенденции изменения потока
	upF95	Верхний доверительный предел (95 %) для тенденции изменения потока
	лайкФАп	Вероятность того, что тенденция сохранится, высока
	Как падение	Вероятность того, что тенденция сохранится, снижается
	Базовый уровень	Расчетная средняя нормализованная по расходу концентрация за первый год, мг/л
	Базовый поток	Расчетный средний поток, приведенный к единице расхода, для начального года, в 10^6 кг/год
	Ибут	Фактическое количество использованных бутстреп-реплик
Произнесение слов		вектор из четырех символьных переменных (название говорит само за себя)
xConc		вектор длины iBoot, представляющий собой изменение нормализованной концентрации потока, рассчитанное для каждой бутстреп-выборки (мг/л)
xFlux		вектор длины iBoot, представляющий собой изменение нормализованного потока, рассчитанного для каждой бутстреп-реплики (10^6 кг/год)
pConc		вектор длины iBoot, представляющий изменение нормализованной концентрации потока, рассчитанное для каждой бутстреп-реплики, выраженное в процентах
Пфлюкс		вектор длины iBoot, представляющий собой изменение нормализованного потока, рассчитанное для каждой бутстреп-выборки, выраженное в процентах

WRTDS Bootstrap Test

WBT (WRTDS Bootstrap Test) можно запускать в интерактивном режиме или в пакетном режиме.

Независимо от того, какой подход используется, если пользователь хочет задать значения параметров для оценки модели или периода анализа, отличные от значений по умолчанию, их необходимо настроить перед запуском кода. Например:

Если период анализа не совпадает с Водным годом (paStart=10, paLong=12), пользователь должен использовать функцию setPA. Например, если мы хотим провести анализ за три месяца, начиная с апреля, команда будет выглядеть так: `eList <- setPA(eList, paStart = 4, paLong = 3)`.

Если желаемое значение windowY равно 10, а не 7, как по умолчанию, то команда будет выглядеть так: `eList$INFO$windowY <- 10`, аналогичные команды можно использовать для windowQ, windowS, minNumObs, minNumUncen и edgeAdjust (см. справочную страницу для modelEstimation в пакете EGRET).

После того как все параметры будут заданы (что не требует никаких действий со стороны пользователя, если используются значения по умолчанию), можно будет выполнить парный анализ с помощью следующих команд:

```
library(EGRET)
library(EGRETci)
eList <- Choptank_eList

year1 <- 1985
year2 <- 2009

pairOut <- EGRET::runPairs(eList,
                           year1, year2,
                           windowSide = 7)

# For good analysis, set nBoot to about 100
# For a quick check that things are working, set it much lower:
boot_pair_out <- runPairsBoot(eList, pairOut, nBoot = 100)
```

Результат выглядит так:

```
Choptank River
Inorganic nitrogen (nitrate and nitrite)
Water Year
```

Change estimates are for 2009 minus 1985

Should we reject H_0 that Flow Normalized Concentration Trend = 0 ? Reject H_0

best estimate of change in concentration is 0.377 mg/L

Lower and Upper 90% CIs 0.2748546 0.4383584

also 95% CIs 0.2517219 0.4588038

and 50% CIs 0.3360355 0.4079827

approximate two-sided p-value for Conc 0.02

* Note p-value should be considered to be < stated value

Likelihood that Flow Normalized Concentration is trending up = 0.995 is trending down = 0.00495

* Note p-value should be considered to be < stated value

Should we reject H_0 that Flow Normalized Flux Trend = 0 ? Reject H_0

best estimate of change in flux is 0.0538 10^6 kg/year

Lower and Upper 90% CIs 0.0367071 0.06235301

also 95% CIs 0.03299696 0.0635553

and 50% CIs 0.04764486 0.05776485

approximate two-sided p-value for Flux 0.02

* Note p-value should be considered to be < stated value

Likelihood that Flow Normalized Flux is trending up = 0.995 is trending down = 0.00495

Upward trend in concentration is highly likely

Upward trend in flux is highly likely

Downward trend in concentration is highly unlikely

Downward trend in flux is highly unlikely

Давайте рассмотрим другой пример. Предположим, что мы хотим использовать набор данных Choptank_eList и у нас есть показатели за декабрь, январь, февраль и март, что мы хотим

установить windowY = 10 и minNumObs = 50, а все остальные параметры сглаживания оставить со значениями по умолчанию. Мы хотим провести анализ тренда за период с 1990 по 2011 год, использовать максимум 50 реплик и длину блока 200. Сценарий был бы таким:

```
library(EGRET)
library(EGRETci)
eList <- Choptank_eList
eList <- setPA(eList, paStart = 12, paLong = 4)
eList$INFO$windowY <- 10
eList$INFO$minNumObs <- 50

year1 <- 1990
year2 <- 2011

pairOut <- EGRET::runPairs(eList,
                           year1, year2,
                           windowSide = 7)

##
##   Choptank River
##   Inorganic nitrogen (nitrate and nitrite)
##   Season Consisting of Dec Jan Feb Mar
##
## Change estimates  2011  minus  1990
##
## For concentration: total change is  0.175 mg/L
## expressed as Percent Change is  +13.29 %
##
## Concentration v. Q Trend Component  +15.36 %
##           Q Trend Component          -2.08 %
##
##
## For flux: total change is  0.0276 million kg/year
## expressed as Percent Change is  +12.56 %
##
## Concentration v. Q Trend Component  +6.77 %
##           Q Trend Component          +5.79 %
##
##
##      TotalChange  CQTC    QTC  x10  x11  x20  x22
## Conc          0.175 0.203 -0.027 1.32 1.32 1.52 1.50
## Flux          0.028 0.015  0.013 0.22 0.22 0.23 0.25

boot_pair_out <- runPairsBoot(eList, pairOut, nBoot = 50)

##
##   Choptank River
##   Inorganic nitrogen (nitrate and nitrite)
##   Season Consisting of Dec Jan Feb Mar
##
## Change estimates are for  2011  minus  1990
##
## Should we reject Ho that Flow Normalized Concentration Trend = 0 ? Do Not Reject Ho
```

```

## best estimate of change in concentration is 0.175 mg/L
## Lower and Upper 90% CIs -0.1041711 0.2976591
## also 95% CIs -0.1658517 0.3008164
## and 50% CIs 0.08048021 0.2408267
## approximate two-sided p-value for Conc 0.28
## Likelihood that Flow Normalized Concentration is trending up = 0.853 is trending down
= 0.147
##
## Should we reject Ho that Flow Normalized Flux Trend = 0 ? Do Not Reject Ho
## best estimate of change in flux is 0.0276 10^6 kg/year
## Lower and Upper 90% CIs -0.01300083 0.04795364
## also 95% CIs -0.03004896 0.05121886
## and 50% CIs 0.00558965 0.03765054
## approximate two-sided p-value for Flux 0.34
## Likelihood that Flow Normalized Flux is trending up = 0.833 is trending down = 0.167
##
## Upward trend in concentration is likely
## Upward trend in flux is likely
## Downward trend in concentration is unlikely
## Downward trend in flux is unlikely

```

Histograms

The function `plotHistogramTrend` plots a histogram of all of the trend magnitudes (expressed in percentage change over the selected period) from the full set of replicates created by `runPairsBoot` or `runGroupsBoot`. These magnitudes are stored in the `eBoot` list. These histograms serve the purpose of providing a graphical impression of the central tendency and the uncertainty about the size of a trend. They can be used to help answer questions like: “How sure are we that the trend is positive?” or “How sure are we that the decrease is at least a 20% decrease over the period of interest?” The `plotHistogramTrend` function can produce histograms either for Flow Normalized Concentration or for Flow Normalized Flux.

When creating a histogram it is important to carefully determine what “bins” to use. In this plot it is a good idea to make sure that the plot covers a range of both negative and positive values even though it might be the case that the entire range of the trend magnitudes is positive (or negative). The function is set up so that it defaults to setting up 10 bins and the bins are set to cover the full range of the magnitudes and at least cover magnitudes as low as -10% and as high as +10%. The bins are set up based on a minimum value (`xMin`), a maximum value (`xMax`), and a step size (`xStep`). The defaults used in an initial run can simply leave out these three arguments and will produce a plot. This first plot would not be suitable for publication or display, but is intended to guide the analyst to set these three arguments to produce a suitable plot.


Ultimately we want a plot with these characteristics: The value of `xStep` should be an integer such as 5, 10, or 20 so the width of the bins is 5%, 10% or 20%. `xStep` should be small enough so that the histogram looks relatively smooth. If it is too small the histogram bars will tend to be irregular. `xStep` should not be so large that there is poor resolution of the shape of the distribution. If a very smooth histogram is desired then the analyst needs to have run the `runPairsBoot` function with a high number of replicates (say `nBoot` = 200). The value of `xStep` should be less than the minimum value observed in the set of bootstrap replicates. `xMin` should be some negative integer multiple of step size. If no values were negative, then setting it at -1 times `xStep` would be a good choice. `xMax` should be larger than the maximum value in the set of bootstrap replicates and should be some positive integer multiple of `xStep`. If there are no positive values then 1 times `xStep` would be a good choice.

Note that the plots always show a vertical solid line at 0% trend, simply as a point of reference for the “no trend” result. They also show a dashed vertical line at the value of the ordinary WRTDS estimate of the trend magnitude in percent. This vertical line fall near the median value for all the bootstrap replicates.

This initial run will give the analyst the basic information needed to set up a good set of values for xMin, xMax and xStep.

```
library(EGRET)
library(EGRETci)

#Concentration an initial run:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                   xMin = -15, xMax = 35, xStep = 5)
```



```
#Flux an initial run:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                   xMin = -15, xMax = 35, xStep = 5,
                   flux = TRUE)
```

Having seen these initial versions of the plot one can run the functions again with a set of arguments that will produce a plot that is suitable for presentation or publication.


Alternatively, the two plots can be shown side-by-side using a workflow. Use the `par` function to set up both functions to plot side-by-side:

```

par(mfrow=c(1,2))
#Concentration, presentation version:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                  xMin = -15, xMax = 35, xStep = 5,
                  flux = FALSE)

#Flux, presentation version:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                  xMin = -15, xMax = 35, xStep = 5,
                  flux = TRUE)

```



```

# To return to figures printing in 1 row, 1 columns:
par(mfrow=c(1,1))

```

Or:


```

par(mfrow=c(2,1))
#Concentration, presentation version:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                  xMin = -15, xMax = 35, xStep = 5,
                  flux = FALSE)


#Flux, presentation version:
plotHistogramTrend(eList = eList, eBoot = boot_pair_out,
                  xMin = -15, xMax = 35, xStep = 5,
                  flux = TRUE)

```

Trend magnitude in Inorganic nitrogen (nitrate and nitrite)
Flow Normalized Concentration 1990 to 2011
Choptank River Season Consisting of Dec Jan Feb Mar



Trend magnitude in Inorganic nitrogen (nitrate and nitrite)
Flow Normalized Flux 1990 to 2011
Choptank River Season Consisting of Dec Jan Feb Mar



```
# To return to figures printing in 1 row, 1 columns:
par(mfrow=c(1,1))
```

Confidence Bands

Introduction

The purpose here is to produce a graphic that looks just like those produced by `plotConcHist` or `plotFluxHist` but with the addition of confidence bands around the flow-normalized histories. There are two versions of the workflow for confidence bands, the first just uses a single computer core which means it takes a long time to run (jobs can take an hour or more), but it is simple to run. It uses the function `ciCalculations` and can be run interactively or in batch. Two scripts for that are provided below. It is best done in the Terminal or some other window, rather than in the console. If run in the console it will make it impossible for other work in R to take place while the job is running. The second way it can be done is using parallel computing in R. A script for that purpose is provided. It does require three extra packages be installed (**foreach**, **doParallel**, and **iterators**). It is also best to run this in the Terminal, because if it is run in the console, no other R work can be done while it is running.

Preliminary Steps

Regardless of the approach (single core or parallel) being taken to the computations, the user needs to set up any non-default values of the parameters for model estimation and period of analysis. For example:

If the period of analysis is to be anything other than a Water Year (`paStart=10`, `paLong=12`), the user must use the `setPA` function. For example if we want to do the analysis for the three months starting with April, the command would be `eList <- setPA(eList, paStart = 4, paLong = 3)`.

If the desired value of `windowY` was 10 rather than the default value of 7, then the command needed would be `eList$INFO$windowY <- 10`, similar commands can be used for `windowQ`, `windowS`, `minNumObs`, `minNumUncen` and `edgeAdjust` (see help page for `modelEstimation`).

It is imperative that the standard WRTDS trend analysis be run prior to running the code for the confidence bands. If the user has made changes in smoothing parameters or modified the data in any way since the last time `modelEstimation` was run, the standard running of `modelEstimation` must be done and the output saved as `eList`. The commands would be:

```
eList <- modelEstimation(eList)
```

Simple Workflow

This example workflow assumes that we use the default values (`nBoot = 100`) for all of the model parameters and PA and uses the example `eList` provided in the package. Remember, this is a very long-running process:

```
library(EGRET)
library(EGRETci)

eList <- Choptank_eList

CIAnnualResults <- ciCalculations(eList)

save(eList, CIAnnualResults, file="CIAnnualResults.RData")
```

To run the `ciCalculations` function in batch mode, the only difference is that additional arguments are specified in the call to the function. For example the call to `ciCalculations` might read as follows:

```
CIAnnualResults <- ciCalculations(eList, nBoot = 100, blockLength = 200, widthCI = 90)
```

As long as all required arguments (`nBoot`, `blockLength`, and `widthCI`) are specified there will be no interaction needed.

Parallel Computing

Taking advantage of the **foreach** package to do parallel computing:

```
library(foreach)
library(doParallel)
library(iterators)
library(EGRET)
library(EGRETci)

eList <- Choptank_eList
eList <- modelEstimation(eList)

nBoot <- 100
blockLength <- 200
coreOut <- 1 #Number of cores to leave out of processing tasks

widthCI <- 90
ciLower <- (50-(widthCI/2))/100
ciUpper <- (50+(widthCI/2))/100
probs <- c(ciLower, ciUpper)

nCores <- detectCores() - coreOut
cl <- makeCluster(nCores)
registerDoParallel(cl)
repAnnual <- foreach(n = 1:nBoot, .packages=c('EGRETci')) %dopar% {
  annualResults <- bootAnnual(eList,
                              blockLength,
                              startSeed = n)
}
stopCluster(cl)

# save(repAnnual, file="repAnnual.RData")

CIAnnualResults <- ciBands(eList, repAnnual, probs)
save(eList, CIAnnualResults, file="CIAnnualResults.RData")
```

CI Result Plots

Regardless of the way that the computations are done the outputs that are needed for the graphics are contained in `eList` and `CIAnnualResults` (which in either script will end up in a file called `CIAnnualResults.RData`). Once that file is loaded the graphics can be produced using the functions `plotConcHistBoot` and `plotFluxHistBoot`. Each of these functions only require two arguments (`eList` and

CIAnnualResults). However, the user can specify a number of other arguments. These other arguments are the same ones used in the `plotConcHist` and `plotFluxHist` functions in the base **EGRET** package.


The user can also view a table of the confidence interval values shown in these graphics simply by using the command `CIAnnualResults` (fluxes will be in units of kg/day).

Here is a script for producing these graphics, using the example `eList` and `CIAnnualResults` data frames included in the package.

```
eList <- Choptank_eList
```

```
CIAnnualResults <- Choptank_CIAnnualResults
```

```
plotConcHistBoot(eList, CIAnnualResults)
```



```
plotFluxHistBoot(eList, CIAnnualResults)
```

Choptank River Inorganic nitrogen (nitrate and nitrite)
Water Year

90 % CI on FN Flux, Replicates = 100 , Block= 200 days

