



Обзор

GPT Model Hub — это облачный сервис для развертывания и использования [больших языковых моделей \(LLM\)](#) в облачной инфраструктуре MWS. Сервис предоставляет готовую платформу для работы с моделями и обеспечивает их безопасное, масштабируемое и управляемое использование в корпоративных и продуктовых решениях.

Сервис позволяет организациям использовать мощь современных LLM без необходимости самостоятельно разворачивать, поддерживать и оптимизировать инфраструктуру машинного обучения.

Ключевые особенности

Гибкость и контроль

Пользователь может выбирать конкретную [модель LLM](#), ее версию и параметры генерации.

Масштабируемость и высокая производительность

Инфраструктура сервиса оптимизирована для параллельной обработки большого количества запросов, обеспечивая низкие задержки и стабильную производительность при пиковых нагрузках.

Управление доступом и аудит

GPT использует IAM для разграничения прав [пользователей](#) и [сервисных аккаунтов](#).

Совместимость с API и SDK

Сервис поддерживает стандартную спецификацию OpenAI API, при этом обеспечивается совместимость с существующими библиотеками и SDK для популярных языков программирования (Python, JavaScript, Go).

Как работает сервис

Сервис организован по принципу «модель как эндпоинт». После создания проекта и выбора модели пользователю предоставляется API-эндпоинт, через который можно выполнять

запросы для диалога, генерации или анализа текста.

Процесс развертывания и работы с сервисом:

1. **Выбор модели** — пользователь выбирает подходящую модель из [списка доступных моделей](#).
2. **Развертывание** — MWS создает [деплоймент](#): развернутую в облачной среде модель с заданными параметрами.
3. **Интеграция** — пользователь или приложение взаимодействует с деплойментом с помощью API-запросов, передавая запросы (промpts) и получая ответы.

Сценарии использования

Интеллектуальные ассистенты и чат-боты

Создание диалоговых систем для поддержки и консультирования клиентов, автоматизации внутренних процессов и обучения персонала.

Автоматизация документооборота

Обработка текстов, резюмирование документов, генерация отчетов, извлечение ключевых данных из заявок, контрактов, писем и т.п.

Генерация контента

Создание маркетинговых и рекламных материалов, описаний товаров, сценариев, статей и публикаций.

Генерация кода и поддержка разработчиков

Автоматическая генерация, анализ и документирование кода, помощь в написании тестов и оптимизации алгоритмов.

Интеграция в продукты и сервисы

Добавление функций естественно-языкового взаимодействия в корпоративные системы, мобильные приложения и веб-интерфейсы.

Data Intelligence и аналитика

Интерпретация аналитических данных, автоматическое формулирование выводов, генерация SQL-запросов и аналитических сводок на естественном языке.

Активация

Чтобы начать пользоваться сервисом GPT Model Hub, его нужно [активировать](#). Для этого достаточно, имея роль admin на уровне проекта, нажать кнопку **Активировать** на странице сервиса в [веб-консоли](#).

Пример интеграции

Для отправки API-запроса к модели используется стандартный формат JSON:

bash

```
1  POST /v1/completions
2  Authorization: Bearer <API-ключ>
3  Content-Type: application/json
4
5  {
6    "model": "<идентификатор деплоймента>",
7    "prompt": "Объясни, как работает механизм attention в нейронных
8    сетях.",
9    "max_tokens": 300,
10   "temperature": 0.7
11 }
```

Ответ возвращается в виде структуры JSON с полем text, содержащим результат генерации.

Последнее обновление: 23.09.2026, 20:09