Обобщенная аддитивная модель

В статистике **обобщённая аддитивная модель** (**GAM**) — это обобщённая линейная модель, в которой линейная переменная отклика линейно зависит от неизвестных гладких функций некоторых переменных-предикторов, а интерес представляет вывод об этих гладких функциях.

GAM изначально были разработаны Тревором Хасти и Робертом Тибширани[1] для объединения свойств обобщенных линейных моделей с аддитивными моделями. Их можно интерпретировать как дискриминативное обобщение генеративной модели наивного байесовского классификатора.[2]

Модель связывает одномерную переменную отклика Y с некоторыми переменными-предикторами x_i. Для Y задается экспоненциальное распределение (например, нормальное, биномиальное или пуассоновское), а также функция связи g (например, тождественная или логарифмическая), связывающая ожидаемое значение Y с переменными-предикторами через такую структуру, как

$$g(\mathrm{E}(Y)) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_m(x_m).$$

Функции f_i могут быть функциями с заданной параметрической формой (например, полином или непеннализированный регрессионный сплайн переменной) или могут быть заданы непараметрически или полупараметрически, просто как «гладкие функции», которые оцениваются с помощью непараметрических методов. Таким образом, типичная обобщенная аддитивная модель может использовать функцию сглаживания для построения диаграммы рассеяния, например локально взвешенное среднее, для $f_1(x_1)$, а затем использовать факторную модель для $f_2(x_2)$. Такая гибкость позволяет использовать непараметрические методы с менее строгими допущениями относительно фактической взаимосвязи между откликом и предиктором, что дает возможность лучше подогнать модель к данным, чем при использовании чисто параметрических моделей, но, возможно, с некоторой потерей интерпретируемости.

Теоретические основы

С 1950-х годов было известно (благодаря теореме Колмогорова — Арнольда о представлении), что любую многомерную непрерывную функцию можно представить в виде суммы и композиции одномерных функций,

$$f(\vec{x}) = \sum_{q=0}^{2n} \Phi_q \left(\sum_{p=1}^{n} \phi_{q,p}(x_p) \right).$$

К сожалению, хотя теорема Колмогорова — Арнольда о представлении утверждает существование функции такого вида, она не дает механизма ее построения. Существуют определенные конструктивные доказательства, но они, как правило, требуют использования очень сложных (то есть фрактальных) функций и поэтому не подходят для моделирования. Поэтому в обобщенной аддитивной модели[1] внешняя сумма опускается, а функция должна принадлежать более простому классу.

$$f(\vec{x}) = \Phi\left(\sum_{p=1}^{n} \phi_p(x_p)\right).$$

где Φ — гладкая монотонная функция. Если обозначить g как обратную функцию к Φ, то это традиционно записывается как

$$g(f(\vec{x})) = \sum_i f_i(x_i).$$

Когда эта функция аппроксимирует математическое ожидание некоторой наблюдаемой величины, ее можно записать как

$$g(\mathbf{E}(Y)) = \beta_0 + f_1(x_1) + f_2(x_2) + \cdots + f_m(x_m).$$

Это стандартная формулировка обобщенной аддитивной модели. Затем было показано[1] что алгоритм обратного обучения всегда будет сходиться для этих функций.

Общие сведения

Класс моделей обобщённой аддитивной модели довольно широк, учитывая, что *гладкая функция* — это довольно обширная категория. Например, ковариата x_j может быть многомерной, а соответствующая f_j — гладкой функцией нескольких переменных, или f_j может быть функцией, сопоставляющей уровень фактора со значением случайного эффекта. Другой пример — изменяющийся коэффициент (географическая регрессия), например $z_j f_j(x_j)$ где z_j и x_j являются ковариатами. Или, если $x_j(t)$ сама по себе является наблюдением за функцией, мы можем включить такой член, как $\int f_j(t)x_j(t)dt$ (иногда его называют членом сигнальной регрессии). f_j также может быть простой параметрической функцией, как и в любой обобщенной линейной модели. Класс моделей был расширен в нескольких направлениях, в частности за счет выхода за рамки экспоненциальных распределений, за рамки моделирования только среднего значения и за рамки одномерных данных. [3][4][5]

Методы подбора GAM

В исходном методе подбора обобщенной аддитивной модели сглаживающие компоненты модели оценивались с помощью непараметрических сглаживателей (например, сглаживающих сплайнов или сглаживателей локальной линейной регрессии) с использованием алгоритма обратного подбора.[1] Обратный подбор работает за счет итеративного сглаживания частичных остатков и представляет собой универсальный модульный метод оценки, позволяющий использовать широкий спектр методов сглаживания для оценки $f_j(x_j)$ параметров. Недостаток метода обратной подгонки заключается в том, что его сложно интегрировать с оценкой степени гладкости модели, поэтому на практике пользователь должен сам задавать эти параметры или выбирать из небольшого набора заранее определенных уровней сглаживания.

Если $f_j(x_j)$ представлены с помощью сглаживающих сплайнов[6] , то степень сглаживания можно оценить в рамках подбора модели с помощью обобщенной перекрестной проверки или с помощью метода ограниченного максимального правдоподобия (REML, иногда называемого GML), который использует двойственность между сплайнами и гауссовыми случайными эффектами. [7] Этот метод с использованием сплайнов требует $O(n^3)$ вычислительных ресурсов, где n — количество наблюдений за зависимой переменной, что делает его непрактичным для умеренно больших наборов данных. В более современных методах эта вычислительная проблема решается либо за счет предварительного уменьшения размера базиса, используемого для сглаживания (снижение ранга)[8][9][10][11][12] , либо за счет поиска разреженных представлений сглаженных данных с использованием марковских случайных полей, которые позволяют применять методы разреженных матриц для вычислений.[13] Эти более эффективные с точки зрения вычислений методы используют GCV (или AIC, или аналогичные методы), REML или полностью байесовский подход для определения степени гладкости компонентов модели. Оценку степени гладкости с помощью REML можно рассматривать как эмпирический байесовский метод.

Альтернативный подход, обладающий особыми преимуществами при работе с многомерными данными, заключается в использовании бустинга, хотя для количественной оценки неопределенности обычно требуется бутстрэппинг. [14][15] Было установлено, что обобщенные аддитивные модели, построенные с помощью бэггинга и бустинга, в целом превосходят обобщенные аддитивные модели, построенные с помощью сплайн-методов. [16]

Система понижения ранга

Many modern implementations of GAMs and their extensions are built around the reduced rank smoothing approach, because it allows well founded estimation of the smoothness of the component smooths at comparatively modest computational cost, and also facilitates implementation of a number of model extensions in a way that is more difficult with other methods. At its simplest the idea is to replace the unknown smooth functions in the model wi basis expansions

$$f_j(x_j) = \sum_{k=1}^{K_j} \beta_{jk} b_{jk}(x_j)$$

где $b_{jk}(x_j)$ — известные базисные функции, обычно выбираемые из-за их хороших теоретических свойств аппроксимации (например, B-сплайны или тонкопластинчатые сплайны пониженного ранга), а β_{jk} — коэффициенты, которые необходимо оценить в рамках подбора модели. Размерность базиса K_j выбирается достаточно большой, чтобы модель могла подогнать имеющиеся данные (тем самым избегая смещения из-за чрезмерного упрощения модели), но при этом достаточно малой, чтобы сохранить вычислительную эффективность. Если $p = \sum_j K_j$, то вычислительные затраты на оценку модели таким способом составят $O(np^2)$.

Обратите внимание, что f_j можно идентифицировать только с точностью до константы (мы могли бы добавить любую константу к f_1 и вычесть ее из f_2 без каких-либо изменений в прогнозах модели), поэтому для устранения этой неоднозначности необходимо наложить ограничения на идентифицируемость сглаживающих членов. Наиболее точные выводы о f_j обычно можно сделать, используя ограничения на сумму, равную нулю.

$$\sum_i f_j(x_{ji}) = 0$$

То есть мы настаиваем на том, что сумма каждого из f_j значений, вычисленных при наблюдаемых значениях ковариаты, должна быть равна нулю. Такие линейные ограничения проще всего наложить путем репараметризации на этапе настройки базиса,[11] поэтому ниже предполагается, что это уже сделано.

Заменив все f_j в модели такими базисными разложениями, мы превратили обобщенную аддитивную модель в обобщенную линейную модель (ОЛМ) с матрицей модели, которая просто содержит базисные функции, вычисленные по наблюдаемым x_j значениям. Однако, поскольку размерность базиса, K_j, была выбрана несколько большей, чем необходимо для данных, модель содержит избыточное количество параметров и будет

переобучена, если оценивать ее как обычную ОЛМ. Решение этой проблемы заключается в том, чтобы наказывать за отклонения от гладкости в процессе подбора модели, контролируя вес, придаваемый сглаживающим штрафам, с помощью параметров сглаживания. Например, рассмотрим ситуацию, в которой все сглаживающие функции являются одномерными. Запишем все параметры в один вектор, β и предположим, что $D(\beta)$ — это отклонение (удвоенная разница между логарифмической вероятностью насыщения и логарифмической вероятностью модели) для данной модели. Минимизация отклонения с помощью обычного метода наименьших квадратов с итеративным взвешиванием привела бы к переобучению, поэтому мы стремимся β минимизировать

$$D(\beta) + \sum_j \lambda_j \int f_j''(x)^2 dx$$

где интегрированные квадратичные штрафы за вторую производную служат для того, чтобы уменьшить «дрожание» (недостаточную гладкость) f_j при подгонке, а параметры сглаживания λ_j регулируют компромисс между качеством подгонки модели и ее гладкостью. В данном примере $\lambda_j \to \infty$ гарантирует, что оценка $f_j(x_j)$ будет представлять собой прямую линию в x_j.

Given the basis expansion for each f_j the wiggliness penalties can be expressed as quadratic forms in the model coefficients.[11] That is we can write

$$\int f_j''(x)^2 dx = \beta_j^T \bar{S}_j \beta_j = \beta^T S_j \beta,$$

where $\bar{S}_j$ is a matrix of known coefficients computable from the penalty and basis, β_j is the vector of coefficients for f_j, and S_j is just $\bar{S}_j$ padded with zeros so that the second equality holds and we can write the penalty in terms of the full coefficient vector β. Many other smoothing penalties can be written in the same way, and given the smoothing parameters the model fitting problem now becomes

$$\hat{\beta} = \mathbf{argmin}_\beta \{D(\beta) + \sum_j \lambda_j \beta^T S_j \beta\},$$

which can be found using a penalized version of the usual iteratively reweighted least squares (IRLS) algorithm for GLMs: the algorithm is unchanged except that the sum of quadratic penalties is added to the working least squared objective at each iteration of the algorithm.

Penalization has several effects on inference, relative to a regular GLM. For one thing the estimates are subject to some smoothing bias, which is the price that must be paid for limiting estimator variance by penalization. However, if smoothing parameters are selected appropriately the (squared) smoothing bias introduced by penalization should be less than the reduction in variance that it produces, so that the net effect is a reduction in mean square estimation error,

relative to not penalizing. A related effect of penalization is that the notion of degrees of freedom of a model has to be modified to account for the penalties' action in reducing the coefficients' freedom to vary. For example, if W is the diagonal matrix of IRLS weights at convergence, and X is the GAM model matrix, then the model effective degrees of freedom is given by $\mathbf{trace}(F)$ where

$$F = (X^T W X + \sum_j \lambda_j S_j)^{-1} X^T W X,$$

is the effective degrees of freedom matrix.[11] In fact summing just the diagonal elements of F corresponding to the coefficients of f_j gives the effective degrees of freedom for the estimate of f_j.

Bayesian smoothing priors

Smoothing bias complicates interval estimation for these models, and the simplest approach turns out to involve a Bayesian approach.[17][18][19][20] Understanding this Bayesian view of smoothing also helps to understand the REML and full Bayes approaches to smoothing parameter estimation. At some level smoothing penalties are imposed because we believe smooth functions to be more probable than wiggly ones, and if that is true then we might as well formalize this notion by placing a prior on model wiggliness. A very simple prior might be

$$\pi(\beta) \propto \mathbf{exp}\{-\beta^T \sum_j \lambda_j S_j \beta/(2\phi)\}$$

(where ϕ is the GLM scale parameter introduced only for later convenience), but we can immediately recognize this as a multivariate normal prior with mean $\mathbf{0}$ and precision matrix $S_\lambda = \sum_j \lambda_j S_j/\phi$. Since the penalty allows some functions through unpenalized (straight lines, given the example penalties), S_λ is rank deficient, and the prior is actually improper, with a covariance matrix given by the Moore–Penrose pseudoinverse of S_λ (the impropriety corresponds to ascribing infinite variance to the unpenalized components of a smooth).[19]

Now if this prior is combined with the GLM likelihood, we find that the posterior mode for β is exactly the $\hat{\beta}$ found above by penalized IRLS.[19][11] Furthermore, we have the large sample result that

$$\beta|y \sim N(\hat{\beta}, (X^T W X + S_\lambda)^{-1}\phi).$$

which can be used to produce confidence/credible intervals for the smooth components, f_j. The Gaussian smoothness priors are also the basis for fully Bayesian inference with GAMs,[9] as well as methods estimating GAMs as mixed models[12][21] that are essentially empirical Bayes methods.

Smoothing parameter estimation

So far we have treated estimation and inference given the smoothing parameters, $\boldsymbol{\lambda}$, but these also need to be estimated. One approach is to take a fully Bayesian approach, defining priors on the (log) smoothing parameters, and using stochastic simulation or high order approximation methods to obtain information about the posterior of the model coefficients.[9][13] An alternative is to select the smoothing parameters to optimize a prediction error criterion such as Generalized cross validation (GCV) or the Akaike information criterion (AIC).[22] Finally we ma choose to maximize the Marginal Likelihood (REML) obtained by integrating the model coefficients, $\boldsymbol{\beta}$ out of the joint density of $\boldsymbol{\beta}, \boldsymbol{y}$,

$$\hat{\boldsymbol{\lambda}} = \mathbf{argmax}_{\boldsymbol{\lambda}} \int \boldsymbol{f}(\boldsymbol{y}|\boldsymbol{\beta}, \boldsymbol{\lambda})\boldsymbol{\pi}(\boldsymbol{\beta}|\boldsymbol{\lambda})\boldsymbol{d}\boldsymbol{\beta}.$$

Since $\boldsymbol{f}(\boldsymbol{y}|\boldsymbol{\beta}, \boldsymbol{\lambda})$ is just the likelihood of $\boldsymbol{\beta}$, we can view this as choosing $\boldsymbol{\lambda}$ to maximize the average likelihood of random draws from the prior. The preceding integral is usually analytically intractable but can be approximated to quite high accuracy using Laplace's method.[21]

Smoothing parameter inference is the most computationally taxing part of model estimation/inference. For example, to optimize a GCV or marginal likelihood typically requires numerical optimization via a Newton or Quasi-Newton method, with each trial value for the (log) smoothing parameter vector requiring a penalized IRLS iteration to evaluate the corresponding $\hat{\boldsymbol{\beta}}$ alongside the other ingredients of the GCV score or Laplace approximate marginal likelihood (LAML). Furthermore, to obtain the derivatives of the GCV or LAML, required for optimization, involves implicit differentiation to obtain the derivatives of $\hat{\boldsymbol{\beta}}$ w.r.t. the log smoothing parameters, and this requires some care is efficiency and numerical stability are to be maintained.[21]

Программное обеспечение

Обратное обучение обобщенных аддитивных моделей изначально обеспечивалось функцией `gam` в языке S,[23] которая теперь перенесена на язык R в виде пакета `gam` . Процедура SAS `GAM` также обеспечивает обратное обучение обобщенных аддитивных моделей. Рекомендуемый пакет для обобщенных аддитивных моделей в R — `mgcv`, что расшифровывается как *mixed GAM computational vehicle*,[11] и основан на подходе с пониженным рангом и автоматическим выбором параметров сглаживания. Процедура SAS `GAMPL` — альтернативная реализация. В Python есть пакет PyGAM с функциями, аналогичными функциям пакета mgcv в R. Кроме того, есть пакет `InterpretML` , в котором реализован подход бэггинга и бустинга. [24] Существует множество альтернативных пакетов. Например, пакеты R `mboost`,[14] в котором реализован подход бустинга; `gss`, в котором представлены все методы сплайн-сглаживания;[25] `VGAM` в котором представлены векторные обобщенные аддитивные модели;[4] и `gamlss`, в

котором представлена обобщенная аддитивная модель местоположения, масштаба и формы. `BayesX` и его интерфейс на языке R позволяют использовать обобщенные аддитивные модели и их расширения с помощью методов Монте-Карло с марковской цепью и методов штрафного правдоподобия.[26] Программное обеспечение `INLA` реализует полностью байесовский подход, основанный на представлениях марковских случайных полей с использованием методов разреженных матриц.[13]

В качестве примера того, как модели можно оценивать на практике с помощью программного обеспечения, рассмотрим пакет R `mgcv`. Предположим, что в нашем рабочем пространстве R есть векторы *y*, *x* и *z*, и мы хотим оценить модель

$$y_i = \beta_0 + f_1(x_i) + f_2(z_i) + \epsilon_i \text{ where } \epsilon_i \sim N(0, \sigma^2).$$

В R мы могли бы вводить команды

```
library(mgcv) # загрузить пакет
b = gam(y ~ s(x) + s(z))
```

Как и большинство функций моделирования в R, `gam` ожидает, что будет передана формула модели, определяющая структуру модели. Переменная отклика указывается слева от `~`, а спецификация линейного предиктора — справа. `gam` задает базисы и штрафы для сглаживающих членов, оценивает модель, включая ее параметры сглаживания, и, в соответствии со стандартами R, возвращает *объект подобранной модели*, который затем можно проанализировать с помощью различных вспомогательных функций, таких как `summary`, `plot`, `predict`, и `AIC`.

В этом простом примере используется несколько настроек по умолчанию, о которых важно знать. Например, предполагается, что распределение является гауссовым, а функция связи — тождественной, а критерием выбора параметра сглаживания является обобщенная перекрестная проверка. Кроме того, сглаживающие члены представлены с помощью «штрафных регрессионных сплайнов с тонкими пластинами», а размерность базиса для каждого из них установлена на уровне 10 (что подразумевает максимум 9 степеней свободы после наложения ограничений на идентифицируемость). Второй пример показывает, как можно контролировать эти параметры. Предположим, что мы хотим оценить модель

$$y_i \sim \text{Poi}(\mu_i) \text{ where } \log \mu_i = \beta_0 + \beta_1 x_i + f_1(t_i) + f_2(v_i, w_i).$$

Мы используем метод REML для выбора параметров сглаживания и ожидаем, что f_1 будет относительно сложной функцией, которую мы хотели бы смоделировать с помощью сплайна кубической регрессии с регуляризацией. Для f_2 нам также нужно решить, находятся ли v и w в одном масштабе, так что подойдет изотропный

сглаживатель, такой как тонкопластинчатый сплайн (задается с помощью `s(v,w)'), или же они действительно находятся в разных масштабах, так что нам нужны отдельные штрафы за сглаживание и параметры сглаживания для v и w , которые обеспечивает сглаживатель тензорного произведения. Предположим, что в данном случае мы выбрали второй вариант. Тогда следующий код на языке R позволит оценить модель

```
b1 = gam(y ~ x + s(t,bs="cr",k=100) +
te(v,w),family=poisson,method="REML")
```

which uses a basis size of 100 for the smooth of t. The specification of distribution and link function uses the `family' objects that are standard when fitting GLMs in R or S. Note that Gaussian random effects can also be added to the linear predictor.

These examples are only intended to give a very basic flavour of the way that GAM software is used, for more detail refer to the software documentation for the various packages and the references below.[11][25][4][23][14][26]

Проверка модели

Как и в случае с любой другой статистической моделью, важно проверить допущения, лежащие в основе обобщенной аддитивной модели. Остаточные графики следует анализировать так же, как и в случае с любой обобщенной линейной моделью. То есть остатки отклонения (или другие стандартизированные остатки) следует анализировать на предмет закономерностей, которые могут указывать на существенное нарушение допущений модели о независимости или соотношении среднего и дисперсии. Обычно это включает в себя построение графика зависимости стандартизированных остатков от подобранных значений и ковариат для выявления проблем со средним значением и дисперсией или отсутствия закономерности, а также может включать в себя изучение коррелограмм (автокорреляционных функций) и/или вариограмм остатков для проверки на нарушение независимости. Если соотношение среднего значения и дисперсии в модели верно, то масштабированные остатки должны иметь примерно постоянную дисперсию. Обратите внимание, что, поскольку обобщенные линейные модели и обобщенные аддитивные модели можно оценить с помощью квазиправдоподобия, детали распределения остатков, выходящие за рамки соотношения среднего и дисперсии, имеют относительно небольшое значение.

Одна из проблем, которая чаще возникает при использовании обобщенных аддитивных моделей, чем при использовании других обобщенных линейных моделей, — это риск ошибочного вывода о том, что данные содержат слишком много нулей. Сложность

возникает, когда данные содержат много нулей, которые можно смоделировать с помощью распределения Пуассона или биномиального распределения с очень низким ожидаемым значением: гибкость структуры обобщенной аддитивной модели часто позволяет представить очень низкое среднее значение в некоторой области ковариационного пространства, но распределение стандартизированных остатков не будет иметь ничего общего с приблизительной нормальностью, которую мы ожидаем увидеть при использовании обобщенных линейных моделей, даже если модель абсолютно верна.[27]

Еще одна дополнительная проверка, которую требуют обобщенные аддитивные модели, — это необходимость убедиться, что выбранные степени свободы подходят. Это особенно актуально при использовании методов, которые не позволяют автоматически оценить степень сглаживания компонентов модели. При использовании методов с автоматическим выбором параметра сглаживания все равно необходимо убедиться, что размерность базиса не слишком мала, хотя это маловероятно, если эффективные степени свободы оценки члена модели значительно ниже размерности базиса. В любом случае проверка $f_j(x_j)$ основана на анализе структуры остатков по отношению к x_j. Это можно сделать, наложив частичные остатки на график $\hat{f}_j(x_j)$, или используя перестановку остатков для построения тестов на выявление закономерностей в остатках.

Выбор модели

Когда параметры сглаживания оцениваются в процессе подбора модели, большая часть того, что традиционно считается выбором модели, включается в процесс подбора: оценка параметров сглаживания уже позволяет выбрать из широкого спектра моделей с разной функциональной сложностью. Однако оценка параметров сглаживания обычно не приводит к полному исключению сглаживающего члена из модели, поскольку большинство регуляризаторов не накладывают ограничений на некоторые функции (например, прямые линии не подвергаются штрафу за производную сплайна, описанному выше). Таким образом, вопрос о том, должен ли тот или иной член присутствовать в модели, остается открытым. Один из простых подходов к решению этой проблемы — добавить дополнительный штраф к каждому сглаживающему члену в обобщенной аддитивной модели, который штрафует те компоненты сглаживания, которые в противном случае не подвергались бы штрафу (и только их). Каждый дополнительный штраф имеет свой собственный параметр сглаживания, и оценка производится так же, как и раньше, но теперь с учетом того, что некоторые члены могут быть полностью обнулены. [28] В условиях высокой размерности может быть целесообразнее

использовать лассо или эластичную сетку. Boosting также автоматически выполняет выбор терминов в процессе подбора.[14]

В качестве альтернативы можно использовать традиционные методы пошаговой регрессии для выбора модели. Этот метод также используется по умолчанию, если параметры сглаживания не оцениваются в процессе подбора модели. В этом случае для каждого сглаживающего члена обычно выбирается один из небольшого набора заранее определенных уровней сглаживания, и эти уровни выбираются пошагово. Пошаговые методы предполагают итеративное сравнение моделей с определенными членами или без них (или, возможно, с разными уровнями сложности членов), и для принятия решения о том, какую модель выбрать на каждом этапе, требуются показатели соответствия модели или значимости членов. Например, мы можем использовать p-значения для проверки каждого члена уравнения на равенство нулю, чтобы определить, какие члены можно исключить из модели, а также сравнить значения информационного критерия Акаике (AIC) для альтернативных моделей.

Вычисление P-значения для сглаженных моделей — непростая задача из-за эффекта штрафования, но существуют приблизительные методы. [1][11] Для обобщенных аддитивных моделей AIC можно вычислить двумя способами. Предельный информационный критерий Акаике основан на предельном правдоподобии (см. выше) с интегрированными коэффициентами модели. В этом случае штраф по критерию Акаике зависит от количества параметров сглаживания (и любых параметров дисперсии) в модели. Однако из-за хорошо известного факта, что метод REML неприменим для сравнения моделей с разными структурами фиксированных эффектов, мы обычно не можем использовать такой критерий Акаике для сравнения моделей с разными сглаживающими членами (поскольку их компоненты без штрафа действуют как фиксированные эффекты). Можно использовать AIC на основе предельной вероятности, в которой интегрируются только эффекты с регуляризацией (количество коэффициентов без регуляризации теперь добавляется к количеству параметров для штрафа AIC), но эта версия предельной вероятности склонна к чрезмерному сглаживанию, что и послужило первоначальной мотивацией для разработки REML. Учитывая эти проблемы, обобщенные аддитивные модели часто сравнивают с помощью условного информационного критерия Акаике, в котором в качестве информационного критерия используется правдоподобие модели (а не предельное правдоподобие), а количество параметров принимается за эффективные степени свободы модели. [1][22]

Naive versions of the conditional AIC have been shown to be much too likely to select larger models in some circumstances, a difficulty attributable to neglect of smoothing parameter uncertainty when computing the effective degrees of freedom,[29] however correcting the effective degrees of freedom for this problem restores reasonable performance.[3]

Предостережения

Переобучение может быть проблемой при использовании обобщенных аддитивных моделей,[22] особенно если присутствует неучтенная остаточная автокорреляция или неучтенная сверхдисперсия. Перекрестная проверка может использоваться для выявления и/или уменьшения проблем с переобучением при использовании обобщенных аддитивных моделей (или других статистических методов),[30] а программное обеспечение часто позволяет увеличить уровень регуляризации, чтобы добиться более плавной аппроксимации. Оценка очень большого количества параметров сглаживания также может быть сопряжена со статистическими трудностями, и известны случаи, когда критерии оценки ошибок прогнозирования (GCV, AIC и т. д.) приводили к существенному недооценке сглаживания, особенно при умеренном размере выборки, в то время как метод REML в этом отношении менее проблематичен. [31]

Там, где это возможно, более простые модели, такие как линейные модели, могут быть предпочтительнее смешанных моделей, если только смешанные модели существенно не повышают точность прогнозирования (на проверочных наборах данных) для рассматриваемой области применения.

См. также

- Аддитивная модель
- Алгоритм обратного подбора
- Обобщенная аддитивная модель местоположения, масштаба и формы (GAMLSS)
- Остаточные эффективные степени свободы
- Полупараметрическая регрессия

Ссылки

1. Хасти, Т. Дж.; Тибширани, Р. Дж. (1990). *Обобщенные аддитивные модели*. Chapman & Hall/CRC. ISBN 978-0-412-34390-2.
2. Рубинштейн, И. Дан; Хасти, Тревор (14 августа 1997 г.). "Дискриминативное и информативное обучение" (https://dl.acm.org/doi/abs/10.5555/3001392.3001401) . *Материалы Третьей международной конференции по обнаружению знаний и интеллектуальному анализу данных*. KDD'97. Ньюпорт-Бич, Калифорния: AAAI Press: 49–53.

3. Вуд, С. Н.; Пья, Н.; Саефкен, Б. (2016). "Параметр сглаживания и выбор модели для общих сглаженных моделей (с обсуждением)". *Journal of the American Statistical Association*. **111** (516): 1548–1575. arXiv:1511.03864 (https://arxiv.org/abs/1511.03864) . doi:10.1080/01621459.2016.1180986 (https://doi.org/10.1080%2F01621459.2016.1180986) . S2CID 54802107 (https://api.semanticscholar.org/CorpusID:54802107) .
4. Йи, Томас (2015). *Векторные обобщенные линейные и аддитивные модели*. Прыгун. ISBN 978-1-4939-2817-0.
5. Ригби, Р.А.; Стасинопулос, Д.М. (2005). "Обобщенные аддитивные модели местоположения, масштаба и формы (с обсуждением)" (https://doi.org/10.1111%2Fj.1467-9876.2005.00510.x) . *Journal of the Royal Statistical Society, Series C*. **54** (3): 507–554. doi:10.1111/j.1467-9876.2005.00510.x (https://doi.org/10.1111%2Fj.1467-9876.2005.00510.x) .
6. Ваба, Грейс. *Сплайновые модели для данных наблюдений*. SIAM.
7. Гу, Ч.; Вахба, Г. (1991). "Минимизация показателей GCV/GML с помощью нескольких параметров сглаживания методом Ньютона" (http://pages.stat.wisc.edu/~wahba/ftp1/oldie/gu.wahba.mult.1991.pdf) (PDF). *Журнал SIAM по научным и статистическим вычислениям*. **12** (2): 383–398. doi:10.1137/0912021 (https://doi.org/10.1137%2F0912021) .
8. Вуд, С. Н. (2000). "Моделирование и оценка параметров сглаживания с помощью множественных квадратичных штрафов" (http://opus.bath.ac.uk/16633/1/mspfinal.pdf) (PDF). *Journal of the Royal Statistical Society*. Серия B. **62** (2): 413–428. doi:10.1111/1467-9868.00240 (https://doi.org/10.1111%2F1467-9868.00240) . S2CID 15500664 (https://api.semanticscholar.org/CorpusID:15500664) .
9. Фармайер Л., Ланг С. (2001). «Байесовский вывод для обобщенных аддитивных смешанных моделей на основе априорных распределений марковского случайного поля». *Journal of the Royal Statistical Society, Series C*. **50** (2): 201–220. CiteSeerX 10.1.1.304.8706 (https://citeseerx.ist.psu.edu/viewdoc/summary?doi=10.1.1.304.8706) . doi:10.1111/1467-9876.00229 (https://doi.org/10.1111%2F1467-9876.00229) . S2CID 18074478 (https://api.semanticscholar.org/CorpusID:18074478) . `{{cite journal}}`: В цитировании используется устаревший параметр `|citeseerx=` (помощь)
10. Kim, Y.J.; Gu, C. (2004). "Smoothing spline Gaussian regression: more scalable computation via efficient approximation" (https://doi.org/10.1046%2Fj.1369-7412.2003.05316.x) . *Journal of the Royal Statistical Society, Series B*. **66** (2): 337–356. doi:10.1046/j.1369-7412.2003.05316.x (https://doi.org/10.1046%2Fj.1369-7412.2003.05316.x) . S2CID 41334749 (https://api.semanticscholar.org/CorpusID:41334749) .

11. Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R (2nd ed)*. Chapman & Hall/CRC. ISBN 978-1-58488-474-3.

12. Ruppert, D.; Wand, M.P.; Carroll, R.J. (2003). *Semiparametric Regression*. Cambridge University Press.

13. Rue, H.; Martino, Sara; Chopin, Nicolas (2009). "Approximate Bayesian inference for latent Gaussian models by using integrated nested Laplace approximations (with discussion)" ps://doi.org/10.1111%2Fj.1467-9868.2008.00700.x) . *Journal of the Royal Statistical Society, Series B*. **71** (2): 319–392. doi:10.1111/j.1467-9868.2008.00700.x (https://doi.org/10.1111%2Fj.1467-9868.2008.00700.x) . hdl:2066/75507 (https://hdl.handle.net/2066%2F75507) .

14. Schmid, M.; Hothorn, T. (2008). "Boosting additive models using component-wise P-splines" (https://epub.ub.uni-muenchen.de/2057/1/tr002.pdf) (PDF). *Computational Statistics and Data Analysis*. **53** (2): 298–311. doi:10.1016/j.csda.2008.09.009 (https://doi.org/10.1016%2Fj.csda.2008.09.009) .

15. Mayr, A.; Fenske, N.; Hofner, B.; Kneib, T.; Schmid, M. (2012). "Generalized additive models for location, scale and shape for high dimensional data - a flexible approach based on boosting". *Journal of the Royal Statistical Society, Series C*. **61** (3): 403–427. doi:10.1111/j.1467-9876.2011.01033.x (https://doi.org/10.1111%2Fj.1467-9876.2011.01033.x) . S2CID 123646605 (https://api.semanticscholar.org/CorpusID:123646605) .

16. Lou, Yin; Caruana, Rich; Gehrke, Johannes (2012). "Intelligible models for classification and regression". *Proceedings of the 18th ACM SIGKDD international conference on Knowledge discovery and data mining - KDD '12*. p. 150. doi:10.1145/2339530.2339556 (https://doi.org/10.1145%2F2339530.2339556) . ISBN 9781450314626. S2CID 7715182 (https://api.semanticscholar.org/CorpusID:7715182) .

17. Wahba, G. (1983). "Bayesian Confidence Intervals for the Cross Validated Smoothing Spline" (http://www.stat.ucla.edu/~cocteau/stat204/readings/wahba1.pdf) (PDF). *Journal of the Royal Statistical Society, Series B*. **45**: 133–150. doi:10.1111/j.2517-6161.1983.tb01239.x (https://doi.org/10.1111%2Fj.2517-6161.1983.tb01239.x) .

18. Nychka, D. (1988). "Bayesian confidence intervals for smoothing splines". *Journal of the American Statistical Association*. **83** (404): 1134–1143. doi:10.1080/01621459.1988.10478711 (https://doi.org/10.1080%2F01621459.1988.10478711) .

19. Silverman, B.W. (1985). "Some Aspects of the Spline Smoothing Approach to Non-Parametric Regression Curve Fitting (with discussion)" (http://www-personal.umich.edu/~jizhu/jizhu/wuke/Silverman-JRSSB85.pdf) (PDF). *Journal of the Royal Statistical Society, Series B*. **47**: 1–53. doi:10.1111/j.2517-6161.1985.tb01327.x (https://doi.org/10.1111%2Fj.2517-6161.1985.tb01327.x) .

20. Marra, G.; Wood, S.N. (2012). "Coverage properties of confidence intervals for generalized additive model components" (http://opus.bath.ac.uk/26662/1/MarraWoodCI.pdf) (PD *Scandinavian Journal of Statistics*. **39**: 53–74. doi:10.1111/j.1467-9469.2011.00760.x (https://doi.org/10.1111%2Fj.1467-9469.2011.00760.x) . S2CID 49393564 (https://api.semanticscholar.org/CorpusID:49393564) .

21. Wood, S.N. (2011). "Fast stable restricted maximum likelihood and marginal likelihood estimation of semiparametric generalized linear models" (http://opus.bath.ac.uk/22707/1/Wood_JRSSB_2011_73_1_3.pdf) (PDF). *Journal of the Royal Statistical Society, Series B*. **73**: 3–36. doi:10.1111/j.1467-9868.2010.00749.x (https://doi.org/10.1111%2Fj.1467-9868.2010.00749.x) . S2CID 123001831 (https://api.semanticscholar.org/CorpusID:123001831) .

22. Wood, Simon N. (2008). "Fast stable direct fitting and smoothness selection for generalized additive models". *Journal of the Royal Statistical Society, Series B*. **70** (3): 495–518. arXiv:0709.3906 (https://arxiv.org/abs/0709.3906) . doi:10.1111/j.1467-9868.2007.00646.x (https://doi.org/10.1111%2Fj.1467-9868.2007.00646.x) . S2CID 17511583 (https://api.semanticscholar.org/CorpusID:17511583) .

23. Chambers, J.M.; Hastie, T. (1993). *Statistical Models in S*. Chapman and Hall.

24. Nori, Harsha; Jenkins, Samuel; Koch, Paul; Caruana, Rich (2019). "InterpretML: A Unified Framework for Machine Learning Interpretability". arXiv:1909.09223 (https://arxiv.org/abs/1909.09223) [cs.LG (https://arxiv.org/archive/cs.LG)].

25. Gu, Chong (2013). *Smoothing Spline ANOVA Models (2nd ed.)*. Springer.

26. Umlauf, Nikolaus; Adler, Daniel; Kneib, Thomas; Lang, Stefan; Zeileis, Achim. "Structured Additive Regression Models: An R Interface to BayesX" (https://www.econstor.eu/bitstream/10419/73863/1/2012-10.pdf) (PDF). *Journal of Statistical Software*. **63** (21): 1–46.

27. Augustin, N.H.; Sauleau, E-A; Wood, S.N. (2012). "On quantile quantile plots for generalized linear models" (http://opus.bath.ac.uk/27091/1/qq_gam_resub.pdf) (PDF). *Computational Statistics and Data Analysis*. **56** (8): 2404–2409. doi:10.1016/j.csda.2012.01.026 (https://doi.org/10.1016%2Fj.csda.2012.01.026) . S2CID 2960406 (https://api.semanticscholar.org/CorpusID:2960406) .

28. Marra, G.; Wood, S.N. (2011). "Practical Variable Selection for Generalized Additive Models". *Computational Statistics and Data Analysis*. **55** (7): 2372–2387. doi:10.1016/j.csda.2011.02.004 (https://doi.org/10.1016%2Fj.csda.2011.02.004) .
29. Greven, Sonja; Kneib, Thomas (2010). "On the behaviour of marginal and conditional AIC in linear mixed models". *Biometrika*. **97** (4): 773–789. doi:10.1093/biomet/asq042 (https://doi.org/10.1093%2Fbiomet%2Fasq042) .
30. Brian Junker (March 22, 2010). "Additive models and cross-validation" (http://www.stat.cmu.edu/~cshalizi/490/10/xval-and-additive/xval-and-additive2.pdf) (PDF).
31. Reiss, P.T.; Ogden, T.R. (2009). "Smoothing parameter selection for a class of semiparametric linear models" (https://doi.org/10.1111%2Fj.1467-9868.2008.00695.x) . *Journal of the Royal Statistical Society, Series B*. **71** (2): 505–523. doi:10.1111/j.1467-9868.2008.00695.x (https://doi.org/10.1111%2Fj.1467-9868.2008.00695.x) . S2CID 51945597 (https://api.semanticscholar.org/CorpusID:51945597) .

Внешние ссылки

- gam (https://cran.r-project.org/web/packages/gam/index.html) , an R package for GAMs by backfitting.
- gam (https://www.statsmodels.org/devel/gam.html) , Python module in statsmodels.gam module.
- InterpretML (https://github.com/interpretml/interpret) , a Python package for fitting GAMs via bagging and boosting.
- mgcv (https://cran.r-project.org/web/packages/mgcv/index.html) , an R package for GAMs using penalized regression splines.
- mboost (https://cran.r-project.org/web/packages/mboost/index.html) , an R package for boosting including additive models.
- gss (https://cran.r-project.org/web/packages/gss/index.html) , an R package for smoothing spline ANOVA.
- INLA (http://www.r-inla.org/) software for Bayesian Inference with GAMs and more.
- BayesX (http://www.uni-goettingen.de/en/bayesx/550513.html) software for MCMC and penalized likelihood approaches to GAMs.
- Doing magic and analyzing seasonal time series with GAM in R (https://petolau.github.io/Analyzing-double-seasonal-time-series-with-GAM-in-R/)
- GAM: The Predictive Modeling Silver Bullet (http://multithreaded.stitchfix.com/blog/2015/07/30/gam/)

- Building GAM by projection descent (https://www.youtube.com/watch?v=eS_k6L638k0)