Сглаживающий сплайн

Сглаживающие сплайны — это оценки функций $\hat{f}(x)$, полученные на основе набора зашумленных наблюдений y_i за целевой функцией $f(x_i)$, которые позволяют сбалансировать меру точности аппроксимации $\hat{f}(x_i)$ к y_i с мерой гладкости $\hat{f}(x)$, основанной на производных. Они позволяют сглаживать зашумленные x_i, y_i данные. Самый известный пример — кубический сглаживающий сплайн, но существует множество других вариантов, в том числе для случая, когда x является векторной величиной.

Определение кубического сплайна

Пусть $\{x_i, Y_i : i = 1, \ldots, n\}$ - набор наблюдений, смоделированных соотношением, $Y_i = f(x_i) + \epsilon_i$ где ϵ_i - независимые случайные величины с нулевым средним значением. Оценка кубического сглаживающего сплайна $\hat{f}$ функции f определяется как единственный минимизатор в пространстве Соболева W_2^2 на компактном интервале из[1][2]

$$\sum_{i=1}^{n}\{Y_i - \hat{f}(x_i)\}^2 + \lambda \int \hat{f}''(x)^2\, dx.$$

Замечания:

- $\lambda \geq 0$ — это параметр сглаживания, определяющий компромисс между точностью соответствия данным и шероховатостью оценки функции. Часто его оценивают с помощью обобщенной перекрестной проверки,[3] или с помощью метода ограниченного максимального правдоподобия (REML)[4] , который использует связь между сплайн-сглаживанием и байесовской оценкой (штраф за сглаживание можно рассматривать как следствие априорной оценки f).[5]
- Интеграл часто вычисляется по всей вещественной прямой, хотя можно ограничить диапазон значениями x_i.
- При $\lambda \to 0$ (без сглаживания) сглаживающий сплайн сходится к интерполирующему сплайну.
- При $\lambda \to \infty$ (бесконечном сглаживании) штраф за шероховатость становится первостепенным, и оценка сходится к оценке линейного метода наименьших квадратов.
- Штраф за шероховатость, основанный на второй производной, является наиболее распространенным в современной статистической литературе, хотя этот метод можно

легко адаптировать для штрафов, основанных на других производных.

- В ранних работах при использовании упорядоченных x_i с равными интервалами в качестве штрафа использовались разности второго или третьего порядка, а не производные.[6] См. также метод сглаживания Уиттекера — Хендерсона.
- Метод сглаживания с регуляризацией суммы квадратов можно заменить на *Метод регуляризации* — метод оптимизации, в котором сумма квадратов отклонений заменяется другой мерой соответствия данных, основанной на логарифмической функции правдоподобия. [1] Сумма квадратов отклонений соответствует методу регуляризации с предположением о гауссовом распределении ϵ_i.

Вывод формулы кубического сглаживающего сплайна

Полезно рассматривать аппроксимацию сглаживающим сплайном в два этапа:

1. Сначала вычислите значения $\hat{f}(x_i); i = 1, \ldots, n$.
2. На основе этих значений вычислите $\hat{f}(x)$ для всех *x*.

Теперь приступайте ко второму этапу.

При заданном векторе $\hat{m} = (\hat{f}(x_1), \ldots, \hat{f}(x_n))^T$ подобранных значений часть критерия сплайна, связанная с суммой квадратов, фиксирована. Остается только минимизировать $\int \hat{f}''(x)^2\,dx$, и минимизатором является натуральный кубический сплайн, интерполирующий точки $(x_i, \hat{f}(x_i))$. Этот интерполирующий сплайн является линейным оператором и может быть записан в виде

$$\hat{f}(x) = \sum_{i=1}^{n} \hat{f}(x_i) f_i(x)$$

где $f_i(x)$ — набор сплайновых базисных функций. В результате штраф за шероховатость принимает следующий вид:

$$\int \hat{f}''(x)^2 dx = \hat{m}^T A \hat{m}.$$

где элементы A – это $\int f_i''(x) f_j''(x) dx$. Базисные функции и, следовательно, матрица A зависят от конфигурации переменных-предикторов x_i, но не от откликов Y_i или $\hat{m}$.

A – это $n \times n$ матрица, заданная $A = \Delta^T W^{-1} \Delta$.

Δ – это $(n-2) \times n$ матрица вторых разностей с элементами:

$\Delta_{ii} = 1/h_i, \Delta_{i,i+1} = -1/h_i - 1/h_{i+1}, \Delta_{i,i+2} = 1/h_{i+1}$

W – это $(n-2) \times (n-2)$ симметричная трехдиагональная матрица с элементами:

$W_{i-1,i} = W_{i,i-1} = h_i/6, W_{ii} = (h_i + h_{i+1})/3$ и $h_i = \xi_{i+1} - \xi_i$, расстояния между соседними узлами (или значениями x).

Теперь вернемся к первому шагу. Сумму квадратов с учетом штрафа можно записать как

$$\{Y - \hat{m}\}^T \{Y - \hat{m}\} + \lambda \hat{m}^T A \hat{m},$$

где $Y = (Y_1, \ldots, Y_n)^T$.

Минимизируем $\hat{m}$ путем дифференцирования по $\hat{m}$. В результате получаем:
$-2\{Y - \hat{m}\} + 2\lambda A\hat{m} = 0$[7] и $\hat{m} = (I + \lambda A)^{-1} Y.$

Подход Де Бура

В подходе де Бура используется та же идея — найти баланс между плавностью кривой и близостью к заданным данным.[8]

$$p \sum_{i=1}^{n} \left(\frac{Y_i - \hat{f}\left(x_i\right)}{\delta_i} \right)^2 + (1-p) \int \left(\hat{f}^{(m)}\left(x\right) \right)^2 dx$$

где p — параметр, называемый коэффициентом сглаживания, который принадлежит интервалу $[0, 1]$, а $\delta_i ; i = 1, \ldots, n$ — величины, определяющие степень сглаживания (они представляют собой вес δ_i^{-2} каждой точки Y_i). На практике, поскольку в основном используются кубические сплайны, m обычно равно 2. Решение для $m = 2$ было предложено Кристианом Райншем в 1967 году.[9] При $m = 2$ и приближении p к 1 $\hat{f}$ сходится к «естественному» сплайну, интерполирующему заданные данные.[8] По мере p приближения 0, $\hat{f}$ сходится к прямой линии (наиболее плавной кривой). Поскольку поиск подходящего значения p является задачей проб и ошибок, для удобства была введена избыточная константа S.[9] S используется для численного определения значения p так , чтобы функция $\hat{f}$ удовлетворяла следующему условию:

$$\sum_{i=1}^{n} \left(\frac{Y_i - \hat{f}\left(x_i\right)}{\delta_i} \right)^2 \leq S$$

Алгоритм, описанный де Буром, начинается с $p = 0$ и увеличивает p до тех пор, пока не будет выполнено условие.[8] Если δ_i является оценкой стандартного отклонения для Y_i, то константу S рекомендуется выбирать в интервале $\left[n - \sqrt{2n}, n + \sqrt{2n}\right]$. Значение $S = 0$ означает, что решение является «естественным» сплайновым интерполятором.[9] Увеличение S означает, что мы получаем более плавную кривую, отдаляясь от заданных данных.

Многомерные сплайны

Существует два основных класса методов, позволяющих перейти от сглаживания по скаляру x к сглаживанию по вектору x. Первый подход заключается в простом обобщении штрафа за сглаживание по сплайну на многомерный случай. Например, при попытке оценить $f(x, z)$ мы можем использовать штраф тонкого пластинчатого сплай и найти $\hat{f}(x, z)$ минимизирующую

$$\sum_{i=1}^{n}\{y_i - \hat{f}(x_i, z_i)\}^2 + \lambda \int \left[\left(\frac{\partial^2 \hat{f}}{\partial x^2}\right)^2 + 2\left(\frac{\partial^2 \hat{f}}{\partial x \partial z}\right)^2 + \left(\frac{\partial^2 \hat{f}}{\partial z^2}\right)^2\right] \mathrm{d}x\, \mathrm{d}z.$$

Метод сплайнов на основе тонких пластин можно обобщить для сглаживания по более чем двум измерениям и для других порядков дифференцирования в штрафном факторе.[1] По мере увеличения размерности возникают некоторые ограничения на наименьший порядок дифференцирования, который можно использовать,[1] но на самом деле в оригинальной статье Дюшона,[10] приводятся несколько более сложные штрафные функции, которые позволяют избежать этого ограничения.

Тонкопластинчатые сплайны изотропны, то есть при повороте системы координат x, z оценка не изменится, но при этом предполагается, что одинаковый уровень сглаживания подходит для всех направлений. Это часто считается разумным при сглаживании в зависимости от пространственного расположения, но во многих других случаях изотропность не является подходящим допущением и может привести к чувствительности к, казалось бы, произвольным единицам измерения. Например, при сглаживании по расстоянию и времени изотропный сглаживатель даст разные результаты, если расстояние измерять в метрах, а время — в секундах, и если мы изменим единицы измерения на сантиметры и часы.

Второй класс обобщений для многомерного сглаживания напрямую решает проблему масштабной инвариантности с помощью конструкций сплайнов на основе тензорного произведения. [11][12][13] Такие сплайны имеют штрафы за сглаживание с несколькими параметрами сглаживания, и это цена, которую приходится платить за то, что не предполагается одинаковая степень гладкости во всех направлениях.

Похожие методы

Сглаживающие сплайны связаны с другими методами, но отличаются от них:

- *Сплайны регрессии*. В этом методе данные подгоняются под набор сплайновых базисных функций с уменьшенным набором узлов, как правило, методом наименьших

квадратов. Штраф за шероховатость не применяется. (См. также многомерные адаптивные сплайны регрессии.)

- *Сплайны с регуляризацией*. Этот метод сочетает в себе уменьшенное количество узлов сплайнов регрессии и штраф за шероховатость сглаживающих сплайнов.[14][15]
- *Тонкопластинчатые сплайны* и метод эластичных карт для обучения на многообразии. Этот метод сочетает в себе штраф за ошибку аппроксимации по методу наименьших квадратов со штрафом за изгиб и растяжение аппроксимирующего многообразия и использует грубую дискретизацию задачи оптимизации.

Исходный код

Исходный код для сплайн-сглаживания можно найти в примерах из книги Карла де Бура *«Практическое руководство по сплайнам»*. Примеры написаны на Fortran языке программирования. Обновленные исходники также доступны на официальном сайте Карла де Бура (http://pages.cs.wisc.edu/~deboor/) .

Ссылки

1. Грин, П. Дж.; Сильверман, Б. У. (1994). *Непараметрическая регрессия и обобщенные линейные модели: подход с учетом шероховатости*. Chapman and Hall.
2. Хасти, Т. Дж.; Тибширани, Р. Дж. (1990). *Обобщенные аддитивные модели*. Chapman and Hall. ISBN 978-0-412-34390-2.
3. Крейвен, П.; Вахба, Г. (1979). "Сглаживание зашумленных данных с помощью сплайн-функций". *Numerische Mathematik*. **31** (4): 377–403. doi:10.1007/bf01404567 (https://doi.org/10.1007%2Fbf01404567) .
4. (PDF) (https://www.stats.ox.ac.uk/~ripley/LME4.pdf) «Ограниченное максимальное правдоподобие как метод оценки в линейных смешанных моделях». *Линейные смешанные модели с односторонним расположением REML от Оксфордского факультета статистики*.
5. Kimeldorf, G.S.; Wahba, G. (1970). "A Correspondence between Bayesian Estimation on Stochastic Processes and Smoothing by Splines" (https://doi.org/10.1214%2Faoms%2F1177697089) . *The Annals of Mathematical Statistics*. **41** (2): 495–502. doi:10.1214/aoms/1177697089 (https://doi.org/10.1214%2Faoms%2F1177697089) .
6. Уиттакер, Э. Т. (1922). "О новом методе градуирования". *Труды Эдинбургского математического общества*. **41**: 63–75. doi:10.1017/S0013091500077853 (https://doi.org/10.1017%2FS0013091500077853) .

7. Родригес, Герман (весна 2001 г.). «Сглаживание и непараметрическая регрессия» (https://grodri.github.io/demography/smoothing.pdf) (PDF). 2.3.1 Вычисления. стр. 12. Дата обращения: 28 апреля 2024.
8. Де Бур, К. (2001). *Практическое руководство по сплайнам* (пересмотренное издание). Springer. стр. 207–214. ISBN 978-0-387-90356-9.
9. Рейнш, Кристиан Х. (1967). "Сглаживание с помощью сплайн-функций". *Numerische Mathematik*. **10** (3): 177–183. doi:10.1007/BF02162161 (https://doi.org/10.1007%2FBF02162161) .
10. Ж. Дюшон, 1976, Сплайны, минимизирующие инвариантные к повороту полунормы в пространствах Соболева. стр. 85–100, в книге: Конструктивная теория функций нескольких переменных, Обервольфах, 1976, под ред. В. Шемппа и К. Целлера, Lecture Notes in Math., т. 571, Springer, Берлин, 1977
11. Ваба, Грейс. *Сплайновые модели для данных наблюдений*. SIAM.
12. Гу, Чонг (2013). *Модели сглаженного сплайнового дисперсионного анализа (2-е изд.)*. Springer.
13. Вуд, С. Н. (2017). *Обобщенные аддитивные модели: введение с использованием R (2-е изд.)*. Chapman & Hall/CRC. ISBN 978-1-58488-474-3.
14. Эйлерс, П.Х.К. и Маркс Б. (1996). «Гибкое сглаживание с помощью B-сплайнов и штрафных функций». *Statistical Science*. **11** (2): 89–121. doi:10.1214/ss/1038425655 (https://doi.org/10.1214%2Fss%2F1038425655) .
15. Рупперт, Дэвид; Уэнд, М. П.; Кэрролл, Р. Дж. (2003). *Полупараметрическая регрессия*. Издательство Кембриджского университета. ISBN 978-0-521-78050-6.

Дополнительная литература

- Ваба, Г. (1990). *Сплайновые модели для данных наблюдений*. SIAM, Филадельфия.
- Грин, П. Дж., и Сильверман, Б. У. (1994). *Непараметрическая регрессия и обобщенные линейные модели*. CRC Press.
- Де Бур, К. (2001). *Практическое руководство по сплайнам (пересмотренное издание)*. Springer.