Векторная обобщенная линейная модель

В статистике был предложен класс **векторных обобщенных линейных моделей** (**VGLM**), чтобы расширить область применения моделей, поддерживаемых обобщенными линейными моделями (**GLM**). В частности, VGLM позволяют использовать переменные отклика, выходящие за рамки классического экспоненциального семейства, и работать более чем одним параметром. Каждый параметр (не обязательно среднее значение) может быть преобразован с помощью *функции связи*. Модель VGLM также достаточно универсальна, чтобы естественным образом учитывать множественные отклики — несколько независимых откликов, каждый из которых соответствует определенному статистическому распределению с возможными различиями в значениях параметров.

Векторные обобщенные линейные модели подробно описаны в работе Йи (2015).[1] В основе алгоритма лежит метод итеративного взвешенного наименьшего квадрата , используемый для оценки максимального правдоподобия обычно всех параметров модели. В частности, для большинства моделей используется метод Фишера, который использует первую и ожидаемую вторую производные функции логарифмического правдоподобия.

Мотивация

Обобщенные линейные модели по сути охватывают однопараметрические модели из классического экспоненциального семейства и включают в себя три наиболее важные статистические регрессионные модели: линейную модель, регрессию Пуассона для подсчета значений и логистическую регрессию для бинарных откликов. Однако экспоненциальное семейство слишком ограничено для обычного анализа данных. Например, при подсчете часто встречаются такие явления, как нулевая инфляция, нулевая усеченность и сверхдисперсия, а импровизированные адаптации биномиальной и пуассоновской моделей в виде квазибиномиальной и квазипуассоновской моделей можно назвать ситуативными и неудовлетворительными. Однако в рамках обобщенной линейной модели со случайными эффектами можно легко работать с такими моделями, как нулевая инфляционная пуассоновская регрессия, нулевая измененная пуассоновская (пороговая) регрессия, позитивная пуассоновская регрессия и отрицательная биномиальная регрессия. Другой пример: в линейной модели дисперсия нормального распределения рассматривается как параметр масштаба и часто считается мешающим параметром (если вообще считается параметром). Однако в рамках обобщенной линейной модели со случайными эффектами дисперсию можно моделировать с помощью ковариат.

В целом можно сказать, что обобщенные линейные модели со случайными эффектами — это обобщенные линейные модели, которые работают со многими моделями, выходящими за рамки классического экспоненциального семейства, и не ограничиваются оценкой одного среднего значения. При оценке вместо взвешенного метода наименьших квадратов при IRLS используется обобщенный метод наименьших квадратов для учета корреляции между *M* линейными предикторами.

Данные и обозначения

Мы предполагаем, что реакция, или результат, или зависимая переменная, $\boldsymbol{y} = (y_1, \ldots, y_{Q_1})^T$ предполагается, что она сгенерирована на основе определенного распределения. Большинство распределений являются одномерными, так что $Q_1 = 1$, и примером $Q_1 = 2$ является двумерное нормальное распределение.

Иногда мы записываем наши данные как $(\boldsymbol{x}_i, w_i, \boldsymbol{y}_i)$ для $i = 1, \ldots, n$. Каждое из *n* наблюдений считается независимым. Тогда $\boldsymbol{y}_i = (y_{i1}, \ldots, y_{iQ_1})^T$. w_i Известны положительные предшествующие веса, и часто $w_i = 1$.

Объясняющие или независимые переменные записываются как $\boldsymbol{x} = (x_1, \ldots, x_p)^T$, или, если требуется *i*, как $\boldsymbol{x}_i = (x_{i1}, \ldots, x_{ip})^T$. Обычно присутствует *пересечение*, в этом случае записывается $x_1 = 1$ или $x_{i1} = 1$.

На самом деле фреймворк VGLM позволяет использовать *S* ответов, каждый из которых имеет размерность Q_1. В приведенном выше примере *S* = 1. Таким образом, размерность $\boldsymbol{y}_i$ в более общем случае равна $Q = S \times Q_1$. Для обработки *S* ответов используется код, например `vglm(cbind(y1, y2, y3) ~ x2 + x3, ..., data = mydata)` для *S* = 3. Для простоты в большей части этой статьи *S* = 1.

Компоненты модели

VGLM обычно состоит из четырех элементов:

1. Функция плотности вероятности или функция распределения вероятностей некоторого статистического распределения, имеющая логарифм правдоподобия ℓ, первые производные $\partial \ell / \partial \theta_j$ и ожидаемую информационную матрицу, которые можно вычислить. Модель должна удовлетворять обычным условиям регулярности метода максимального правдоподобия.
2. Линейные предикторы η_j для моделирования каждого параметра θ_j, описанные ниже. $j = 1, \ldots, M.$
3. Свяжите функции g_j таким образом, чтобы $\theta_j = g_j^{-1}(\eta_j).$

4. *Матрицы ограничений* $\boldsymbol{H}_k$ для $\boldsymbol{k} = 1, \ldots, \boldsymbol{p}$, каждой из них имеют полный ранг по столбцам и известны.

Линейные предикторы

Каждый *линейный предиктор* — это величина, которая включает в модель информацию о независимых переменных. Символ $\boldsymbol{\eta}_j$ (греческая буква эта) обозначает линейный предиктор, а индекс *j* используется для обозначения *j*-го предиктора. Он связывает *j*-й параметр с объясняющими переменными и $\boldsymbol{\eta}_j$ выражается в виде линейных комбинаций (отсюда «линейный») неизвестных параметров $\boldsymbol{\beta}_j$, то есть коэффициентов регрессии $\beta_{(j)k}$.

j-й параметр $\boldsymbol{\theta}_j$, распределения зависит от независимых переменных $\boldsymbol{x}$, через

$$g_j(\theta_j) = \eta_j = \boldsymbol{\beta}_j^T \boldsymbol{x}.$$

Пусть $\boldsymbol{\eta} = (\eta_1, \ldots, \eta_M)^T$ — вектор всех линейных предикторов. (Для удобства мы всегда указываем, что $\boldsymbol{\eta}$ имеет размерность *M*). Таким образом, *все* ковариаты, входящие в $\boldsymbol{x}$, потенциально влияют на *все* параметры через линейные предикторы $\boldsymbol{\eta}_j$. Позже мы расширим линейные предикторы до аддитивных предикторов, которые представляют собой сумму гладких функций от каждого $\boldsymbol{x}_k$, и каждая функция будет оцениваться на основе данных.

Функции связи

Каждая функция связи устанавливает взаимосвязь между линейным предиктором и параметром распределения. Существует множество часто используемых функций связи, и их выбор может быть в некоторой степени произвольным. Имеет смысл попытаться сопоставить область определения функции связи с диапазоном значений параметра распределения. Обратите внимание, что $\boldsymbol{g}_j$ позволяет использовать разные функции связи для каждого параметра. Они обладают теми же свойствами, что и обобщенные линейные модели, например, распространенные функции связи включают *логит* для параметров в $(0, 1)$ и логарифм для положительных параметров. В пакете `VGAM` есть функция `identitylink()` для параметров, которые могут принимать как положительные, так и отрицательные значения.

Матрицы ограничений

В более общем смысле, метод VGLM позволяет задавать любые линейные ограничения между коэффициентами регрессии $\beta_{(j)k}$ каждого линейного предиктора. Например, мы можем установить, что некоторые из них равны 0, или ограничить их равенство. У нас есть

$$\boldsymbol{\eta} = \sum_{k=1}^{p} \boldsymbol{\beta}_{(k)}\, x_k = \sum_{k=1}^{p} \boldsymbol{H}_k\, \boldsymbol{\beta}^*_{(k)}\, x_k$$

где $\boldsymbol{H}_k$ — *матрицы ограничений*. Каждая матрица ограничений известна и задана заранее, она состоит из *M* строк и от 1 до *M* столбцов. Элементы матриц ограничений имеют конечные значения, чаще всего это 0 или 1. Например, значение 0 фактически исключает этот элемент, а значение 1 — включает. В некоторых моделях часто используется предположение о *параллелизме*, то есть $\boldsymbol{H}_k = \boldsymbol{1}_M$ для $k = 2, \ldots, p$, а в некоторых моделях — и для $k = 1$ тоже. Особый случай, когда $\boldsymbol{H}_k = \boldsymbol{I}_M$ для всех $k = 1, \ldots, p$ известен как *тривиальные ограничения*; все коэффициенты регрессии оцениваются и не связаны между собой. А $\boldsymbol{\theta}_j$ известен как параметр *только с константой*, если *j*-я строка всех $\boldsymbol{H}_k$ = равна $\boldsymbol{0}^T$ для $k = 2, \ldots, p$, то есть $\eta_j = \beta^*_{(j)1}$ равен только константе. Таким образом, параметры только с константой моделируются максимально просто, как скаляр.

The unknown parameters, $\boldsymbol{\beta}^* = (\boldsymbol{\beta}^{*T}_{(1)}, \ldots, \boldsymbol{\beta}^{*T}_{(p)})^T$, are typically estimated by the method of maximum likelihood. All the regression coefficients may be put into a matrix as follows:

$$\boldsymbol{\eta}_i = \boldsymbol{B}^T \boldsymbol{x}_i = \begin{pmatrix} \boldsymbol{\beta}_1^T\, \boldsymbol{x}_i \\ \vdots \\ \boldsymbol{\beta}_M^T\, \boldsymbol{x}_i \end{pmatrix} = \left(\boldsymbol{\beta}_{(1)}, \ldots, \boldsymbol{\beta}_{(p)}\right)\ \boldsymbol{x}_i.$$

The xij facility

With even more generally, one can allow the value of a variable $\boldsymbol{x_k}$ to have a different value for each $\boldsymbol{\eta_j}$. For example, if each linear predictor is for a different time point then one might have a time-varying covariate. For example, in discrete choice models, one has *conditional* logit models, *nested* logit models, *generalized* logit models, and the like, to distinguish between certain variants and fit a multinomial logit model to, e.g., transport choices. A variable such as cost differs depending on the choice, for example, taxi is more expensive than bus, which is more expensive than walking. The `xij` facility of `VGAM` allows one to generalize $\boldsymbol{\eta_j(x_i)}$ to $\boldsymbol{\eta_j(x_{ij})}$.

The most general formula is

$$\boldsymbol{\eta}_i = \boldsymbol{o}_i + \sum_{k=1}^{p} diag(x_{ik1}, \ldots, x_{ikM})\, \mathbf{H}_k\, \boldsymbol{\beta}^*_{(k)}.$$

Here the $\boldsymbol{o_i}$ is an optional *offset*; which translates to be a $\boldsymbol{n \times M}$ matrix in practice. The `VGAM` package has an `xij` argument that allows the successive elements of the diagonal matrix to be inputted.

Программное обеспечение

Йи (2015)[1] описывает реализацию пакета R под названием VGAM.[2] В настоящее время это программное обеспечение поддерживает около 150 моделей/распределений. Основными функциями моделирования являются `vglm()` и `vgam()`. Аргументу `family` присваивается *семейство функций VGAM*, например `family = negbinomial` для отрицательной биномиальной регрессии, `family = poissonff` для пуассоновской регрессии, `family = propodds` для *модели пропорциональных шансов* или *модели кумулятивного логита* для порядковой категориальной регрессии.

Подгонка

Метод максимального правдоподобия

Мы максимизируем логарифм правдоподобия

$$\ell = \sum_{i=1}^{n} w_i \, \ell_i,$$

где w_i — положительные и известные *априорные веса*. Оценки максимального правдоподобия можно найти с помощью алгоритма итеративного взвешенного метода наименьших квадратов с использованием метода оценки Фишера, с обновлениями следующего вида:

$$\boldsymbol{\beta}^{(a+1)} = \boldsymbol{\beta}^{(a)} + \boldsymbol{\mathcal{I}}^{-1}(\boldsymbol{\beta}^{(a)}) \, \mathbf{u}(\boldsymbol{\beta}^{(a)}),$$

где $\boldsymbol{\mathcal{I}}(\boldsymbol{\beta}^{(a)})$ — матрица информации Фишера на итерации *a*. Ее также называют *матрицей ожидаемой информации* или *МОИ*.

VLM

Для вычислений (малая) *матрица модели*, построенная на основе правой части формулы в `vglm()`, и матрицы ограничений объединяются в *большую* матрицу модели. К этой большой **X** применяется метод IRLS. Эта матрица известна как матрица VLM, поскольку *векторная линейная модель* — это базовая задача, решаемая методом наименьших квадратов. VLM — это взвешенная многомерная регрессия, в которой ковариационная матрица для каждой строки матрицы откликов не обязательно одинакова и известна заранее. (В классической многомерной регрессии все ошибки имеют одинаковую ковариационную матрицу, которая неизвестна). В частности, VLM минимизирует взвешенную сумму квадратов

$$\text{ResSS} = \sum_{i=1}^{n} w_i \left\{ \mathbf{z}_i^{(a-1)} - \boldsymbol{\eta}_i^{(a-1)} \right\}^T \mathbf{W}_i^{(a-1)} \left\{ \mathbf{z}_i^{(a-1)} - \boldsymbol{\eta}_i^{(a-1)} \right\}$$

This quantity is minimized at each IRLS iteration. The *working responses* (also known as *pseudo-response* and *adjusted dependent vectors*) are

$$\mathbf{z}_i = \boldsymbol{\eta}_i + \mathbf{W}_i^{-1}\mathbf{u}_i,$$

where the $\mathbf{W}_i$ are known as *working weights* or *working weight matrices*. They are symmetric and positive-definite. Using the EIM helps ensure that they are all positive-definite (and not just the sum of them) over much of the parameter space. In contrast, using Newton–Raphson wo' mean the observed information matrices would be used, and these tend to be positive-definite a smaller subset of the parameter space.

С вычислительной точки зрения разложение Холецкого используется для обращения матриц рабочих весов и преобразования общей задачи обобщенного метода наименьших квадратов в задачу обычного метода наименьших квадратов.

Примеры

Обобщённые линейные модели

Конечно, все обобщенные линейные модели являются частными случаями обобщенных линейных моделей со случайными эффектами. Но мы часто оцениваем все параметры с помощью метода максимального правдоподобия, а не метода моментов для параметра масштаба.

Упорядоченный категориальный ответ

Если переменная отклика представляет собой порядковое измерение с *M* + 1 *уровнями*, то можно использовать модельную функцию следующего вида:

$$g(\theta_j) = \eta_j \quad \text{где } \theta_j = \Pr(Y \leq j),$$

для $j = 1, \ldots, M.$ различных связей *g* используются модели пропорциональных шансов или упорядоченные пробит-модели, например, функция семейства `VGAM` `cumulative(link = probit)` использует пробит-связь для кумулятивных вероятностей, поэтому эту модель также называют *моделью кумулятивного пробит-анализа*. В целом их называют *моделями кумулятивной связи*.

Для категориальных и полиномиальных распределений подобранные значения представляют собой (*M* + 1)-вектор вероятностей, в котором сумма всех вероятностей равна 1. Каждая вероятность указывает на вероятность появления одного из *M* + 1 возможных значений.

Неупорядоченный категориальный ответ

Если зависимая переменная является номинальным измерением или данные не соответствуют допущениям упорядоченной модели, можно использовать модель следующего вида:

$$\log\left[\frac{Pr(Y=j)}{\Pr(Y=M+1)}\right] = \eta_j,$$

for $j = 1, \ldots, M$. The above link is sometimes called the *multilogit* link, and the model is called the multinomial logit model. It is common to choose the first or the last level of the response as the *reference* or *baseline* group; the above uses the last level. The `VGAM` family function `multinomial()` fits the above model, and it has an argument called `refLevel` that can be assigned the level used for as the reference group.

Count data

Classical GLM theory performs Poisson regression for count data. The link is typically the logarithm, which is known as the *canonical link*. The variance function is proportional to the mean:

$$\operatorname{Var}(Y_i) = \tau\mu_i,$$

where the dispersion parameter τ is typically fixed at exactly one. When it is not, the resulting quasi-likelihood model is often described as Poisson with overdispersion, or *quasi-Poisson*; then τ is commonly estimated by the method-of-moments and as such, confidence intervals for τ are difficult to obtain.

In contrast, VGLMs offer a much richer set of models to handle overdispersion with respect to the Poisson, e.g., the negative binomial distribution and several variants thereof. Another count regression model is the *generalized Poisson distribution*. Other possible models are the *zeta distribution* and the *Zipf distribution*.

Расширения

Reduced-rank vector generalized linear models

RR-VGLMs are VGLMs where a subset of the **B** matrix is of a lower rank. Without loss of generality, suppose that $\boldsymbol{x} = (\boldsymbol{x}_1^T, \boldsymbol{x}_2^T)^T$ is a partition of the covariate vector. Then the part of the **B** matrix corresponding to $\boldsymbol{x}_2$ is of the form $\boldsymbol{A}\boldsymbol{C}^T$ where $\boldsymbol{A}$ and $\boldsymbol{C}$ are thin matrices (i.e., with *R* columns), e.g., vectors if the rank *R* = 1. RR-VGLMs potentially offer several advantages when applied to certain models and data sets. Firstly, if *M* and *p* are large then the number of regression coefficients that are estimated by VGLMs is large ($\boldsymbol{M} \times \boldsymbol{p}$). Then RR-VGLMs can reduce the number of estimated regression coefficients enormously if *R* is low, e.g., *R* = 1 or

R = 2. An example of a model where this is particularly useful is the RR-multinomial logit model, also known as the *stereotype model*. Secondly, $\boldsymbol{\nu} = \boldsymbol{C}^T \boldsymbol{x}_2 = (\nu_1, \ldots, \nu_R)^T$ is an *R*-vector of latent variables, and often these can be usefully interpreted. If *R* = 1 then we can write $\boldsymbol{\nu} = \boldsymbol{c}^T \boldsymbol{x}_2$ so that the latent variable comprises loadings on the explanatory variables. It may be seen that RR-VGLMs take optimal linear combinations of the $\boldsymbol{x}_2$ and then a VGLM is fitted to the explanatory variables $(\boldsymbol{x}_1, \boldsymbol{\nu})$. Thirdly, a biplot can be produced if *R* = 2 , and this allows the model to be visualized.

It can be shown that RR-VGLMs are simply VGLMs where the constraint matrices for the variables in $\boldsymbol{x}_2$ are unknown and to be estimated. It then transpires that $\boldsymbol{H}_k = \boldsymbol{A}$ for such variables. RR-VGLMs can be estimated by an *alternating* algorithm which fixes $\boldsymbol{A}$ and estimates $\boldsymbol{C}$, and then fixes $\boldsymbol{C}$ and estimates $\boldsymbol{A}$, etc.

In practice, some uniqueness constraints are needed for $\boldsymbol{A}$ and/or $\boldsymbol{C}$. In `VGAM`, the `rrvglm()` function uses *corner constraints* by default, which means that the top *R* rows of $\boldsymbol{A}$ is set to $\boldsymbol{I}_R$. RR-VGLMs were proposed in 2003.[3]

Two to one

A special case of RR-VGLMs is when *R* = 1 and *M* = 2. This is *dimension reduction* from 2 parameters to 1 parameter. Then it can be shown that

$$\theta_2 = g_2^{-1}\left(t_1 + a_{21} \cdot g_1(\theta_1)\right),$$

where elements t_1 and a_{21} are estimated. Equivalently,

$$\eta_2 = t_1 + a_{21} \cdot \eta_1 .$$

This formula provides a coupling of η_1 and η_2. It induces a relationship between two parameters of a model that can be useful, e.g., for modelling a mean-variance relationship. Sometimes there is some choice of link functions, therefore it offers a little flexibility when coupling the two parameters, e.g., a logit, probit, cauchit or cloglog link for parameters in the unit interval. The above formula is particularly useful for the negative binomial distribution, so that the RR-NB has variance function

$$\operatorname{Var}(Y \mid \boldsymbol{x}) = \mu(\boldsymbol{x}) + \delta_1 \, \mu(\boldsymbol{x})^{\delta_2}.$$

This has been called the *NB-P* variant by some authors. The δ_1 and δ_2 are estimated, and it is also possible to obtain approximate confidence intervals for them too.

Incidentally, several other useful NB variants can also be fitted, with the help of selecting the right combination of constraint matrices. For example, *NB* − 1, *NB* − 2 (`negbinomial()` default), *NB* − *H*; see Yee (2014)[4] and Table 11.3 of Yee (2015).[1]

RCIMs

The subclass of *row-column interaction models* (RCIMs) has also been proposed; these are a special type of RR-VGLM. RCIMs apply only to a matrix **Y** response and there are no explicit explanatory variables $\boldsymbol{x}$. Instead, indicator variables for each row and column are explicitly set up, and an order-*R* interaction of the form $\boldsymbol{AC}^T$ is allowed. Special cases of this type of model include the *Goodman RC association model* and the quasi-variances methodology as implemented by the `qvcalc` R package.

RCIMs can be defined as a RR-VGLM applied to **Y** with

$$g_1(\theta_1) \equiv \eta_{1ij} = \beta_0 + \alpha_i + \gamma_j + \sum_{r=1}^{R} c_{ir}\, a_{jr}.$$

For the Goodman RC association model, we have $\eta_{1ij} = \log \mu_{ij}$, so that if *R* = 0 then it is a Poisson regression fitted to a matrix of counts with row effects and column effects; this has a similar idea to a no-interaction two-way ANOVA model.

Another example of a RCIM is if g_1 is the identity link and the parameter is the median and the model corresponds to an asymmetric Laplace distribution; then a no-interaction RCIM is similar to a technique called *median polish*.

In `VGAM`, `rcim()` and `grc()` functions fit the above models. And also Yee and Hadi (2014)[5] show that RCIMs can be used to fit unconstrained quadratic ordination models to species data; this is an example of indirect gradient analysis in ordination (a topic in statistical ecology).

Vector generalized additive models

Vector generalized additive models (VGAMs) are a major extension to VGLMs in which the linear predictor η_j is not restricted to be linear in the covariates $\boldsymbol{x_k}$ but is the sum of smoothing functions applied to the $\boldsymbol{x_k}$:

$$\boldsymbol{\eta}(\boldsymbol{x}) = \boldsymbol{H}_1\, \boldsymbol{\beta}^*_{(1)} + \boldsymbol{H}_2\, \boldsymbol{f}^*_{(2)}(x_2) + \boldsymbol{H}_3\, \boldsymbol{f}^*_{(3)}(x_3) + \cdots$$

where $\boldsymbol{f}^*_{(k)}(x_k) = (f^*_{(1)k}(x_k), f^*_{(2)k}(x_k), \ldots)^T$. These are *M additive predictors*. Each smooth function $f^*_{(j)k}$ is estimated from the data. Thus VGLMs are *model-driven* while VGAMs are *data-driven*. Currently, only smoothing splines are implemented in the `VGAM` package. For *M* > 1 they are actually *vector splines*, which estimate the component functions in $\boldsymbol{f}^*_{(j)k}(\boldsymbol{x_k})$ simultaneously. Of course, one could use regression splines with VGLMs. The motivation behind VGAMs is similar to that of Hastie and Tibshirani (1990)[6] and Wood (2017).[7] VGAMs were proposed in 1996 .[8]

Currently, work is being done to estimate VGAMs using *P-splines* of Eilers and Marx (1996) .[9] This allows for several advantages over using smoothing splines and vector backfitting, such as

the ability to perform automatic smoothing parameter selection easier.

Quadratic reduced-rank vector generalized linear models

These add on a quadratic in the latent variable to the RR-VGLM class. The result is a bell-shaped curve can be fitted to each response, as a function of the latent variable. For *R* = 2, one has bell-shaped surfaces as a function of the 2 latent variables---somewhat similar to a bivariate normal distribution. Particular applications of QRR-VGLMs can be found in ecology, in a field of multivariate analysis called ordination.

As a specific rank-1 example of a QRR-VGLM, consider Poisson data with *S* species. The model for Species *s* is the Poisson regression

$$\log \mu_s(\nu) = \eta_s(\nu) = \beta_{(s)1} + \beta_{(s)2}\,\nu + \beta_{(s)3}\,\nu^2 = \alpha_s - \frac{1}{2}\left(\frac{\nu - u_s}{t_s}\right)^2,$$

for $s = 1, \ldots, S$. The right-most parameterization which uses the symbols α_s, u_s, t_s, has particular ecological meaning, because they relate to the species *abundance*, *optimum* and *tolerance* respectively. For example, the tolerance is a measure of niche width, and a large value means that that species can live in a wide range of environments. In the above equation, one would need $\beta_{(s)3} < 0$ in order to obtain a bell-shaped curve.

QRR-VGLMs fit Gaussian ordination models by maximum likelihood estimation, and they are an example of direct gradient analysis. The `cqo()` function in the `VGAM` package currently calls `optim()` to search for the optimal $\boldsymbol{C}$, and given that, it is easy to calculate the site scores and fit a suitable generalized linear model to that. The function is named after the acronym CQO, which stands for *constrained quadratic ordination*: the *constrained* is for direct gradient analysis (there are environmental variables, and a linear combination of these is taken as the latent variable) and the *quadratic* is for the quadratic form in the latent variables $\boldsymbol{\nu}$ on the $\boldsymbol{\eta}$ scale. Unfortunately QRR-VGLMs are sensitive to outliers in both the response and explanatory variables, as well as being computationally expensive, and may give a local solution rather than a global solution. QRR-VGLMs were proposed in 2004.[10]

См. также

- Generalized linear models
- R (software)
- Regression analysis
- Statistical model
- Natural exponential family

Ссылки

1. Yee, T. W. (2015). *Vector Generalized Linear and Additive Models: With an Implementation in R*. New York, USA: Springer. ISBN 978-1-4939-2817-0.
2. "Vector Generalized Linear Models" (http://cran.R-project.org/package=VGAM) . 2016-01-18.
3. Yee, T. W.; Hastie, T. J. (2003). "Reduced-rank vector generalized linear models". *Statistical Modelling*. **3** (1): 15–41. doi:10.1191/1471082x03st045oa (https://doi.org/10.1191%2F1471082x03st045oa) . S2CID 122810408 (https://api.semanticscholar.org/CorpusID:122810408) .
4. Yee, T. W. (1996). "Reduced-rank vector generalized linear models with two linear predictors". *Computational Statistics & Data Analysis*. **71**: 889–902. doi:10.1016/j.csda.2013.01.012 (https://doi.org/10.1016%2Fj.csda.2013.01.012) .
5. Yee, T. W.; Hadi, A. F. (2014). "Row-column interaction models, with an R implementation". *Computational Statistics*. **29** (6): 1427–1445. doi:10.1007/s00180-014-0499-9 (https://doi.org/10.1007%2Fs00180-014-0499-9) . S2CID 253724333 (https://api.semanticscholar.org/CorpusID:253724333) .
6. Hastie, T. J.; Tibshirani, R. J. (1990). *Generalized Additive Models*. London:Chapman and Hall.
7. Wood, S. N. (2017). *Generalized Additive Models: An Introduction with R* (second ed.). London: Chapman and Hall. ISBN 978-1-4987-2833-1.
8. Yee, T. W.; Wild, C. J. (1996). "Vector generalized additive models". *Journal of the Royal Statistical Society, Series B*. **58** (3): 481–493. doi:10.1111/j.2517-6161.1996.tb02095.x (https://doi.org/10.1111%2Fj.2517-6161.1996.tb02095.x) .
9. Eilers, P. H. C.; Marx, B. D. (1996). "Flexible smoothing with B-splines and penalties". *Statistical Science*. **11** (2): 89–121. doi:10.1214/ss/1038425655 (https://doi.org/10.1214%2Fss%2F1038425655) .
10. Yee, T. W. (2004). "A new technique for maximum-likelihood canonical Gaussian ordination". *Ecological Monographs*. **74** (4): 685–701. doi:10.1890/03-0078 (https://doi.org/10.1890%2F03-0078) .

Дополнительная литература

- Hilbe, Joseph (2011). *Negative Binomial Regression* (2nd ed.). Cambridge: Cambridge University Press. ISBN 978-0-521-19815-8.