Проверь модель на примере нейросетей

Да. Проверим модель на нейросетях — и она работает особенно хорошо, потому что у ИИ вред часто **распространяется во времени**: одна ошибка может повторяться тысячи раз, пока её не исправят.

Базовая формула

$$\boxed{V(T) = B(T) - R(T) + \int_0^T D(t)S(t)\,dt}$$

Где:

- $B(T)$ — польза от ИИ;
  - $R(T)$ — вред от ошибок ИИ;
  - $S(t)$ — исправления, компенсации, защита пользователей;
  - $D(t)$ — коэффициент задержки реакции;
  - T — период наблюдения.

Применение к ИИ

Пусть:

- $B(T)$ — полезные ответы, автоматизация, помощь людям;
- $R(T)$ — ошибки, дискриминация, утечки, вредные советы;
- $S(t)$ — блокировка, исправление модели, компенсация, объяснение;
- $D(t)$ — насколько быстро система отреагировала.

Тогда:
$$

V_{\text{ИИ}}(T)=B_{\text{ИИ}}(T)-R_{\text{ИИ}}(T)+\int_0^T D(t)S_{\text{ИИ}}(t)dt

$$

Что происходит при задержке

Если ИИ ошибся, но система не реагирует:

$$D(t) \downarrow$$

Тогда:

$$\int_0^T D(t)S(t)dt \downarrow$$

И итог:

$$V(T) \downarrow$$

То есть даже если исправление будет сделано потом, его ценность уже ниже, потому что вред успел распространиться.

В реальных системах ИИ задержка между обнаружением проблемы и её устранением увеличивает масштаб ущерба: чем дольше ошибка остаётся активной, тем больше людей она затрагивает. [1] [2] [3]

Пример с числами

Пусть:

- $B(T) = 100$;
  - $R(T) = 80$;
  - $S(t) = 50$;
  - $D(t) = 1$ при немедленной реакции.

  Тогда:
  $$

V(T)=100-80+50=70

$$

Теперь пусть реакция задержалась:

$$D(t) = 0{,}2$$

Тогда:

$$V(T) = 100 - 80 + 0{,}2 \cdot 50 = 30$$

То есть:

$$70 \rightarrow 30$$

Вывод: **та же по объёму помощь даёт гораздо меньший эффект, если пришла слишком поздно.**

Что такое S(t) для ИИ

Для нейросети $S(t)$ — это не только «исправить баг». Это набор мер:

$$S(t) = S_b(t) + S_m(t) + S_c(t) + S_e(t)$$

Где:

- $S_b(t)$ — блокировка вредного поведения;
  - $S_m(t)$ — исправление модели;
  - $S_c(t)$ — компенсация пострадавшим;
  - $S_e(t)$ — объяснение и право на обжалование.

  Тогда:
  $$

V_{\text{ИИ}}(T)=B_{\text{ИИ}}(T)-R_{\text{ИИ}}(T)+\int_0^T D(t)\left(S_b+S_m+S_c+S_e\right)dt

$$

Ключевой вывод

В ИИ модель показывает:

Позднее исправление не отменяет уже причинённый вред, а лишь частично его у

То есть:

- быстрая блокировка — высокая $D(t)$;
- медленное исправление — низкая $D(t)$;
- отсутствие реакции — почти нулевой эффект помощи.

Связь с исходной историей

В истории с мужчиной:

- $B(T)$ — спасённая жизнь ребёнка;
  - $R(T)$ — инвалидность мужчины;
  - $S(t)$ — помощь мужчине;
  - $D(t)$ — скорость реакции общества.

  Если общество помогает сразу — ущерб меньше.
  Если общество медлит — мужчина остаётся один.
  Если общество игнорирует — V становится отрицательной.
  То есть модель работает одинаково:
  $$

\boxed{
\text{Ошибка ИИ и человеческая трагедия подчиняются одной логике: задержка помощи увеличивает цену.}
}

$$

Финальная проверка

Модель подтверждается:

- в ИИ — задержка увеличивает масштаб вреда;
- в финансах — задержка повышает стоимость кризиса;
- в медицине — задержка ухудшает исход;
- в социальной сфере — задержка усиливает бедность и одиночество.

И универсальный вывод:

> Любая система, которая медлит с реакцией, превращает ошибку в системный ущ

Именно это и есть главная проверка нашей модели: она не только описывает мораль, но и **предсказывает последствия промедления.** [4] [5] [6] [7]

⁂

1. http://www.learn.microsoft.com/en-us/security/zero-trust/sfi/incident-response-ai-systems
2. https://www.microsoft.com/en-us/security/blog/2026/04/15/incident-response-for-ai-same-fire-different-fuel/
3. https://www.cybersecuritydive.com/spons/improving-incident-response-with-ai-agents/872988/
4. https://airc.nist.gov/airmf-resources/playbook/manage/
5. https://www.unesco.org/en/articles/comparing-governance-mechanisms-ai
6. https://cltc.berkeley.edu/publication/cltc-white-paper-ais-redress-problem/
7. https://www.cambridge.org/core/services/aop-cambridge-core/content/view/A1EBCD6CAA146F503C8F6842914F3FB3/S3033373325000092a.pdf/toward-empowering-ai-governance-with-redress-mechanisms.pdf
8. https://www.holisticai.com/ai-risk-management
9. https://www.coalitionforsecureai.org/wp-content/uploads/2026/03/AI-Incident-Response-1.pdf
10. https://github.com/kentaz/ai-governance-toolkit/blob/main/03-operate/ai-incident-response-playbook.md
11. https://www.gov.uk/government/publications/ai-risk-management-toolkit/ai-risk-management-toolkit-guidance
12. https://committees.parliament.uk/writtenevidence/148345/html/
13. https://2021-2025.state.gov/risk-management-profile-for-ai-and-human-rights/
14. https://galileo.ai/blog/ai-incident-response-detection-triage-playbook
15. https://cloudsecurityalliance.org/blog/2026/08/14/when-the-playbook-breaks-ai-incident-response-for-systems-that-don-t-behave-like-anything-else