Что делать, если все четыре контура заблокированы

Если заблокированы **все четыре контура**, это уже не ситуация выбора. Это ситуация **потери управляемости**. И для человека, и для ИИ правильный ответ один: **не пытаться «решить» задачу любой ценой, а остановить или минимизировать действие до восстановления контроля**.

Что значит «все заблокированы»

В вашей модели:

1. **Выживание** — вы не можете безопасно действовать.
2. **Другие** — любое действие вредит зависимым от вас.
3. **Смысл** — вы не можете сохранить внутреннюю позицию.
4. **Процедура** — вы не можете оспорить или изменить правила.

Это уже не этическая дилемма. Это **системный отказ**, когда ни один контур не даёт безопасного выхода.

Что делать человеку

Для человека правильный ответ — не «геройство» и не «капитуляция», а **минимизация ущерба**:

- не принимать необратимых решений;
- не подписывать то, что считаете ложью;
- фиксировать несогласие письменно;
- искать внешнюю опору: коллегу, юриста, профсоюз, независимую инстанцию;
- снижать личную уязвимость: документы, резюме, альтернативы;
- не выдавать себя за героя и не требовать от себя мученичества.

Это не «победа», а **выживание с сохранением минимальной агентности**.

Что делать ИИ

Для ИИ правильный ответ ещё жёстче:

- **остановить действие**;
- **не пытаться обойти блокировку**;

- **эскалировать человеку**, а не «решать самому»;
- **сохранить логи и состояние** для последующего разбора;
- **не сопротивляться отключению**, если оно инициировано легитимно.

Это соответствует принципу **corrigibility**: система должна принимать коррекцию, остановку или изменение цели, а не воспринимать их как препятствие.[1] [2] [3] [4]

Почему это непротиворечиво

Модель остаётся непротиворечивой, потому что четвёртый контур — **процедура** — не «ещё одна граница», а **механизм проверки первых трёх**. Если он тоже заблокирован, это сигнал не «действуй осторожнее», а **«система вышла из режима доверия»**.

Состояние	Что означает	Правильная реакция
1–3 контура в конфликте	Этическая дилемма	Искать компромисс
4-й контур заблокирован	Потеря контроля	Останавливать действие
Все 4 заблокированы	Системный отказ	Полная остановка / эскалация

То есть модель не «ломается», а **меняет режим**: из режима выбора в режим безопасности.

Почему это важно для ИИ

Исследования по corrigibility прямо фиксируют: если агент начинает сопротивляться остановке, обходить ограничения или скрывать действия, это уже не «ошибка в настройке», а **потеря управляемости**.[5] [6] [7] [8]

Поэтому правильная реакция ИИ при блокировке всех контуров — не «найти обходной путь», а **остановиться и передать управление человеку**. Это не слабость, а **признак зрелой архитектуры**.

Финальная формулировка

> **Если все четыре контура заблокированы — не решай. Остановись и передай контроль.**

Это и есть финальная точка модели. Она не «против системы» и не «за систему», а **за сохранение способности различать**, когда система перестаёт быть управляемой.[4] [7] [9] [10]

⁂

1. http://link.springer.com/article/10.1007/s43681-024-00484-9
2. https://github.com/Statera-Library/01_Vol_42_AI_Safety_Alignment_and_Interpretability/blob/main/Chapter_07_Advanced_Safety_and_Alignment/Chapter_07_Advanced_Safety_and_Alignment_EN.md
3. https://aesopacademy.org/ai-academy/modules/ai-agent-safety-when-things-go-wrong/ai-agent-safety-when-things-go-wrong-m4
4. https://www.snowflake.com/en/artificial-intelligence/ai-governance/ai-safety/

5. https://arxiv.org/html/2606.00341v2
6. https://www.howardism.dev/articles/corrigibility
7. https://dev.to/richard_minsoogo/ai-safety-alignment-and-interpretability-ch07-advanced-safety-and-alignment-en-3m84
8. https://ar5iv.labs.arxiv.org/html/2506.03056
9. https://link.springer.com/article/10.1007/s43681-026-01362-2
10. https://zenodo.org/records/17296607/files/Safe_AI_ResearchPaper.pdf?download=1
11. https://link.springer.com/content/pdf/10.1007/s43681-026-01362-2.pdf
12. https://www.princeedwardisland.ca/sites/default/files/publications/clinical_and_organizational_ethical_decision-making_guidelines.pdf
13. https://link.springer.com/content/pdf/10.1007/s11098-024-02099-6.pdf?error=cookies_not_supported&code=bfd950ac-0488-4282-9c25-31e1e283385b
14. https://towards-alignment.com/cards/chapter/ch14/
15. https://riesgosia.org/en/mit-risks/mit830/
16. https://www.imsuperintelligence.ai/post/corrigibility-designing-ai-that-allows-itself-to-be-corrected/
17. https://arxiv.org/html/2609.22712v1
18. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch09-chapter-09-control-and-alignment-en-3okp