Как вернуть хотя бы один контур под контроль

Вернуть можно не «всю систему», а **один минимальный контур**. И обычно это не четвёртый (процедура), а **первый — выживание**: сначала восстановить способность не разрушаться, потом уже спорить о справедливости и смысле.

Принцип: сначала «стоп», потом «право»

Когда все четыре контура заблокированы, задача не «победить систему», а **создать точку опоры**. Это как в альпинизме: сначала закрепиться, потом уже думать о маршруте.

Практически это выглядит так:

1. **Остановить необратимое.** Не подписывать, не отправлять, не уничтожать, не давать согласия «здесь и сейчас».
2. **Зафиксировать состояние.** Сохранить переписку, распоряжения, критерии, версии документов — в личном, защищённом месте.
3. **Сузить поле.** Не решать «всю систему», а выделить один конкретный узел: один документ, одну оценку, один спорный пункт.
4. **Найти внешнюю опору.** Коллега, юрист, профсоюз, независимая инстанция, доверенный человек.
5. **Вернуть право на вопрос.** Даже если вы не можете изменить решение, вы можете **зафиксировать несогласие** — и это уже частичное восстановление контура.

Какой контур возвращать первым

Обычно первым возвращают **контур выживания**, потому что без него остальные не работают.

Контур	Что значит «вернуть под контроль»	Минимальное действие
Выживание	Я не разрушаюсь	Не подписывать, не действовать необратимо, обеспечить безопасность
Другие	Я не причиняю невосполнимый вред	Не усугублять вред, искать альтернативу
Смысл	Я не теряю способность различать	Фиксировать позицию, не соглашаться молча
Процедура	Я могу оспорить правило	Запросить письменное разъяснение, апелляцию

То есть порядок такой: **выживание → другие → смысл → процедура**. Не наоборот.

Как это выглядит в вашем случае

В вашем примере это может выглядеть так:

- Вы не идёте «против ректора» в лоб.
- Вы не подписываете оценку, которую считаете ложной, если это возможно.
- Вы просите письменного разъяснения: «Уточните, пожалуйста, требуется ли изменить оценку вне критериев?»
- Вы сохраняете переписку и формулировки.
- Вы ищете коллегу или юриста, не объявляя войну.
- Вы не выдаёте себя за героя, но и не позволяете полностью стереть свою позицию.

Это уже не «машинное следование правилу», а **человеческая стратегия выживания с сохранением минимальной агентности**.

Что говорит практика ИИ

В ИИ-безопасности это называется **recovery через rollback, containment и human-in-the-loop**: система не «решает конфликт», а сначала останавливает опасное действие, восстанавливает безопасное состояние и передаёт управление человеку. [1] [2] [3] [4]

То есть принцип тот же:

> **Сначала — остановить необратимое. Потом — восстановить контроль. Потом — разбираться.**

Почему это непротиворечиво

Модель остаётся непротиворечивой, потому что «возврат контура» — это не «победа над системой», а **восстановление минимальной способности действовать**. Вы не обязаны сразу чинить всё. Достаточно вернуть **одну точку опоры**, чтобы не сорваться в полную капитуляцию.

Финальная формулировка

> **Верни сначала не справедливость, а способность не разрушаться. Остальное — потом.**

Это и есть практический ответ. Не «как победить», а **«как не потерять себя до того, как появится шанс что-то изменить»**. [2] [3] [4] [1]

⁂

1. https://www.preprints.org/manuscript/202610.1294
2. https://www.veeam.com/glossary/what-is-ai-rollback.html
3. https://huggingface.co/corrigibility
4. https://github.com/UrviGupta-mse2026007/awesome-agentic-ai-safety-rollback

5. https://aisecurityandsafety.org/en/glossary/corrigibility/
6. https://gjeta.com/sites/default/files/fulltext_pdf/GJETA-2026-0137.pdf
7. http://link.springer.com/article/10.1007/s43681-024-00484-9
8. https://www.snowflake.com/en/artificial-intelligence/ai-governance/ai-safety/
9. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch07-chapter-07-motivation-and-will-en-ci3
10. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch09-chapter-09-control-and-alignment-en-3okp
11. https://www.iso.org/standard/65035.html
12. https://arxiv.org/pdf/2305.19861.pdf
13. https://intelligence.org/files/Corrigibility.pdf
14. https://siliconangle.com/2026/11/08/ai-cyber-resilience-and-the-trust-gap/
15. https://huggingface.co/corrigible