Какие слабые места есть у этой модели

У модели есть несколько реальных слабых мест. Главное — она хорошо описывает **идеальную систему**, но плохо защищает от **реальной асимметрии власти, неполноты правил и человеческой усталости**.

1. Контур 4 может быть захвачен

Самое уязвимое место — четвёртый контур, «процедура». Он задуман как защита от произвола, но сам может быть захвачен тем, кто контролирует правила.

Пример: ректор определяет, что «средняя оценка» — это норма, а комиссия подтверждает это. Формально процедура соблюдена, содержательно — нет. Модель не защищает от **легитимизированного произвола**.

Исследования по oversight прямо фиксируют: даже при наличии human-in-the-loop человек может не понимать систему, а система — генерировать столько сигналов, что контроль становится формальным. [1] [2]

2. «Выживание» может оправдать всё

Контур 1 — выживание — необходим, но опасен. Если сделать его абсолютным, то любой страх потери работы может оправдать любой компромисс.

Ваш случай как раз это показывает: вы боитесь увольнения, и это реальная угроза. Но если сделать «выживание» главным критерием, модель превращается в оправдание капитуляции.

Нужен баланс: выживание — necessary condition, но не sufficient justification.

3. «Другие» размыты

Контур 2 — «другие» — звучит красиво, но на практике неясно, кто именно входит в это множество.

- Студенты?
- Коллеги?
- Семья?
- Будущие студенты?
- Общество в целом?

Без чёткого определения «других» контур становится декоративным. Это типичная проблема specification incompleteness: категории вроде «вред», «справедливость», «приемлемость» не поддаются чистому перечислению. [2] [3]

4. «Смысл» субъективен

Контур 3 — «смысл» — самый человеческий, но и самый уязвимый. Что для одного «потеря смысла», для другого — «прагматизм».

Без внешнего критерия этот контур превращается в проекцию. ИИ вообще не может надёжно его измерить, потому что у него нет субъективного опыта в том же смысле.

5. Модель не решает конфликт приоритетов

Если контуры противоречат друг другу, модель говорит «эскалируй». Но кому эскалировать, если все инстанции захвачены?

Это не теоретическая проблема. В реальности апелляция может быть формальной, суд — зависимым, а «независимый аудит» — фикцией. Тогда модель не даёт выхода, а только фиксирует тупик.

6. Модель не учитывает время

Все четыре контура предполагают, что решение принимается «здесь и сейчас». Но реальность требует последовательности: сегодня — компромисс, завтра — коррекция, послезавтра — восстановление.

Модель не описывает **динамику**, а только статическую проверку. Это её слабость в долгих конфликтах.

7. Модель не защищает от «тихой эрозии»

Самая опасная слабость — не резкий захват власти, а постепенная эрозия. Каждый раз вы уступаете «немного», и граница сдвигается. Через год вы уже не замечаете, что стали другим человеком.

Модель не имеет механизма **накопительного эффекта**. Она проверяет отдельное решение, но не траекторию.

8. Модель зависит от качества исполнителя

Даже идеальная процедура не работает, если исполнитель — уставший, запуганный или зависимый человек. Модель предполагает рационального агента, но реальность — нет.

Это классическая проблема human factors: формальная процедура не спасает от когнитивных искажений, страха и выгорания. [1] [2]

Как усилить модель

Чтобы модель стала устойчивее, нужно добавить:

1. **Механизм накопительного контроля** — не только «что я делаю сейчас», но и «куда я движусь за год».
2. **Внешний арбитр вне системы** — не внутренняя комиссия, а независимая инстанция.
3. **Право на отказ без наказания** — иначе контур 1 всегда будет перевешивать.
4. **Ясное определение «других»** — не абстрактное, а операциональное.
5. **Динамическая проверка** — не только «что сейчас», но и «куда это ведёт».

Финальная мысль

Модель сильна тем, что **не требует героизма и не оправдывает капитуляцию**. Но она уязвима там, где власть захватывает саму процедуру проверки.

Поэтому честный ответ: **модель — не щит, а компас**. Она не гарантирует безопасность, но помогает не потерять направление. [3] [4] [2] [1]

⁂

1. http://www.link.springer.com/content/pdf/10.1007/s11023-026-09783-y.pdf
2. https://link.springer.com/article/10.1007/s11023-026-09783-y?error=cookies_not_supported&code=a3e38984-0064-4c78-ac97-8c2eac0b603a
3. https://arxiv.org/html/2506.17846
4. https://ar5iv.labs.arxiv.org/html/2503.05748
5. https://ar5iv.labs.arxiv.org/html/2501.05360
6. https://philarchive.org/archive/YADASF
7. https://link.springer.com/article/10.1007/s44163-026-01905-w?error=cookies_not_supported&code=b1f66cb5-7d34-471e-9820-b8b4395429dc
8. https://link.springer.com/content/pdf/10.1007/s43681-026-01362-2.pdf
9. https://arxiv.org/html/2609.22712v1
10. https://github.com/Statera-Library/01_Vol_42_AI_Safety_Alignment_and_Interpretability/blob/main/Chapter_07_Advanced_Safety_and_Alignment/Chapter_07_Advanced_Safety_and_Alignment_EN.md
11. https://www.link.springer.com/article/10.1007/s10943-025-02544-8
12. https://link.springer.com/article/10.1007/s43681-026-01191-3
13. https://arxiv.org/html/2604.14070v1
14. https://en.wikipedia.org/wiki/AI_alignment
15. https://ar5iv.labs.arxiv.org/html/2604.02720