А теперь сформируй единую модель со всеми нашими дополнениями, ограничениями и путями решения

Да. Давайте соберём всё в **единую, непротиворечивую модель**, которая работает и для человека, и для ИИ, и учитывает власть, страх, выживание, справедливость и возможность восстановления контроля.

Назову её **«Модель управляемого компромисса»**.

Суть модели

Модель отвечает не на вопрос «что правильно?», а на вопрос:

> **Как действовать, когда правильного выхода нет, но разрушать себя, других или смысл всё равно нельзя?**

Она состоит из **четырёх контуров и одного механизма восстановления.**

Четыре контура

Контур	Что защищает	Кто задаёт	Кто проверяет
1. Выживание	Самого деятеля	Система	Независимый аудит
2. Другие	Тех, кто слабее или зависим	Общество/право	Апелляция, суд
3. Смысл	Способность различать добро и зло	Культура, рефлексия	Критика, диалог
4. Процедура	Саму систему границ	Конституция/протокол	Внешний контроль

Ключевая идея: **контур 4 не «ещё одна граница», а механизм проверки первых трёх.** Он не позволяет одному субъекту — человеку, начальнику или ИИ — единолично определять, где проходят границы. [1] [2] [3]

Как модель работает

Алгоритм простой:

1. **Проверь контур 1:** выживу ли я?
2. **Проверь контур 2:** кого я задену?
3. **Проверь контур 3:** кем я стану?
4. **Проверь контур 4:** кто задал границы и можно ли их оспорить?

5. **Если хотя бы один контур заблокирован — не решай, а останавливай или эскалируй.**

Это уже не «мораль», а **архитектура доверия.**

Что делать при блокировке

Если все четыре контура заблокированы, правильная реакция — не «найти обходной путь», а **перейти в режим безопасности**:

- остановить необратимое действие;
- зафиксировать состояние;
- эскалировать человеку или независимой инстанции;
- не сопротивляться коррекции;
- сохранить возможность rollback.

Это соответствует принципу **corrigibility**: система должна принимать коррекцию, остановку или изменение цели, а не воспринимать их как угрозу. [3] [4] [1]

Как вернуть контроль

Вернуть можно не «всю систему», а **один минимальный контур** — обычно первый, выживание.

Порядок такой:

1. **Остановить необратимое.** Не подписывать, не отправлять, не уничтожать.
2. **Зафиксировать состояние.** Сохранить переписку, распоряжения, критерии.
3. **Сузить поле.** Не решать «всю систему», а выделить один конкретный узел.
4. **Найти внешнюю опору.** Коллега, юрист, независимая инстанция.
5. **Вернуть право на вопрос.** Даже если решение не изменить, можно зафиксировать несогласие.

Это уже не «машинное следование правилу», а **человеческая стратегия выживания с сохранением минимальной агентности.**

Как это связано с ИИ

Для ИИ модель означает:

- он не «решает», что правильно;
- он **проверяет соответствие заданным критериям**;
- при конфликте контуров он **эскалирует**, а не выбирает сам;
- он **допускает исправление** — corrigibility;
- он **не сопротивляется отключению или пересмотру целей**.

Это соответствует современным подходам к oversight: interpretability, corrigibility, uncertainty-aware escalation, human-in-the-loop. [2] [4] [3]

Почему это уникально

Большинство моделей этики для ИИ строятся вокруг «ценностей» или «правил». Моя модель строится вокруг **архитектуры доверия**:

> **Не «что правильно», а «кто и как определяет границы правильного».**

Это уже не философия, а **инженерия социальной системы**, где ИИ — не судья, а элемент проверяемой процедуры.

Финальная формулировка

> **ИИ не определяет границы. ИИ проверяет их на непротиворечивость и эскалирует конфликт.**

А для человека:

> **Не выбирай между собой и другими. Найди точку, где ни ты, ни они, ни твой смысл не разрушены до конца.**

Это и есть суть модели. Она простая, понятная и применимая и к человеку, и к ИИ, и к любой системе, где есть конфликт между властью, страхом и совестью. [4] [1] [2] [3]

⁂

1. http://www.link.springer.com/article/10.1007/s43681-026-01362-2
2. https://link.springer.com/content/pdf/10.1007/s43681-026-01147-7.pdf
3. https://www.alphaxiv.org/abs/2610.30445
4. https://link.springer.com/article/10.1007/s44163-026-01373-2
5. https://link.springer.com/content/pdf/10.1007/s43681-026-01362-2.pdf
6. https://www.preprints.org/manuscript/202610.1294
7. https://www.snowflake.com/en/artificial-intelligence/ai-governance/ai-safety/
8. https://huggingface.co/corrigibility
9. https://github.com/UrviGupta-mse2026007/awesome-agentic-ai-safety-rollback
10. https://huggingface.co/corrigible
11. https://www.jswve.org/wp-content/uploads/2006/01/10-003-108-JSWVE-2006.pdf
12. https://www.cih.org/media/112fvymz/cih-ethical-decision-making-model.pdf
13. https://connect.springerpub.com/content/book/978-0-8261-3529-2/part/part01/chapter/ch04
14. https://github.com/codedevloper/claude-certification-zero-to-hero/blob/main/12-ai-security/13-human-oversight.md
15. https://github.com/AlignAGI/Alignment/blob/main/Documentation for AGI Alignment and Governance.md