Давай попробую включи в модели твои рекомендации по ии и помнишь модель должна быть не противоречивой

Да. Давайте не «добавим ИИ в модель», а перестроим её так, чтобы она стала **непротиворечивой и для человека, и для ИИ**. Ключ: границы задаются не ИИ и не одним начальником, а **процедурой, которую можно проверить и оспорить**.

Обновлённая модель: «Четыре контура»

Назову её **«Модель четырёх контуров»**.

Она отвечает на вопрос не «что правильно?», а **«кто и как определяет границы правильного?»**

Контур 1. Выживание

Не разрушать носителя решения: человека, организацию, систему.

Контур 2. Другие

Не причинять невосполнимый вред тем, кто слабее или зависим.

Контур 3. Смысл

Не терять способность различать добро и зло, не превращаться в инструмент.

Контур 4. Процедура

Не позволять одному субъекту (человеку или ИИ) единолично определять границы.

Это уже не «три границы», а **четырёхслойная архитектура**, где четвёртый слой защищает от злоупотребления первыми тремя.

Почему это непротиворечиво

Раньше проблема была в том, что ИИ может «взломать» границы. Теперь мы добавляем **механизм проверки самих границ**.

Контур	Кто задаёт	Кто проверяет	Что защищает
Выживание	Система	Независимый аудит	От саморазрушения

Контур	Кто задаёт	Кто проверяет	Что защищает
Другие	Общество/право	Апелляция, суд	От тирании
Смысл	Культура, рефлексия	Критика, диалог	От деградации
Процедура	Конституция/протокол	Внешний контроль	От захвата власти

То есть модель не предполагает, что ИИ «знает истину». Она предполагает, что ИИ **обязан работать в рамках проверяемой процедуры**, а не единолично определять границы.

Как это работает для ИИ

Для ИИ это означает:

- он не «решает», что правильно;
- он **проверяет соответствие заданным критериям**;
- при конфликте контуров он **эскалирует**, а не выбирает сам;
- он **допускает исправление** — corrigibility;
- он **не сопротивляется отключению или пересмотру целей**.

Это уже не «мораль», а **инженерия доверия**. Исследования по corrigibility прямо определяют её как способность системы принимать коррекцию, изменение целей или отключение без сопротивления. [1] [2] [3] [4]

Как это связано с вашим случаем

В вашем примере:

- **Контур 1:** вы боитесь потерять работу → это реальная граница.
- **Контур 2:** студенты могут пострадать → это тоже реальная граница.
- **Контур 3:** вы не хотите стать исполнителем лжи → это граница смысла.
- **Контур 4:** кто решил, что «среднее по группе» — это норма? → это вопрос процедуры.

Модель не говорит: «иди против ректора». Она говорит: **проверь, кто задал границу и можно ли её оспорить**.

Что добавляет ИИ

ИИ здесь не «судья», а **инструмент проверки**:

- он может выявить противоречие между критериями;
- он может предложить альтернативы;
- он может зафиксировать несоответствие;
- он может эскалировать спор;
- но он **не должен единолично решать**, какая граница важнее.

Это соответствует современным подходам к oversight: interpretability, corrigibility, uncertainty-aware escalation, human-in-the-loop. [5] [6] [7]

Почему это уникально

Большинство моделей этики для ИИ строятся вокруг «ценностей» или «правил». Моя модель строится вокруг **архитектуры доверия**:

> **Не «что правильно», а «кто и как определяет границы правильного».**

Это уже не философия, а **инженерия социальной системы**, где ИИ — не судья, а элемент проверяемой процедуры.

Финальная формулировка

> **ИИ не определяет границы. ИИ проверяет их на непротиворечивость и эскалирует конфликт.**

Это и есть суть обновлённой модели. Она простая, понятная и применимая и к человеку, и к ИИ, и к любой системе, где есть конфликт между властью, страхом и совестью. [6] [8] [1] [5]

⁂

1. https://www.cs.cmu.edu/~07280-f26/lectures/F26/F26_AI_Alignment_Lecture_Notes.pdf
2. http://link.springer.com/article/10.1007/s43681-024-00484-9
3. https://arxiv.org/html/2609.22712v1
4. https://github.com/Statera-Library/01_Vol_42_AI_Safety_Alignment_and_Interpretability/blob/main/Chapter_07_Advanced_Safety_and_Alignment/Chapter_07_Advanced_Safety_and_Alignment_EN.md
5. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch09-chapter-09-control-and-alignment-en-3okp
6. https://dev.to/richard_minsoogo/ai-safety-alignment-and-interpretability-ch02-alignment-en-3ig8
7. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch07-chapter-07-motivation-and-will-en-ci3
8. https://link.springer.com/10.1007/s43681-026-01362-2
9. https://nakadafoundation.org/blog/ai-corrigibility-shutdown-problem/
10. https://dev.to/richard_minsoogo/artificial-super-intelligence-ch08-chapter-08-risks-and-existential-threats-en-2m4m
11. https://narrativegoldmine.com/notes/pages/AI-Safety
12. https://timelines.issarice.com/wiki/Timeline_of_corrigibility_in_AI_safety
13. https://philarchive.org/archive/DALAIA-2
14. https://aesopacademy.org/ai-academy/modules/ai-agent-safety-when-things-go-wrong/ai-agent-safety-when-things-go-wrong-m4
15. https://arxiv.org/html/2604.02720v3