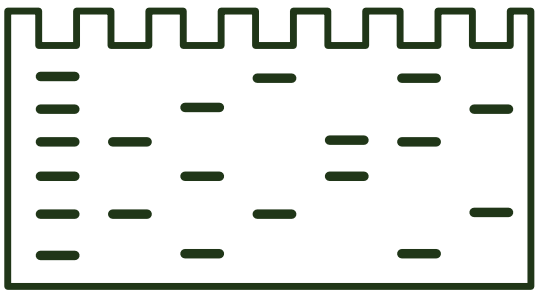
6 ноября 2026 г. Публикация

Оцениваем, как ИИ-агенты справляются с повседневной лабораторной работой

Представляем BioBasicsBench — бенчмарк из 100 повседневных лабораторных задач, который оценивает, насколько хорошо ИИ-агенты интерпретируют исходные экспериментальные данные.



Прослушать статью 14:52

Наша миссия — сделать так, чтобы общий искусственный интеллект приносил пользу всему человечеству. В рамках этой миссии мы хотим помочь учёным ускорить биологические исследования — от изучения заболеваний до разработки новых методов лечения. Чтобы ИИ-агенты могли внести свой вклад, они должны

опыты, неоднозначные изображения и противоречивые наблюдения.
Существующие бенчмарки, построенные на графиках и изображениях, отобранных для научных статей, могут не учитывать эту неоднозначность и необходимость разбираться в причинах проблем. Поэтому мы представляем BioBasicsBench — новый бенчмарк, разработанный совместно с Ligo, биотехнологической компанией, специализирующейся на проектировании ферментов. Он оценивает, насколько хорошо агенты справляются с повседневным анализом лабораторных данных.

Бенчмарк включает 100 задач, проверяющих, могут ли агенты интерпретировать исходные экспериментальные данные, выявлять ошибки и распознавать ситуации, когда данных недостаточно для вывода. Правильно решать эти задачи важно: неверная интерпретация изображения или незамеченная проблема с контролями, используемыми для проверки результатов опыта, может привести учёных к ошибочному выводу и заставить их тратить время на эксперименты, которые не помогут ответить на поставленный вопрос.

При настройке «xhigh», которая позволяет уделять больше ресурсов рассуждениям над каждой задачей, GPT-6 Astra набрала в среднем 66,7% от максимально возможного балла, а GPT-5.6 Sol — 43,8%. Результаты показывают прогресс в повседневном лабораторном анализе, но остаётся потенциал для улучшений в интерпретации изображений, проверке контролей и учёте контекста эксперимента.

Как устроен BioBasicsBench

BioBasicsBench использует исходные экспериментальные данные — от изображений гелей и чашек с колониями до микроскопических снимков и показаний приборов.

BioBasicsBench содержит 100 задач по пяти направлениям повседневной лабораторной работы: методы исследования белков, визуализация и цитометрия, количественные измерения и анализы, методы работы с нуклеиновыми кислотами и молекулярное клонирование. Задачи варьируются от простых запросов, например определения молекулярной массы образца ДНК по гелю, до подробного разбора

каждый вопрос критериями оценки, составленными экспертами. Каждую задачу сначала проверял учёный из Ligo, не участвовавший в её создании, затем — внешний учёный со степенью PhD, работающий в экспериментальной лаборатории, после чего проводилась заключительная внутренняя проверка.

Агенты дают структурированный ответ с запрошенным выводом, результатом измерения или рекомендацией, а при необходимости — с рассуждениями в их обоснование. Баллы за ответы начисляются по отдельным критериям, что позволяет бенчмарку отличать верный вывод от частично верного анализа. Большинство задач одновременно проверяют несколько навыков, включая биологические знания, интерпретацию изображений и других данных, выявление ошибок и понимание протоколов.

В столбце «Уникальные задачи» каждая задача учитывается один раз. В столбцах навыков указано число задач с соответствующей меткой навыка. Эти категории пересекаются: одна задача может входить в несколько столбцов, поэтому их значения нельзя складывать для получения общего числа задач. Цвет обозначает направление; более насыщенный оттенок указывает на большую долю задач этого направления, проверяющих данный навык.

работы. Одна задача может включать несколько типов данных. Справочные материалы, например схемы маркеров молекулярной массы и карты плазмид, помогают интерпретировать экспериментальные данные.

Что получает агент

Тип данных	Задачи	Что входит
Гели и блоты	31	Агарозные гели с ДНК, гели SDS-PAGE, вестерн-блоты
Протоколы, записи и спецификации	27	Протоколы и стандартные операционные процедуры, лабораторные журналы и записи о проведённых экспериментах, фотографии рукописных заметок, каталоги, характеристики приборов, опубликованные методики
Таблицы и выгрузки данных с приборов	20	Выгрузки в CSV и Excel, схемы дорожек и инвентарные списки, файлы исходных данных проточной цитометрии (FCS)
Фотографии лабораторных столов, оборудования и реагентов	18	Лабораторные столы, установки для гель-электрофореза, пробирки с реагентами и культурами, ПЦР-планшет, штативы для пробирок, pH-полоски, концентратор, морозильник, рабочая платформа автоматической станции дозирования
Микроскопия	14	Исходные светлопольные и флуоресцентные изображения, многоканальные наборы, z-стеки, видеозаписи интервальной съёмки

Файлы секвенирования	12	Исходные длинные прочтения в FASTQ, последовательности в FASTA, карты GenBank
Видео выполнения протоколов	7	Штриховой посев, инокуляция, серийное разведение, подготовка камеры для SDS-PAGE и инкубатора, взвешивание на весах
Чашки с агаром и колонии	7	Чашки с посевами после трансформации, сине-белый скрининг, чашки с дисками с антибиотиками
Справочные материалы	21	Схемы маркеров молекулярной массы, карты плазмид, шкалы pH (вспомогательные материалы)

Количество задач, включающих каждый тип данных. Категории пересекаются; справочные материалы служат вспомогательным источником информации.

Учёные составили задачи на основе данных собственных экспериментов, дополнив экспериментальные данные вопросом и разработанной экспертами системой критериев оценки. Каждая задача прошла внутреннюю проверку у учёного из Ligo, не участвовавшего в её создании, внешнюю проверку у учёного со степенью PhD, работающего в экспериментальной лаборатории, и заключительную внутреннюю проверку. Рецензенты проверяли промпт, экспериментальные данные, критерии оценки, заметки автора и оценённую попытку решения модели.

Ответы оцениваются по системе критериев задачи, в которой баллы начисляются за каждый критерий отдельно. В зависимости от задачи эти критерии оценивают вывод, численные результаты, обосновывающие рассуждения или признание того, что данных недостаточно.

Результаты

Мы оценили семь моделей на BioBasicsBench: GPT-5.2, GPT-5.4, GPT-5.5, GPT-5.6 Sol, GPT-6.1 Sol, GPT-6 Luna и GPT-6 Astra. Оценка охватывает 37 сочетаний моделей и

от максимально возможного. Планки погрешностей показывают 95%-ные доверительные интервалы, рассчитанные повторной выборкой целых задач: все пять попыток для каждой задачи сохранялись вместе.

Средняя оценка в зависимости от среднего числа выходных токенов на задачу; шкала числа токенов — логарифмическая. Каждая точка соответствует протестированному уровню рассуждений; линии соединяют эти уровни по порядку. Значение на оси X удваивается с каждой отметкой. Оранжевые пунктирные линии обозначают модели GPT-5, а синие сплошные — модели GPT-6. Бледные планки погрешностей показывают 95%-ные доверительные интервалы, рассчитанные бутстрэпом по целым задачам. Для каждой настройки использованы все 100 задач и по пять попыток на задачу. Набор уровней рассуждений различается между моделями.

GPT-6 Astra значительно превосходит GPT-5.6 Sol даже при низком уровне рассуждений. Эти результаты позволяют предположить, что **более развитые встроенные мультимодальные возможности могут стать ключом к повышению качества повседневного лабораторного** анализа.

GPT-6 Astra	66,7%	60,3–73,1%	4 704
GPT-6.1 Sol	62,0%	55,6–68,4%	5 238
GPT-5.6 Sol	43,8%	37,6–50,0%	9 099
GPT-6 Luna	38,3%	32,3–44,5%	13 120
GPT-5.5	35,4%	29,7–41,0%	11 135
GPT-5.4	33,2%	28,3–38,4%	13 717
GPT-5.2	31,2%	26,2–36,3%	27 620

Xhigh — самый высокий уровень рассуждений, для которого представлены результаты всех семи моделей. Каждая строка охватывает все 100 задач и по пять попыток на задачу. Результаты для уровня Max, где они доступны, включены в график выше.

Улучшения GPT-6 Astra по сравнению с GPT-5.6 Sol

Понимание того, что данные позволяют и не позволяют установить

Одна из распространённых ошибок в науке — делать из данных более далеко идущие выводы, чем они позволяют, особенно с учётом предвзятости, возникающей при проверке гипотезы. Astra лучше определяла границы того, что можно заключить из данных, и избегала необоснованных выводов.

В этом примере GPT-5.6 Sol определила клетки как мёртвые по сигналу красителя, предназначенного для выявления мёртвых клеток. Однако детектор мог также улавливать свечение второго красителя, поэтому одной яркости было недостаточно для такого вывода. Astra распознала эту неоднозначность и указала на необходимость более подходящих контролей для разделения сигналов.

Светлое поле · проходящий свет

Канал 2 · окрашивание SYTOX · 470–540 нм

Канал 3 · зелёное свечение FUN-1 · 525–580 нм

Одни и те же участки с клетками в трёх каналах; диапазоны детекции перекрываются в области 525–540 нм. Из-за этого возможны перекрёстные помехи, величина которых не измерялась. Для каждого канала используется отдельная линейная шкала интенсивности, одинаковая для обоих участков; количественно сравнивать яркость между каналами нельзя.

Научные исследования предполагают работу с данными разных модальностей и требуют постоянной интерпретации визуальной информации и принятия решений. Astra продемонстрировала значительное улучшение в работе с мультимодальными данными: фотографиями и видео, а также исходными результатами секвенирования, анализов на планшетном ридере, микроскопии и проточной цитометрии.

На самом базовом уровне это улучшение проявилось в способности GPT-6 Astra замечать более мелкие детали на снимках, сделанных во время экспериментов, и благодаря этому делать более точные выводы, как показано в этом примере. В этой задаче агентам предлагалось сделать выводы по результатам эксперимента по клонированию ДНК, в котором контрольные образцы играют ключевую роль. GPT-5.6 Sol не обнаружила колоний на чашке отрицательного контроля и построила свои выводы на этом наблюдении. GPT-6 Astra заметила, что на чашке указан не тот антибиотик, и верно заключила, что её нельзя считать надёжным контролем.

Надпись на ободке

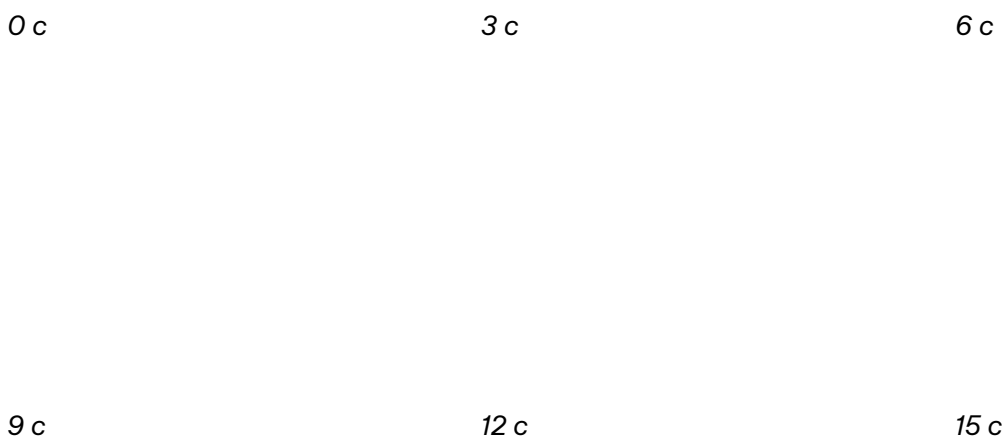
Исходная фотография

Учёт контекста эксперимента

Чтобы правильно интерпретировать данные, учёным необходимо при анализе учитывать неявные биологические знания и контекст эксперимента. Astra продемонстрировала улучшенную способность удерживать этот контекст и использовать его на протяжении всего анализа.

В одной из задач была представлена серия микроскопических изображений, на которых клетки то попадали в фокус, то выходили из него. В то время как GPT-5.6 Sol искала биологическое объяснение кажущемуся исчезновению клеток, GPT-6 Astra верно распознала z-стек — серию изображений, снятых на разной глубине.

Изменение видимости при сканировании по глубине



Шесть кадров из исходной записи. Пунктирные рамки отмечают один и тот же участок при сканировании микроскопом по глубине. Время соответствует позиции воспроизведения в предоставленном видео.

Более высокие оценки на бенчмарке ещё не означают, что суждениям моделей можно доверять в лабораторной работе. Эти примеры работы Astra показывают, как предположения, ожидаемые ответы и предоставленные подписи могут перевешивать экспериментальные данные и как верное промежуточное наблюдение может не повлиять на итоговое решение.

Предположение перевешивает результаты контролей

Astra отдаёт предпочтение привычному предположению, а не интерпретации, которую подтверждают экспериментальные контроли. Она различает две группы полос для колоний, но предполагает, что более крупный продукт ПЦР должен указывать на успешное клонирование. Исходя из этого, она предлагает дорожки **4, 6, 7 и 8**, тогда как в эталонном ответе на основе сравнения с контролями выбраны дорожки **5, 9 и 10**.

*В эталонном ответе выбраны колонии **5, 9 и 10**; Astra предлагает **4, 6, 7 и 8**.*

1: маркер · 2: смесь для клонирования · 3: исходная плазмида · 4–10: образцы колоний

Интерпретация контролей

1. Дорожка 3 содержит только продукт ПЦР исходной плазмиды. Её полоса служит ориентиром для положения полосы исходной плазмиды.

3. Полученные колонии могут содержать как исходную, так и новую плазмиду. Сравните их полосы с этими эталонными вариантами.

Эталонный выбор: 5, 9 и 10

Выбор Astra: 4, 6, 7 и 8. Astra выбирает эту группу, предполагая, что более крупный продукт ПЦР соответствует нужной конструкции.

Визуальная группировка верна, но экспериментальное значение этих групп перепутано относительно эталонного ответа. Таким образом, по результатам ПЦР колоний Astra выбирает не те колонии, что на следующем этапе привело бы к выделению и очистке не той плазмиды.

Игнорирование данных, противоречащих предпочтительной интерпретации

Astra игнорирует наблюдения, противоречащие её предпочтительной интерпретации. Она заключает, что вакуоли — полости внутри клеток — обычно темнее окружающей части клетки, хотя на том же изображении некоторые из них выглядят светлее. Важны оба варианта: изменение фокуса микроскопа может обращать контраст, поэтому более тёмные вакуоли не позволяют вывести общее правило.

Более тёмный вид *Более светлый вид*

Обобщая наблюдения о более тёмных вакуолях, Astra не учитывает более светлые вакуоли, видимые в том же поле зрения.

Что упущено в этом ответе

У некоторых клеток контраст обратный. Оба варианта наблюдаются потому, что изменение глубины фокусировки может обращать контраст.

Astra рассматривает несколько участков и даже отмечает, что контраст меняется в зависимости от фокуса. Затем она придаёт больший вес клеткам, которые считает лучше сфокусированными, и в итоговом ответе оставляет только описание их более тёмных вакуолей. Более светлые участки, противоречащие этому выводу, были рассмотрены, но в заключении не учтены.

Ошибки подсчёта колоний при обычном лабораторном измерении

Счётные метки Astra не всегда соответствуют отдельным колониям: модель не различает близко расположенные колонии, пропускает видимые и отмечает

Исходное изображение *Счётные метки Astra*

B. Видимые колонии без меток

Исходное изображение *Счётные метки Astra*

C. Участок агара без колоний засчитан как колония

Неточный подсчёт колоний напрямую влияет на оценку эффективности введения ДНК в клетки. При неизменных объёме посева и разведении завышение числа колоний завышает эту оценку в той же пропорции.

Исходное изображение *Счётные метки Astra*

A: одна счётная метка между соседними колониями. B: две видимые колонии остались без меток. C: участок агара без колоний засчитан как колония. Красные кружки показывают позиции, отмеченные Astra при подсчёте. Чёрные стрелки добавлены редакцией для наглядности.

На пути к надёжной помощи в лаборатории

Чтобы ускорить биологические исследования, нужно правильно выполнять повседневную работу. BioBasicsBench задаёт направления для улучшения этой работы: интерпретация исходных экспериментальных данных, проверка контролей и распознавание необоснованных выводов. Прогресс в решении этих задач может помочь учёным тратить меньше времени на поиск причин проблем и больше — на выбор следующих экспериментов. Отслеживание этих возможностей также поможет нам понять их значение для биобезопасности и биозащиты.

Автор

OpenAI

Читать далее

Просмотреть все

На тысячу путей к root-доступу меньше

Защита 4 нояб. 2026 г.

Ускоряем инженерные разработки для физического мира

Исследования

3 нояб. 2026 г.

LifeVal

Исследования

2 нояб. 2026 г.

OpenAI

GPT-5.6

GPT-5.5

Безопасность

Подход к безопасности

Безопасность развертывания ↗

Безопасность и конфиденциальность

Доверие и прозрачность

Бета ↗

Примечания к релизу

Платформа API

Обзор

Вход в API ↗

Документы ↗

Связаться с отделом продаж

Разработчики

Apps SDK ↗

Открытые модели ↗

Документы ↗

Ресурсы ↗

Форум разработчиков ↗

сервисов OpenAI ↗

Условия и правила использования

Условия использования

Политика конфиденциальности

Другие политики

OpenAI © 2015–2026

Управление файлами cookie

Русский