



## ← Опубликовать пост



Брайан Армстронг    
@brian\_armstrong




Как сохранить неизменным объем расходов на ИИ, в то время как использование токенов растет в геометрической прогрессии: без лишних сложностей и предупреждений о расходах. С улучшенными настройками по умолчанию, маршрутизацией и кэшированием. Улучшенные настройки по умолчанию (а не ограничения по использованию). Инженеры могут выбрать любую модель, но настройки по умолчанию имеют значение. Мы экспериментируем с использованием по умолчанию моделей с открытым исходным кодом, таких как GLM 5.2 и Kimi 2.7, через наш шлюз больших языковых моделей, но при этом призываем инженеров выбирать модель, подходящую для решения конкретной задачи. 91% наших сотрудников никогда не превышали лимиты использования, поэтому вместо снижения лимитов и увеличения количества предупреждений мы переходим на более дешёвые модели по умолчанию. Обратите внимание, что при проверке кода используются разные модели, чтобы они могли проверять работу друг друга. Улучшенная маршрутизация. В наших пользовательских наборах инструментов мы предварительно обрабатываем запросы и направляем их в модель, которая лучше всего подходит для выполнения задачи, с учетом попаданий в кэш и стоимости модели. Например, для планирования вам может понадобиться модель, использующая метод предельных значений, но не для выполнения, где она может оказаться избыточной. В конечном счете люди не должны выбирать модели — эту задачу может автоматизировать искусственный интеллект. Улучшенное кэширование. Пропуски в кэше — самый простой способ увеличить затраты. Все наши запросы учитывают кэширование, поэтому мы по возможности повторно используем «теплый» кэш. Например, после правильной реализации в LibreChat доля попаданий в кэш выросла с 5 % до 60 %. Не перегружайте контекст. Запускайте новые сеансы при переключении между задачами. Ограничивайте контекст файлов. Отключайте неиспользуемые инструменты. Не просто сжимайте данные. Цель не в том, чтобы использовать меньше токенов, а в том, чтобы тратить их с умом. Улучшенная видимость. Наши инженеры могут использовать столько токенов, сколько захотят, из любой модели, но мы сделали использование токенов видимым — и чем больше вы тратите на ИИ, тем большего эффекта мы ожидаем. Цель не в том, чтобы ограничить использование. Цель в том, чтобы создать инфраструктуру, которая сделает экспоненциальный рост устойчивым. Благодаря этому мы сократили расходы на ИИ почти вдвое, при этом использование токенов продолжает расти.

**Посмотреть все ответы**

Открыть приложение X

## AI Spend at Coinbase (Bars) -vs- Token Usage (Line)

Left axis = USD spend (stacked by org). Right axis = total company tokens.



0:48 · 27 июн. 2026 г. · **4,2 млн** Просмотры

478

745

6 тыс.

6 тыс.



**Smakosh** @smakosh · 27 июн.



**Посмотреть все ответы**

Открыть приложение X

3

27

404

34 тыс.



**clem** 🧐 @ClementDelangue · 27 июн.



следующий шаг: дообучение собственных моделей на основе открытого кода!

22

13

320

26 тыс.



**Tim** @open\_founder · 27 июн.



Мы создали механизм «рассуждений» на основе искусственного интеллекта, чтобы решить именно эту проблему @openservai  
Выполняйте все агентские задачи на моделях меньшего размера, которые обходятся в разы дешевле, но при этом не уступают по производительности лучшим моделям. Это идеальное решение проблемы надежности и стоимости искусственного интеллекта на сегодняшний день.

1

5

49

935



**Посмотреть все ответы**

Открыть приложение X