



Поиск моделей, наборов данных, пользователей...



← Назад к статьям

Предоставьте своим агентам ZeroGPU, чтобы они могли самостоятельно выпускать вирусные ИИ-приложения



Статья сообщества

Опубликовано 26 мая 2026 г.

▲ Отметить как понравившуюся 10



Виктор Мустар

[victor](#) Подписаться

Как я создал [LongCat-Video-Avatar 1.5 Space](#) (работает на ZeroGPU, на 35% быстрее эталонного пути, модель под лицензией MIT) за один сеанс работы с агентом.




Victor M @victormustar · May 24


New: LongCat just dropped an excellent open-source talking-avatar model (probably SOTA) + MIT licensed 🔥

Made a Hugging Face Space for it and it's very impressive. So many cool products to build with it: AI tutors with a face, dubbing pipelines, talking-head coding agents

[Show more](#)



Victor M @victormustar · Apr 7, 2024



Making an AI Genie that checks what I'm doing, he's roasting me hard 😭😭

44

287

1.8K

192K

🔖

Разблокировка: подписка Hugging Face PRO дает вашему агенту собственную ИИ-лабораторию (живое пространство ZeroGPU) и 40 минут в день на GPU Blackwell. Сформулируйте цель, вставьте суть, уходите. Агент разрабатывает, развертывает, тестирует на работающем API, исправляет и публикует. Автономно.

Ниже приведен точный рецепт. Это может сделать каждый.

🔗 Что вам нужно

- **Hugging Face PRO** (\$9 в месяц): размещение до 10 пространств ZeroGPU, 40 минут в день на Blackwell (48 ГБ), приоритетная очередь. При превышении квоты: 1 доллар за 10 минут с использованием предоплаченных кредитов, если необходимо.
- **Любой достойный агент для написания кода**: Codex CLI, Claude Code, Cursor, что угодно. Рекомендуется: тот, который поддерживает `/goal` (Codex CLI, Claude Code), чтобы он мог автономно приближаться к цели на протяжении многих итераций.
- **Модель, которую вы хотите продемонстрировать**: в нашем случае [meituan-longcat/LongCat-Video-Avatar-1.5](https://huggingface.co/meituan-longcat/LongCat-Video-Avatar-1.5).

Вот и всё. Никакой инфраструктуры, никакого Docker, никакого Kubernetes, никакой аренды GPU, никаких счетов за Vercel. Вы делаете `git push`, и появляется карточка с публичным URL-адресом, размещенная на Blackwell.

🔗 Почему ZeroGPU — это ключ к успеху

Обычный облачный графический процессор = арендуйте его 24/7, платите даже в режиме ожидания. ZeroGPU = графический процессор подключается **только во время выполнения вашей функции**, а затем отключается. Вы украшаете одну функцию:

```
import spaces

@spaces.GPU(duration=120)
def generate(image, audio, prompt):
    return pipe(image, audio, prompt)
```

- **Ваши 9 долларов в месяц позволяют людям бесплатно пользоваться вашим пространством.** Посетителям не нужна учетная запись HF. Анонимные пользователи получают 2 минуты работы графического процессора в день, пользователи с бесплатными аккаунтами — 5 минут в день, а пользователи с PRO-аккаунтами — 40 минут в день. Квота принадлежит им, а не вам.
- Вы тратите время графического процессора только во время декорированного вызова. В режиме ожидания — бесплатно.
- Модель переходит в `cuda` на уровне модуля (эмуляция PyTorch CUDA обрабатывает это до подключения реального графического процессора).
- Только для Gradio SDK; PyTorch 2.8+; Python 3.10 или 3.12.

Это самый дешевый способ серьезных вычислений в интернете для демонстрации возможностей широкой аудитории.

Рецепт

Настройка (однократная): Оформите подписку на [Hugging Face PRO](#) (9 долларов в месяц). Это открывает доступ к двум функциям: размещению собственных пространств ZeroGPU и квоте ZeroGPU на 40 минут в день, которая сбрасывается каждые 24 часа. Затем установите `hf CLI` с помощью официальной команды и войдите в систему:

```
curl -LsSf https://hf.co/cli/install.sh | bash
# Windows: irm https://hf.co/cli/install.ps1 | iex

hf auth login
```

Paste this into your agent (Codex CLI or Claude Code, both have `/goal`):

```
/goal Build a ZeroGPU Space demoing <MODEL_CARD_URL>.

First, read https://gist.github.com/gary149/2aba2962375fa9ca56bb9ef53f0
These are the operational rules for iterating on HF Spaces.

Use the hf CLI to create the Space and clone it locally.

The deployed Space is your AI lab. Work autonomously: push, diagnose,
repeat. Verify every change by calling the live API. Never declare a cl
done without that round-trip.

Success = a Space that loads, runs the model on ZeroGPU, and returns a
result via the API.
```

That's the whole kickoff. The two non-obvious lines are *"the deployed Space is your AI lab"* and *"verify every change by calling the live API."* Together they license the agent to operate autonomously: it owns the deploy loop, it owns verification, you don't sit in the middle.

The gist link is doing the rest of the heavy lifting. It teaches the agent:

- Builds are slow (1 to 15 min), **reading logs is instant** → iterate by logs, not guesses.
- The iteration ladder: hot-reload → dev-mode SSH → selective upload → full rebuild.
- ZeroGPU patterns: model on `cuda` at module level, `@spaces.GPU` on inference, `dynamic duration=callable`, 4-bit NF4 for LLMs $\geq 10B$.
- Verification means actually calling the deployed API via `gradio_client.Client` and inspecting the output file.

Once you have a first version live, **steer it with one-liners** to tweak behavior: *"check the ZeroGPU docs about xlarge", "cache the Gradio examples", "limit generation to 4 seconds"*. The agent integrates each and keeps moving.

🔗 What the agent actually did

533 shell commands over ~2h. The loop: `hf spaces logs (×97)`, `hf spaces info (×50)`, `selective hf upload (×18)`, `hf spaces restart (×12)`, then `gradio_client.Client(...).predict(...)` to time the live API on every change.

Shipped: DBCache (from CacheDiT) caching denoise steps [2, 4, 6] for **35% faster** generation (186s → 121s), Gradio 6.10 + 8-step DMD2 INT8 DiT, `cache_examples=True`, `cache_mode="lazy"` (1.3s instead of 80s), ElevenLabs voices for the examples. When asked about `xlarge`, it read the docs, surfaced the trade-off (2× quota, longer queue, full Blackwell), and then deployed on it. That's autonomous decision-making, not you babysitting.

Final tab: 1,834,906 tokens, ~2h 2m, (and still \$9/mo for the GPU).

🔗 Why this stack beats everything else right now

- **\$9/mo flat ceiling** for hosting. No per-request invoice surprise.
- **ZeroGPU = idle is free.** A demo with 0 users or 10k costs the same. One that goes viral autoscales on Hugging Face's infra.
- **Public URL out of the box.**
<https://huggingface.co/spaces/victor/LongCat-Video-Avatar-1.5> is shareable, embeddable, and indexed.

- **Agent-native loop.** `hf CLI + gradio_client + --follow` logs means an agent can drive the whole edit-deploy-verify cycle without a human in the loop.
- **The community sees it.** A trending Space gets surfaced on the Hub homepage. Distribution is built in.

Let's go: pick a SOTA open-source model, give your agent the gist + a kickoff prompt, and ship.

Models mentioned in this article 1

 [meituan-longcat/LongCat-Video-Avatar-1.5](#)
Updated Jun 4 •  1.75k •  695

Spaces mentioned in this article 1

LongCat-Video-Avatar 1.5 
Audio-driven talking-head video generation (Meituan LongCat)

  297

Community

Edit

Preview

Start discussing this article

 Tap or paste here to upload images

 Comment

[Sign up](#) or [log in](#) to comment

 System theme

Company

TOS

Privacy

About

Careers

Website

Models

Datasets

Spaces

Pricing

Docs

