



Облако на основе искусственного интеллекта для разработчиков и агентов

Запускайте модели, масштабируйте
графические процессоры и создавайте
ИИ-агентов — и все это на одной
платформе.

Начать разработку

Для агента

Связаться с нами >

НАМ ДОВЕРЯЮТ



Hugging Face



TiDB



Kilo Code



Quora



OpenRouter



Fish Audio

hygo



Gizmo



SIMULAR



WIZ.AI

Программа для стартапов

Build with Novita Agent Sandbox



МОДЕЛИ API



1 Бессерверные API-интерфейсы для моделей

Запускайте более 200 моделей через один API. Не нужно управлять инфраструктурой.

Текст, изображения, аудио, видео — все бессерверные, все готовы к использованию в продакшене. Вы вызываете, мы запускаем. Оплата по токenu, а не по часам.

Изучить все модели



Deepseek V4 Pro

\$1,74/Mt на входе · \$3,48/Mt на выходе
1048576 контекстов

LLM



MiniMax M2.7

\$0,3/Mt на входе · \$1,2/Mt на выходе
204800 контекстов

LLM



GLM-5.1

\$1.4/Mt Input · \$4.4/Mt Output
204800 Context

LLM



Kimi K2.6

\$0.95/Mt Input · \$4/Mt Output
262144 Context

LLM



Ge

\$0.
26:


LL

2 Выделенные конечные точки

Частные конечные точки. Гарантированная производительность. Отсутствие шумных соседей.

Ваша модель. Ваши вычисления. Изолированные ресурсы обеспечивают стабильную задержку при любой пропускной способности. Потому что в продакшене нет бюджета на повторные попытки.

Начать работу >



AGENT SANDBOX

AGENT ["CODING AGENTS"]

CODING AGENT · ACTIVE

Запустить набор тестов · pytest

Написать исправление · патч применен

Выявить ошибку · нулевой указатель, строка 84

Прочитать кодовую базу · src/api/routes.py

ЗАПУСК
~200 мс

ИЗОЛЯЦИЯ
ПОЛНАЯ

БИЛЛИНГ
В СЕКУНДУ

СТАТУС
РАБОТАЕТ

ПЕСОЧНИЦА

В ОЧЕРЕДИ

ВЫПОЛНЯЕТСЯ

ВЫПОЛНЕНО

ВЫПОЛНЕНО

1 Песочница для агентов


Безопасные изолированные
среды выполнения. Созданы для



Это не блокнот. И не контейнер, который вы настраиваете самостоятельно. Это специально созданная среда, в которой агенты работают, используют инструменты, вызывают модели и выполняют задачи — всегда чисто, изолированно.

Начать работу >

GPU CLOUD



1 Инстансы с графическими процессорами

Машины с графическими процессорами под полным контролем. Ваши за считанные секунды.

Развертывайте модели, выполняйте логический вывод, обучайте с нуля на выделенных инстансах с графическими процессорами, которыми вы полностью управляете. Предсказуемая производительность. Никаких общих ресурсов. Никаких сюрпризов.


Начать работу >



Отправьте задание. мы позаботимся обо всем остальном.

Не нужно выделять инстансы. Не нужно платить за простаивающие вычислительные ресурсы. Novita автоматически распределяет ресурсы графического процессора, масштабируется в зависимости от нагрузки и возвращается к нулевому состоянию, когда вы заканчиваете работу. Вы платите только за выполнение, больше ни за что.


Начать работу >



CLUSTER ["CLUSTER-01"]

CLUSTER-01 · 6 NODES
NVLINK · GPUDIRECT RDMA · PCIE

NODE-01	NODE-02	NODE-03
51%	79%	86%
NODE-05	NODE-06	NODE-07



3 Bare Metal

Maximum performance. Zero abstraction overhead.

Dedicated physical GPU clusters for large-scale inference, training runs, and enterprise deployments that can't compromise on throughput. When you need the hardware to yourself, this is it.


Get Started >

Why Novita AI

Built for AI from day one.
Designed for what you're
actually building.


Get Started >





Better price-performance

Up to 50% less than major cloud providers. Not because we cut corners, because we built the infrastructure.



Built for production reliability

Stable infrastructure with low latency, high throughput, and reliable uptime at scale.



● AGENT RUNTIME

SANDBOX

● MODEL APIS

200+ MODELS

● GPU INFRASTRUCTURE

BARE METAL

One platform for the full AI stack

Model APIs, GPU infrastructure, and agent runtimes — all in one platform.

● SERVERLESS API

⋮

● DEDICATED ENDPOINTS

⋮

● GPU CONTROL

Scale with your workload

Start small and scale seamlessly from APIs to dedicated clusters.



HAVING LATENCY SPIKES IN
PROD – CAN YOU HELP DEBUG?

2 MIN AGO

ON IT – PULLING YOUR LOGS
NOW. IT'S A CONFIG ISSUE,
FIX INCOMING.

JUST NOW

Dedicated support when it matters

Fast technical support from a team that understands AI infrastructure.

Built with Novita AI



Render Arena

Compare multiple models side by
side



NovitaClaw

Run OpenClaw in the Cloud with
One Command



Deploy a Hermes Agen

Run Hermes Agent on Novita
Sandboxes





Hugging Face

"I appreciate how fast Novita AI moves to deploy newly released models. Their team is often the first to get stable, production ready inference support online – often on Day One. That speed is critical for the whole open-source AI community."



Julien Chaumond
Co-Founder & CTO

Fish Audio

"Novita has been a huge help for us at Fish Audio. Their reliable GPU infrastructure allows us focus on developing and improving our text-to-speech models instead of dealing with hardware headaches. Their support and performance have made it much easier to push our work forward."



Shijia Liao
Co-Founder & Chief Scientist

Gizmo

"Novita's Model API was super simple to integrate, and it's been great in powering our AI-driven flashcards and quizzes. The platform takes care of the heavy lifting, so we can focus on building better learning tools for our users without worrying about infrastructure or scaling issues."



Petros Christodoulou
Co-Founder and CEO

Kilo

"Working with Novita AI has been a fantastic experience for Kilo. Their inference platform helps us deliver fast and reliable AI coding workflows across multiple LLMs, with strong real-world performance for agentic workflows. And the team has been remarkably easy to work with! They are always optimizing based on the latest models and technology—a perfect partner for Kilo Code."



Ari Messer
Head of Partnerships

What's New



ANNOUNCEMENT

Kimi K2.7 Code

Available on Novita AI now

LLM

ANNOUNCEMENT

Deepseek V4 Pro

Available on Novita AI now

LLM

ANNOUNCEMENT

Qwen3.7-Max

Available on Novita AI now

LLM



Everything you need to build production AI.

200+ models, on-demand GPUs, and secure agent runtimes — unified under one API. Free to start, scales as you grow.

Get Started >

Power your AI applications with Novita AI's model APIs, GPU instances, and agent sandbox.



Product

Model APIs

Agent Sandbox

GPU Instance

GPU Bare Metal

Resource

Talk to Sales

Contact Support

Pricing

Docs

Partners

Refer to Earn

Supply GPUs

Company

Careers

Blog

Trust Center

© 2026 Novita AI. All rights reserved



[Terms of Service](#)

[Privacy Policy](#)

[Cookie Policy](#)

[Cookie Settings](#)

[Do Not Sell or Share My Personal Information](#)