

Старый текст, распознанный с помощью оптического распознавания символов, мешает обучению языковых моделей, и FineBooks хочет решить эту проблему в масштабах всего проекта.



Маттиас Бастиан [in](#) 10 августа 2026 года



Ключевые моменты

- В рамках проекта FineBooks, совместного проекта Hugging Face и EleutherAI, были протестированы 14 моделей оптического распознавания символов с открытым исходным кодом на более чем 2000 страниц исторических книг, чтобы оценить, насколько хорошо они могут преобразовывать отсканированные тексты в чистые обучающие данные для языковых моделей с искусственным интеллектом.

- Более компактные модели часто превосходили по эффективности более крупные. Самая эффективная модель обеспечивала точность распознавания более 97 % при стоимости менее двух долларов США за тысячу страниц.
- Хотя исследователи считают, что качество результатов достаточно для обучения ИИ, они отмечают, что модели по-прежнему слишком подвержены ошибкам для использования в академических или научных целях.

Спросите об этой статье...



Темы

- Миллионам общедоступных страниц требуется более качественное распознавание текста
- Малые модели превосходят более крупные аналоги
- Достаточно хороши для обучения ИИ, но слишком неточны для научных исследований


В рамках проекта FineBooks от Hugging Face и EleutherAI было протестировано 14 моделей оптического распознавания символов на более чем 2000 страницах исторических книг. Лучшие модели уже позволяют получать текст, достаточно качественный для обучения ИИ, но они не готовы к использованию в научных целях.

При обучении языковых моделей с открытым исходным кодом на общедоступных книгах приходится иметь дело с некачественным текстом. Библиотеки много лет назад извлекали тексты из отсканированных страниц с помощью оптического распознавания символов, и в результатах часто полно ошибок. [Проект Talkie](#) подсчитал потенциальный ущерб: языковая модель, обученная на тексте, полученном с помощью оптического распознавания символов, усвоила информацию лишь на 30 % эффективнее, чем модель, обученная на текстах тех же книг, расшифрованных людьми.

[FineBooks](#), совместный проект Hugging Face и EleutherAI, проверил, могут ли современные модели оптического распознавания символов с открытым исходным кодом решить эту проблему. Команда протестировала 14 моделей с открытым исходным кодом на 2165 страницах исторических книг и опубликовала результаты [в виде таблицы лидеров](#). Лучшие модели обеспечили точность распознавания символов выше 97 % при стоимости менее двух долларов за тысячу страниц.

РЕКЛАМА





Three of the 2,165 ground-truth pages: a single-column English natural history text, a multilingual table of contents, and an illustration plate whose entire transcription is a single line of artist credit. | Image: FineBooks / Biodiversity Heritage Library

Millions of public-domain pages need better text recognition

When EleutherAI and its partners released Common Pile last year, the largest openly licensed training corpus to date, it contained about 300,000 public-domain books with text from older OCR runs. The FineBooks authors say reprocessing those books with better models is one of the most effective ways to improve open AI training datasets.

The project picked [the Biodiversity Heritage Library \(BHL\)](#) as its first target, which holds more than 300,000 digitized natural history documents totaling [over 64 million pages](#). The BHL offers its collection as a [bulk download via AWS](#).

Measuring OCR quality requires pages with known correct transcriptions. The team used work from [the IMPACT project](#) and [BHL-Europe](#): between 2011 and 2012, experts transcribed six BHL volumes in English, French, German, and Latin with an error rate of about one character per 2,000. That data is available under a CC-BY license in a [GitHub repository](#) and forms the basis of the new ground-truth dataset.

Small models beat larger rivals

All 14 models are freely available and run on local hardware without an API key. The metric is Character Error Rate (CER), the share of incorrectly recognized characters. The leaderboard splits results into a "diplomatic" variant that counts modernization of archaic characters like the long s (f) as an error and a "reading" variant that tolerates such changes.

The leading dots.mocr model uses just 3 billion parameters, while Qwen3.5-9B scores lower despite being nearly three times as large. OvisOCR2 takes second place with only 0.9 billion parameters at 46 cents per thousand pages. Model size and OCR quality don't correlate for historical documents.

Model	Size	Accuracy	Cost/1,000 pages
dots.mocr	3B	97.6%	\$1.94
OvisOCR2	0.9B	96.9%	\$0.46
PaddleOCR-VL-1.6	1B	96.1%	\$0.34
olmOCR-2	8.3B	95.7%	\$0.45
LightOnOCR-2	1B	95.1%	\$0.37
Qwen3.5-9B	9.7B	94.9%	\$0.89
DeepSeek-OCR	3.3B	93.8%	\$0.37

The evaluation covers only Antiqua typefaces in four languages. It doesn't account for [Fraktur](#), non-Latin scripts, or handwriting, and FineBooks is limited to single-column book pages. The team plans to reprocess about 200,000 public-domain BHL documents with one of the top models and release the text as an open dataset. New models are added to the leaderboard on a rolling basis, and [the evaluation framework](#) is openly available.

AD

Good enough for AI training, too inaccurate for scholarship

The FineBooks authors judge results by intended use. For training language models, the top performers work well enough, they write. The models produce far fewer errors than the older pipelines, and reprocessing a collection the size of BHL is realistic at the measured costs.

Libraries face a different problem, the team notes. Their systems rely on [ALTO XML](#), a format with word-level coordinates. The new models output Markdown or plain text without word positions, so they can't plug into existing library infrastructure.


For scholarly transcriptions, accuracy still falls short, but not because the models misread characters. They silently modernize them, swapping the long "s" or ligatures for modern equivalents. Targeted fine-tuning could fix this, the team says.

AI News Without the Hype – Curated by Humans

Subscribe to THE DECODER for ad-free reading, a weekly AI newsletter, our exclusive "AI Radar" frontier report six times a year, full archive access, and access to our comment section.

[Subscribe now](#)

Source: [Hugging Face](#)



NEWSLETTER - THE DECODER

Stay in the loop on AI. Clear, useful, no fluff.

Enter your email



Subscribe to our Newsletter



INFORMATION

[About](#)

[Advertise](#)

[Publish with us](#)

[Login](#)

LEGAL

[Privacy Policy](#)

[Privacy Manager](#)

[Imprint](#)

[Terms and Conditions](#)

[Cancellation & Refund](#)

TOPICS

[AI and society](#)

[AI in practice](#)

[AI research](#)

[Frontier Radar](#)

[Short News](#)