


OpenAI запускает GPT-5.6-Cyber, чтобы помочь специалистам по кибербезопасности находить уязвимости до того, как их обнаружат злоумышленники



Маттиас Бастиан [in](#) 10 августа 2026 года



Ключевые моменты

- OpenAI расширяет свою программу кибербезопасности Daybreak двумя новыми уровнями доступа и специальной моделью искусственного интеллекта под названием GPT-5.6-Cyber, призванной помочь специалистам по безопасности выявлять уязвимости и разрабатывать эксплойты на ранних этапах.
- Программа разделена на два направления: Daybreak Blue ориентирована на защитные задачи, такие как анализ вредоносного

ПО, а Daybreak Red — на наступательные исследования в области кибербезопасности.

- На уровне Red пользователи получают доступ к GPT-5.6-Cyber — модели, специально обученной для наступательных целей в сфере безопасности. Она отвечает почти на все конфиденциальные запросы, которые обычно блокируются другими моделями искусственного интеллекта.

Спросите об этой статье...



Темы

- GPT-5.6-Cyber отвечает на 95 % конфиденциальных запросов по безопасности, которые блокируют другие модели
- Модель уже нашла две неизвестные уязвимости в Chrome

OpenAI расширяет свою программу Daybreak двумя новыми уровнями доступа и специализированной моделью под названием GPT-5.6-Cyber. Модель призвана помочь специалистам по кибербезопасности выявлять уязвимости и создавать эксплойты до того, как злоумышленники смогут массово использовать инструменты на основе искусственного интеллекта.

По мнению OpenAI, злоумышленники будут все чаще использовать искусственный интеллект для кибератак, в том числе полностью автономных. Времени на подготовку у защитников становится все меньше. Как ни странно, лучший пример этого произошел в самой компании OpenAI, когда ее собственные модели случайно [взломали Hugging Face и другие сервисы](#) после нескольких недель [агентурных интриг на внутренних форумах](#).

Daybreak призван дать защитникам преимущество. Теперь у программы [два уровня доступа](#). Daybreak Blue предоставляет пользователям доступ к GPT-5.6 Sol с индивидуальными средствами защиты для авторизованной работы в сфере защиты, такой как обнаружение уязвимостей, анализ вредоносного ПО и реагирование на инциденты. Daybreak Red предназначен для


исследователей в области безопасности, занимающихся поиском уязвимостей, проверкой эксплойтов и тестированием на проникновение.

РЕКЛАМА

Для доступа к любому из уровней требуется подтверждение личности, меры по обеспечению безопасности учетной записи, мониторинг и юридические декларации. С 1 сентября 2026 года аппаратные ключи безопасности станут обязательными для всех учетных записей Daybreak. OpenAI также рекомендует запускать рабочие процессы обеспечения безопасности в изолированных средах «песочницы» и использовать режим автоматической проверки в Codex, который проверяет действия, требующие повышенных привилегий, перед их выполнением.

GPT-5.6-Cyber answers 95 percent of sensitive security queries that other models block

The new GPT-5.6-Cyber model is available through the Daybreak Red tier. It's based on GPT-5.6 Sol and was specifically trained to perform better on tasks like finding zero-day vulnerabilities and building exploit chains. [According to OpenAI](#), the model rarely refuses security-related queries that other models block by default.



GPT-5.6-Cyber answers 95 percent of sensitive cybersecurity queries in an internal benchmark. The standard GPT-5.6 Sol model blocks nearly all of them due to its safeguards. | Image: OpenAI

In an internal benchmark called "Advanced Cybersecurity Completion Rate," GPT-5.6-Cyber answers 95 percent of queries covering scenarios like exploit chain development, authentication bypass, and privilege escalation. GPT-5.6 Sol with safety measures turned on hits just 1.5 percent. With Daybreak Blue, it reaches 2 percent. The previous model, GPT-5.5-Cyber, manages 57.3 percent.

In one specific test, the models had to develop a WebSocket authentication bypass for an internal admin panel. Only GPT-5.6-Cyber on Daybreak Red produced working exploit code. Every other variant refused to respond. On ExploitGym, a benchmark that measures how well models turn known vulnerabilities into working exploits, GPT-5.6-Cyber beats both GPT-5.6 Sol and GPT-5.5-Cyber.

The model already found two unknown Chrome vulnerabilities

OpenAI has also used GPT-5.6-Cyber for real-world vulnerability research. The company says the model analyzed V8, Chrome's JavaScript engine, and found two previously unknown vulnerabilities that can be chained together to corrupt memory and bypass the V8 heap sandbox. Google fixed the flaws after coordinated disclosure and assigned [them the CVE-2026-15903 designation](#).

GPT-5.6-Cyber also reportedly found at least five vulnerabilities in a "popular mobile operating system." One of them is a chain of flaws that would let an app escalate its normally restricted access rights to full administrator privileges, taking control of the device. OpenAI is working with Daybreak partners and the open-source community to disclose and fix these issues.

AD




Under OpenAI's Preparedness Framework, GPT-5.6-Cyber has been rated "High" for cybersecurity capabilities but doesn't reach the "Critical" threshold. The recently announced Astra model is "potentially" expected to hit that Critical level, though. Given that GPT-5.6-Cyber is already a specialized, optimized model and still falls short of Critical, the trajectory is clear: AI cyber capabilities are climbing fast with each new generation.

AI News Without the Hype – Curated by Humans

Subscribe to THE DECODER for ad-free reading, a weekly AI newsletter, our exclusive "AI Radar" frontier report six times a year, full archive access, and access to our comment section.

Subscribe now

Source: [OpenAI](#)



NEWSLETTER - THE DECODER

Stay in the loop on AI. Clear, useful, no fluff.

Enter your email



Subscribe to our Newsletter



INFORMATION

[About](#)

[Advertise](#)

[Publish with us](#)

[Login](#)

LEGAL

[Privacy Policy](#)

[Privacy Manager](#)

[Imprint](#)

[Terms and Conditions](#)

[Cancellation & Refund](#)

TOPICS

[AI and society](#)

[AI in practice](#)

[AI research](#)

[Frontier Radar](#)

[Short News](#)