



Поиск моделей, наборов данных, пользователей...



Hugging Face — это гораздо веселее в компании друзей и коллег! 😊 [Присоединиться к организации](#)

Заккрыть это сообщение

< Статьи

arxiv:2606.19348

Скопировать в формате Markdown



DeepSeek-V4: Towards Highly Efficient Million-Token Context Intelligence

Опубликовано 26 апр. · [DeepSeek](#)

▲ Отметить как понравившееся 26

+18

Авторы: [DeepSeek-AI](#), [Аньи Сюй](#), [Бангай Линь](#), [Бин Сюэ](#), [Бинсюань Ван](#), [Бинчжэн Сюй](#), [Бочао У](#), [Бовэй Чжан](#), [Чаофань Линь](#), [Чэнь Дун](#), [Чэньчэнь Лин](#), [Чэнда Лу](#), [Чэнган Чжао](#), [Чэнци Дэн](#), [Чэнъюй Хоу](#), [Чэньхао Сюй](#), [Чэньцзэ Шао](#), [Чун Жуань](#), [Коннер Сан](#), [Дамай Дай](#), [Дая Го](#), [Дэцзянь Ян](#) + 297 авторов

Аннотация

Серия DeepSeek-V4 представляет собой усовершенствованные языковые модели Mixture-of-Experts с повышенной эффективностью работы с длинными контекстами за счет гибридных механизмов внимания, новых гиперсвязей и передовых методов оптимизации.

✦ Сгенерировано [Qwen/Qwen2.5-Coder-32B-Instruct](#)

Мы представляем предварительную версию серии DeepSeek-V4, включающую две мощные языковые модели Mixture-of-Experts (MoE) — DeepSeek-V4-Pro с 1,6 трлн параметров (49 млрд активированных) и DeepSeek-V4-Flash с 284 млрд параметров (13 млрд активированных). Обе модели поддерживают контекст длиной в миллион токенов. Серия DeepSeek-V4 включает в себя несколько ключевых усовершенствований в области архитектуры и оптимизации: (1) гибридную архитектуру внимания, которая сочетает в себе сжатое разреженное внимание (Compressed Sparse Attention, CSA) и сильно сжатое разреженное внимание (Highly Compressed Sparse Attention, HCA) для повышения эффективности



Спросить HuggingChat об этой статье



(2) гиперсвязи с ограничениями на многообразии (Manifold-Constrained Hyper-Connections, mHC), которые улучшают традиционные остаточные связи; (3) оптимизатор Muon для ускорения сходимости и повышения стабильности обучения. Мы предварительно обучаем обе модели на более чем 32 триллионах разнообразных и высококачественных токенов, после чего применяем комплексный пост-тренировочный конвейер, который раскрывает и дополнительно расширяет их возможности. DeepSeek-V4-Pro-Max, режим максимального логического усилия в DeepSeek-V4-Pro, устанавливает новый стандарт для открытых моделей, превосходя своих предшественников в решении основных задач. В то же время модели серии DeepSeek-V4 очень эффективны в сценариях с большим контекстом. В контексте с одним миллионом токенов DeepSeek-V4-Pro требует всего 27 % вычислений для одного токена и 10 % кэша KV по сравнению с DeepSeek-V3.2. Это позволяет нам без проблем работать с контекстами, содержащими один миллион токенов, что делает более осуществимыми задачи с долгосрочным горизонтом планирования и дальнейшее масштабирование времени тестирования. Контрольные точки модели доступны по адресу <https://huggingface.co/collections/deepseek-ai/deepseek-v4>.

[↗ Просмотреть страницу arXiv](#)[↗ Просмотреть PDF](#)[📑 Добавить в коллекцию](#)

👉 Сообщество

🟡 **Амир27272727** 30 июня



سلام

[↩ Ответить](#)

🟡 **Амир27272727** 30 июня



Hdhdhdhdhdhd

[↩ Ответить](#)

🟡 **SDFGSGFDGDFGHFGDHGF** 4 июля



Привет






Ответить

SDFGSGFDGDFGHFGDHGF 4 июля



Привет



Ответить

Alexs28 3 дня назад



Привет



Ответить

Редактировать

Предварительный просмотр

Start discussing about this paper

Нажмите или вставьте сюда, чтобы загрузить изображения

Комментарий



Добавьте эту статью в свой агент:

hf papers read 2606.19348



У вас не установлена последняя версия интерфейса командной строки?

Models citing this paper 94

deepseek-ai/DeepSeek-V4-Pro

Text Generation • 1.6T • Updated Jun 22 • 1.62M • 5.38k

deepseek-ai/DeepSeek-V4-Flash-0731

Text Generation • 304B • Updated 3 days ago • 433k • 2.2k

[Просмотреть 94 модели, цитирующие эту статью](#)

Datasets citing this paper 1

NovatasticRoScript/IIIfSLM-v1

Viewer • Updated about 22 hours ago • 694 • 126 • 1

Spaces citing this paper 345

victor/DeepSeek-V4-Flash-0731-free-endpoint

smolagents/ml-intern

zoom-ai/hle-leaderboard

akhaliq/DeepSeek-V4-Pro

wangsheng/DeepSeekV4Chat

+ 3 Spaces

[Просмотреть 345 пространств, цитирующих эту статью](#)

Collections including this paper 3

Deepseek Papers Collection

Deepseek papers collection • 32 items • Updated 1 day ago • 361

Papers Collection

7 items • Updated 25 days ago

AI-模型 Collection





System theme

Company

TOS

Privacy

About

Careers

Website

Models

Datasets

Spaces

Pricing

Docs

