


АГЕНТЫ ИИ / СТРАТЕГИЯ ИИ / ИНСТРУМЕНТЫ ДЛЯ РАЗРАБОТЧИКОВ

Ваш агент хочет искать работу, как квант в 2010 году

Поиск Perplexity в виде кода делает профессиональный поиск с помощью искусственного интеллекта массовым явлением. Узнайте, как простая реализация может принести огромную пользу.

21 июня 2026 года, 12:00 [Джон Братсет](#)



Летний флаг для Unsplash+

[Vespa.ai](#) спонсировала этот пост.

Чтобы хорошо работать, ИИ-агентам нужна правильная информация. От того, смогут ли они ее найти, зависит успех или неудача в большинстве реальных случаев, и это становится все более важным по мере совершенствования моделей.

Первым этапом стал период **векторных баз данных** в 1924 году, когда считалось, что все, что нужно сделать, — это разбить текст на независимые фрагменты, создать для каждого из них вектор эмбединга и найти их с помощью поиска ближайших соседей. Это было просто, но, увы, не работало. Фрагменты имели слишком мало контекста, и оценка **основанная исключительно на векторном** сходстве не позволяла надежно выявлять полезную информацию.

Наступил *второй этап*, на котором опыт поиска информации человеком за последние полвека был объединен с векторным поиском: **гибридный поиск**, BM25, ранжирование на основе машинного обучения и так далее. Это стало огромным прорывом, благодаря которому многие сценарии использования перешли с демонстрационного уровня на производственный.

Но потенциал для совершенствования огромен, и с анонсом **поиска как кода** от Perplexity мы, возможно, официально вступаем в *третий этап*. Видите ли, в сфере поиска возникла одна большая проблема: пользователи ленивы и несведущи, по крайней мере когда дело касается поиска. Учитывая это, получается, что слова, которые люди вводят в поисковую строку, следует рассматривать как расплывчатые указания на то, что им может быть нужно, а предоставлять более детальный контроль бессмысленно, потому что никто не станет им пользоваться. Наиболее ярко это можно проследить на примере эволюции поиска Google: от возможности находить веб-страницы, содержащие определенные слова, до того, что мы имеем сейчас; **вызывает искреннее сожаление**, но, конечно, в основе этого лежит наблюдение за реальными пользователями.



опытом. Она обрабатывает большие объемы данных и выполняет большое количество запросов, обеспечивая эффективное управление данными, логическими выводами и логикой. Доступна как в виде управляемого сервиса, так и с открытым исходным кодом.

[Learn More →](#)

THE LATEST FROM VESPA.AI

[Re-autoresearching MSMARCO BM25, on Vespa](#)

29 May 2026

[Vespa Newsletter, May 2026](#)

27 May 2026

[Scaling a Vespa Application: Feeding Fast and Furiously](#)

28 April 2026

HEAR MORE FROM OUR SPONSOR

svo1975pvn1982@gmail.com

[Submit](#)

“The search field has needed to deal with one big problem: Human users are lazy and clueless, at least when it comes to search.”

Agents, in contrast, are not so clueless. And they certainly aren't lazy! There's no reason to limit their options to those of a casual human user. They should be able to:

- Search for the names of those involved *near* each other in text when researching a legal case
- Do a pure semantic search prioritizing high-quality sources when seeking a broad overview of a topic

Select a year range and group by month when constructing a timeline of some events

forming hypotheses, verifying important details in them, and so on. In short, search like an expert who knows what they are doing and really cares about the results—like a quant doing financial analysis.

TRENDING STORIES

1. The Anthropic leader who built Claude Code says he ditched prompting — now he just writes loops.
2. Greptile, Cursor, and Devin agree that agents should run their code. What they run it against matters.
3. Anthropic gives @Claude a permanent seat in your Slack channels
4. Claude Code vs. Cursor vs. Codex vs. Antigravity — six months in
5. "Bring it to our shop": Workday's pitch for keeping AI agents close to your most valuable data

It seems *obvious* that this will yield better results, and this is also what evaluations such as those published by Perplexity in its [search as code blog post](#) show (ignore the “code” aspect, as code execution is generally useful and *where* that code runs doesn’t impact quality).

Doing this in practice, with your own data, is actually quite easy. The models already know how to write complex queries in the languages of [well-known AI search engines](#); they just need to be told

- That they can
- What fields are available and what they mean
- What choices they have in ranking the results

How you tell them doesn’t actually matter that much; any simple textual description of what fields and ranking options are available will do. Models today are smart enough to use this effectively to connect their intents to practical detail queries.

It’s time to let your agents search like a 2010 quant.”

some types of queries cannot be improved because doing so would impact other types. When implementing for agents, the focus shifts to providing a wide toolbox for the agent to use to address their varied informational needs: broad *and* highly specific lexical recall, metadata attributes for filtering, grouping, and aggregation, as well as different ranking methods suited to different needs.

Accordingly, developers working on agentic search need to shift their focus from reusing techniques that have worked well for casual humans to the much richer capabilities traditionally provided by solutions for competent professionals.

It's time to let your agents search like a 2010 quant.

TNS



Jon Bratseth is the CEO and a cofounder of Vespa.ai, and the architect and one of the main contributors to Vespa, the platform for applications combining AI and data online. Jon has 25 years of experience as an architect and...

[Read more from Jon Bratseth →](#)

SHARE THIS STORY



TRENDING STORIES

1. The Anthropic leader who built Claude Code says he ditched prompting — now he just writes loops.
2. Greptile, Cursor, and Devin agree that agents should run their code. What they run it against matters.
3. Anthropic gives @Claude a permanent seat in your Slack channels
4. Claude Code vs. Cursor vs. Codex vs. Antigravity — six months in

INSIGHTS FROM OUR SPONSOR



Vespa.ai is a platform for building AI-driven applications for search, recommendation, personalization, and RAG. It handles large data volumes and high query rates, offering efficient data, inference, and logic management. Available as both a managed service and open source.

[Learn More →](#)

Re-autoresearching MSMARCO BM25, on Vespa

29 May 2026

Vespa Newsletter, May 2026

27 May 2026

Scaling a Vespa Application: Feeding Fast and Furiously

28 April 2026

The Vespa Cloud Metrics Dashboard

24 April 2026

Using Large ONNX Models with External Data in Vespa Embedders

27 March 2026

How Metal AI Built an Agent-Driven Intelligence Platform on Vespa Cloud

10 March 2026

most recent TNS articles in your inbox each day.

svo1975pvn1982@gmail.com

SUBSCRIBE

The New Stack does not sell your information or share it with unaffiliated third parties. By continuing, you agree to our [Terms of Use](#) and [Privacy Policy](#).

ARCHITECTURE

Cloud Native Ecosystem
Containers
Databases
Edge Computing
Infrastructure as Code
Linux
Microservices
Open Source
Networking
Storage

ENGINEERING

AI
AI Engineering
API Management
Backend development
Data
Frontend Development
Large Language Models
Security
Software Development
WebAssembly

OPERATIONS

AI Operations
CI/CD
Cloud Services
DevOps
Kubernetes

CHANNELS

Podcasts
Ebooks
Events
Webinars
Newsletter

THE NEW STACK

[About / Contact](#)
[Sponsors](#)
[Advertise With Us](#)
[Contributions](#)



Community created roadmaps, articles, resources and journeys for developers to help you choose your path and grow in your career.

[Frontend Developer Roadmap](#)
[Backend Developer Roadmap](#)
[Devops Roadmap](#)

FOLLOW TNS



© The New Stack 2026

[Disclosures](#)
[Terms of Use](#)
[Advertising Terms & Conditions](#)
[Privacy Policy](#)
[Cookie Policy](#)