



Новый навык за несколько недель

[Войти](#)

ig_novvv

10 часов назад

Два движка, два разных веба: почему ChatGPT-search и Яндекс-нейропоиск цитируют из 174 доменов только 7 общих

Средний

7 мин

6K

Интернет-маркетинг*, Искусственный интеллект, Поисковые технологии*, Контент и копирайтинг*

[Аналитика](#)

Я гоняю один и тот же пул из 60 промптов через шесть ИИ-движков раз в месяц — это часть мониторинга, который я веду для одной ниши. В какой-то момент решил не просто читать ответы, а посчитать, откуда движки берут источники. Ожидал разную выдачу по одной теме — обычное дело для поисковиков. Получил другое: два практически несвязанных множества доменов. Из 174 уникальных источников за последний срез общих оказалось 7.

Расскажу, как я это посчитал, почему дело не в шуме прогона, а в архитектуре, и почему первый вывод оказался не там, где я его искал.

Что за данные и почему их вообще можно сравнивать

Логи мониторинга — это JSON-файлы, по одному на пару (движок, промпт, прогон). У каждого есть поле `sources_cited` — список объектов с `domain` и `url`, если движок в принципе показывает источники. Три временных среза с разницей примерно в месяц: майский, июньский, июльский — один и тот же набор из 60 промптов, одна ниша (контент-производство), русскоязычные запросы.

Первое, что выяснилось при попытке собрать пулы источников по всем пяти движкам, — три из пяти не дают материала для анализа:

- **Perplexity** (sonar-pro) в ответе оставляет только числовые сноски вида [6][8] , сами URL приходят отдельным полем API, которое мой прокси не пробрасывает в лог. В майском срезе изредка проскакивали (19 доменов), но это флаки, не система — для честного сравнения массив недостаточен.
- **Gemini** (gemini-2.5-flash) и **Claude** (claude-sonnet-4.5) в этой связке работают без веб-ретрива — генеративка отвечает по весам модели, источников не цитирует по дизайну. Ноль здесь — не баг парсера, а ожидаемое поведение.

Остаются два движка, которые реально отдают машиночитаемый список источников:

ChatGPT-search (gpt-4o-search-preview , ссылки идут inline в тексте вида domain) и **Яндекс-нейропоиск** (search-api-gen , отдаёт чистый список).

Дальше речь только о них. Не потому что остальные три неинтересны, а потому что у них физически нет данных для этого конкретного сравнения. Нельзя сказать, что источники не пересекаются у пяти движков, когда трое из пяти источники вообще не показывают. Честно сравнимы ровно два. Прежде чем считать пересечение, приходится проверить куда более скучную вещь — а движок вообще отдаёт то, что можно сравнивать?

Код: как я считал пересечение

Для каждого среза каждого движка собрать множество доменов, а потом посчитать коэффициент Жаккара между всеми парами множеств. $Jaccard = |A \cap B| / |A \cup B|$: единица — множества совпадают полностью, ноль — не пересекаются вообще.

```
"""
```

Считает, насколько пересекаются пулы источников, которые разные ИИ-движки цитируют по одному и тому же набору запросов.

Вход: логи мониторинга — по одному JSON на (движок, промпт, прогон).

В каждом JSON есть поле sources_cited: [{"url": ..., "domain": ...}, ...].

Выход: матрица коэффициентов Жаккара между пулами + доля уникальных доменов.

```
"""
```

```
import glob
```

```
import json
```

```
import os
```

```
# (метка, путь к папке с логами движка за один срез времени)
```

```
POINTS = [ ("ChatGPT-май", "logs/baseline-iter1/chatgpt"), ("ChatGPT-июн", "logs/baseline-iter2/chatgpt") ]
```

```
def domain_pool(folder): """Множество доменов-источников, процитированных движком"""
```

```
def jaccard(a, b): union = a | b return len(a & b) / len(union) if union else 0
```

```
pools = [(label, domain_pool(folder)) for label, folder in POINTS]
```

```
# --- матрица Жаккара ---
```

```
print("пул источников по срезам:")
```

```
for label, pool in pools: print(f" {label:12s} {len(pool):4d} доменов")
```

```

print("\nматрица Жаккара:")
print(" " * 13 + "".join(f"{lbl[:11]:>12}" for lbl, _ in pools))
for l1, p1 in pools:    cells = "".join(f"{jaccard(p1, p2):12.2f}" for _, p2 in
# --- доля источников, уникальных для одного движка (последний срез) ---
cg = dict(pools)["ChatGPT-июл"]
yx = dict(pools)["Yandex-июл"]
shared = cg & yx
union = cg | yx
print(f"\нобщих доменов у ChatGPT и Yandex (июль): {len(shared)} из {len(union)}
print(f"уникальны только ChatGPT: {len(cg - yx)} ({(len(cg - yx) / len(cg)):.0%}
print(f"уникальны только Yandex: {len(yx - cg)} ({(len(yx - cg) / len(yx)):.0%}
print(f"встречаются у обоих: {len(shared)} ({(len(shared) / len(union)):.0%}

```

Объяснить с  SourceCraft

Являл не пару «ChatGPT сейчас vs Яндекс сейчас», а шесть точек — три среза каждого движка. Это нужно, чтобы отличить структурное непересечение от банального шума. Если ChatGPT-май и ChatGPT-июль пересекаются между собой не сильно лучше, чем ChatGPT и Яндекс в один момент времени, то весь разговор про «разную природу индексов» можно закрывать — окажется, что источники просто дрейфуют случайно у всех.

Что получилось: пересечение не шум, оно структурное

Размеры пулов: ChatGPT май/июнь/июль — 47/78/79 доменов, Яндекс — 92/91/102.

МАТРИЦА ЖАККАРА ПО 6 СРЕЗАМ

Коэффициент Жаккара между пулами доменов-источников · 2 движка × 3 среза времени · 60 промптов. 1.00 — пулы совпали, 0.00 — не пересеклись.

	ChatGPT-май	ChatGPT-июн	ChatGPT-июл	Яндекс-май	Яндекс-июн	Яндекс-июл
ChatGPT-май	1.00	0.23	0.17	0.05	0.04	0.04
ChatGPT-июн	0.23	1.00	0.25	0.07	0.06	0.07
ChatGPT-июл	0.17	0.25	1.00	0.04	0.04	0.04
Яндекс-май	0.05	0.07	0.04	1.00	0.43	0.35
Яндекс-июн	0.04	0.06	0.04	0.43	1.00	0.46
Яндекс-июл	0.04	0.07	0.04	0.35	0.46	1.00

Оранжевые блоки по диагонали — движок с самим собой во времени: ChatGPT 0.17–0.25, Яндекс 0.35–0.46. Белые клетки — ChatGPT против Яндекса: 0.04–0.07 при любой паре срезов. Пересечение движка с собой в 4–9 раз выше, чем двух движков между собой → непересечение структурное, не шум.

Расчёт jaccard_sources.py · sources_cited логов monitor.py · срезы 10–11 мая / 11 июн / 11 июл 2026

Матрица Жаккара по всем шести срезам. распадается на два блока чётко, как по линейке

Внутри блока ChatGPT (три среза друг с другом) — 0.17–0.25. Внутри блока Yandex — 0.35–0.46, заметно стабильнее во времени, чем ChatGPT. А между блоками, в любой паре срезов — 0.04–0.07. Разница в 4–9 раз между «движок сам с собой два месяца спустя» и «два движка в один момент» — это и есть ответ на вопрос из предыдущего раздела: непересечение не шум, потому что шум размазал бы значения примерно поровну. Клетки группируются по движку, а не по времени и не по теме запроса.

Меня удивила асимметрия внутри блоков. Ожидал, что оба движка будут одинаково текучими во времени. ChatGPT ощутимо более волатилен — за месяц пул обновляется почти наполовину. У Яндекса core источников устойчивее. Кажется, ChatGPT-search в этой связке чаще подмешивает свежепроиндексированные страницы (в том числе из недавно появившихся нишевых сайтов), а топ органики Яндекса по устоявшимся коммерческим запросам меняется медленнее — крупные площадки годами удерживают позиции.

Уникальность по последнему срезу: 7 доменов из 174

На июльском срезе объединение пулов — 174 домена. Пересечение — 7. Уникальны только для ChatGPT — 72 (91% его пула). Уникальны только для Yandex — 95 (93% его пула). Иначе говоря, 96% всех доменов, которые встретились хоть у одного движка, живут ровно в одном из двух.

96%_ИСТОЧНИКОВ_ЖИВУТ_В_ОДНОМ_ДВИЖКЕ

Июльский срез · объединение пулов ChatGPT-search и Яндекс-нейропоиска — 174 домена

Только ChatGPT		72
Только Яндекс		95
У обоих движков		7

91% пула ChatGPT и 93% пула Яндекса — домены, которых нет у второго движка.

Общих — 7 из 174 (4% объединения): крупные тематические агрегаторы ниши плюс habr.com.

У ChatGPT в его 91% уникального пула — плотный хвост нишевых продуктовых и инструментальных сайтов: opusdigital.ru , aizavod.io , contentmatrix.ru , aicontentforge.ru , pixorion.ai , luminai.ru , sellscard.ru , textmark.io и подобные. Заметная доля доменов на .io , .ai , .guru — типичные для стартап-инструментов и небольших продуктовых сайтов зоны, международные по формату, даже когда контент на русском.

У Яндекса в его 93% — крупные российские медиа и площадки экосистемы: vc.ru , dzen.ru , sostav.ru , dtf.ru , companies.rbc.ru , seonews.ru , tenchat.ru ,

etxt.ru , raketadigital.com . По сути это узнаваемый топ органической выдачи Яндекса по коммерческим и около-коммерческим запросам этой ниши.

В 7 общих источниках — крупные тематические агрегаторы и каталоги ниши, плюс habr.com . Да, эта площадка попала в пул источников у обоих движков одновременно — что логично: авторитетный технический ресурс индексируется и краулится широко, попадает в оба индекса.

Почему так: разные индексы, не разные мнения

ChatGPT-search в этой связке ходит в собственный веб-индекс — по механике похоже на связку с Bing-подобным индексом плюс собственный краулинг OpenAI. Индекс заточен под покрытие широкого веба, включая небольшие и свежие сайты. Отсюда обилие .io/.ai/.guru -доменов и продуктовых страниц, которые никогда не попадут в топ-10 обычной поисковой выдачи по коммерческому запросу, но вполне могут быть проиндексированы и процитированы как источник конкретного факта.

С Яндексом иначе. Нейропоиск строит ответ поверх топа собственной органической выдачи: сначала работает классический поисковый ранжировщик Яндекса — тот же самый, что формирует SERP для обычного пользователя, — а генеративная надстройка суммирует и цитирует то, что уже прошло отбор в топ. Отсюда и объяснение, почему в пуле Яндекса крупные, давно проиндексированные, коммерчески сильные медиа — это буквально топ-10 обычного поиска по теме, только пересказанный моделью.

Это не значит, что Яндекс и ChatGPT по-разному оценили одни и те же 174 страницы. Это два движка, у каждого из которых своя предварительная выборка кандидатов, и выборки почти не пересекаются на входе до ранжирования и генерации. И асимметрия волатильности из прошлого раздела ложится сюда же: если ChatGPT-search сегодня краулит свежую страницу, а завтра — уже нет, пул естественно скачет сильнее. Если Яндекс завязан на топ органики, который меняется медленно (SEO-позиции крупных сайтов инерционны), пул стабильнее во времени.

Что из этого следует

Термин «видимость в ИИ-поиске» без уточнения, в какой именно ЛЛМ — вообще не метрика. Попадание в источники ChatGPT-search и попадание в источники Яндекс-нейропоиска — две разные, почти не связанные задачи с пересечением на уровне 4–7%. Публикация на площадке, которая хорошо ранжируется в органике Яндекса, покрывает пул одного движка и почти не задевает пул другого. И наоборот: присутствие на нишевом продуктивном ресурсе, который любит краулить ChatGPT, ничего не гарантирует по части Яндекс-нейропоиска.

Если задача — присутствовать в источниках обоих движков одновременно, придётся закрывать оба типа площадок отдельно. Рассчитывать, что успех в одном автоматически

конвертируется в успех в другом, не выходит: они физически не читают одно и то же.

Ограничения

- Сравнимы **2 движка из 5**, не пять. У Perplexity URL прячутся за числовыми сносками — прокси не пробросил это поле, поэтому у него нет данных, а не ноль пересечения; неправильно было бы делать вывод, что Perplexity «не цитирует источники» — это методологическая дыра сбора, а не наблюдение о движке. У Gemini и Claude в этой связке нет веб-ретрива вовсе, это архитектурная особенность их подключения, а не общий факт про модели.
- Выборка — 60 промптов одной ниши (контент-производство), русскоязычные запросы. На другой тематике или в другом языке цифры сдвинутся, возможно ощутимо — я не проверял на второй нише.
- Гранулярность — домен, не URL. Один домен может отдавать десятки разных страниц под разные промпты; это огрубляет картину в обе стороны.
- Коэффициент Жаккара чувствителен к разнице размеров множеств — пулы 79 и 102 не равны, что немного занижает коэффициент математически. На порядок величины это не влияет, но на третьем знаке после запятой стоит делать скидку.
- Три среза с шагом в месяц — маловато, чтобы строить долгосрочный тренд волатильности; для этого нужно больше точек во времени.

Дальше интересно повторить то же самое на другой нише и посмотреть, держится ли структура блоков — или это специфика именно этого набора запросов.

Теги: AEO, GEO, AI-поиск, цитируемость, видимость в нейросетях, ChatGPT, коэффициент Жаккара, источники, LLM, алиса

Хабы: Интернет-маркетинг, Искусственный интеллект, Поисковые технологии, Контент и копирайтинг

Редакторский дайджест

Присылаем лучшие статьи раз в месяц

Электронная почта

Подписаться



2

Карма

Игорь Новиков @ig_novvv

15+ лет в маркетинге, специализация в AEO/GEO

Подписаться



 Комментарии 1

Публикации

ЛУЧШИЕ ЗА СУТКИ

ПОХОЖИЕ



ndokutovich
22 часа назад

Теория относительности — это синус. Мнимого угла



Сложный



12 мин



16K



+79



81



25



monobogdan
15 часов назад

Полный разбор схемотехники кнопочного телефона. Samsung C100 — маленькое чудо корейской инженерной мысли



Простой



11 мин



11K

Ретроспектива



+31



12



26



Erwinmal
20 часов назад

Онигири: путь рисового коlobка от японской древности до наших супермаркетов



Простой



14 мин



10K

Ретроспектива



+26



13



3



YuriPanchul
14 часов назад

Из обучения школьников цифре на макетке нужно выкинуть все резисторы и вставить микросхемы с FIFO



Простой



3 мин



12K



+25



26



86



inkedsymon
21 час назад

Мамба: архитектура, которая шла убивать трансформеры



Средний



7 мин



11K

Обзор

 +23

 19

 2



runaway_llm
9 часов назад

Слишком просто, чтобы быть правдой? GPT-5.6 выдал доказательство 50-летней математической гипотезы

 Простой  4 мин  7.5K

Обзор

 +22

 8

 4



BiktorSergeev
17 часов назад

Worms: как и почему игра про боевых червей уже почти 30 лет остается культовой и популярной

 8 мин  10K

 +22

 3

 13



Lunathecat
16 часов назад

Лёгкий кастомный стратокастер из дешёвых комплектующих

 Простой  8 мин  9.1K

Тutorial

 +21

 3

 4



IvanKlut
19 часов назад

Новая версия языка разметки текстов Markvan

 Средний  4 мин  9.9K

Кейс

 +14

 19

 12



Kova13v
16 часов назад

Я запретил Claude говорить «всё работает» без пруфов. Это изменило всё

 Средний  9 мин  9.2K

Кейс

Из песочницы

 +13

 26

 17

Суперсилы и слабости IT-компаний: началось исследование работодателей 2026

Турбо

Показать еще

ВАКАНСИИ

LEAD AI/ML ENGINEER

от 400 000 ₽ · Selecty · Москва

Backend Engineer (Node.js, TypeScript, Data, Real-time)

от 3 500 до 5 500 \$ · DataLouna · Можно удаленно

Data Scientist Middle

от 120 000 до 150 000 ₽ · Strikt · Можно удаленно

Больше вакансий на Хабр Карьере


МИНУТОЧКУ ВНИМАНИЯ



DPL в Overlay-слое: общение виртуальных машин



Отпуск? Обучение? Курсы? Есть скидки на все



Просто добавь IT: как совмещать код и свёрла в сезоне DIY

БЛИЖАЙШИЕ СОБЫТИЯ




2 марта – 10 августа

**PROBA Awards —
международная
коммуникационная премия,
учрежденная в 2000 году**

Санкт-Петербург

[Маркетинг](#)

[Больше событий в календаре](#)



11 июня – 2 сентября

**Робозон: хакатон с призовым
фондом 15 млн руб.**

Москва • Онлайн

[Разработка](#)

[Больше событий в календаре](#)



15 июля

**Веби
эпох**

Онлайн

[Марк](#)

[Больше](#)



 [Настройка языка](#)

[Техническая поддержка](#)

