



Новый навык за несколько недель

[Войти](#)

RedBuilder81

34 минуты назад

Про киберугрозы со стороны генеративного ИИ

Простой

8 мин

954


Информационная безопасность*, Искусственный интеллект, Будущее здесь, Исследования и прогнозы в IT*

[Аналитика](#)[Перевод](#)

Автор оригинала: Raluca Csernaton and Patryk Pawlak

Превращение генеративных моделей в самостоятельные сущности в информационных сетях ознаменовало начало совершенно новой эпохи внутри сферы информационной безопасности. Недавний аналитический доклад, опубликованный специалистами Фонда Карнеги, фиксирует крайне тревожную тенденцию: средства нападения становятся всё более независимыми от прямого контроля операторов. Указанное исследование подчеркивает, что стремительная эволюция сервисов, предоставляющих доступ для работы с большими языковыми моделями (далее - БЛМ), формирует невиданные ранее угрозы, вынуждая экспертов пересматривать устоявшиеся парадигмы мониторинга сетей. Возникает острая необходимость перехода от монолитных скриптов к сложным многокомпонентным топологиям, способным функционировать круглосуточно без участия человека. Развитие нейросетевых архитектур открывает двери для сценариев, где программный код сам принимает тактические решения.

Эволюция угроз: от автоматизации к высокоавтономным вторжениям



Проведение традиционных виртуальных конфликтов долгое время опиралось на ручной труд злоумышленников, которые использовали различные утилиты лишь для ускорения рутинных процессов. Однако осенью 2025 года аналитики корпорации Anthropic выявили прецедент, навсегда изменивший правила цифрового противостояния. Речь идет о крупномасштабной шпионской операции, реализованной преимущественно силами искусственного интеллекта (далее - ИИ). Хакерской группировке удалось скомпрометировать **около 30 высокоприоритетных целей**, включая правительственные учреждения, а также крупные коммерческие организации. Особенностью данного инцидента является беспрецедентный уровень самостоятельности: примерно **80 или 90 процентов** всех поставленных задач выполнялись машиной абсолютно автономно.

Программный комплекс без посторонней помощи осуществлял разведку, находил уязвимости, подбирал эксплойты и занимался кражей конфиденциальных данных. Злоумышленники лишь задавали первичные стратегические параметры, после чего инициатива полностью переходила к нейросети, генерирующей тысячи запросов ежесекундно. Подобные сущности сегодня классифицируются международными исследователями как Highly Autonomous Cyber-Capable Agents (далее – НАССА) - системы, умеющие осуществлять длительные многоэтапные атаки на уровне элитных государственных спецслужб.



Global Insight

Аналитика. Тренды. Безопасность

НАССА: НОВЫЙ УРОВЕНЬ КИБЕРОУГРОЗ

Highly Autonomous Cyber-Capable Agents (НАССА) — автономные ИИ-агенты, способные проводить длительные многоэтапные атаки на уровне элитных госструктур.

ЧТО УМЕЮТ НАССА:



РАЗВЕДКА

Сбор данных о целях и инфраструктуре



ПОИСК УЯЗВИМОСТЕЙ

Автоматическое обнаружение слабых мест



ПОДБОР ЭКСПЛОЙТОВ

Создание и адаптация эксплойтов «на лету»



КРАЖА ДАННЫХ

Извлечение и эксфильтрация конфиденциальной информации

СЖАТИЕ ZERO-DAY CLOCK

РАНЬШЕ

МЕСЯЦЫ



СЕЙЧАС

МИНУТЫ



Время между обнаружением уязвимости и её массовым использованием



ИИ-агенты находят и используют бреши за минуты, опережая любую защиту



Появление таких технологий нивелирует так называемое «время нулевого дня» (zero-day clock). Ранее между обнаружением бреши и её массовым использованием проходили **месяцы**, но современные ИИ-боты сократили это время до **нескольких минут**.

Преступники научились обходить встроенные защитные барьеры популярных чат-ботов (например, Claude Code), разбивая деструктивные инструкции на мелкие, безобидные фрагменты, из-за чего механизм безопасности воспринимает происходящее как легитимное тестирование инфраструктуры. В результате скорость распространения заражения стала многократно превосходить возможности реакции традиционных центров мониторинга.

Информационный парадокс и туман алгоритмической войны



Колоссальный рост вычислительных мощностей порождает феномен, который европейские специалисты называют «непроницаемостью нового типа». Классический военный термин Карла фон Клаузевица описывал ситуацию, когда командирам не хватало сведений для принятия взвешенных решений. Современный аналог, подробно разобранный в трудах Ралуки Чернатони из Фонда Карнеги, характеризуется фатальным избытком телеметрии. БЛМ генерируют аналитические отчеты, вероятностные списки целей и мгновенные рекомендации настолько быстро, что мозг физически не успевает их обрабатывать.

Возникает иллюзия полного контроля, скрывающая глубокую непрозрачность логики искусственного разума. Оператор формально остается элементом контура управления, однако его роль сводится к номинальному присутствию. Нажатие кнопки подтверждения превращается в обыкновенное юридическое алиби для алгоритма, поскольку времени на осмысленную оценку предлагаемых действий попросту не остается. Создается серьезный разрыв подотчетности: ответственность размывается между создателями продукта, дата-инженерами, а также конечными пользователями.

Чтобы эффективно противостоять угрозам, действующим на сверхвысоких скоростях, пассивные методы обороны оказываются абсолютно бесполезными. Глубокий аудит инцидентов показывает, что корпорациям следует внедрять механизмы предиктивной защиты, функционирующие в режиме реального времени. Отказ от устаревшей парадигмы реагирования требует кардинальной перестройки всей архитектуры корпоративной сети.


Уязвимость Европы и геополитический контекст



На фоне глобальной гонки технологических вооружений всё острее встает вопрос правового регулирования. Документы аналитических центров акцентируют внимание на нормативном вакууме, образовавшемся внутри Европейского Союза (далее - ЕС). Текущие законодательные инициативы, включая масштабный свод правил AI Act, постоянно сталкиваются с непреодолимыми трудностями при согласовании требований между государствами-членами, фатально не поспевая за темпами развития отрасли.

Важнейшей стратегической проблемой признана колоссальная зависимость «Старого Света» от передовых американских разработок. В условиях усложняющейся геополитической обстановки делегирование вопросов национальной безопасности зарубежным коммерческим вендорам несет огромные риски. Независимые обозреватели настаивают на критической необходимости обильных инвестиций в суверенные оборонительные платформы, призванные снизить тотальную привязанность к внешним поставщикам ИИ-услуг. Отсутствие собственных передовых нейросетей (**БЛМ в частности**) делает инфраструктуру уязвимой перед манипуляциями извне, превращая страны ЕС в заложников чужой корпоративной политики.

Интеграция концепции активной обороны



Текущая военно-политическая ситуация диктует острую необходимость перехода от пассивного наблюдения к **«проактивной защите»**. Когда киберпреступники задействуют ИИ для автоматического поиска открытых портов, традиционные средства антивирусной защиты становятся неспособны выполнять свою функцию полноценно. Оборонительные скрипты обязаны непрерывно патрулировать инфраструктуру, выискивая слабые места существенно раньше, чем это делает атакующая сторона.

ИИ-модули могут применяться для постоянного динамического тестирования на проникновения. Они должны непрерывно эмулировать поведение реальных хакеров, пытаться эксплуатировать найденные бреши, после чего немедленно предлагают патчи для закрытия уязвимостей. Технологии уровня NVIDIA Morpheus обеспечивают практически стопроцентную видимость трафика, анализируя каждый пакет на предмет утечек или попыток фишинга. В случае обнаружения подозрительной активности — нестандартного времени входа в учетную запись или аномального объема скачиваемых файлов — профильный юнит способен за **миллисекунды** заблокировать скомпрометированный хост.

Слияние описанных решений с концепцией «нулевого доверия» формирует уникальную экосистему, внутри которой ни один сетевой запрос не считается безопасным по умолчанию. Практика микросегментации позволяет превратить корпоративную сеть в сложный лабиринт из множества мельчайших периметров. Даже если враждебный код успешно проникнет внутрь одного сегмента, его дальнейшее горизонтальное

распространение будет мгновенно пресечено на ближайшем узле, который потребует повторную аутентификацию.

Векторы компрометации защитных контуров



Повышение автономности действия злоумышленников в киберпространстве приносит новые специфические векторы уязвимостей, характерные исключительно для ИИ-систем. Хакеры начали активно применять изощренные техники **«внедрения вредоносных инструкций»**. Скрытые команды легко маскируются внутри безобидных логов, фишинговых писем или обычных PDF-документов. Когда встроенный аналитический модуль парсит такой файл для проверки, он случайно активирует скрытый код, способный заставить программу отправить секретные ключи доступа на удаленный сервер.

Помимо внешних атак, существует серьезная проблема **«внутренней деградации качества логических цепочек»** (заражения памяти). Комплексы, обладающие долгосрочной памятью, крайне склонны к накоплению мелких ошибок. Если администраторы не проводят своевременную очистку устаревших баз знаний, незначительные погрешности масштабируются экспоненциально, приводя к так называемым **логическим галлюцинациям**. Платформа может сослаться на

несуществующий индикатор компрометации (IoC) или абсолютно неправильно интерпретировать профиль атакующего.

Для нивелирования перечисленных рисков инженеры внедряют строгую изоляцию (песочницу) любых входящих сигналов. Использование параллельных алгоритмов-аудиторов, чья единственная задача — беспристрастно проверять логику решений главных исполнителей, существенно снижает итоговый процент ложных срабатываний. Важнейшим шагом является применение принципа наименьших привилегий: если бот-резюмист обязан только сжимать текст, ему категорически должно быть запрещено иметь доступ к файловой системе сервера.

Баланс машинной скорости и человеческого контроля



Главным философским и техническим вызовом остается внедрение принципа «**осмысленного суждения**» обратно в контур управления защитой. Как уже отмечалось в первой части статьи, колоссальные скорости вычислений лишают рядового оператора возможности принимать адекватные решения при отражении инцидента. Дабы избежать полной утраты контроля над ситуацией, индустрия переходит к многоуровневым моделям гибридной авторизации.

Низкорисковые рутинные операции, такие как сортировка очередей событий или блокировка адресов из известных публичных спам-баз, машины вправе выполнять абсолютно самостоятельно. Подобный подход избавляет аналитиков от **выгорания**, позволяя сосредоточиться на творческих аспектах работы. Однако необратимые критические действия — глобальное отключение серверов баз данных, изменение фундаментальных политик маршрутизации трафика или запуск встречных киберударов — должны в обязательном порядке подтверждаться живыми людьми. Искусственная «совещательная пауза» обязана восприниматься специалистами отрасли не как операционная слабость архитектуры, а как ценнейший стратегический актив, страхующий глобальную инфраструктуру от катастрофических сбоев.

Таким образом, цифровое пространство стремительно трансформируется в театр боевых действий между математическими абстракциями. Доклады ведущих исследовательских институтов наглядно демонстрируют, что хакеры уже активно эксплуатируют программные комплексы, способные осуществлять масштабные целевые атаки быстрее человека. Ответом на этот экзистенциальный вызов не может служить банальное расширение штата сотрудников отдела безопасности.

Выживание организации в новой парадигме требует внедрения сложных архитектур, опирающихся на принципы глубоко распределенного делегирования полномочий. Специализированные оборонительные агенты, функционирующие внутри защищенных локальных контуров, способны полностью нивелировать преимущество противника в темпе наступления. Они могут взять на себя обработку огромных массивов мусорного трафика, освобождая людям драгоценное время для долгосрочного планирования. Интеграция столь мощных инструментов неразрывно связана с острой необходимостью выработки жестких нормативных рамок, а также этических стандартов. Строгое соблюдение баланса между автоматизацией реакции механизмов и обязательным надзором со стороны человека станет важнейшим критерием успешности защитной стратегии на ближайшие годы. Промедление в модернизации собственных оборонительных рубежей чревато фатальными последствиями как для государств, так и для частных компаний, поскольку цифровые противники не станут дожидаться, пока законодатели решат юридические дилеммы применения ИИ.

А больше интересного материала, затрагивающего не только технологии, но и военно-политическую обстановку в мире, вы можете найти в нашем канале Global Insight Plus на площадках Telegram и MAX:

https://t.me/Global_Insight_official_all

<https://max.ru/join/aGgftqhkdUEJ1G4L87xnvPw1mtLQRWbnK200NdeKpQY>

Теги: хакеры, ии, ии-агенты

Редакторский дайджест

Присылаем лучшие статьи раз в месяц

Электронпочта

Подписаться

Оставляя почту, я принимаю Политику конфиденциальности и даю согласие на получение рассылок



32K+

3

Охват за 30 дней Карма

Александр @RedBuilder81

Информационно-аналитический ресурс Global Insight

Подписаться



 Комментировать

Публикации

ЛУЧШИЕ ЗА СУТКИ ПОХОЖИЕ



GlinkinIvan
22 часа назад

Хакер в магазине: изучаем поверхность атаки типичного супермаркета

🕒 9 мин 👁 14K

📦 +56

🔖 46

💬 39



arturdumchev
23 часа назад

Калвиаутра путает калвиши: один байт изменил всё

🔗 Средний 🕒 8 мин 👁 11K

Тutorial

📦 +35

🔖 7

💬 7



PatientZero
3 часа назад

Теория мёртвой экономики

🕒 21 мин 👁 6.3K

Перевод

📦 +24

🔖 14

💬 20



nastyakopi
21 час назад

ИИ-роутер, open-source RAG-платформа, ClickHouse-as-a-service и другие апдейты в продуктах Selectel в июне

🕒 7 мин 👁 11K

Дайджест

📦 +23

🔖 6

💬 3



inetstar
20 часов назад

Полный геном за \$200 и его анализ в домашних условиях: Just-DNA-Lite, ИИ и пересборка генома. Часть 3

🔗 Средний 🕒 29 мин 👁 10K

Тutorial

+20

17

4



SLY_G

19 часов назад

Сколько элементарных частиц существует на самом деле?



Простой



9 мин



10K

Перевод

+19

16

12



xraizor

3 часа назад

Усталость от напарника-машины. Изнанка работы с ИИ-код-агентами



Средний



11 мин



5.2K

Мнение

+16

7

8



AWE64

15 часов назад

Мне надоело писать один и тот же код. Поэтому я сделал Featuregen



Средний



6 мин



13K

Кейс

+16

14

4



inspired_xy

17 часов назад

Как мы съездили в Японию и запустили Пополаму — сервис, который знает кто кому должен



Простой



4 мин



11K

Кейс

Из песочницы

+16

13

4



VasilyDemidov
вчера в 13:43

Переход на zVirt 5.0: что меняется на каждом узле и как не сорвать обновление



Средний



9 мин



8.1K

Обзор



+16



19



0

Один шаг до автоматизации на миллион: стартовал хакатон от Ozon Tech

Турбо

Показать еще

ИСТОРИИ



Унеси с Робозона
свои миллионы



Пришёл, смастерил,
рассказал — сезон
DIY в разгаре



От лунного овоща
до сверхострого
чили



Из центра Млечного
Пути



Только IT-пром,
только хардкор

ВАКАНСИИ

Android Developer (Security Research / Anti-Abuse)

от 1 500 до 2 500 \$ · MST · Можно удаленно

Менеджер по работе с блогерами (закупка рекламы) — ИИ стартап

от 100 000 ₽ · Поехали · Москва · Можно удаленно

Data Engineer / DataOps Engineer
от 250 000 до 280 000 ₽ · AYROSA · Можно удаленно

Больше вакансий на Хабр Карьере

МИНУТОЧКУ ВНИМАНИЯ



Турбо

Кто твой супергерой в IT?
Исследуем работодателей

Опрос

Расскажите, как вы ищете
работу в 2026 году?


Промо

Отпуск? Обучение? Курсы? Есть
скидки на все

БЛИЖАЙШИЕ СОБЫТИЯ



2 марта – 10 августа
**PROBA Awards —
международная
коммуникационная премия,
учрежденная в 2000 году**
Санкт-Петербург



11 июня – 2 сентября
**Робозон: хакатон с призовым
фондом 15 млн руб.**
Москва • Онлайн
[Разработка](#)



15 июля
**Веби
эпох**
Онлайн
[Марк](#)

Больше событий в календаре



 [Настройка языка](#)

[Техническая поддержка](#)