

Products



Solutions



Developers



Partners



Pricing

Log in

Sign up

Обновления продукта

Теперь доступны серверные инструменты для DigitalOcean Inference Engine



Автор: [Грейс Морган](#)

Обновлено: 22 июня 2026 г. • 3 минуты чтения

[← Вернуться на главную страницу блога](#)

Возможности ИИ-приложений и агентов зависят от инструментов, данных и систем, к которым у них есть доступ. Благодаря инструментам на стороне сервера, которые теперь доступны в режиме публичного предварительного тестирования для DigitalOcean Inference Engine, модель может выполнять поиск в интернете, считывать ваши данные, обращаться к вашим системам и выполнять действия — и все это в рамках одного запроса на логический вывод. Вы можете включить новые инструменты, используя существующий ключ доступа к моделям DigitalOcean. Не нужно собирать отдельную инфраструктуру инструментов, получать новые учетные данные или использовать уровень оркестрации.

Серверные инструменты обеспечивают веб-поиск, веб-загрузку, доступ к базам знаний DigitalOcean, серверам MCP и поддерживаемым инструментам Anthropic и OpenAI в ваших [запросах на логический вывод](#). Каждый из этих инструментов описан ниже.

Добавляйте информацию в реальном времени в свои ИИ-приложения

Когда приложениям нужна актуальная информация, например новости, документация или оперативные данные, модели могут получать доступ к сети непосредственно во время логического вывода.

Веб-поиск: получайте оперативные ответы из интернета

Веб-поиск позволяет получать актуальную информацию из интернета. Это открывает возможности для исследовательских процессов, поддержки пользователей и агентных приложений, которым необходимо анализировать недавние события, меняющуюся информацию или контент, недоступный в обучающих данных модели.

```

print('Usage: python3 server_side_tools_example.py "<prompt>"')
sys.exit(1)

prompt = " ".join(sys.argv[1:])

client = Client(token=os.environ["MODEL_ACCESS_KEY"])

resp = client.chat.completions.create(
    model="openai-gpt-4o",
    messages=[
        {
            "role": "user",
            "content": prompt,
        }
    ],
    tools=[
        {
            "type": "web_search",
            "max_uses": 3,
            "max_results": 5,
        }
    ],
    tool_choice="auto",
    max_completion_tokens=512,
    stream=False,
)

```

Web Fetch: получение контента с URL-адресов и из документов

Web Fetch извлекает контент с определенных URL-адресов или из PDF-файлов во время логического вывода. Эта функция полезна для обобщения информации на страницах, извлечения структурированных данных из документов или получения справочных материалов по запросу.

```

import os
import sys
from pydo import Client

def main() -> None:
    if len(sys.argv) < 2:
        print('Usage: python3 server_side_tools_example.py "<prompt>"')
        sys.exit(1)

    prompt = " ".join(sys.argv[1:])

    client = Client(token=os.environ["MODEL_ACCESS_KEY"])

    resp = client.chat.completions.create(
        model="openai-gpt-4o",
        messages=[
            {
                "role": "user",
                "content": prompt,
            }
        ],
        tools=[
            {
                "type": "web_fetch",
                "max_uses": 3,
                "max_results": 5,
            }
        ]
    )

```

И веб-поиск, и веб-выборка осуществляются с помощью Eха. Цены зависят от использования; актуальные тарифы см. на [странице с ценами](#).

Веб-режим: включите веб-доступ через URL модели

Некоторые фреймворки для агентов позволяют настроить только имя модели и не предоставляют возможности настройки инструментов. Для таких случаев DigitalOcean поддерживает веб-режим, который автоматически включает веб-поиск и веб-загрузку через поле модели. Это дает модели доступ к веб-поиску и веб-загрузке без необходимости явного определения инструментов, что упрощает интеграцию с фреймворками для агентов, которые позволяют настраивать только модель.

Наземные ответы на основе ваших собственных данных

Для приложений, которым необходимо работать с собственными данными и системами, Server-Side Tools предлагает два варианта.

1. **DigitalOcean Knowledge Bases:** Give your models access to retrieve relevant content from your [indexed data](#) automatically without you building a separate retrieval pipeline. Attach your knowledge base, send the request, and the model grounds its response in your content.
2. **MCP Servers:** Connect models to your systems and services through the Model Context Protocol. MCP servers expose internal APIs, databases, and tools, allowing models to retrieve information and take actions like writing data, updating systems, or triggering workflows directly within inference requests.

Support for Anthropic and OpenAI Tools

If you are already using Anthropic or OpenAI tool conventions, those same tool definitions work within DigitalOcean Inference Engine. There is no need to rewrite your application logic or adapt to a new interface.

- **Anthropic tools include:** Web fetch, Tool search, Bash, Text editor, Computer use
- **OpenAI tools include:** Function calling, Computer use, Tool search, Apply Patch, Local shell

All tools incur token costs based on use. For the full list of supported tools, see the [documentation](#).

Use Your Existing Agent Tooling Without Changes

Server-Side Tools also power coding agents and developer workflows. Coding assistants such as Claude Code, Codex, and other agent frameworks rely on capabilities like web search, web fetch, bash, text editing, and computer use to gather context and

complete tasks. By supporting these tools directly within inference requests, DigitalOcean Inference Engine makes it easier to run coding agents and agent frameworks without managing additional tool infrastructure.

How to Access Server-Side Tools

Server-Side Tools are available today in Public Preview through your existing DigitalOcean Model Access Key. No new credentials or account changes are required, and we plan to add more tools.

To get started, specify tools as part of your [inference request](#), or enable Web Mode through the model URL. Server-Side Tools are available through Serverless Inference, Inference Router, and Dedicated Inference. Full [documentation](#), including request examples and supported tool configurations, is available [here](#).

About the author



Grace Morgan Author

[See author profile](#)

Share




Product Updates

Start building today

From GPU-powered inference and Kubernetes to managed databases and storage, get everything you need to build, scale, and deploy intelligent applications.

Sign up →

Related Articles




Product updates

Run Codex in the cloud – DigitalOcean for Codex is now available

[Ari Sigal](#)

June 25, 2026 • 3 min read

Read more →




Product updates

Model Evaluations: Prove Your Routing Policy Actually Works

Sathish Jothikumar

June 4, 2026 • 7 min read

[Read more →](#)



Product updates

Powering the Inference Era: Inside the DigitalOcean Data & Learning Layer

Zach Peirce

June 3, 2026 • 5 min read

[Read more →](#)

Company



Products



Resources



Solutions



