

Используйте бессерверный инференс

Последнее обновление: 29 июня 2026 г.

Inference предоставляет единую плоскость управления для рабочих процессов логического вывода. Она включает в себя каталог моделей, в котором можно просматривать доступные базовые модели, в том числе как размещенные на DigitalOcean, так и сторонние коммерческие модели, сравнивать возможности моделей и цены, использовать маршрутизацию для сопоставления запросов логического вывода с наиболее подходящей моделью, а также выполнять логический вывод с помощью бессерверных или выделенных развертываний.

[📄 Скопировать страницу в формате Markdown](#)[📄 Посмотреть страницу в формате Markdown](#)

Начало работы



Обзор Бессерверного Вывода

Что такое бессерверный логический вывод и чем он отличается от выделенного логического вывода.



Как управлять предоплатой бессерверного логического вывода

Добавьте предоплаченный баланс для Serverless Inference и включите автопополнение, чтобы автоматически пополнять баланс, когда он заканчивается.



Бессерверные конечные точки API логического вывода

Синхронные и асинхронные конечные точки API для бессерверного логического вывода.



Как создавать ключи доступа к моделям и управлять ими

Создавайте ключи доступа к базовым моделям, маршрутизаторам логического вывода и пакетному логическому выводу, а также управляйте ими, применяя ограничения VPC и предоставляя доступ владельцам команд.



Как получить доступные модели

Как получить доступ к моделям, доступным для бессерверного логического вывода.

Создание Завершений чата



Как отправлять подсказки модели с помощью API Chat Completions

Отправляйте подсказки и используйте рассуждения с помощью API Chat Completions.



Как отправлять подсказки модели с помощью API ответов

Отправляйте подсказки с помощью Responses API.



Как использовать кэширование подсказок в API завершения и ответов в чате

Используйте кэширование подсказок с помощью API автозаполнения и ответов в чате.



Как использовать Reasoning с API автозаполнения и ответов в чате

Используйте логику в API автозаполнения и ответов в чате.

Генерация изображений, аудио, видео и преобразование текста в речь



Как создавать изображения на основе текстовых подсказок

Создавайте или редактируйте изображения на основе текстовых подсказок.



How to Use Multimodal Inference

Process and generate content across multiple data types, including images, audio, video, and text using multimodal models.



How to Use fal Models to Generate Image, Audio, or Text-to-Speech

Generate image, audio, or text-to-speech using fal models.

Update Model



How to Use Serverless Inference After Updating to Another Model

How to use serverless inference after updating a model.

COMPANY

[About](#)
[Careers](#)
[Blog](#)

DOCS

[Docs Home](#)
[API Reference](#)
[CLI Reference](#)
[Release Notes](#)
[llms.txt](#)
[Trust Platform](#)

COMMUNITY

[Tutorials](#)
[Q&A](#)
[Write for DOnations](#)
[Currents Research](#)
[Legal](#)
[Code of Conduct](#)

SUPPORT

[Support Center](#)
[Report Abuse](#)



© 2026 DigitalOcean, LLC. All rights reserved [Cookie Preferences](#)

